

UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE CIÊNCIAS

DEPARTAMENTO DE COMPUTAÇÃO

PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIAS DA COMPUTAÇÃO

MESTRADO ACADÊMICO EM CIÊNCIAS DA COMPUTAÇÃO

DANIEL OLIVEIRA DOS SANTOS

APRENDIZADO DE MÁQUINA PARA ESTRATIFICAÇÃO DE RISCO DE MORTE SÚBITA CARDÍACA A PARTIR DO HOLTER DE 24 HORAS

FORTALEZA

2026

DANIEL OLIVEIRA DOS SANTOS

APRENDIZADO DE MÁQUINA PARA ESTRATIFICAÇÃO DE RISCO DE MORTE SÚBITA CARDÍACA A PARTIR DO HOLTER DE 24 HORAS

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciências da Computação do Programa de Pós-Graduação em Ciências da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Ciências da Computação. Área de Concentração: Ciências da Computação

Orientador: Prof. Dr. João Paulo do Vale Madeiro

Coorientador: Prof. José Maria da Silva Monteiro Filho

FORTALEZA

2026

DANIEL OLIVEIRA DOS SANTOS

APRENDIZADO DE MÁQUINA PARA ESTRATIFICAÇÃO DE RISCO DE MORTE SÚBITA CARDÍACA A PARTIR DO HOLTER DE 24 HORAS

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciências da Computação do Programa de Pós-Graduação em Ciências da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Ciências da Computação. Área de Concentração: Ciências da Computação

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. João Paulo do Vale Madeiro (Orientador)
Universidade Federal do Ceará (UFC)

Prof. José Maria da Silva Monteiro Filho (Coorientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Quatro (SIGLA)

À minha mãe, Norma de Oliveira Souza, que acreditou no meu potencial e esteve ao meu lado em cada etapa desta caminhada.

AGRADECIMENTOS

Agradeço, em primeiro lugar, à minha mãe, Norma de Oliveira Souza, pelo carinho e por sempre acreditar no meu potencial. Sua presença ao meu lado me deu força para prosseguir e coragem para enfrentar os desafios da vida. Esta conquista também é sua.

Ao meu orientador, Prof. Dr. João Paulo do Vale Madeiro, pela dedicação, pela confiança e pelo empenho em conduzir este trabalho. Agradeço pela paciência nas discussões, pelas orientações que deram rumo à pesquisa e por me incentivar a buscar sempre uma análise mais rigorosa dos resultados.

Ao meu coorientador, Prof. José Maria da Silva Monteiro Filho, pelo acompanhamento, pelas sugestões e pelas contribuições ao longo da pesquisa, que enriqueceram este trabalho.

Aos colegas do Laboratório Insight-Logia, pelo ambiente colaborativo, pela troca constante de conhecimentos e pelo companheirismo nos momentos de dificuldade.

A João Samuel, pela ajuda durante a pesquisa e pelos esclarecimentos que tornaram o caminho mais claro.

Ao Prof. César Lincoln, referência em modelos de aprendizado de máquina, cujos ensinamentos contribuíram decisivamente para este trabalho.

A todos os professores das disciplinas que cursei, que contribuíram para a minha formação, e à Universidade Federal do Ceará, ao Departamento de Computação e ao Programa de Pós-Graduação em Ciências da Computação, pela oportunidade e pela estrutura oferecida.

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001. Agradeço à CAPES pela concessão da bolsa de estudos, que permitiu a dedicação a esta pesquisa.

Aos membros da banca examinadora, pelo tempo dedicado à leitura deste trabalho e pelas contribuições que certamente o aprimorarão.

Aos pesquisadores responsáveis pelo estudo MUSIC, por disponibilizarem publicamente os registros que tornaram esta pesquisa possível.

Aos meus familiares e amigos, pela compreensão nos momentos de ausência e pelo apoio ao longo de toda esta jornada.

Por fim, a todos que, direta ou indiretamente, contribuíram para a realização deste trabalho.

"O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado."

(Ariano Suassuna)

RESUMO

A morte súbita cardíaca (MSC) é uma das principais causas de óbito em pacientes com insuficiência cardíaca (IC). Este trabalho tem como objetivo a predição da ocorrência de MSC em uma população de pacientes com IC, em um período de acompanhamento de quatro anos, com base em parâmetros extraídos do eletrocardiograma (ECG) Holter de 24 horas e no uso de modelos de aprendizado de máquina. A população foi formada por 517 pacientes em ritmo sinusal da base pública MUSIC: 55 que morreram de MSC e 462 que sobreviveram aos quatro anos. Foram avaliados três cenários, em validação cruzada estratificada em cinco partições por paciente, pela área sob a curva ROC (AUC) da predição de MSC, com intervalo de confiança de 95 % (IC). No cenário (I), redes neurais profundas — convolucionais, residuais (ResNet-18 a ResNet-50) e com atenção — processaram o ECG original (sinal bruto). No cenário (II), o sinal passou por pré-processamento e extração de características — variabilidade da frequência cardíaca (SDNN, RMSSD, potências LF e HF, Poincaré e entropia), ectopia e morfologia do batimento (QRS, QT e ondas P e T) —, usadas em modelos de aprendizado de máquina clássico: regressão logística com penalização L1 e L2, análise de componentes principais e floresta aleatória. No cenário (III), para fins de comparação e análise, foram avaliados modelos baseados em variáveis clínicas — dados de representação do paciente (idade, sexo, classe NYHA), laudos do ECG, medidas do Holter e exames laboratoriais e de imagem, como o Pro-BNP e o ecocardiograma —, isoladas e combinadas aos dados do ECG. O cenário (I) produziu AUC entre 0,48 e 0,56; a melhor rede, a ResNet-18 mínima, obteve 0,562 (IC: 0,48–0,64). O cenário (II) produziu AUC entre 0,58 e 0,62 com 44 marcadores e de 0,647 (IC: 0,56–0,73) com dois marcadores escolhidos com base na literatura, a variação da frequência cardíaca ao longo do dia e a carga de ectopia. No cenário (III), seis variáveis clínicas obtiveram AUC de 0,661 (IC: 0,58–0,74); combinadas aos marcadores do ECG, 0,681 (IC: 0,60–0,76); e combinadas aos exames, 0,733 (IC: 0,66–0,80). Os modelos baseados em parâmetros extraídos do ECG, em especial os ligados à frequência cardíaca, superaram as redes neurais profundas que recebem o sinal puro (AUC de 0,647 contra 0,562), e a combinação das variáveis clínicas com os dados do ECG superou as variáveis clínicas isoladas (0,681 contra 0,661). Esses ganhos não atingiram significância estatística.

Palavras-chave: Morte Súbita Cardíaca. ECG Holter. Aprendizado Profundo. Variabilidade da Frequência Cardíaca. Insuficiência Cardíaca. Estratificação de Risco.

ABSTRACT

Sudden cardiac death (SCD) is one of the main causes of death in patients with heart failure (HF). This work aims to predict the occurrence of SCD in a population of HF patients, over a four-year follow-up period, based on parameters extracted from the 24-hour Holter electrocardiogram (ECG) and on machine learning models. The population comprised 517 patients in sinus rhythm from the public MUSIC database: 55 who died of SCD and 462 who survived four years. Three scenarios were evaluated in stratified five-fold cross-validation with patient-level splits, by the area under the ROC curve (AUC) for SCD prediction, with 95 % confidence intervals (CI). In scenario (I), deep neural networks — convolutional, residual (ResNet-18 to ResNet-50) and attention networks — processed the original ECG (raw signal). In scenario (II), the signal underwent preprocessing and feature extraction — heart rate variability (SDNN, RMSSD, LF and HF power, Poincaré and entropy), ectopy and beat morphology (QRS, QT and P and T waves) —, used in classical machine learning models: L1- and L2-penalized logistic regression, principal component analysis and random forest. In scenario (III), for comparison and analysis, models based on clinical variables were evaluated — patient data (age, sex, NYHA class), ECG reports, Holter measurements and laboratory and imaging exams, such as Pro-BNP and echocardiography —, alone and combined with the ECG data. Scenario (I) yielded AUC between 0.48 and 0.56; the best network, the minimal ResNet-18, reached 0.562 (CI: 0.48–0.64). Scenario (II) yielded AUC between 0.58 and 0.62 with 44 markers and 0.647 (CI: 0.56–0.73) with two markers chosen from the literature, the variation of heart rate over the day and the ectopic burden. In scenario (III), six clinical variables reached AUC 0.661 (CI: 0.58–0.74); combined with the ECG markers, 0.681 (CI: 0.60–0.76); and combined with the exams, 0.733 (CI: 0.66–0.80). Models based on parameters extracted from the ECG, especially those related to heart rate, outperformed deep neural networks that take the raw signal as input (AUC 0.647 versus 0.562), and combining clinical variables with ECG data outperformed clinical variables alone (0.681 versus 0.661). These gains were not statistically significant.

Keywords: Sudden Cardiac Death. Holter ECG. Deep Learning. Heart Rate Variability. Heart Failure. Risk Stratification.

LISTA DE FIGURAS

Figura 1 – Blocos residuais básico (tipo a) e de gargalo (tipo b) 41
Figura 2 – Fluxograma de seleção da coorte 53
Figura 3 – Trecho de 10 segundos do Holter de um paciente controle da coorte, nas derivações X, Y e Z, após o filtro passa-faixa de 0,5 a 40 Hz 56
Figura 4 – Arquitetura da rede convolucional unidimensional 60
Figura 5 – Fluxo da validação cruzada estratificada em 5 partições. As etapas 2–4 são repetidas para cada partição, com avaliação no nível do paciente. 71

LISTA DE TABELAS

Tabela 1 – Marcadores calculáveis em segmentos de 5 minutos e de 30 segundos 36
Tabela 2 – Matriz de confusão de um classificador binário 46
Tabela 3 – Métricas derivadas da matriz de confusão 46
Tabela 4 – Fluxo de seleção da base MUSIC e disponibilidade dos registros de Holter. . 54
Tabela 5 – Arquiteturas de redes neurais avaliadas sobre o sinal de Holter 59
Tabela 6 – Canais e comprimento das representações intermediárias das variantes da rede convolucional 60
Tabela 7 – Distribuição dos parâmetros das variantes da rede convolucional 62
Tabela 8 – Configurações das redes residuais avaliadas 63
Tabela 9 – Dimensões e campo receptivo das redes residuais para janela de 24 000 amostras 64
Tabela 10 – Configuração da camada de atenção 65
Tabela 11 – Distribuição dos parâmetros da ResNet-18 reduzida com camada de atenção 66
Tabela 12 – Parâmetros de representação do sinal 67
Tabela 13 – Hiperparâmetros de treinamento 68
Tabela 14 – Combinações avaliadas da rede convolucional 69
Tabela 15 – Protocolos de extração dos marcadores 73
Tabela 16 – Marcadores eletrocardiográficos extraídos: definição e significado 75
Tabela 17 – Efeito do cálculo sobre intervalos NN nos marcadores de variabilidade (328 807 segmentos) 77
Tabela 18 – Ambiente computacional 84
Tabela 19 – Desempenho das redes convolucionais segundo a capacidade e a duração da janela 86
Tabela 20 – Desempenho da ResNet-18 em três larguras 86
Tabela 21 – Desempenho das redes residuais segundo a profundidade 87
Tabela 22 – Desempenho das redes configuradas por busca de hiperparâmetros 87
Tabela 23 – Métricas dependentes de limiar das redes neurais, calculadas sobre as predições fora da partição dos 517 pacientes 90
Tabela 24 – Limiar de decisão e matriz de confusão agregada das redes neurais sobre os 517 pacientes 91
Tabela 25 – Marcadores do protocolo A com $p < 0{,}05$ na comparação entre casos e controles 93
Tabela 26 – Desempenho dos modelos sobre os marcadores do protocolo A 93

Tabela 27 – Efeito da forma de seleção dos marcadores no protocolo A 94
Tabela 28 – Número de marcadores, entre 24, com diferença significativa entre casos e controles segundo a unidade de análise 95
Tabela 29 – Modelos treinados sobre cada segmento de 30 segundos e avaliados por paciente 97
Tabela 30 – Modelos sobre os resumos por paciente dos segmentos de 30 segundos (extração corrigida) 97
Tabela 31 – Síntese dos resultados com marcadores eletrocardiográficos 98
Tabela 32 – Desempenho da rede com concatenação segundo a estratégia de treinamento do extrator de sinal 100
Tabela 33 – Melhor resultado de cada cenário na predição de morte súbita cardíaca (MSC) 101
Tabela 34 – Os três melhores resultados de cada cenário 102
Tabela 35 – Replicação nas condições de Swee *et al.* (2026): 746 pacientes, derivação Y, segmentos de 30 segundos contíguos 104

LISTA DE ABREVIATURAS E SIGLAS

AUC	área sob a curva ROC
AUPRC	área sob a curva de precisão–revocação
CNN	rede neural convolucional
ECG	eletrocardiograma
FEVE	fração de ejeção do ventrículo esquerdo
HF	alta frequência (*high frequency*)
HRT	turbulência da frequência cardíaca (*heart rate turbulence*)
IC	intervalo de confiança
LF	baixa frequência (*low frequency*)
MSC	morte súbita cardíaca
MUSIC	*Muerte Súbita en Insuficiencia Cardiaca*
NN	intervalo entre batimentos sinusais normais consecutivos
NYHA	*New York Heart Association*
PCA	análise de componentes principais (*principal component analysis*)
pNN50	percentual de diferenças sucessivas entre intervalos NN superiores a 50 ms
QT	intervalo do início do complexo QRS ao fim da onda T
QTc	intervalo QT corrigido pela frequência cardíaca
ResNet	rede neural residual
RMSSD	raiz quadrática média das diferenças sucessivas entre intervalos NN
ROC	característica de operação do receptor (*receiver operating characteristic*)
RR	intervalo entre picos R consecutivos
SD1	dispersão do gráfico de Poincaré perpendicular à diagonal
SD2	dispersão do gráfico de Poincaré ao longo da diagonal
SDNN	desvio-padrão dos intervalos NN
TVNS	taquicardia ventricular não sustentada
TWA	alternância da onda T (*T-wave alternans*)
VFC	variabilidade da frequência cardíaca
VLF	muito baixa frequência (*very low frequency*)
VPN	valor preditivo negativo
VPP	valor preditivo positivo

LISTA DE SÍMBOLOS

$b_{c'}$	Termo de viés do filtro c'
B	Tamanho do lote de treinamento
B^*	Número de reamostragens *bootstrap*
C	Número de derivações do sinal (canais de entrada)
C'	Número de filtros de uma camada convolucional
d	Dimensão das representações no *Transformer*
d_k	Dimensão das consultas e das chaves
d_{ff}	Dimensão interna da rede alimentada adiante
E	Fator de expansão do bloco residual
f	Frequência
f_c	Frequência de corte
f_{inf}	Frequência de corte inferior
f_{sup}	Frequência de corte superior
$H(f)$	Resposta em frequência do filtro
i	Índice do paciente
J	Índice de Youden
K	Número de partições da validação cruzada
L	Comprimento do sinal, em amostras
L'	Comprimento da sequência após as camadas convolucionais
m	Índice da janela
M_i	Número de janelas do paciente i
n	Ordem do filtro de Butterworth
n_h	Número de cabeças de atenção
N	Número de pacientes da coorte
N_0	Número de controles
N_1	Número de casos

$\hat{p}_i$	Probabilidade estimada de óbito para o paciente i
$\hat{p}_{i,m}$	Probabilidade estimada para a m-ésima janela do paciente i
P	Número de canais do primeiro estágio da rede residual
r	Fator de agrupamento
t	Posição temporal no sinal
w_+	Peso da classe positiva na função de perda
y_i	Rótulo do paciente i
z_i	*Logit* do paciente i
$\mathbf{Q}, \mathbf{K}, \mathbf{V}$	Matrizes de consultas, chaves e valores
$\mathbf{S}$	Sinal de eletrocardiograma (ECG), matriz de C derivações por L amostras
$\mathbf{U}_Q, \mathbf{U}_K, \mathbf{U}_V, \mathbf{U}_O$	Matrizes de projeção da atenção
$\mathbf{x}$	Entrada de um bloco residual
$\mathbf{X}$	Sequência de entrada do *Transformer*
$\mathscr{B}$	Lote de exemplos de treinamento
$\mathscr{C}_0$	Conjunto dos controles
$\mathscr{C}_1$	Conjunto dos casos
$\mathscr{F}$	Transformação aprendida por um bloco residual
$\mathscr{H}$	Mapeamento desejado de um bloco residual
$\mathscr{L}$	Função de perda
β	Parâmetro de deslocamento da normalização em lote
γ	Parâmetro de escala da normalização em lote
δ	Limiar de decisão
δ^*	Limiar escolhido pelo índice de Youden
Δ	Diferença entre duas medidas
ε	Constante de estabilidade numérica
θ	Conjunto de parâmetros treináveis
Θ	Pesos de uma camada convolucional
Θ_s	Projeção do atalho residual

κ	Largura do núcleo convolucional
λ	Coeficiente de decaimento de pesos
$\mu_{\mathscr{B}}$	Média calculada sobre o lote
π	Prevalência do evento na coorte
$\sigma(\cdot)$	Função logística
$\sigma^2_{\mathscr{B}}$	Variância calculada sobre o lote
φ	Função de comparação entre um caso e um controle

SUMÁRIO

1 INTRODUÇÃO 20
1.1 Motivação do problema 20
1.2 Modelos preditivos para a morte súbita cardíaca 20
1.3 O que a literatura tem feito 21
1.4 Desafios e lacunas 21
1.5 Objetivos 22
1.5.1 Objetivo geral 22
1.5.2 Objetivos específicos 22
1.6 Organização do trabalho 23
2 TRABALHOS RELACIONADOS 24
2.1 Marcadores eletrocardiográficos e clínicos na coorte MUSIC 24
2.2 Integração de marcadores de segmentos curtos e variáveis clínicas . . . 25
2.3 Aprendizado profundo no Holter de 24 horas 26
2.4 Comparação e posicionamento deste trabalho 27
3 FUNDAMENTAÇÃO TEÓRICA 28
3.1 Pré-processamento de sinais eletrocardiográficos 28
3.1.1 Fontes de interferência 28
3.1.2 Filtragem digital 29
3.1.2.1 Filtro de Butterworth *29*
3.1.2.2 Filtragem de fase nula *29*
3.1.3 Normalização de amplitude 30
3.1.4 Amostragem em janelas e independência entre exemplos 30
3.2 Extração de características do sinal eletrocardiográfico 31
3.2.1 Detecção do complexo QRS e delineação das ondas 31
3.2.2 Intervalos RR e intervalos NN 32
3.2.3 Variabilidade da frequência cardíaca 32
3.2.3.1 Domínio do tempo *33*
3.2.3.2 Domínio da frequência *33*
3.2.3.3 Medidas não lineares *34*
3.2.4 Morfologia do batimento 34

3.2.5 ***Ectopia*** . . . 35
3.2.6 ***Duração do segmento de análise*** . . . 35
3.3 **Redes neurais convolucionais unidimensionais** . . . 36
3.3.1 ***Convolução unidimensional*** . . . 37
3.3.2 ***Função de ativação*** . . . 37
3.3.3 ***Normalização em lote*** . . . 38
3.3.4 ***Agrupamento*** . . . 38
3.3.5 ***Descarte*** . . . 39
3.3.6 ***Função de perda e desbalanceamento*** . . . 39
3.4 **Redes neurais residuais** . . . 40
3.4.1 ***Aprendizado residual*** . . . 40
3.4.2 ***Blocos residuais*** . . . 41
3.4.2.1 *Bloco básico* . . . *41*
3.4.2.2 *Bloco de gargalo* . . . *42*
3.5 **Mecanismo de atenção** . . . 42
3.5.1 ***Autoatenção*** . . . 42
3.5.1.1 *Atenção com múltiplas cabeças* . . . *43*
3.5.2 ***Camada codificadora*** . . . 43
3.5.3 ***Custo computacional*** . . . 44
3.6 **Modelos de aprendizado de máquina clássico** . . . 44
3.6.1 ***Regressão logística regularizada*** . . . 44
3.6.2 ***Análise de componentes principais*** . . . 45
3.6.3 ***Floresta aleatória*** . . . 45
3.7 **Avaliação de classificadores binários** . . . 45
3.7.1 ***Matriz de confusão e métricas dependentes de limiar*** . . . 46
3.7.2 ***Curva ROC e área sob a curva*** . . . 47
3.7.3 ***Curva precisão-revocação e área sob a curva*** . . . 48
3.7.4 ***Escolha do limiar de decisão*** . . . 48
3.7.5 ***Agregação por paciente*** . . . 49
3.7.6 ***Validação cruzada estratificada por paciente*** . . . 50
3.7.7 ***Intervalos de confiança e comparação entre modelos*** . . . 50
4 **METODOLOGIA** . . . 52

4.1 População de estudo . . . 52
4.1.1 Base de dados . . . 52
4.1.2 Definição da população e critérios de seleção . . . 53
4.1.3 Variáveis clínicas e exames . . . 55
4.2 Pré-processamento do sinal . . . 56
4.2.1 Extração de janelas . . . 56
4.2.2 Filtragem . . . 57
4.2.3 Normalização . . . 57
4.3 Cenário I: aprendizado profundo sobre o sinal bruto . . . 58
4.3.1 Arquiteturas avaliadas . . . 58
4.3.2 Arquitetura da rede convolucional . . . 59
4.3.2.1 Variantes de capacidade . . . *59*
4.3.2.2 Largura do núcleo . . . *61*
4.3.2.3 Agrupamento combinado . . . *61*
4.3.2.4 Ausência de conexões residuais . . . *61*
4.3.2.5 Classificador e número de parâmetros . . . *62*
4.3.3 Arquitetura das redes residuais . . . 62
4.3.3.1 Configurações avaliadas . . . *63*
4.3.3.2 Dimensões e campo receptivo . . . *63*
4.3.3.3 Distribuição dos parâmetros . . . *64*
4.3.4 Regime de dados das redes residuais . . . 64
4.3.5 Arquitetura da rede residual com atenção . . . 65
4.3.5.1 Ausência de codificação posicional . . . *65*
4.3.6 Regime de dados da rede com atenção . . . 66
4.4 Cenário I: treinamento e avaliação das redes . . . 67
4.4.1 Representação do sinal . . . 67
4.4.2 Treinamento . . . 68
4.4.3 Desbalanceamento entre classes . . . 69
4.4.4 Experimentos com a rede convolucional . . . 69
4.4.4.1 Amostragem das janelas . . . *70*
4.4.4.2 Filtragem com margem . . . *70*
4.4.4.3 Configuração comum . . . *70*

4.4.5 ***Protocolo de treinamento e avaliação*** 71
4.4.5.1 *Divisão dos pacientes* *71*
4.4.5.2 *Seleção da época* *72*
4.4.5.3 *Avaliação no teste* *72*
4.4.5.4 *Consolidação das cinco rodadas* *72*
4.5 **Cenário II: extração de características do ECG** 73
4.5.1 ***Marcadores extraídos*** 73
4.5.2 ***Protocolo A: segmentos de 5 minutos*** 74
4.5.3 ***Protocolo B: segmentos de 30 segundos*** 76
4.5.3.1 *Classificação dos intervalos* *76*
4.5.3.2 *Marcadores calculados* *76*
4.5.3.3 *Controle de qualidade* *77*
4.5.3.4 *Resumo por paciente* *78*
4.5.4 ***Número de variáveis e risco de sobreajuste*** 78
4.6 **Cenário II: modelos de aprendizado de máquina sobre os marcadores** . 78
4.6.1 ***Revisão estatística*** 79
4.6.2 ***Modelos*** 79
4.6.3 ***Comparações planejadas*** 80
4.6.4 ***Marcadores pré-especificados nas três derivações*** 80
4.7 **Cenário III: variáveis clínicas e combinação com o ECG** 81
4.7.1 ***Modelos baseados em variáveis clínicas*** 81
4.7.2 ***Combinação com os marcadores do ECG*** 81
4.7.3 ***Combinação com o sinal: rede profunda com variáveis clínicas concatenadas*** 82
4.7.3.1 *Estratégias de treinamento da rede com concatenação* *82*
4.8 **Protocolo de avaliação** 82
4.8.1 ***Particionamento*** 82
4.8.2 ***Validação e agregação por paciente*** 83
4.8.3 ***Métricas*** 83
4.8.4 ***Ambiente computacional*** 84
5 **RESULTADOS** 85
5.1 **Cenário I: aprendizado profundo sobre o sinal bruto** 85
5.1.1 ***Redes convolucionais: capacidade e duração da janela*** 85

5.1.2 ***Redes residuais: largura da ResNet-18*** . . . 86
5.1.3 ***Redes residuais: profundidade (ResNet-18, ResNet-34 e ResNet-50)*** . . . 86
5.1.4 ***ResNet-18 com mecanismo de atenção*** . . . 87
5.1.5 ***Busca de hiperparâmetros*** . . . 87
5.1.6 ***Comportamento durante o treinamento*** . . . 88
5.1.7 ***Variabilidade entre execuções*** . . . 88
5.1.8 ***Análise de sensibilidade: ResNet-18 sem restrição ao ritmo sinusal*** . . . 89
5.1.9 ***Métricas dependentes de limiar*** . . . 89
5.1.10 ***Síntese*** . . . 90
5.2 Cenário II: aprendizado de características do ECG . . . 91
5.2.1 ***Protocolo A: segmentos de 5 minutos*** . . . 92
5.2.1.1 Comparação univariada . . . *92*
5.2.1.2 Modelos . . . *93*
5.2.1.3 Número reduzido de marcadores e otimismo da seleção . . . *94*
5.2.2 ***Protocolo B: segmentos de 30 segundos*** . . . 95
5.2.2.1 Comparação dos marcadores: segmento ou paciente como unidade . . . *95*
5.2.2.2 Modelos treinados sobre cada segmento . . . *96*
5.2.2.3 Modelos sobre os resumos por paciente . . . *97*
5.2.3 ***Marcadores pré-especificados (segmentos de 30 segundos)*** . . . 98
5.2.4 ***Síntese*** . . . 98
5.3 Cenário III: variáveis clínicas e combinação com o ECG . . . 99
5.3.1 ***Variáveis clínicas e exames*** . . . 99
5.3.2 ***Combinação com os marcadores do ECG*** . . . 99
5.3.3 ***Combinação com o sinal: rede profunda com variáveis clínicas concatenadas*** 99
5.3.4 ***Síntese dos três cenários*** . . . 100
6 CONCLUSÕES E TRABALHOS FUTUROS . . . 102
6.1 Conclusões . . . 102
6.2 Comparação com os trabalhos relacionados . . . 104
6.3 Limitações . . . 105
6.4 Trabalhos futuros . . . 106
REFERÊNCIAS . . . 107

1 INTRODUÇÃO

1.1 Motivação do problema

A insuficiência cardíaca é uma síndrome crônica e progressiva em que o coração não consegue manter o débito adequado às necessidades do organismo. Entre os pacientes acometidos, a morte ocorre por duas vias principais: a falência de bomba, em que a função cardíaca se deteriora progressivamente, e a MSC, um evento abrupto, em geral causado por uma arritmia ventricular — taquicardia ou fibrilação ventricular — em um paciente que, muitas vezes, se encontrava estável. A MSC responde por parcela expressiva dos óbitos nessa população, estimada em cerca de metade das mortes de pacientes com insuficiência cardíaca (TOMASELLI; ZIPES, 2004).

A gravidade do problema decorre também do caráter inesperado do evento. Diferentemente da falência de bomba, que costuma ser precedida de piora clínica e de internações, a MSC pode ocorrer sem sinais de alerta, e a chance de sobrevivência depende de atendimento em poucos minutos. A prevenção, portanto, precisa ser feita antes do evento, identificando os pacientes em risco. A principal medida disponível é o cardiodesfibrilador implantável, que reverte a arritmia no momento em que ela ocorre e reduziu a mortalidade de pacientes com insuficiência cardíaca e fração de ejeção reduzida (BARDY *et al.*, 2005).

A indicação do dispositivo para prevenção primária baseia-se, principalmente, na fração de ejeção do ventrículo esquerdo (ZEPPENFELD *et al.*, 2022). Esse critério, no entanto, é reconhecidamente imperfeito: parte dos pacientes que recebem o dispositivo nunca chega a utilizá-lo, enquanto parte das mortes súbitas ocorre em pacientes com fração de ejeção acima do limiar de indicação (ZEPPENFELD *et al.*, 2022). Há, portanto, espaço para ferramentas que estratifiquem melhor o risco de MSC, distinguindo-o do risco de morte por falência de bomba.

1.2 Modelos preditivos para a morte súbita cardíaca

Um modelo preditivo de MSC estima, para cada paciente, a probabilidade de que ele venha a sofrer o evento em um horizonte de tempo definido. Esse tipo de modelo permite ordenar os pacientes por risco e concentrar a prevenção naqueles com maior probabilidade de benefício, em vez de depender de um único limiar clínico. Para que seja útil, o modelo precisa basear-se em informações disponíveis na rotina e ser avaliado de forma que seu desempenho em

pacientes novos possa ser estimado com confiança.

O ECG de Holter de 24 horas reúne essas condições. É um exame não invasivo, de baixo custo e amplamente disponível, que registra a atividade elétrica do coração ao longo de um dia inteiro, captando batimentos ectópicos, pausas e variações da frequência cardíaca entre o sono e a vigília que um traçado de repouso de poucos segundos não alcança. Como a MSC tem origem, na maior parte dos casos, em uma instabilidade elétrica, é plausível que o Holter contenha sinais do substrato arrítmico que a antecede. O aprendizado de máquina oferece meios para explorar esses sinais, seja a partir de medidas extraídas do traçado, seja diretamente a partir do sinal bruto.

1.3 O que a literatura tem feito

Os estudos de predição de MSC a partir do ECG ambulatorial têm seguido dois caminhos, descritos em detalhe no Capítulo 2. O primeiro, mais antigo, extrai do Holter marcadores definidos por especialistas — variabilidade da frequência cardíaca, ectopia, turbulência da frequência, alternância da onda T, dinâmica da repolarização — e os combina com variáveis clínicas em modelos estatísticos ou de aprendizado de máquina clássico. Na base *Muerte Súbita en Insuficiencia Cardiaca* (MUSIC), utilizada neste trabalho, esse caminho produziu escores de risco que combinam marcadores da repolarização e variáveis clínicas (RAMÍREZ *et al.*, 2017) e modelos de aprendizado de máquina sobre marcadores de segmentos curtos do Holter (SWEE *et al.*, 2026).

O segundo caminho, mais recente, aplica redes neurais profundas diretamente ao sinal, apoiado no sucesso dessas redes em tarefas diagnósticas sobre o ECG, como a detecção de arritmias no Holter (HANNUN *et al.*, 2019) e o diagnóstico automático no ECG de 12 derivações (RIBEIRO *et al.*, 2020). Na predição de eventos cardíacos a partir do Holter, as abordagens que obtiveram melhores resultados partiram de redes pré-treinadas em grandes bases de ECG e ajustaram apenas um classificador pequeno com os poucos eventos disponíveis (KIM *et al.*, 2025).

1.4 Desafios e lacunas

A predição de MSC difere das tarefas diagnósticas em que as redes profundas se destacaram. Nas tarefas diagnósticas, o padrão procurado está presente no traçado no momento

do exame e há dezenas de milhares de exemplos rotulados. Na predição de MSC, o evento ocorre meses ou anos depois do Holter, e não se sabe se o registro daquele dia já contém algum sinal do que vai acontecer; além disso, as coortes com causa de óbito adjudicada reúnem poucas centenas de pacientes. Nessas condições, a escolha entre aprender diretamente do sinal ou de medidas extraídas dele não é óbvia e precisa ser avaliada empiricamente.

Três lacunas motivam este trabalho. A primeira é que os estudos anteriores avaliaram, cada um, uma única abordagem, em coortes e com protocolos diferentes, o que impede saber qual delas prevê melhor a MSC. Faltam comparações diretas, nos mesmos pacientes e com a mesma forma de avaliação, entre redes profundas aplicadas ao sinal bruto, modelos baseados em marcadores extraídos do ECG e modelos baseados em variáveis clínicas.

A segunda é que parte dos estudos adota escolhas de avaliação que inflam o desempenho estimado. Uma delas é calcular as métricas sobre trechos do sinal, e não sobre pacientes: como um mesmo exame fornece centenas de trechos, cada paciente passa a contar centenas de vezes. Outra é selecionar as variáveis observando o desfecho de toda a coorte, inclusive dos pacientes usados no teste (KAPOOR; NARAYANAN, 2023). Neste trabalho, os trechos são usados no treinamento, mas toda avaliação é feita por paciente.

A terceira é a inclusão de pacientes com fibrilação atrial, ritmo facilmente reconhecível no sinal e associado a pior prognóstico, que pode elevar a discriminação sem que o modelo capte marcadores de vulnerabilidade elétrica ventricular (SWEE *et al.*, 2026).

1.5 Objetivos

1.5.1 Objetivo geral

Este trabalho propõe a investigação de métodos baseados em aprendizado de máquina e no pré-processamento do sinal de ECG para a predição da ocorrência de MSC em uma população de pacientes com insuficiência cardíaca crônica, a partir do Holter de 24 horas, ao longo de um período de acompanhamento de quatro anos.

1.5.2 Objetivos específicos

(i) Comparar três cenários para a predição da MSC: (1) modelos de aprendizado profundo aplicados ao sinal bruto do ECG; (2) pré-processamento do sinal, extração de características e uso de modelos de aprendizado de máquina clássico; e (3) modelos baseados em variáveis

clínicas, isoladas e combinadas aos dados extraídos do ECG.

(ii) Avaliar a combinação de modelos baseados em dados clínicos com modelos baseados em dados extraídos do ECG, quantificando o ganho de desempenho de cada combinação.

(iii) Revisar os trabalhos da literatura que propõem a predição de MSC a partir do ECG ambulatorial e posicionar os resultados deste trabalho em relação a eles.

1.6 Organização do trabalho

O Capítulo 2 apresenta os trabalhos relacionados. O capítulo de fundamentação teórica descreve o pré-processamento e a extração de características do ECG, os modelos de aprendizado profundo e de aprendizado de máquina aplicados ao sinal e os métodos de avaliação. A metodologia apresenta a população de estudo e detalha os três cenários, na mesma ordem em que seus resultados são apresentados no capítulo seguinte. O último capítulo reúne as conclusões, as limitações e os trabalhos futuros.

2 TRABALHOS RELACIONADOS

A predição de morte súbita cardíaca a partir do ECG ambulatorial tem seguido dois caminhos. O primeiro, mais antigo, extrai do registro de Holter marcadores definidos por especialistas — variabilidade da frequência cardíaca, turbulência da frequência, alternância da onda T, dinâmica da repolarização, contagem de arritmias — e os combina com variáveis clínicas em modelos estatísticos. O segundo, mais recente, aplica redes neurais profundas diretamente ao sinal, na expectativa de que a rede encontre padrões que os marcadores clássicos não capturam. Esse segundo caminho se apoia no sucesso das redes convolucionais em tarefas diagnósticas sobre o ECG, como a detecção de arritmias no Holter (HANNUN *et al.*, 2019) e o diagnóstico automático no ECG de 12 derivações (RIBEIRO *et al.*, 2020). Há, contudo, uma diferença importante entre essas tarefas e a predição de morte súbita: nas tarefas diagnósticas, o padrão a ser reconhecido está presente no traçado e há dezenas de milhares de exemplos rotulados; na predição de um evento futuro, o padrão pode não existir no traçado e os eventos são poucos.

Este capítulo apresenta três trabalhos que representam esses caminhos e que servem de referência para a interpretação dos resultados desta dissertação. O primeiro e o segundo utilizam a mesma base de dados deste trabalho, a coorte MUSIC (MARTÍN-YEBRA *et al.*, 2024): um com marcadores clássicos e modelos de Cox, o outro com marcadores de segmentos curtos e aprendizado de máquina. O terceiro aplica aprendizado profundo ao Holter de 24 horas em uma coorte coreana de pacientes com infarto ou insuficiência cardíaca. O capítulo se encerra com uma comparação entre eles e com o posicionamento desta dissertação.

2.1 Marcadores eletrocardiográficos e clínicos na coorte MUSIC

Ramírez *et al.* (2017) construíram modelos de risco para morte súbita e para morte por falência de bomba na coorte MUSIC, combinando marcadores do Holter e variáveis clínicas. A análise incluiu os pacientes em ritmo sinusal com todos os índices calculáveis — 597 dos 992 pacientes originais —, seguidos por mediana de 44 meses, período em que ocorreram 49 mortes súbitas e 62 mortes por falência de bomba. Os pacientes com fibrilação atrial, ritmo de marca-passo ou ausência de extrassístoles ventriculares foram excluídos, este último critério porque a turbulência da frequência depende de extrassístoles para ser calculada.

Os marcadores eletrocardiográficos incluíram a turbulência da frequência (HRT), a alternância da onda T (TWA), índices de restituição do intervalo QT e do intervalo entre o pico

e o fim da onda T, a restituição da morfologia da onda T, a amplitude dos intervalos RR e um índice de arritmia complexa. Para cada desfecho, os autores ajustaram três modelos de Cox — clínico, apenas eletrocardiográfico e combinado —, com seleção das variáveis por eliminação regressiva, e derivaram deles escores de risco em pontos. O modelo combinado para morte súbita reteve sexo masculino, classe III da *New York Heart Association* (NYHA), fração de ejeção $\leq$ 35 % e três marcadores da repolarização. Os pacientes no quintil de maior risco tiveram risco de morte súbita 13,8 vezes maior que os dos dois quintis de menor risco, contra 4,0 vezes com o modelo apenas clínico. No subgrupo com fração de ejeção reduzida, a área sob a curva ROC (AUC) para morte súbita foi de 0,73 [0,64–0,81] com o modelo combinado.

Os próprios autores apontam a principal limitação do trabalho: não houve coorte de validação separada, pelo número reduzido de eventos. A seleção das variáveis e a estimativa do desempenho foram feitas sobre os mesmos pacientes, o que tende a superestimar a discriminação. Ainda assim, o trabalho estabelece duas referências para esta dissertação: a restrição ao ritmo sinusal como critério da coorte e a evidência de que, na MUSIC, a informação prognóstica do Holter para morte súbita está concentrada em marcadores da repolarização, que exigem delineação precisa da onda T.

2.2 Integração de marcadores de segmentos curtos e variáveis clínicas

Swee *et al.* (2026) também utilizaram a coorte MUSIC, com o objetivo de prever morte súbita e morte por falência de bomba a partir da integração de marcadores do Holter com variáveis clínicas. Em vez de marcadores calculados sobre o registro inteiro, os autores extraíram marcadores de segmentos de 30 segundos não sobrepostos, com detecção dos picos R na derivação Y, e processaram a sequência de segmentos de cada paciente com uma rede convolucional temporal em um arcabouço de aprendizado de múltiplas instâncias, além de modelos de aprendizado de máquina sobre essas representações. O desenho desses segmentos foi adotado no protocolo B desta dissertação (subseção 4.5.3).

O trabalho incluiu 746 pacientes, sem restrição ao ritmo sinusal, e relata AUC de 0,682 $\pm$ 0,030 para o modelo apenas com marcadores do ECG, expressa como média entre as partições da validação cruzada. Dois aspectos limitam a comparação com os resultados desta dissertação. O primeiro é a coorte: sem a restrição ao ritmo sinusal, ela inclui pacientes em fibrilação atrial, ritmo facilmente reconhecível no sinal e associado a pior prognóstico, o que pode por si só elevar a discriminação, como mostrou a análise de sensibilidade da subseção 5.1.8.

O segundo é a métrica: a média entre partições não equivale à AUC das predições agrupadas usada como medida principal neste trabalho.

2.3 Aprendizado profundo no Holter de 24 horas

Kim *et al.* (2025) aplicaram aprendizado profundo ao Holter de 24 horas de 1 108 pacientes hospitalizados por infarto agudo do miocárdio (885) ou insuficiência cardíaca aguda (223), provenientes de um registro prospectivo em 25 centros da Coreia do Sul. O desfecho foi composto por morte cardíaca e arritmias ventriculares em três anos, com 70 eventos.

O modelo não foi treinado de ponta a ponta sobre o sinal do Holter. Os autores partiram de um codificador do tipo *Transformer* pré-treinado como autocodificador mascarado sobre ECGs de 12 derivações de 10 segundos e, em seguida, ajustado para estimar a fração de ejeção, usada como rótulo substituto. Com o codificador congelado, cada registro de 24 horas da derivação V1, amostrado a 125 Hz, foi dividido em 9 600 segmentos de 9 segundos, cada um representado por um vetor latente. Somente a etapa final — uma ResNet unidimensional compacta sobre a sequência de vetores — foi treinada com o desfecho, em validação cruzada de cinco partições por paciente.

Na coorte completa, o modelo obteve AUC de 0,74 [0,70–0,77] para o desfecho composto e 0,79 [0,74–0,84] para morte cardíaca, superando a turbulência da frequência (0,62) e a alternância da onda T (0,55), e comparável à fração de ejeção isolada (0,75). No subgrupo de insuficiência cardíaca, no entanto, a AUC caiu para 0,60 [0,53–0,68], igual à da turbulência da frequência, e a combinação com a fração de ejeção não acrescentou desempenho (0,58). Os autores reconhecem o número reduzido de eventos e a ausência de validação externa.

Dois elementos desse trabalho são particularmente relevantes aqui. O primeiro é a estratégia: o extrator de características foi aprendido em grandes bases de ECG de repouso e com um rótulo substituto abundante, e apenas um classificador pequeno foi ajustado com os poucos eventos disponíveis — o oposto do treinamento de ponta a ponta adotado nas redes desta dissertação. O segundo é o resultado no subgrupo de insuficiência cardíaca, população equivalente à da coorte MUSIC, em que mesmo esse modelo pré-treinado ficou próximo do limite inferior de discriminação útil.

2.4 Comparação e posicionamento deste trabalho

A comparação dos resultados desses trabalhos com os desta dissertação é apresentada nas conclusões (seção 6.2).

Os três trabalhos revelam um padrão. Os desempenhos mais altos foram obtidos em condições que favorecem a discriminação: avaliação nos mesmos dados usados para selecionar as variáveis (RAMÍREZ *et al.*, 2017), coortes que incluem ritmos não sinusais (SWEE *et al.*, 2026) ou populações em que predominam pacientes pós-infarto, nas quais a fração de ejeção já discrimina bem (KIM *et al.*, 2025). Quando a população se restringe a pacientes com insuficiência cardíaca, como no subgrupo de 223 pacientes de Kim *et al.* (2025), a AUC para o desfecho composto — morte cardíaca ou arritmia ventricular em três anos — cai para 0,60 [0,53–0,68], igual à da turbulência da frequência cardíaca isolada.

Esta dissertação se diferencia dos trabalhos anteriores em três aspectos. O primeiro é a avaliação, no mesmo protocolo e sobre os mesmos pacientes, de três abordagens — redes treinadas sobre o sinal, marcadores extraídos do Holter e variáveis clínicas —, o que permite compará-las diretamente. O segundo é a ênfase no controle do otimismo: validação cruzada por paciente, seleção de variáveis dentro de cada partição, AUC das predições agrupadas com intervalos de confiança e o registro das configurações que não funcionaram, em vez de apenas da melhor (KAPOOR; NARAYANAN, 2023). O terceiro é a restrição ao ritmo sinusal, que elimina o atalho oferecido pela fibrilação atrial e torna a tarefa mais próxima do problema clínico de interesse: identificar, entre pacientes com insuficiência cardíaca em ritmo sinusal, aqueles com maior risco de morte súbita.

3 FUNDAMENTAÇÃO TEÓRICA

3.1 Pré-processamento de sinais eletrocardiográficos

O sinal registrado pelo eletrocardiógrafo contém, além da atividade elétrica cardíaca, componentes de origem diversa que se sobrepõem a ela. O pré-processamento tem por objetivo atenuar esses componentes preservando a morfologia das ondas de interesse, e a escolha de seus parâmetros resulta de um compromisso entre remover ruído e não distorcer o sinal (CLIFFORD *et al.*, 2006).

3.1.1 Fontes de interferência

Três fontes de interferência predominam no registro ambulatorial.

A *oscilação da linha de base* consiste em variações lentas do nível do sinal, provocadas pela respiração, pela movimentação do paciente e pela alteração da impedância na interface entre eletrodo e pele. Seu conteúdo espectral concentra-se abaixo de 0,5 Hz, e seu efeito é deslocar o traçado verticalmente ao longo do tempo, dificultando a comparação de amplitudes entre batimentos.

A *interferência da rede elétrica* manifesta-se como componente senoidal na frequência de alimentação e em seus harmônicos. Essa frequência é de 50 Hz na Espanha, onde foi adquirida a base empregada neste trabalho, e de 60 Hz no Brasil. Como está acima da frequência de corte superior do filtro adotado (40 Hz), essa interferência é removida pela própria filtragem passa-faixa, sem necessidade de um filtro específico.

O *ruído muscular*, decorrente da atividade elétrica dos músculos esqueléticos, ocupa banda larga, predominantemente acima de 20 Hz. No Holter, ao qual o paciente permanece conectado durante suas atividades habituais, esse ruído é mais frequente que no exame de repouso, e se soma aos *artefatos de movimento* produzidos pelo deslocamento dos eletrodos.

A energia do próprio ECG, por sua vez, concentra-se em faixa relativamente estreita. As ondas P e T, de evolução lenta, ocupam predominantemente frequências abaixo de 10 Hz; o complexo QRS, de transição rápida, estende-se até algumas dezenas de hertz. Essa separação parcial entre o conteúdo do sinal e o das interferências é o que torna a filtragem por faixa de frequência eficaz.

3.1.2 Filtragem digital

Um filtro passa-faixa atenua as componentes situadas abaixo de uma frequência de corte inferior f_{inf} e acima de uma frequência de corte superior f_{sup}, preservando a faixa intermediária. A escolha de f_{inf} determina quanto da oscilação de linha de base é removida; a de f_{sup}, quanto do ruído muscular e da interferência da rede.

As recomendações da American Heart Association para o ECG diagnóstico estabelecem frequência de corte inferior de 0,05 Hz para filtros convencionais, admitindo até 0,67 Hz quando o filtro digital não introduz distorção de fase (KLIGFIELD *et al.*, 2007). A ressalva decorre de que filtros com resposta de fase não linear deslocam componentes de frequências distintas por intervalos de tempo diferentes, o que distorce segmentos de evolução lenta, como o segmento ST.

3.1.2.1 Filtro de Butterworth

O filtro de Butterworth (BUTTERWORTH, 1930) caracteriza-se por resposta em magnitude maximamente plana na banda passante. Para um filtro passa-baixas de ordem n e frequência de corte f_c, a magnitude da resposta em frequência é

$$|H(f)| = \frac{1}{\sqrt{1 + (f/f_c)^{2n}}}. \tag{3.1}$$

A ausência de ondulações na banda passante preserva a amplitude relativa das componentes do sinal, propriedade desejável quando a morfologia das ondas é a informação de interesse. A ordem n controla a inclinação da transição entre as bandas passante e de rejeição: ordens maiores produzem corte mais abrupto, ao custo de maior atraso e maior sensibilidade numérica. A implementação em seções de segunda ordem em cascata contorna essa sensibilidade, decompondo o filtro em blocos de baixa ordem numericamente estáveis.

3.1.2.2 Filtragem de fase nula

A filtragem direta e reversa aplica o mesmo filtro duas vezes: primeiro no sentido temporal e, em seguida, sobre o sinal invertido no tempo (GUSTAFSSON, 1996). O atraso de fase introduzido na primeira passagem é exatamente compensado pela segunda, de modo que o resultado não apresenta distorção de fase. A magnitude da resposta, por sua vez, é elevada ao

quadrado, o que equivale a dobrar a ordem efetiva do filtro.

A operação não é causal, pois a saída em cada instante depende de amostras futuras. Essa restrição impede seu uso em monitoramento em tempo real, mas não representa limitação na análise de registros já adquiridos, como é o caso do Holter.

3.1.3 Normalização de amplitude

Redes neurais são sensíveis à escala da entrada: valores de magnitudes muito distintas entre exemplos dificultam a otimização. Duas estratégias de normalização são usuais em sinais, e diferem quanto à informação que preservam.

A *padronização por segmento* subtrai a média e divide pelo desvio-padrão de cada trecho individualmente. Todos os segmentos passam a ter média nula e variância unitária, independentemente da amplitude original. A estratégia é robusta a diferenças de ganho entre equipamentos, mas elimina a informação de amplitude absoluta — um traçado de baixa voltagem e outro de alta voltagem tornam-se indistinguíveis quanto à escala.

A *normalização por escala global* divide todos os segmentos por uma mesma constante, estimada sobre o conjunto de treinamento. A amplitude relativa entre pacientes é preservada, o que é relevante no ECG: a baixa voltagem e a hipertrofia ventricular manifestam-se justamente como amplitudes anormalmente reduzidas ou elevadas. A estimativa da constante por percentil elevado do valor absoluto, em lugar do máximo, confere robustez a artefatos pontuais de grande amplitude.

3.1.4 Amostragem em janelas e independência entre exemplos

Registros de longa duração raramente são processados integralmente por redes neurais, em razão do volume de memória envolvido: 24 horas a 200 Hz em três derivações correspondem a aproximadamente 17 milhões de amostras. A prática usual consiste em extrair janelas de duração fixa, cada uma tratada como exemplo de treinamento.

Essa estratégia introduz uma dependência entre exemplos que tem consequências metodológicas. Janelas de um mesmo paciente compartilham características individuais estáveis — eixo elétrico, morfologia do complexo QRS, relação de amplitude entre derivações —, e não constituem observações independentes. Se janelas de um mesmo indivíduo forem distribuídas entre os conjuntos de treinamento e teste, o modelo pode reconhecer o paciente em lugar de estimar o desfecho, produzindo estimativas de desempenho otimistas. Esse tipo de vazamento de

informação está entre as causas mais frequentes de resultados não reprodutíveis em aprendizado de máquina aplicado (KAPOOR; NARAYANAN, 2023). A prevenção exige que a divisão entre conjuntos seja realizada no nível do paciente, e que as métricas sejam calculadas após a agregação das predições de suas janelas.

3.2 Extração de características do sinal eletrocardiográfico

As redes neurais descritas nas seções anteriores aprendem diretamente do sinal quais padrões são relevantes para a tarefa. A alternativa clássica inverte essa ordem: calculam-se do ECG medidas com significado fisiológico conhecido, e um modelo estatístico simples relaciona essas medidas ao desfecho. Essas medidas são chamadas, neste trabalho, de *marcadores eletrocardiográficos*; na literatura, recebem também os nomes de biomarcadores digitais ou de métricas derivadas do ECG.

A abordagem tem duas vantagens em uma coorte pequena. A primeira é a economia de parâmetros: cada marcador condensa milhares de amostras do sinal em um único número, e um modelo com poucas dezenas de coeficientes pode ser ajustado com 55 eventos sem memorizar os pacientes de treinamento. A segunda é a interpretabilidade: cada coeficiente refere-se a um mecanismo fisiológico identificável — o controle autonômico do ritmo, a duração da repolarização ventricular, a frequência de batimentos ectópicos —, o que permite confrontar os resultados com o conhecimento clínico. Em contrapartida, o modelo só tem acesso à informação que os marcadores escolhidos capturam; padrões do sinal que não correspondam a nenhum deles são descartados.

Os marcadores empregados pertencem a três grupos: a variabilidade da frequência cardíaca, a morfologia do batimento e a ectopia. Todos partem da mesma etapa inicial, a detecção dos complexos QRS e a delineação das ondas de cada batimento.

3.2.1 Detecção do complexo QRS e delineação das ondas

A extração de características começa pela localização de cada batimento no sinal filtrado. A detecção do complexo QRS identifica o pico R de cada batimento a partir das variações bruscas de inclinação que caracterizam a despolarização ventricular, e fornece a sequência de instantes dos batimentos sobre a qual são calculados os intervalos RR. A delineação, em seguida, localiza o início, o pico e o fim das ondas P, QRS e T de cada batimento, a partir dos quais se

medem as durações e os intervalos da morfologia. Neste trabalho, as duas etapas foram realizadas com a biblioteca NeuroKit2 (MAKOWSKI *et al.*, 2021), cujos parâmetros são apresentados na metodologia.

3.2.2 Intervalos RR e intervalos NN

O pico R é o ponto de maior amplitude do complexo QRS e marca a despolarização ventricular de cada batimento. Detectados os picos, o intervalo RR_ℓ é o tempo, em milissegundos, entre o ℓ-ésimo pico e o seguinte. A sequência de intervalos RR descreve a frequência cardíaca batimento a batimento e é a matéria-prima de todos os marcadores de ritmo.

Nem todo intervalo RR reflete, porém, a modulação normal do ritmo sinusal. Um batimento ectópico — originado fora do nó sinusal — produz um intervalo curto seguido de outro longo; um pico não detectado produz um intervalo com aproximadamente o dobro da duração esperada; um artefato detectado como pico produz dois intervalos curtos. A diretriz da *Task Force* (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996) estabelece, por isso, que os marcadores de variabilidade sejam calculados apenas sobre intervalos entre batimentos sinusais normais, chamados intervalos NN. Na prática, um intervalo é considerado normal quando não se afasta mais que uma fração pré-definida da mediana dos intervalos vizinhos. Um único batimento ectópico em um segmento curto pode multiplicar o valor de alguns marcadores, como se mostra na seção 4.5.

A distinção é especialmente importante neste trabalho, que procura nos batimentos ectópicos um sinal de risco. Os intervalos que não são NN não são descartados da análise: eles deixam de entrar nos marcadores de variabilidade, mas passam a compor os marcadores de ectopia descritos na subseção 3.2.5.

3.2.3 Variabilidade da frequência cardíaca

A frequência cardíaca de um indivíduo saudável em repouso não é constante. Ela oscila continuamente sob a ação do sistema nervoso autônomo: o ramo parassimpático, mediado pelo nervo vago, produz variações rápidas, acopladas à respiração; o ramo simpático, variações mais lentas. A variabilidade da frequência cardíaca (VFC) quantifica essas oscilações e funciona, assim, como uma medida indireta do equilíbrio autonômico. Na insuficiência cardíaca, a ativação simpática persistente e a retirada vagal reduzem a VFC. A redução da VFC está associada a maior mortalidade desde os primeiros estudos com Holter, realizados em pacientes após infarto

do miocárdio (KLEIGER *et al.*, 1987).

3.2.3.1 Domínio do tempo

Os marcadores do domínio do tempo são estatísticas calculadas diretamente sobre a sequência de n_{NN} intervalos NN de um segmento. O desvio-padrão dos intervalos NN (SDNN),

$$\mathrm{SDNN} = \sqrt{\frac{1}{n_{\mathrm{NN}} - 1} \sum_{\ell=1}^{n_{\mathrm{NN}}} \left(\mathrm{NN}_\ell - \overline{\mathrm{NN}}\right)^2}, \tag{3.2}$$

em que $\overline{\mathrm{NN}}$ é a média dos intervalos, reflete a variabilidade total do segmento, somando as componentes rápidas e lentas. A raiz quadrática média das diferenças sucessivas entre intervalos NN (RMSSD),

$$\mathrm{RMSSD} = \sqrt{\frac{1}{n_{\mathrm{NN}} - 1} \sum_{\ell=1}^{n_{\mathrm{NN}}-1} (\Delta\mathrm{NN}_\ell)^2}, \qquad \Delta\mathrm{NN}_\ell = \mathrm{NN}_{\ell+1} - \mathrm{NN}_\ell, \tag{3.3}$$

e o percentual de diferenças sucessivas entre intervalos NN superiores a 50 ms (pNN50), isolam as variações de um batimento para o seguinte e são, por isso, associados predominantemente à modulação vagal. A diferença $\Delta\mathrm{NN}_\ell$ só tem significado quando os dois intervalos são adjacentes no registro: se um batimento ectópico foi removido entre eles, a diferença compararia intervalos que não se sucederam, e não entra no cálculo.

3.2.3.2 Domínio da frequência

A análise espectral decompõe a variância dos intervalos em faixas de frequência associadas a mecanismos distintos (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996). A faixa de alta frequência (*high frequency*) (HF), de 0,15 a 0,4 Hz, corresponde à arritmia sinusal respiratória e à modulação vagal; a de baixa frequência (*low frequency*) (LF), de 0,04 a 0,15 Hz, a uma combinação de influências simpáticas e vagais ligadas ao barorreflexo; a de muito baixa frequência (*very low frequency*) (VLF), abaixo de 0,04 Hz, a mecanismos mais lentos, como a termorregulação. A razão LF/HF é frequentemente interpretada como índice do balanço simpatovagal, embora essa leitura seja controversa.

A estimativa espectral impõe uma duração mínima ao segmento. Um ciclo de 0,04 Hz, limite inferior da faixa LF, dura 25 s, e uma estimativa estável da potência nessa faixa

exige que vários ciclos estejam contidos no segmento. A *Task Force* recomenda segmentos de pelo menos 2 minutos para a faixa LF e de 5 minutos como padrão para a análise espectral de curta duração (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996).

3.2.3.3 Medidas não lineares

O gráfico de Poincaré representa cada intervalo NN contra o seguinte. A dispersão dos pontos perpendicularmente à diagonal, SD1, mede a variabilidade de curto prazo; a dispersão ao longo da diagonal, SD2, a de longo prazo (BRENNAN *et al.*, 2001). Ambas podem ser obtidas das variâncias já definidas:

$$\mathrm{SD1} = \sqrt{\tfrac{1}{2}\,\mathrm{Var}(\Delta\mathrm{NN})}, \qquad \mathrm{SD2} = \sqrt{2\,\mathrm{Var}(\mathrm{NN}) - \tfrac{1}{2}\,\mathrm{Var}(\Delta\mathrm{NN})}. \tag{3.4}$$

A primeira expressão mostra que SD1 é proporcional ao RMSSD e carrega, portanto, a mesma informação. A razão SD1/SD2 descreve a forma da nuvem de pontos e é menos redundante em relação aos demais marcadores.

A entropia amostral mede a regularidade da sequência de intervalos: valores baixos indicam uma série previsível, e valores altos, uma série complexa (RICHMAN; MOORMAN, 2000). Por depender da contagem de padrões repetidos, ela exige sequências de centenas de batimentos para ser estimada com estabilidade.

3.2.4 Morfologia do batimento

Os marcadores de morfologia descrevem a forma do batimento, e não o intervalo entre batimentos. Sua obtenção exige delinear cada batimento, isto é, localizar o início, o pico e o fim das ondas P, QRS e T.

A *duração do QRS* mede o tempo de despolarização dos ventrículos. Seu prolongamento indica condução intraventricular lenta, como nos bloqueios de ramo, e está associado a pior prognóstico na insuficiência cardíaca. O *intervalo QT*, do início do QRS ao fim da onda T, abrange a despolarização e a repolarização ventriculares. Como o QT encurta naturalmente quando a frequência cardíaca aumenta, ele é comparado entre pacientes após correção pela frequência. A correção de Bazett (BAZETT, 1920) divide o QT pela raiz quadrada do intervalo RR expresso em segundos:

$$\mathrm{QTc} = \frac{\mathrm{QT}}{\sqrt{\mathrm{RR}}}. \tag{3.5}$$

O prolongamento do QTc reflete repolarização ventricular lenta ou heterogênea, substrato conhecido para arritmias ventriculares.

A delineação automática é a etapa menos robusta da extração. As fronteiras das ondas não têm definição única, os algoritmos divergem entre si, e o ruído do Holter — registrado durante as atividades diárias do paciente — desloca as marcações. Por isso, as durações obtidas automaticamente devem ser entendidas como estimativas consistentes dentro de um mesmo método, e não como medidas comparáveis aos valores de referência clínicos.

3.2.5 Ectopia

Um batimento ectópico ocorre antes do esperado e, quando de origem ventricular, costuma ser seguido de uma pausa compensatória. As extrassístoles ventriculares frequentes e, sobretudo, as sequências de dois ou mais batimentos ectópicos consecutivos são reconhecidas como marcadores de instabilidade elétrica na insuficiência cardíaca.

A identificação definitiva da origem de um batimento exige a análise de sua morfologia. Na ausência dessa análise, a ectopia pode ser aproximada pelo ritmo: um intervalo RR muito mais curto que os vizinhos indica um batimento precoce; um intervalo curto seguido de um longo, uma extrassístole com pausa compensatória; dois intervalos curtos consecutivos, um duplete. Essa aproximação não distingue a origem ventricular da supraventricular e deve ser descrita como um indicador de ectopia, e não como uma contagem de extrassístoles ventriculares.

3.2.6 Duração do segmento de análise

Os marcadores não são calculados sobre o Holter inteiro, mas sobre segmentos, e a duração do segmento determina quais deles podem ser estimados. A Tabela 1 resume essa relação. Segmentos curtos permitem acompanhar a evolução dos marcadores ao longo do dia, mas restringem o conjunto calculável e aumentam a variância de cada estimativa: com cerca de 35 batimentos em 30 segundos, um único intervalo anômalo pesa sobre o SDNN e o RMSSD muito mais que em 5 minutos.

Como cada paciente contribui com dezenas ou centenas de segmentos, os valores precisam ser resumidos em uma única linha por paciente antes da modelagem, pelas razões

Tabela 1 – Marcadores calculáveis em segmentos de 5 minutos e de 30 segundos

Marcador	5 minutos	30 segundos	Motivo
SDNN, RMSSD, pNN50, SD1, SD2	calculável	calculável, com maior variância	Dependem apenas das diferenças entre batimentos; com cerca de 35 batimentos em 30 s, um único intervalo anômalo pesa muito sobre o resultado.
Potência LF, HF e razão LF/HF	calculável	não calculável	Análise espectral: as oscilações da banda LF (0,04–0,15 Hz) duram até 25 s, e um trecho de 30 s contém pouco mais de um ciclo. Recomendam-se ao menos 2 minutos para a LF.
Potência VLF	calculável, pouco confiável	não calculável	As oscilações da banda VLF (0,0033–0,04 Hz) duram até 5 minutos: um segmento de 5 minutos contém no máximo um ciclo, e a estimativa em registros curtos não é recomendada.
Entropia amostral	calculável	não calculável	Mede a regularidade da série de intervalos e exige algumas centenas de pontos para ser estável.
QRS, QT, QTc	calculável	calculável	Medidas de cada batimento, obtidas em qualquer trecho que contenha batimentos.
Indicadores de ectopia	calculável	calculável	Contagens de batimentos precoces e pausas, possíveis em qualquer trecho.

Fonte: elaborado pelo autor (2026), com base em Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology (1996). Calculável: o marcador pode ser estimado de forma confiável com a duração indicada. Não calculável: o marcador não foi calculado naquela duração, e não foi obtido de outra forma.

discutidas na subseção 3.7.5. O resumo pode descrever o nível típico de cada marcador, por exemplo pela mediana, e também sua variação ao longo do registro, que reflete a modulação circadiana e a instabilidade do controle autonômico.

A metodologia (seção 4.5) reúne, em tabela, os marcadores extraídos neste trabalho, com sua definição, unidade e significado fisiológico, e descreve como cada um é resumido por paciente.

3.3 Redes neurais convolucionais unidimensionais

As redes neurais convolucionais (CNN) foram concebidas para dados com estrutura espacial ou temporal, nos quais elementos próximos guardam relação entre si (LECUN *et al.*, 1998). Embora popularizadas no processamento de imagens, sua formulação unidimensional aplica-se diretamente a sinais fisiológicos, nos quais a vizinhança temporal carrega a informação

relevante (KIRANYAZ *et al.*, 2021). No ECG, a morfologia de cada onda é definida pela sucessão de amostras ao longo de algumas dezenas de milissegundos, e é essa estrutura local que a convolução explora.

Esta seção apresenta as operações que compõem as redes convolucionais e, por extensão, as redes residuais e com atenção descritas nas seções seguintes. As arquiteturas construídas neste trabalho são descritas na metodologia (seção 4.3).

3.3.1 Convolução unidimensional

Seja $\mathbf{S} \in \mathbb{R}^{C \times L}$ um sinal com C derivações e L amostras. Uma camada convolucional unidimensional aplica C' filtros, cada um definido por um núcleo $\Theta_{c'} \in \mathbb{R}^{C \times \kappa}$ de largura κ. A saída do filtro c' na posição t é dada por

$$h_{c'}(t) = b_{c'} + \sum_{c=1}^{C} \sum_{j=0}^{\kappa-1} \Theta_{c',c,j}\, S_c(t + j - \lfloor \kappa/2 \rfloor), \tag{3.6}$$

em que $b_{c'}$ é um termo de viés. O filtro percorre o sinal posição a posição, e em cada uma combina os κ valores vizinhos de todas as derivações em um único número. Valores elevados indicam que o trecho analisado se assemelha ao padrão codificado no filtro.

Duas propriedades tornam a operação adequada a sinais. A primeira é o *compartilhamento de pesos*: o mesmo núcleo é aplicado em todas as posições, de modo que um padrão aprendido em um instante é reconhecido em qualquer outro. A segunda é a *conectividade local*: cada saída depende apenas de κ amostras vizinhas, o que reduz drasticamente o número de parâmetros em relação a uma camada totalmente conectada. Uma camada com C entradas, C' filtros e núcleo κ possui $C \cdot C' \cdot \kappa$ pesos, independentemente do comprimento L do sinal.

O preenchimento de $\lfloor \kappa/2 \rfloor$ amostras nas extremidades preserva o comprimento da saída. A largura do núcleo, por sua vez, determina a escala temporal dos padrões que cada filtro é capaz de representar isoladamente.

3.3.2 Função de ativação

A composição de operações lineares resulta em operação linear, de modo que empilhar camadas convolucionais sem não linearidades intermediárias não aumentaria a capacidade de representação do modelo. Emprega-se, por isso, a função de ativação retificada linear (NAIR; HINTON, 2010):

$$\mathrm{ReLU}(z) = \max(0, z). \tag{3.7}$$

A função anula valores negativos e preserva os positivos. Em termos interpretativos, cada filtro passa a indicar a presença do padrão correspondente, e não sua ausência. Do ponto de vista da otimização, sua derivada unitária na região positiva evita a atenuação do gradiente que afeta funções saturantes, como a tangente hiperbólica.

3.3.3 Normalização em lote

À medida que os parâmetros de uma camada se alteram durante o treinamento, a distribuição de suas saídas também se altera, o que obriga as camadas seguintes a se readaptarem continuamente. A normalização em lote (IOFFE; SZEGEDY, 2015) atenua esse efeito padronizando cada canal com a média $\mu_{\mathscr{B}}$ e a variância $\sigma^2_{\mathscr{B}}$ calculadas sobre o lote $\mathscr{B}$:

$$\hat{h} = \gamma \frac{h - \mu_{\mathscr{B}}}{\sqrt{\sigma^2_{\mathscr{B}} + \varepsilon}} + \beta, \tag{3.8}$$

em que γ e β são parâmetros aprendidos que permitem à rede recuperar a escala original, caso seja conveniente, e ε é uma constante de estabilidade numérica. Durante a avaliação, $\mu_{\mathscr{B}}$ e $\sigma^2_{\mathscr{B}}$ são substituídas por médias móveis acumuladas no treinamento, de modo que a predição de um paciente não dependa dos demais presentes no mesmo lote.

3.3.4 Agrupamento

O agrupamento máximo com fator r divide a sequência em trechos de r posições e retém apenas o maior valor de cada um, reduzindo o comprimento por esse fator. A operação tem dois efeitos. O primeiro é a redução do custo computacional das camadas seguintes. O segundo é a ampliação progressiva da escala temporal: após o agrupamento, cada posição resume r amostras da camada anterior, e a convolução seguinte, com o mesmo núcleo κ, passa a abranger trecho r vezes mais longo do sinal original.

Ao término da sequência de camadas convolucionais, o agrupamento global colapsa integralmente o eixo temporal (LIN *et al.*, 2014). O agrupamento global por média produz, para cada canal, o valor médio ao longo da janela; o agrupamento global máximo, o valor no instante de maior ativação:

$$z_c^{\text{méd}} = \frac{1}{L'}\sum_{t=1}^{L'} h_c(t), \qquad z_c^{\text{máx}} = \max_t h_c(t), \tag{3.9}$$

em que L' é o comprimento da sequência após as camadas convolucionais. A representação resultante tem dimensão fixa, independente do comprimento da entrada, o que permite à mesma rede processar janelas de durações distintas.

3.3.5 Descarte

O descarte (*dropout*) anula aleatoriamente uma fração p das unidades a cada passo de treinamento (SRIVASTAVA *et al.*, 2014). Como nenhuma unidade pode contar com a presença das demais, a rede é impelida a distribuir a informação entre múltiplos caminhos redundantes, o que reduz a tendência de memorizar exemplos específicos. Na avaliação, todas as unidades são mantidas e suas saídas, escaladas pelo fator correspondente.

3.3.6 Função de perda e desbalanceamento

A rede produz, para cada exemplo i, um valor real z_i denominado *logit*, convertido em probabilidade pela função logística:

$$\hat{p}_i = \sigma(z_i) = \frac{1}{1+\mathrm{e}^{-z_i}}. \tag{3.10}$$

O ajuste dos parâmetros θ minimiza a entropia cruzada binária. Em problemas com classes desbalanceadas, a contribuição dos exemplos positivos é multiplicada por um peso w_+:

$$\mathscr{L}(\theta) = -\frac{1}{B}\sum_{i=1}^{B}\Big[w_+\, y_i \log \hat{p}_i + (1-y_i)\log(1-\hat{p}_i)\Big], \tag{3.11}$$

em que B é o tamanho do lote e $y_i \in \{0,1\}$ o rótulo. Sem a ponderação, a perda poderia ser minimizada atribuindo-se a classe majoritária a todos os exemplos — solução que, com prevalência de 10,6 %, alcança acurácia de 89,4 % com sensibilidade nula. A escolha $w_+ = N_0/N_1$, razão entre o número de exemplos negativos e positivos, torna a contribuição total das duas classes equivalente, o que corresponde a replicar cada exemplo positivo w_+ vezes sem descartar exemplos negativos.

A minimização emprega o otimizador AdamW (LOSHCHILOV; HUTTER, 2019), que adapta a taxa de aprendizado de cada parâmetro à magnitude histórica de seus gradientes e aplica a regularização por decaimento de pesos de forma desacoplada da atualização do gradiente.

3.4 Redes neurais residuais

A profundidade é um dos fatores que determinam a capacidade de representação de uma rede neural: camadas sucessivas permitem compor padrões simples em padrões progressivamente mais abstratos. Empiricamente, contudo, o acréscimo de camadas a partir de certo ponto deixa de melhorar e passa a piorar o desempenho — não por sobreajuste, mas porque o próprio erro de treinamento aumenta. He *et al.* (2016) denominaram esse fenômeno *problema de degradação* e propuseram as redes residuais como solução.

3.4.1 Aprendizado residual

O argumento parte de uma construção. Uma rede mais profunda poderia, em princípio, reproduzir o desempenho de uma rede rasa se as camadas adicionais implementassem a função identidade. Que redes profundas não alcancem sequer esse desempenho indica que aproximar a identidade por meio de sucessivas transformações não lineares é difícil para os métodos de otimização usuais.

A proposta consiste em reformular o que cada bloco aprende. Em lugar de estimar diretamente o mapeamento desejado $\mathscr{H}(\mathbf{x})$, o bloco estima o resíduo $\mathscr{F}(\mathbf{x}) = \mathscr{H}(\mathbf{x}) - \mathbf{x}$, e a saída é obtida somando-se a entrada de volta:

$$\mathbf{y} = \mathscr{F}(\mathbf{x}; \Theta) + \mathbf{x}. \tag{3.12}$$

A soma com a entrada, denominada *conexão de atalho*, não introduz parâmetros. Se a transformação ideal for próxima da identidade, basta que os pesos de $\mathscr{F}$ tendam a zero — solução mais simples de alcançar que aproximar a identidade por meio de camadas não lineares. Do ponto de vista da otimização, o atalho oferece ao gradiente um caminho direto entre camadas distantes, que não depende das derivadas das transformações intermediárias, o que mitiga sua atenuação ao longo de redes profundas.

Quando o bloco altera o número de canais ou reduz o comprimento temporal, a soma da Equação 3.12 não é definida, pois as dimensões de $\mathscr{F}(\mathbf{x})$ e $\mathbf{x}$ diferem. Nesse caso, a entrada é projetada por uma convolução de núcleo unitário Θ_s, com o mesmo passo da transformação principal, seguida de normalização em lote:

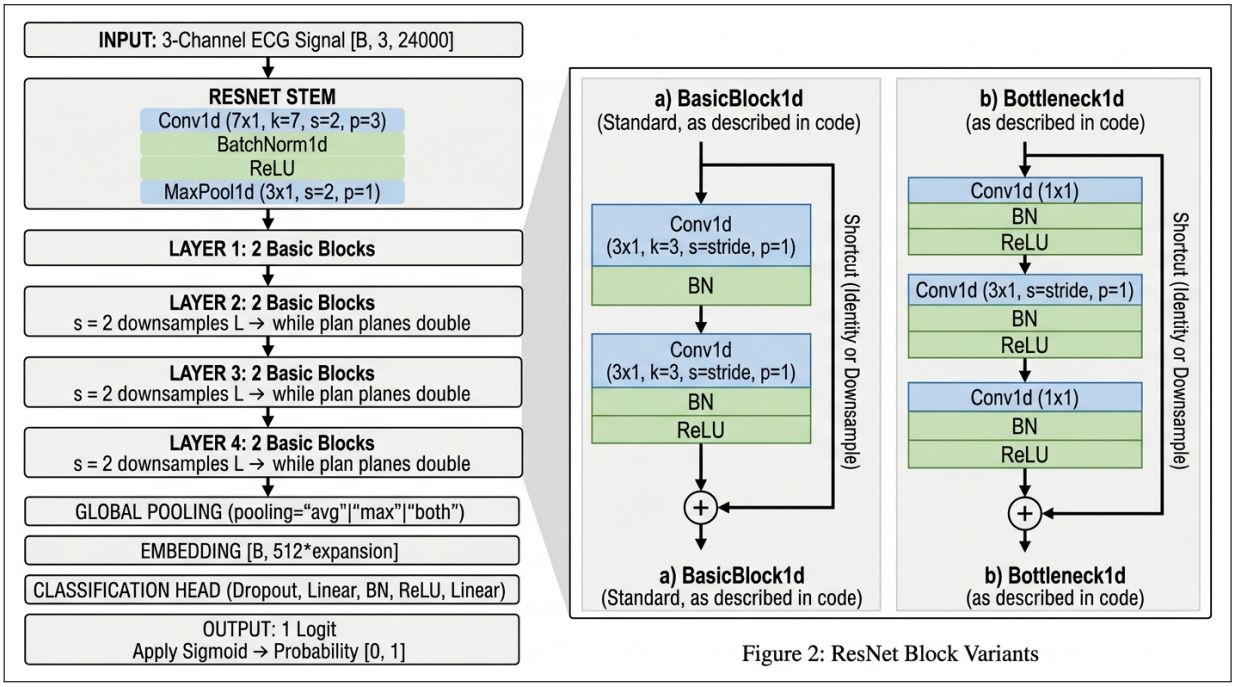
$$\mathbf{y} = \mathscr{F}(\mathbf{x}; \Theta) + \Theta_s \mathbf{x}. \tag{3.13}$$

Nos demais blocos de um mesmo estágio, em que as dimensões coincidem, o atalho é a identidade e não acrescenta custo.

3.4.2 Blocos residuais

Duas variantes de bloco foram empregadas neste trabalho, ilustradas na Figura 1.

Figura 1 – Blocos residuais básico (tipo a) e de gargalo (tipo b)



Fonte: adaptado de He *et al.* (2016).

3.4.2.1 Bloco básico

O bloco básico é composto por duas convoluções de núcleo $\kappa = 3$, cada uma seguida de normalização em lote, com ativação *ReLU* após a primeira e após a soma com o atalho:

$$\mathscr{F}(\mathbf{x}) = \mathrm{BN}\Big(\mathrm{Conv}_3\big(\mathrm{ReLU}(\mathrm{BN}(\mathrm{Conv}_3(\mathbf{x})))\big)\Big), \qquad \mathbf{y} = \mathrm{ReLU}\big(\mathscr{F}(\mathbf{x}) + \mathbf{x}\big). \tag{3.14}$$

O número de canais na saída é igual ao da camada interna, o que se expressa por um fator de expansão $E = 1$.

3.4.2.2 Bloco de gargalo

Em redes mais profundas, o custo de duas convoluções de núcleo três com muitos canais torna-se proibitivo. O bloco de gargalo substitui-as por três convoluções: a primeira, de núcleo unitário, reduz o número de canais; a segunda, de núcleo três, opera sobre a dimensão reduzida; a terceira, também de núcleo unitário, expande os canais em $E = 4$ vezes. A convolução de núcleo unitário não considera vizinhança temporal — combina apenas os canais em cada posição —, e é por isso computacionalmente barata.

Para um bloco com 256 canais na entrada e na saída, a versão básica exigiria $2 \times 256 \times 256 \times 3 \approx 393\,000$ pesos; a de gargalo, com dimensão interna de 64, exige $256 \times 64 + 64 \times 64 \times 3 + 64 \times 256 \approx 45\,000$ — cerca de nove vezes menos. É essa economia que viabiliza arquiteturas com dezenas de camadas.

3.5 Mecanismo de atenção

As arquiteturas descritas nas seções anteriores relacionam instantes do sinal por meio de operações locais. Cada convolução combina apenas κ posições vizinhas, e a relação entre instantes distantes só se estabelece indiretamente, pelo empilhamento de camadas — daí o campo receptivo de 2,2 s ao final da ResNet-18, inferior à janela de dois minutos analisada.

O mecanismo de atenção adota princípio distinto: cada posição da sequência pode ser relacionada diretamente a qualquer outra, em uma única operação, com intensidade aprendida a partir dos próprios dados. Proposto no contexto da tradução automática (VASWANI *et al.*, 2017), tornou-se o componente central das arquiteturas denominadas *Transformer*.

3.5.1 Autoatenção

Seja $\mathbf{X} \in \mathbb{R}^{L \times d}$ uma sequência de L posições, cada uma representada por um vetor de dimensão d. A autoatenção projeta essa sequência em três matrizes, por meio de transformações lineares aprendidas:

$$\mathbf{Q} = \mathbf{X}\mathbf{U}_Q, \qquad \mathbf{K} = \mathbf{X}\mathbf{U}_K, \qquad \mathbf{V} = \mathbf{X}\mathbf{U}_V, \tag{3.15}$$

denominadas consultas, chaves e valores. A saída é obtida ponderando os valores pela similaridade entre consultas e chaves:

$$\text{Ateno}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right)\mathbf{V}, \tag{3.16}$$

em que d_k é a dimensão das consultas e chaves. O produto $\mathbf{Q}\mathbf{K}^\top$ resulta em matriz $L \times L$ cujo elemento (t,s) mede o quanto a posição t deve considerar a posição s. A função *softmax*, aplicada a cada linha, converte essas similaridades em pesos não negativos que somam um. A divisão por $\sqrt{d_k}$ evita que, em dimensões elevadas, os produtos internos assumam magnitudes que saturariam a *softmax* e anulariam seus gradientes.

Cada posição da saída é, portanto, uma média ponderada das representações de todas as posições da sequência, com pesos que dependem do conteúdo. No contexto do ECG, isso permite, em princípio, que a representação de um batimento incorpore informação de batimentos distantes cujo padrão seja relevante — uma extrassístole e a pausa que a sucede, por exemplo.

3.5.1.1 Atenção com múltiplas cabeças

Em vez de uma única operação de atenção, a formulação usual executa h operações em paralelo, cada uma com projeções próprias de dimensão $d_k = d/h$, e concatena os resultados:

$$\text{MultiCabea}(\mathbf{X}) = \left[\text{cabea}_1;\ldots;\text{cabea}_h\right]\mathbf{U}_O, \qquad \text{cabea}_i = \text{Ateno}\left(\mathbf{X}\mathbf{U}_Q^{(i)}, \mathbf{X}\mathbf{U}_K^{(i)}, \mathbf{X}\mathbf{U}_V^{(i)}\right). \tag{3.17}$$

Cada cabeça pode especializar-se em um tipo de relação — uma em vizinhança imediata, outra em padrões periódicos, por exemplo —, sem que o custo total seja superior ao de uma única cabeça de dimensão d.

3.5.2 Camada codificadora

A camada codificadora do *Transformer* combina a atenção com múltiplas cabeças e uma rede totalmente conectada aplicada a cada posição separadamente, ambas envolvidas por conexões residuais e normalização:

$$\mathbf{X}' = \mathrm{LN}\big(\mathbf{X} + \mathrm{MultiCabea}(\mathbf{X})\big), \tag{3.18}$$

$$\mathbf{Y} = \mathrm{LN}\big(\mathbf{X}' + \mathrm{FFN}(\mathbf{X}')\big), \tag{3.19}$$

em que FFN é composta por duas camadas lineares com ativação intermediária, a primeira expandindo a dimensão de d para d_{ff} e a segunda restaurando-a. As conexões residuais desempenham o mesmo papel discutido na subseção 3.4.1.

A normalização empregada é a normalização de camada (BA *et al.*, 2016), que padroniza cada vetor individualmente, ao longo de suas d dimensões, em lugar de cada canal ao longo do lote como na Equação 3.8. A escolha torna a operação independente do tamanho do lote e do comprimento da sequência.

3.5.3 Custo computacional

A matriz de atenção possui L^2 elementos por cabeça, e o custo da operação cresce com o quadrado do comprimento da sequência. Esse aspecto determina onde a atenção pode ser inserida em arquiteturas para sinais longos.

Aplicada diretamente à janela de 24 000 amostras, a atenção exigiria matriz de 576 milhões de elementos por cabeça e por exemplo — volume incompatível com o processamento em lote. Aplicada após o corpo convolucional, que reduz a sequência a 750 posições, a matriz passa a ter 562 500 elementos, redução de aproximadamente mil vezes. A combinação de camadas convolucionais seguidas de atenção explora essa complementaridade: as convoluções extraem padrões locais e comprimem a sequência, e a atenção relaciona os padrões resultantes ao longo de toda a janela.

3.6 Modelos de aprendizado de máquina clássico

Os marcadores extraídos do ECG e as variáveis clínicas formam uma tabela, com uma linha por paciente e uma coluna por variável. Esta seção descreve os modelos de aprendizado de máquina clássico ajustados sobre essas tabelas.

3.6.1 Regressão logística regularizada

A regressão logística estima a probabilidade de evento de um paciente com variáveis $\mathbf{x}$ como

$$p(\mathbf{x}) = \sigma\left(\beta_0 + \beta^\top \mathbf{x}\right), \tag{3.20}$$

em que σ é a função logística (Equação 3.10). Com as variáveis padronizadas, e^{β_j} é a razão de chances associada ao aumento de um desvio-padrão na variável j. Os coeficientes são obtidos minimizando a entropia cruzada acrescida de uma penalização: a penalização L2, $\lambda\|\beta\|_2^2$, encolhe todos os coeficientes sem anulá-los; a penalização L1, $\lambda\|\beta\|_1$, anula parte deles e realiza, portanto, seleção de variáveis. Com poucos eventos, a penalização reduz o sobreajuste, mas não o elimina: a regra usual de dez eventos por variável (PEDUZZI *et al.*, 1996) indica que, com 33 casos de treinamento, um modelo confiável comporta poucas variáveis, o que favorece conjuntos pequenos definidos antes de olhar os dados.

3.6.2 Análise de componentes principais

Quando há muitas variáveis correlacionadas, a análise de componentes principais (*principal component analysis*) (PCA) as substitui por poucas combinações lineares não correlacionadas, ordenadas pela variância que explicam. As direções são estimadas apenas com os pacientes de treinamento e aplicadas, sem alteração, aos de teste. Neste trabalho, a PCA condensa os marcadores extraídos do ECG, fortemente correlacionados entre si, em quatro a seis componentes, usados em seguida por uma regressão logística.

3.6.3 Floresta aleatória

A floresta aleatória combina as predições de muitas árvores de decisão, cada uma ajustada sobre uma amostra *bootstrap* dos pacientes e, em cada divisão, sobre um subconjunto aleatório das variáveis (BREIMAN, 2001). A média das árvores reduz a variância de uma árvore isolada e permite representar relações não lineares e interações entre variáveis, sem exigir que sejam especificadas de antemão.

3.7 Avaliação de classificadores binários

Um classificador binário, como as redes e os modelos logísticos deste trabalho, produz para cada paciente i uma probabilidade estimada $\hat{p}_i \in [0,1]$ de pertencer à classe positiva — neste trabalho, o óbito por MSC. Avaliar o classificador significa medir o quanto essas probabilidades separam os pacientes que sofreram o evento dos que não o sofreram. Esta seção

apresenta as métricas empregadas, distinguindo as que dependem de um limiar de decisão das que avaliam a ordenação das probabilidades, e descreve os procedimentos usados para estimar a incerteza dessas métricas em uma amostra pequena e desbalanceada.

3.7.1 Matriz de confusão e métricas dependentes de limiar

Para converter a probabilidade em uma decisão, fixa-se um limiar δ: o paciente é classificado como positivo se $\hat{p}_i \geq \delta$ e como negativo caso contrário. O cruzamento entre a classe predita e a classe real gera os quatro desfechos da matriz de confusão, apresentada na Tabela 2.

Tabela 2 – Matriz de confusão de um classificador binário

	Predito positivo	Predito negativo
Real positivo ($y = 1$)	Verdadeiro positivo (VP)	Falso negativo (FN)
Real negativo ($y = 0$)	Falso positivo (FP)	Verdadeiro negativo (VN)

Fonte: elaborado pelo autor (2026).

A partir dessas contagens definem-se as métricas da Tabela 3. A sensibilidade e a especificidade descrevem o desempenho dentro de cada classe real e não dependem da proporção entre as classes. O valor preditivo positivo (VPP) e o valor preditivo negativo (VPN), ao contrário, respondem à pergunta clínica — dado o resultado do classificador, qual a probabilidade de o paciente estar na classe indicada — e por isso dependem da prevalência π do evento na população avaliada.

Tabela 3 – Métricas derivadas da matriz de confusão

Métrica	Definição	Interpretação
Sensibilidade (revocação)	$\frac{\text{VP}}{\text{VP}+\text{FN}}$	fração dos óbitos identificada
Especificidade	$\frac{\text{VN}}{\text{VN}+\text{FP}}$	fração dos sobreviventes corretamente descartada
VPP (precisão)	$\frac{\text{VP}}{\text{VP}+\text{FP}}$	probabilidade de óbito entre os sinalizados
VPN	$\frac{\text{VN}}{\text{VN}+\text{FN}}$	probabilidade de sobrevida entre os não sinalizados
Acurácia	$\frac{\text{VP}+\text{VN}}{N}$	fração total de acertos
F1	$\frac{2 \cdot \text{VPP} \cdot \text{Sens.}}{\text{VPP}+\text{Sens.}}$	média harmônica entre VPP e sensibilidade

Fonte: elaborado pelo autor (2026).

A acurácia merece cautela em problemas desbalanceados. Com prevalência de

10,6 %, um classificador que declare todos os pacientes sobreviventes alcança acurácia de 89,4 % sem identificar nenhum óbito. Pelo mesmo motivo, o VPP deve ser lido em relação à prevalência: um VPP próximo de π indica que ser sinalizado pelo classificador pouco altera a probabilidade de óbito em relação à da coorte como um todo.

Todas essas métricas dependem do limiar escolhido. Reduzir δ aumenta a sensibilidade à custa da especificidade, e vice-versa, de modo que um único par de valores descreve apenas um ponto de operação do classificador. Por esse motivo, a métrica principal deste trabalho é independente de limiar.

3.7.2 Curva ROC e área sob a curva

A curva ROC (*Receiver Operating Characteristic*) representa o classificador em todos os limiares possíveis simultaneamente: para cada δ, marca-se a taxa de verdadeiros positivos (sensibilidade) contra a taxa de falsos positivos ($1-$ especificidade) (FAWCETT, 2006). Um classificador sem capacidade discriminativa produz a diagonal que liga $(0,0)$ a $(1,1)$; um classificador perfeito passa pelo ponto $(0,1)$.

A AUC resume a curva em um único número e admite uma interpretação probabilística direta (HANLEY; MCNEIL, 1982): é a probabilidade de que um paciente sorteado entre os que sofreram o evento receba probabilidade estimada maior que um paciente sorteado entre os que não o sofreram. Com N_1 positivos e N_0 negativos, ela é estimada por

$$\mathrm{AUC} = \frac{1}{N_1 N_0} \sum_{i \in \mathscr{C}_1} \sum_{j \in \mathscr{C}_0} \varphi\left(\hat{p}_i, \hat{p}_j\right), \qquad \varphi(a,b) = \begin{cases} 1, & a > b, \\ \frac{1}{2}, & a = b, \\ 0, & a < b, \end{cases} \tag{3.21}$$

em que $\mathscr{C}_1$ e $\mathscr{C}_0$ são os conjuntos de casos e de controles, com N_1 e N_0 elementos. A função φ compara um caso i com um controle j e vale 1 quando o caso recebeu a maior probabilidade. A AUC é, portanto, a fração dos $N_1 N_0$ pares em que o caso foi ordenado acima do controle: 0,5 corresponde à ordenação aleatória e 1,0 à separação perfeita.

Duas propriedades tornam a AUC adequada como métrica principal deste trabalho. Ela não depende de limiar, o que permite comparar modelos independentemente do ponto de operação escolhido. E ela não depende da prevalência, já que cada par contém exatamente um caso e um controle, o que a torna comparável entre coortes com proporções diferentes de eventos.

Em contrapartida, a AUC mede apenas a ordenação: um modelo pode ter AUC elevada e, ainda assim, produzir probabilidades mal calibradas ou um VPP baixo quando o evento é raro.

3.7.3 Curva precisão-revocação e área sob a curva

Quando a classe positiva é rara, a curva ROC pode transmitir uma impressão otimista: como a taxa de falsos positivos é calculada sobre os numerosos negativos, um número absoluto elevado de falsos positivos pode corresponder a uma taxa pequena. A curva precisão-revocação contorna esse efeito ao relacionar o VPP (precisão) à sensibilidade (revocação), concentrando-se no desempenho sobre a classe positiva (SAITO; REHMSMEIER, 2015; DAVIS; GOADRICH, 2006).

A área sob a curva de precisão–revocação (AUPRC) resume essa curva pela área sob ela. Como a curva é formada por um número finito de pontos, a área precisa ser estimada, e a interpolação linear entre pontos vizinhos, adequada no espaço ROC, superestima a área no espaço precisão-revocação (DAVIS; GOADRICH, 2006). Neste trabalho, a AUPRC foi estimada pela soma do VPP em cada limiar, ponderada pelo incremento de sensibilidade:

$$\mathrm{AUPRC} \approx \sum_{q} \left(\mathrm{Sens}_q - \mathrm{Sens}_{q-1}\right) \mathrm{VPP}_q, \tag{3.22}$$

em que VPP_q e Sens_q são o VPP e a sensibilidade no q-ésimo limiar, percorridos em ordem decrescente. Esse estimador, que não interpola entre os pontos, é o implementado na biblioteca *scikit-learn*, na qual recebe o nome de *average precision*. Diferentemente da AUC, a AUPRC depende da prevalência: o valor de referência de um classificador aleatório não é 0,5, mas a própria prevalência π, igual a 0,106 nesta coorte. Uma AUPRC só indica capacidade discriminativa quando supera esse valor.

3.7.4 Escolha do limiar de decisão

As métricas da Tabela 3 exigem que um limiar seja fixado. Neste trabalho, o limiar é o que maximiza o índice de Youden (YOUDEN, 1950):

$$J(\delta) = \mathrm{Sensibilidade}(\delta) + \mathrm{Especificidade}(\delta) - 1, \qquad \delta^{*} = \arg\max_{\delta} J(\delta). \tag{3.23}$$

Geometricamente, δ^* corresponde ao ponto da curva ROC mais distante da diagonal. O critério atribui o mesmo peso a sensibilidade e especificidade, o que é apropriado quando não se fixou previamente o custo relativo de um falso negativo e de um falso positivo.

O limiar é um parâmetro ajustado aos dados e, como tal, deve ser escolhido sem acesso ao conjunto de teste. Escolhê-lo sobre os mesmos pacientes em que as métricas são reportadas produziria estimativas otimistas de sensibilidade e especificidade. Por isso, δ^* é determinado no conjunto de validação interna de cada partição e aplicado, sem alteração, ao conjunto de teste correspondente.

3.7.5 Agregação por paciente

Pseudorreplicação é o erro de tratar como réplicas independentes medidas repetidas de uma mesma unidade experimental (HURLBERT, 1984). A unidade, aqui, é o paciente: é a ele que pertence o desfecho, e as janelas ou segmentos extraídos de um mesmo Holter são medidas repetidas da mesma pessoa, que compartilham o mesmo rótulo e são fortemente correlacionadas entre si. Um registro de 24 horas fornece centenas de segmentos; tratá-los como observações independentes faria os 517 pacientes valerem como centenas de milhares de observações. O tamanho amostral efetivo seria superestimado, os intervalos de confiança ficariam estreitos demais e os valores-p, pequenos demais, de modo que diferenças mínimas entre casos e controles pareceriam estatisticamente significativas. A subseção 5.2.2 quantifica esse efeito sobre os marcadores deste trabalho.

As redes neurais deste trabalho não recebem o Holter inteiro, mas janelas extraídas dele, e produzem uma probabilidade para cada janela. O rótulo, por outro lado, pertence ao paciente. Calcular as métricas de desempenho sobre janelas incorreria na mesma pseudorreplicação, além de permitir que um paciente com muitas janelas pesasse mais que os demais.

Por esse motivo, toda métrica é calculada no nível do paciente. A probabilidade do paciente i é a média das probabilidades de suas M_i janelas:

$$\hat{p}_i = \frac{1}{M_i} \sum_{m=1}^{M_i} \hat{p}_{i,m}, \tag{3.24}$$

em que $\hat{p}_{i,m}$ é a probabilidade estimada para a m-ésima janela. A média reflete o risco típico ao longo do registro e é menos sensível a janelas isoladas com artefato do que alternativas como o máximo.

3.7.6 Validação cruzada estratificada por paciente

Com 517 pacientes e 55 eventos, separar um único conjunto de teste deixaria cerca de uma dezena de casos para a avaliação, e o resultado dependeria fortemente de quais pacientes fossem sorteados. A validação cruzada em K partições reduz essa dependência: os pacientes são divididos em K grupos disjuntos, e cada grupo é usado uma vez como teste enquanto os demais formam o treinamento (KOHAVI, 1995). Ao final, cada paciente recebe exatamente uma predição feita por um modelo que não o viu durante o treinamento — a predição *fora da partição*.

Dois cuidados são essenciais nesse procedimento. O primeiro é a *estratificação*: as partições são formadas de modo que a proporção de eventos seja aproximadamente a mesma em todas, o que evita partições com pouquíssimos casos. O segundo é a *separação por paciente*: todas as janelas de um mesmo exame pertencem à mesma partição. Se janelas de um paciente estivessem simultaneamente no treinamento e no teste, o modelo poderia reconhecer o indivíduo, e não o padrão associado ao desfecho, inflando as métricas. Esse tipo de vazamento de informação está entre os erros mais frequentes em estudos de aprendizado de máquina aplicado (KAPOOR; NARAYANAN, 2023).

Pelo mesmo princípio, todo procedimento que aprende a partir dos dados — imputação de valores ausentes, padronização, cálculo da escala do sinal, redução de dimensionalidade e escolha do limiar — é ajustado apenas com os pacientes de treinamento de cada partição e então aplicado ao teste.

3.7.7 Intervalos de confiança e comparação entre modelos

Uma AUC estimada em 517 pacientes, dos quais 55 positivos, está sujeita a variabilidade amostral considerável, e reportá-la sem intervalo de confiança impediria distinguir um resultado de outro ou do acaso. Os intervalos foram obtidos por *bootstrap* (EFRON; TIBSHIRANI, 1993). O procedimento sorteia, com reposição, N pacientes entre os N da coorte, recalcula a métrica sobre essa reamostra a partir das predições fora da partição e repete o processo B^* vezes. O intervalo de confiança de 95 % é formado pelos percentis 2,5 e 97,5 da distribuição das B^* estimativas. O valor de B^* adotado em cada experimento é informado na metodologia.

O intervalo oferece um critério direto de comparação com o acaso: se ele contém 0,5, o desempenho do classificador não é distinguível de uma ordenação aleatória dos pacientes.

Comparar dois modelos exige um cuidado adicional. Como ambos são avaliados sobre os mesmos pacientes, suas AUC são correlacionadas, e comparar intervalos calculados separadamente seria conservador. Emprega-se, por isso, o *bootstrap* pareado: em cada reamostra, calcula-se a diferença

$$\Delta_b = \mathrm{AUC}_b^{(1)} - \mathrm{AUC}_b^{(2)}, \qquad b = 1, \ldots, B^*, \tag{3.25}$$

sobre o mesmo conjunto de pacientes sorteados, e o intervalo de confiança da diferença é obtido pelos percentis da distribuição de Δ_b. O modelo 1 é considerado superior ao modelo 2 apenas se esse intervalo não contiver zero.

4 METODOLOGIA

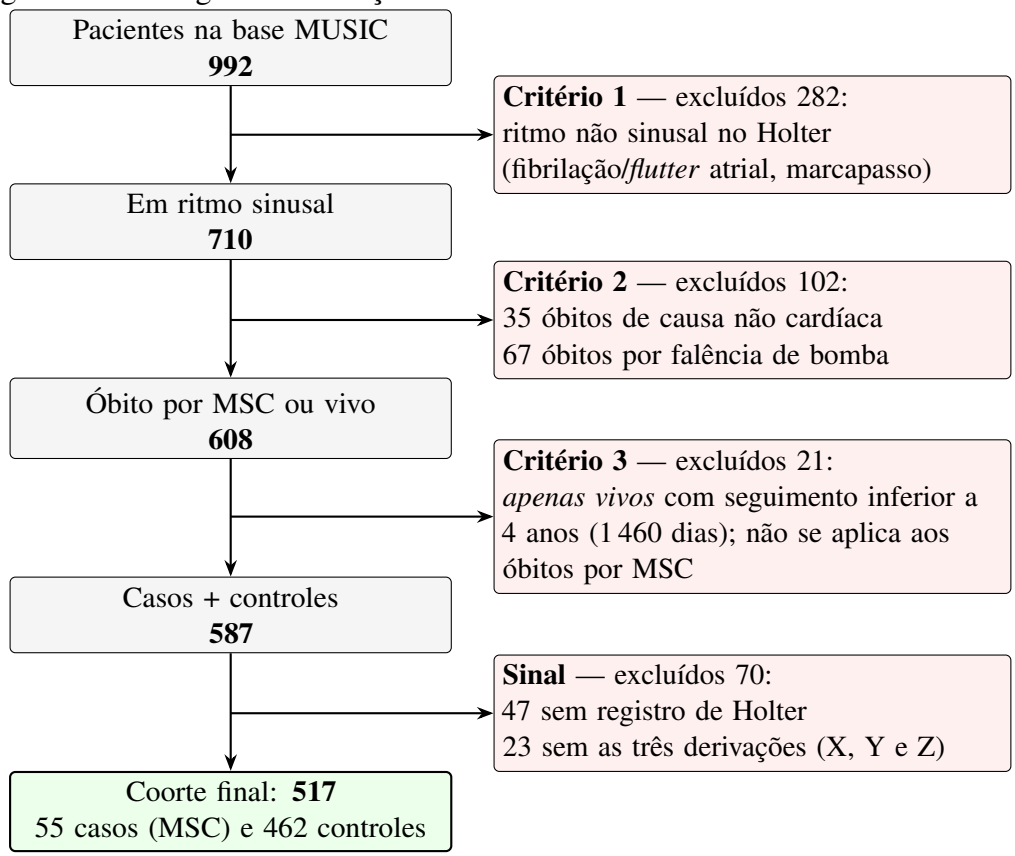
4.1 População de estudo

4.1.1 Base de dados

Os dados deste trabalho provêm da base MUSIC, disponibilizada publicamente no PhysioNet (MARTIN-YEBRA *et al.*, 2025; MARTÍN-YEBRA *et al.*, 2024). A base reúne 992 pacientes com insuficiência cardíaca crônica sintomática (classes II e III da *New York Heart Association*), recrutados entre abril de 2003 e dezembro de 2004 em oito hospitais universitários da Espanha e acompanhados por uma mediana de 44 meses. Para 936 deles há um registro de Holter de 24 horas, com três derivações ortogonais (X, Y e Z) amostradas a 200 Hz, e as causas de óbito foram adjudicadas segundo definições explícitas, que separam a MSC do óbito por falência de bomba. Além do Holter, a base fornece, para cada paciente, variáveis clínicas e resultados de exames realizados na entrada do estudo, descritos na subseção 4.1.3.

Três características tornam a MUSIC adequada ao problema estudado. Primeiro, trata-se de uma população em que a MSC é um desfecho frequente e clinicamente relevante, e não de uma amostra da população geral, na qual o evento seria raro demais para o aprendizado. Segundo, o Holter de 24 horas oferece uma observação longa do ECG, que capta variações ao longo do dia inacessíveis a um traçado de repouso de poucos segundos. Terceiro, a adjudicação do mecanismo de óbito permite isolar a morte de origem elétrica, que é o objeto deste trabalho.

Figura 2 – Fluxograma de seleção da coorte



Fonte: elaborado pelo autor (2026).

4.1.2 Definição da população e critérios de seleção

O problema foi formulado como uma classificação binária no nível do paciente: a partir do Holter, distinguir quem veio a óbito por MSC de quem sobreviveu ao período de acompanhamento de quatro anos. Essa formulação exige que o rótulo de cada paciente seja inequívoco, e os critérios de seleção decorrem dessa exigência. A partir dos 992 pacientes da base, a população foi definida pelos três critérios a seguir, resumidos na Figura 2 e na Tabela 4.

Critério 1: ritmo sinusal durante o Holter. Foram excluídos os pacientes cujo registro foi anotado com ritmo diferente do sinusal (282 pacientes, com fibrilação atrial permanente, *flutter* atrial ou ritmo de marcapasso). Na fibrilação atrial não há onda P organizada e os intervalos entre batimentos são irregulares por definição, de modo que as medidas de variabilidade da frequência cardíaca e de morfologia perdem o significado fisiológico que têm em ritmo sinusal; o ritmo de marcapasso, por sua vez, não reflete a atividade elétrica espontânea do coração. Além disso, o próprio ritmo está associado ao risco: incluí-lo permitiria que um modelo aprendesse a reconhecer a arritmia atrial, e não marcadores de vulnerabilidade elétrica ventricular.

Critério 2: classe 0 (sobreviventes) e classe 3 (morte súbita cardíaca). Foram mantidos apenas os pacientes vivos ao fim do acompanhamento (classe 0 da variável de causa de óbito), que formam o grupo de controles, e os pacientes com óbito adjudicado como MSC (classe 3), que formam o grupo de casos. Foram excluídos os óbitos por falência de bomba (67 pacientes), cujo mecanismo é mecânico e progressivo, e os óbitos de causa não cardíaca (35 pacientes). Incluir a falência de bomba entre os casos ensinaria o modelo a reconhecer a gravidade da insuficiência cardíaca em geral, e não o risco específico de morte súbita; incluí-la entre os controles colocaria do lado "sem evento" pacientes que também morreram de causa cardíaca.

Critério 3: exclusão dos sobreviventes que deixaram o acompanhamento antes de quatro anos. Foram excluídos os pacientes da classe 0 com seguimento inferior a 1 460 dias (21 pacientes). Um sobrevivente observado por menos de quatro anos pode ter sofrido o evento depois de deixar o estudo, e rotulá-lo como controle introduziria erro no rótulo. O critério não se aplica aos casos, cujo desfecho já foi observado.

Por fim, exigiu-se a presença das três derivações no registro de Holter: foram excluídos 47 pacientes sem registro disponível e 23 cujo registro não continha a derivação Z. A população final compreendeu 517 pacientes, dos quais 55 casos de MSC e 462 controles, com prevalência de 10,6 %.

Tabela 4 – Fluxo de seleção da base MUSIC e disponibilidade dos registros de Holter.

Etapa	**N**
Registros de Holter na base (total)	936
Pacientes na base MUSIC	992
Excluídos: ritmo não sinusal	282
Em ritmo sinusal	710
Excluídos por desfecho ambíguo	123
Morte não cardíaca (código 1)	35
Falência de bomba (códigos 6 e 7)	67
Vivos com seguimento inferior a 4 anos	21
Casos + controles	587
Sem registro de Holter	47
Registro sem derivação Z	23
Analisados	517
Casos (MSC; prevalência de 10,6%)	55
Controles	462

Os critérios têm um custo. A restrição ao ritmo sinusal e a exclusão dos desfechos ambíguos reduzem a população a pouco mais da metade da base, e os resultados se aplicam a

pacientes com insuficiência cardíaca em ritmo sinusal, sem poderem ser estendidos, sem nova avaliação, a pacientes com fibrilação atrial. Optou-se por essa troca porque um rótulo confiável e um sinal de entrada homogêneo são pré-requisitos para que um resultado, positivo ou negativo, possa ser interpretado.

4.1.3 Variáveis clínicas e exames

Nos experimentos que combinam o sinal a variáveis clínicas, foram empregadas seis, de três tipos: a idade, variável numérica de valor inteiro, em anos; a classe funcional NYHA, variável categórica ordinal; e quatro variáveis binárias, codificadas como 0 (ausente) ou 1 (presente) — gênero (1 = masculino), presença de ondas Q de necrose no ECG de repouso, taquicardia ventricular não sustentada (TVNS) e taquiarritmia supraventricular paroxística. A idade e a classe NYHA foram padronizadas pela média e pelo desvio-padrão do conjunto de treinamento de cada partição.

Duas particularidades da coorte merecem registro. A classe funcional NYHA assume apenas os valores II e III, comportando-se, na prática, como variável binária. A variável de taquiarritmia supraventricular paroxística é originalmente categórica nominal, com códigos para taquicardia supraventricular, fibrilação atrial paroxística, *flutter* e outras; o código de ausência por fibrilação atrial crônica deixa de ocorrer após a restrição ao ritmo sinusal, e a variável foi tratada como indicadora da presença de qualquer episódio.

Além dessas seis variáveis, a base fornece os resultados de exames realizados na entrada do estudo, empregados no Cenário III (seção 4.7) e agrupados por origem: o ecocardiograma e a radiografia de tórax (fração de ejeção do ventrículo esquerdo (FEVE), tamanho do átrio esquerdo, diâmetros diastólico e sistólico do ventrículo esquerdo, espessuras do septo e da parede posterior, diâmetro e contratilidade do ventrículo direito e índice cardiotorácico), todos numéricos de valor real, exceto a contratilidade do ventrículo direito, binária; o laudo do ECG de repouso (intervalos PR e QT, QT corrigido e duração do QRS, numéricos, e QRS acima de 120 ms, hipertrofia ventricular esquerda e distúrbio de condução intraventricular, binários); as medidas do Holter tabuladas pela equipe do estudo (intervalos RR mínimo e máximo e sua amplitude, número de extrassístoles ventriculares e supraventriculares em 24 horas, dupletes, SDNN, SDANN, RMSSD e pNN50, numéricos); e o exame laboratorial do Pro-BNP, numérico. As contagens de extrassístoles e o Pro-BNP, de distribuição muito assimétrica, foram transformados por $\log(1+x)$.

4.2 Pré-processamento do sinal

Cada registro de Holter contém três derivações, X, Y e Z, amostradas a 200 Hz ao longo de cerca de 24 horas. A Figura 3 mostra, como exemplo, um trecho de 10 segundos de um paciente controle da coorte, sorteado aleatoriamente, após a filtragem descrita na subseção 4.2.2. As três derivações registram os mesmos batimentos sob ângulos diferentes, o que se reflete na amplitude e na forma distintas dos complexos QRS e das ondas T em cada uma.

Figura 3 – Trecho de 10 segundos do Holter de um paciente controle da coorte, nas derivações X, Y e Z, após o filtro passa-faixa de 0,5 a 40 Hz



Fonte: elaborado pelo autor (2026), a partir da base MUSIC. Grade no padrão do papel de ECG: 0,2 s e 0,5 mV nas linhas fortes.

4.2.1 Extração de janelas

Cada registro foi representado por janelas de 24 000 amostras, equivalentes a dois minutos a 200 Hz. Os cinco minutos iniciais e finais de cada registro foram descartados, por concentrarem artefatos de calibração do equipamento, de acomodação do paciente e de retirada dos eletrodos.

As posições das janelas foram definidas de modo distinto no treinamento e na avaliação. Nas redes residuais e com concatenação, cada uma das 250 janelas de treinamento por paciente teve sua posição sorteada a cada época, de forma independente, ao longo do trecho

útil do registro. O procedimento expõe o modelo a recortes diferentes a cada passagem pelos dados e admite sobreposição entre janelas. Na avaliação, as 100 janelas por paciente foram posicionadas em grade regular, igualmente espaçadas ao longo do registro, o que torna as métricas reprodutíveis. Nas redes convolucionais, implementadas posteriormente, a amostragem foi refinada para 350 janelas de treinamento sem sobreposição e 200 de avaliação, conforme a subseção 4.4.4.

4.2.2 Filtragem

Cada janela foi submetida a filtro passa-faixa de Butterworth de terceira ordem, com frequências de corte de 0,5 e 40 Hz, implementado em seções de segunda ordem e aplicado nos sentidos direto e reverso. A filtragem de fase nula resultante dobra a ordem efetiva do filtro e preserva a morfologia das ondas, conforme discutido na subseção 3.1.2.2.

A frequência de corte inferior remove a oscilação de linha de base e o deslocamento contínuo do sinal, que varia entre pacientes conforme o posicionamento dos eletrodos. A superior atenua o ruído muscular e elimina a interferência da rede elétrica de 50 Hz, situada acima da banda passante. O valor de 0,5 Hz encontra-se dentro do limite admitido pela American Heart Association para filtros digitais de fase nula (KLIGFIELD *et al.*, 2007).

A filtragem foi aplicada a cada janela individualmente, e não ao registro completo. A escolha torna o deslocamento de linha de base removido específico de cada trecho, sem pressupor estabilidade ao longo das 24 horas.

4.2.3 Normalização

Após a filtragem, cada derivação foi dividida por uma constante de escala global, comum a todos os pacientes. A constante corresponde ao percentil 99 do valor absoluto do sinal filtrado, estimado sobre 100 pacientes sorteados do conjunto de treinamento de cada partição, com cinco janelas de 60 s por paciente. As janelas usadas na estimativa passam pelo mesmo filtro aplicado no treinamento, de modo que a escala corresponde à distribuição efetivamente apresentada ao modelo.

A estimativa é refeita a cada partição da validação cruzada, utilizando exclusivamente pacientes do respectivo conjunto de treinamento. Calculá-la uma única vez sobre a coorte completa introduziria informação dos pacientes de teste no pré-processamento.

Os valores normalizados foram limitados ao intervalo $[-5, 5]$. Amostras fora desse

intervalo correspondem a amplitudes superiores a cinco vezes a referência de escala, ocorrência compatível com artefato de movimento e não com atividade cardíaca.

A separação entre filtragem e normalização é deliberada. A filtragem por janela remove o deslocamento individual de cada trecho; a escala global preserva as diferenças de amplitude entre pacientes. A padronização por janela, alternativa descartada, realizaria as duas operações simultaneamente e eliminaria a informação de amplitude absoluta.

4.3 Cenário I: aprendizado profundo sobre o sinal bruto

No primeiro cenário, redes neurais profundas recebem o sinal do Holter, apenas filtrado e normalizado conforme a seção 4.2, e são treinadas diretamente para prever a MSC. Cada rede recebe janelas do sinal, produz uma probabilidade por janela e é avaliada no nível do paciente, após a agregação descrita na subseção 3.7.5. Os fundamentos de cada componente foram apresentados no Capítulo 3; esta seção descreve as arquiteturas construídas e as escolhas de treinamento efetivamente adotadas.

4.3.1 Arquiteturas avaliadas

As arquiteturas foram organizadas em três famílias, avaliadas em ordem crescente de complexidade, e a rede profunda com variáveis clínicas concatenadas, que compartilha o mesmo extrator e é avaliada no Cenário III (seção 4.7). A Tabela 5 resume cada uma delas.

1. **Redes convolucionais sem atalhos.** A rede convolucional descrita na seção 3.3, em três variantes de capacidade — mínima, simples e média — que diferem apenas no número de blocos e de filtros. É a família de menor capacidade e serve de referência para as demais.
2. **Redes residuais.** Adaptações unidimensionais da ResNet (HE *et al.*, 2016), na linha das redes empregadas para a classificação de ECG por Hannun *et al.* (2019) e Ribeiro *et al.* (2020). Foram avaliadas profundidades de 18, 34 e 50 camadas e, para a profundidade de 18 camadas, três larguras, de modo a separar o efeito da profundidade do efeito do número de canais.
3. **Rede residual com atenção.** A ResNet-18 seguida de um codificador *Transformer* (VASWANI *et al.*, 2017), que recebe a sequência de vetores produzida pelo último estágio residual e permite que cada trecho da janela seja relacionado aos demais antes do agrupamento.

Tabela 5 – Arquiteturas de redes neurais avaliadas sobre o sinal de Holter

Família	Variante	Parâmetros	Entrada
Convolucional	mínima (3 blocos)	14 425	2 min e 10 s
	simples (4 blocos)	109 361	2 min e 10 s
	média (4 blocos)	418 145	2 min e 10 s
Residual	ResNet-18 mínima	78 169	5,12 s
	ResNet-18 reduzida	1 029 985	2 min
	ResNet-18	3 976 385	2 min e 5,12 s
	ResNet-34	7 350 721	2 min
	ResNet-50	16 479 937	2 min
Atenção	ResNet-18 + *Transformer*	1 491 553	2 min
Concatenação	ResNet-18 + variáveis clínicas	3 987 041	2 min + 6 variáveis

Fonte: elaborado pelo autor (2026).

Todas as variantes compartilham o mesmo classificador final — agrupamento global por média e máximo, seguido de duas camadas totalmente conectadas com descarte — e a mesma saída: um único *logit* por janela, convertido em probabilidade pela Equação 3.10. A diferença entre elas está apenas no extrator de características, o que permite atribuir as diferenças de desempenho à arquitetura.

4.3.2 Arquitetura da rede convolucional

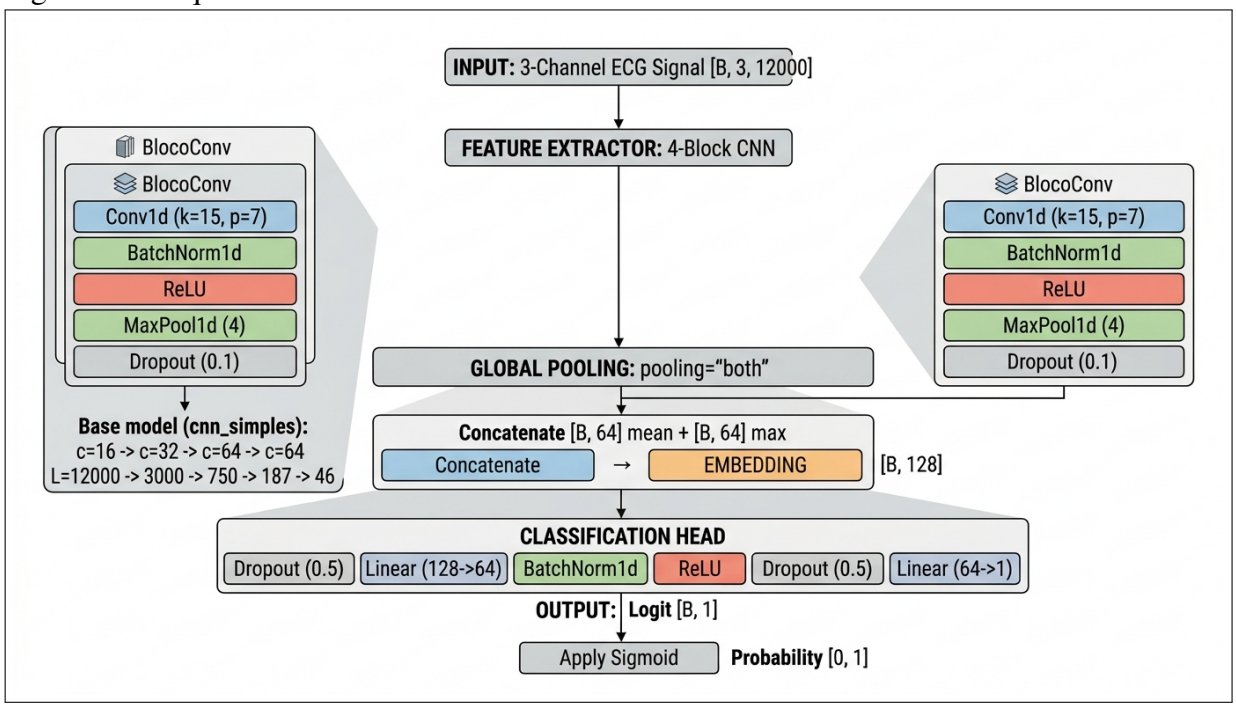
A rede convolucional adotada neste trabalho é composta por blocos sequenciais, seguidos de agrupamento global e de um classificador de duas camadas. Cada bloco aplica, nesta ordem, convolução, normalização em lote, ativação *ReLU*, agrupamento máximo com fator quatro e descarte com probabilidade 0,1. A Figura 4 ilustra o fluxo.

4.3.2.1 Variantes de capacidade

Para avaliar se o desempenho depende da capacidade do modelo, a mesma estrutura foi instanciada em três tamanhos, que diferem apenas no número de blocos e de filtros por bloco. A variante *mínima* tem três blocos, com 8, 16 e 32 filtros; a *simples*, quatro blocos, com 16, 32, 64 e 64 filtros; a *média*, quatro blocos, com 32, 64, 128 e 128 filtros. Todos os demais elementos — largura do núcleo, agrupamento, descarte, classificador e inicialização — são idênticos. Entre a menor e a maior variante, o número de parâmetros cresce cerca de 29 vezes. Se o desempenho não acompanhar esse crescimento, a limitação não está na capacidade da rede, mas na informação disponível nos dados.

A Tabela 6 detalha os canais de cada variante e o comprimento das representa-

Figura 4 – Arquitetura da rede convolucional unidimensional



Fonte: elaborado pelo autor (2026).

ções intermediárias para as duas durações de janela avaliadas: 2 minutos (24 000 amostras) e 10 segundos (2 000 amostras).

Tabela 6 – Canais e comprimento das representações intermediárias das variantes da rede convolucional

	Canais			Comprimento		
Etapa	Mínima	Simples	Média	2 min	10 s	Campo receptivo
Entrada	3	3	3	24 000	2 000	5 ms
Bloco 1	8	16	32	6 000	500	90 ms
Bloco 2	16	32	64	1 500	125	430 ms
Bloco 3	32	64	128	375	31	1,8 s
Bloco 4	—	64	128	93	7	7,2 s
Agrupamento global	64	128	256	—	—	janela inteira

Fonte: elaborado pelo autor (2026).

A coluna de campo receptivo indica a extensão do sinal original que influencia cada posição de saída e não depende da duração da janela. Ao final do primeiro bloco, cada posição reflete 90 ms de registro — aproximadamente a duração de um complexo QRS —; ao final do quarto, 7,2 s, o equivalente a oito a nove ciclos cardíacos a 70 bpm. A rede, portanto, combina progressivamente padrões morfológicos de batimentos isolados em padrões que abrangem sequências de batimentos.

A duração da janela altera o que esses padrões representam no conjunto. Na janela

de 2 minutos, o quarto bloco ainda produz 93 posições, cada uma resumindo alguns segundos, e o agrupamento global combina dezenas de trechos distintos. Na janela de 10 segundos, restam 7 posições cujo campo receptivo já cobre a maior parte da janela, de modo que a rede analisa essencialmente um único trecho de poucos batimentos. Na variante mínima, que não possui o quarto bloco, o campo receptivo final é de 1,8 s, cerca de dois ciclos cardíacos.

4.3.2.2 Largura do núcleo

O núcleo convolucional foi dimensionado em $\kappa = 15$ amostras, equivalentes a 75 ms na frequência de 200 Hz. A escolha difere da convenção predominante em arquiteturas originadas no processamento de imagens, em que núcleos de três elementos são usuais e corresponderiam, neste contexto, a apenas 15 ms. Com núcleo de 75 ms, um único filtro da primeira camada abrange parcela substancial de um complexo QRS, cuja duração normal situa-se entre 80 e 100 ms, podendo representar diretamente padrões de despolarização ventricular.

4.3.2.3 Agrupamento combinado

Ao término do último bloco, os canais são reduzidos a um vetor com o dobro da sua dimensão pela concatenação dos agrupamentos globais por média e máximo, conforme a Equação 3.9: 64, 128 e 256 dimensões nas variantes mínima, simples e média. As duas operações capturam aspectos complementares: a média reflete o comportamento típico da janela, enquanto o máximo registra o instante de maior ativação de cada filtro. A combinação permite que a rede seja sensível tanto a alterações persistentes quanto a eventos breves, como extrassístoles isoladas, que a média isoladamente diluiria.

4.3.2.4 Ausência de conexões residuais

A arquitetura não emprega as conexões residuais descritas na seção 3.4. Essas conexões foram concebidas para viabilizar o treinamento de redes com dezenas de camadas, nas quais o gradiente tenderia a se atenuar ao percorrer a sequência de transformações. Com três ou quatro blocos convolucionais, o gradiente alcança as camadas iniciais sem atenuação significativa, e os atalhos acrescentariam parâmetros sem benefício correspondente.

4.3.2.5 Classificador e número de parâmetros

O vetor resultante do agrupamento alimenta um classificador composto por duas camadas totalmente conectadas — a primeira com 64 unidades, normalização em lote e ativação *ReLU*, a segunda com uma unidade de saída —, ambas precedidas por descarte com probabilidade 0,6. Os pesos das camadas convolucionais são inicializados conforme He *et al.* (2015), esquema adequado a redes com ativação *ReLU*.

A Tabela 7 decompõe os parâmetros treináveis de cada variante. Como as camadas convolucionais não dependem do comprimento do sinal, os valores são os mesmos para as duas durações de janela.

Tabela 7 – Distribuição dos parâmetros das variantes da rede convolucional

Componente	Mínima	Simples	Média
Bloco 1	360	720	1 440
Bloco 2	1 920	7 680	30 720
Bloco 3	7 680	30 720	122 880
Bloco 4	—	61 440	245 760
Normalização dos blocos	112	352	704
Classificador	4 353	8 449	16 641
Total	14 425	109 361	418 145
Por paciente de treino	47	354	1 353

Fonte: elaborado pelo autor (2026).

Cada bloco convolucional tem $C \cdot C' \cdot \kappa$ pesos, sem termo de viés, pois a normalização em lote seguinte o tornaria redundante. A última linha divide o total pelos 309 pacientes do conjunto de treinamento de cada partição. Mesmo a variante média tem cerca de dez vezes menos parâmetros por paciente que a ResNet-18 descrita na seção 3.4, que tem 3 976 385 parâmetros, ou 12 869 por paciente de treinamento.

4.3.3 Arquitetura das redes residuais

A arquitetura empregada adapta ao domínio unidimensional a estrutura proposta por He *et al.* (2016), seguindo a prática estabelecida em trabalhos de classificação de ECG com redes residuais (HANNUN *et al.*, 2019; RIBEIRO *et al.*, 2020). Uma etapa inicial precede quatro estágios de blocos residuais:

- **Etapa inicial:** convolução com núcleo 7 e passo 2, seguida de normalização em lote, *ReLU* e agrupamento máximo com núcleo 3 e passo 2. O comprimento é reduzido por quatro antes do primeiro bloco.

- **Estágios 1 a 4:** sequências de blocos residuais com P, $2P$, $4P$ e $8P$ canais internos, em que P denota a largura inicial. O primeiro bloco dos estágios 2 a 4 emprega passo 2, dividindo o comprimento pela metade e exigindo projeção no atalho.
- **Agrupamento global e classificador:** idênticos aos da subseção 4.3.2, com o vetor resultante de dimensão $2 \times 8 \cdot P \cdot E$ ao combinar média e máximo.

A cada estágio, portanto, o comprimento temporal é dividido por dois e a profundidade da representação, multiplicada por dois — progressão distinta da adotada na rede convolucional da seção 3.3, que divide o comprimento por quatro a cada bloco.

4.3.3.1 Configurações avaliadas

Três parâmetros definem cada configuração: o tipo de bloco, o número de blocos por estágio e a largura inicial P. A Tabela 8 reúne as quatro variantes avaliadas, que percorrem uma faixa de dezesseis vezes em número de parâmetros.

Tabela 8 – Configurações das redes residuais avaliadas

Configuração	Bloco	Blocos por estágio	P	Saída	Parâmetros
ResNet-18 reduzida	básico	2–2–2–2	32	256	1 029 985
ResNet-18 completa	básico	2–2–2–2	64	512	3 976 385
ResNet-34	básico	3–4–6–3	64	512	7 350 721
ResNet-50	gargalo	3–4–6–3	64	2 048	16 479 937

Fonte: elaborado pelo autor (2026).

As configurações permitem examinar separadamente duas dimensões da capacidade. A comparação entre as duas variantes da ResNet-18 isola o efeito da *largura*: mesma profundidade, o dobro de canais. A comparação entre a ResNet-18 completa e a ResNet-34 isola o efeito da *profundidade*: mesma largura, o dobro de blocos. A ResNet-50 combina a profundidade da ResNet-34 com o bloco de gargalo e saída quatro vezes mais larga.

Os números de parâmetros são inferiores aos das versões bidimensionais homônimas, nas quais a ResNet-18 possui cerca de 11 milhões, porque o núcleo unidimensional de largura três contém três pesos por par de canais, contra nove do núcleo 3×3.

4.3.3.2 Dimensões e campo receptivo

A Tabela 9 apresenta as dimensões das representações intermediárias para a janela de 24 000 amostras e o campo receptivo ao término de cada etapa.

Tabela 9 – Dimensões e campo receptivo das redes residuais para janela de 24 000 amostras

		Canais		Campo receptivo	
Etapa	Comprimento	18 e 34	50	ResNet-18	ResNet-34
Entrada	24 000	3	3	5 ms	5 ms
Etapa inicial	6 000	64	64	55 ms	55 ms
Estágio 1	6 000	64	256	215 ms	295 ms
Estágio 2	3 000	128	512	495 ms	895 ms
Estágio 3	1 500	256	1 024	1,1 s	2,7 s
Estágio 4	750	512	2 048	2,2 s	4,5 s

Fonte: elaborado pelo autor (2026).

O campo receptivo ao final da ResNet-18 é de 2,2 s — inferior aos 7,2 s da rede convolucional rasa, apesar de esta possuir apenas quatro camadas convolucionais contra dezessete. A diferença decorre do núcleo: com três amostras (15 ms), cada convolução residual amplia pouco a extensão observada, e a cobertura temporal depende do empilhamento de muitas camadas. A ResNet-34, com o dobro de blocos, alcança 4,5 s. A ResNet-50 apresenta campo receptivo semelhante ao da ResNet-18, pois apenas uma das três convoluções de cada bloco de gargalo considera vizinhança temporal.

Ainda que inferior à duração da janela, esse campo receptivo não limita a informação disponível ao classificador: o agrupamento global da Equação 3.9 combina as 750 posições do último estágio, abrangendo os dois minutos integralmente.

4.3.3.3 Distribuição dos parâmetros

Os parâmetros concentram-se nos estágios finais, em que o número de canais é maior. Na ResNet-18 completa, o quarto estágio, com 512 canais, responde por aproximadamente três quartos do total. Na ResNet-50, o classificador recebe vetor de 4 096 dimensões — 2 048 de cada agrupamento —, e sua primeira camada sozinha possui cerca de 525 000 parâmetros.

Os pesos das camadas convolucionais são inicializados conforme He *et al.* (2015), e os parâmetros de escala e deslocamento da normalização em lote, com um e zero, respectivamente, de modo que cada bloco inicie próximo da identidade.

4.3.4 Regime de dados das redes residuais

As redes residuais foram concebidas para conjuntos de treinamento de grande porte. A ResNet original foi avaliada sobre 1,28 milhão de imagens (HE *et al.*, 2016); no domínio do ECG, os trabalhos que estabeleceram seu desempenho empregaram dezenas de milhares a

milhões de registros (HANNUN *et al.*, 2019; RIBEIRO *et al.*, 2020).

Neste trabalho, cada partição dispõe de 309 pacientes no treinamento, dos quais 33 casos. A razão entre parâmetros e pacientes varia de 3 333 na ResNet-18 reduzida a cerca de 53 000 na ResNet-50. Nesse regime, a capacidade da rede é amplamente suficiente para ajustar individualmente cada exemplo de treinamento, o que motiva a comparação sistemática entre configurações de capacidade crescente apresentada no Capítulo 5: se a capacidade fosse o fator limitante, o desempenho deveria variar com ela.

4.3.5 Arquitetura da rede residual com atenção

A arquitetura avaliada mantém integralmente o corpo da ResNet-18 reduzida (Tabela 8), que produz sequência de 750 posições com 256 canais, e insere entre ele e o agrupamento global uma camada codificadora com os parâmetros da Tabela 10.

Tabela 10 – Configuração da camada de atenção

Parâmetro	Valor
Comprimento da sequência (L)	750 posições
Dimensão do modelo (d)	256
Número de cabeças (h)	4
Dimensão por cabeça (d_k)	64
Dimensão da rede interna (d_{ff})	512
Número de camadas	1
Descarte	0,3

Fonte: elaborado pelo autor (2026).

A saída do codificador, com as mesmas dimensões da entrada, passa pelo agrupamento global combinado de média e máximo, resultando em vetor de 512 dimensões. Diferentemente das demais redes, o classificador consiste em uma única camada linear precedida de descarte, sem camada intermediária: a capacidade adicional introduzida pela atenção dispensa a não linearidade extra no classificador.

A Tabela 11 decompõe os parâmetros.

A camada de atenção acrescenta 527 104 parâmetros, cerca de metade do corpo convolucional e 35 % do total.

4.3.5.1 Ausência de codificação posicional

A operação da Equação 3.16 é invariante à ordem das posições: se a sequência de entrada for permutada, a saída é permutada da mesma forma. Em aplicações nas quais a ordem é

Tabela 11 – Distribuição dos parâmetros da ResNet-18 reduzida com camada de atenção

Componente	Parâmetros	Fração
Corpo residual	963 936	64,6 %
Atenção com múltiplas cabeças	263 168	17,6 %
Rede interna (FFN)	262 912	17,6 %
Normalização de camada	1 024	0,1 %
Classificador	513	$<$ 0,1 %
Total	1 491 553	100,0 %

Fonte: elaborado pelo autor (2026).

essencial, como a linguagem, acrescenta-se à entrada uma *codificação posicional* que identifica cada posição (VASWANI *et al.*, 2017).

A arquitetura empregada não utiliza codificação posicional. Duas razões sustentam a escolha. A primeira é que as representações produzidas pelo corpo convolucional já carregam informação local de ordem, pois cada posição resume um trecho contíguo do sinal. A segunda é que a saída do codificador é submetida ao agrupamento global, operação também invariante à ordem: a posição absoluta de um padrão dentro da janela de dois minutos não altera a representação final. O que a atenção acrescenta, nesse arranjo, é a possibilidade de cada posição ser representada em função do conteúdo das demais, e não a modelagem da ordem temporal propriamente dita.

4.3.6 Regime de dados da rede com atenção

As arquiteturas baseadas em atenção apresentam menos vieses indutivos que as convolucionais. Uma convolução pressupõe, por construção, que padrões relevantes são locais e podem ocorrer em qualquer posição; a atenção não pressupõe localidade e precisa aprender, a partir dos dados, quais relações são relevantes. Dosovitskiy *et al.* (2021) mostraram que essa flexibilidade só se converte em vantagem quando o conjunto de treinamento é suficientemente grande: em conjuntos de pequeno porte, modelos baseados em atenção apresentaram desempenho inferior ao de redes convolucionais de capacidade semelhante.

A arquitetura híbrida aqui empregada atenua esse problema ao preservar o corpo convolucional e restringir a atenção a uma única camada sobre representações já comprimidas. Ainda assim, com 33 casos positivos por partição de treinamento, a estimativa dos 527 104 parâmetros adicionais encontra-se no regime em que a literatura reporta menor eficácia do mecanismo.

4.4 Cenário I: treinamento e avaliação das redes

As arquiteturas avaliadas nas seções seguintes compartilham o mesmo protocolo de preparação dos dados, treinamento e avaliação. Essa uniformidade é condição para que a comparação entre elas isole o efeito da arquitetura, e não o de escolhas acessórias de configuração. Os valores adotados foram fixados a partir das primeiras execuções e mantidos ao longo dos experimentos; são apresentados a seguir, acompanhados da justificativa correspondente. Duas configurações foram empregadas: a das redes residuais, de atenção e com concatenação, e a das redes convolucionais, que estendeu o número de épocas e de janelas. As diferenças entre elas são indicadas nas tabelas.

4.4.1 Representação do sinal

Cada paciente é representado por janelas extraídas de seu registro de 24 horas, e não pelo registro integral. A opção decorre de uma limitação prática: a 200 Hz, três derivações durante 24 horas correspondem a aproximadamente 17 milhões de amostras por paciente, volume incompatível com o processamento em lote na memória disponível.

A Tabela 12 reúne os parâmetros de representação.

Tabela 12 – Parâmetros de representação do sinal

Parâmetro	Valor	Justificativa
Comprimento da janela	24 000 amostras	2 min, cerca de 140 ciclos cardíacos
Janelas por paciente (treino)	250 / 350	posições sorteadas a cada época
Janelas por paciente (avaliação)	100 / 200	posições em grade fixa
Margem descartada	5 min	calibração do equipamento
Filtro passa-banda	0,5–40 Hz	remove deriva e ruído muscular
Normalização	percentil 99 por derivação	preserva amplitude relativa
Limitação de amplitude	$[-5, 5]$	atenua artefatos de movimento

Fonte: elaborado pelo autor (2026). Nota: quando há dois valores, o primeiro refere-se às redes residuais, de atenção e com concatenação, e o segundo, às redes convolucionais.

A janela de dois minutos abrange aproximadamente 140 ciclos cardíacos a uma frequência de 70 bpm, quantidade suficiente para que a morfologia se repita e para que a variabilidade entre batimentos seja observável. Janelas mais curtas podem recair sobre trechos sem conteúdo relevante; janelas mais longas elevam o consumo de memória e reduzem o número de amostras disponíveis por paciente.

No treinamento, as posições das janelas são sorteadas a cada época, funcionando como forma de aumento de dados: o modelo nunca observa exatamente o mesmo recorte duas

vezes. Na avaliação, as posições seguem grade regular determinística, assegurando reprodutibilidade das métricas.

A separação entre filtragem e normalização é deliberada. O filtro passa-banda remove o deslocamento de linha de base de cada janela individualmente — deslocamento que varia entre pacientes conforme o posicionamento dos eletrodos. A escala, por sua vez, é estimada uma única vez sobre o conjunto de treinamento de cada partição, de modo idêntico para todos os pacientes, o que preserva as diferenças de amplitude entre indivíduos — informação associada a condições como baixa voltagem e hipertrofia ventricular. A padronização por janela, alternativa descartada, executaria as duas operações simultaneamente e eliminaria essa informação.

4.4.2 Treinamento

A Tabela 13 apresenta os hiperparâmetros de otimização, comuns a todas as arquiteturas, salvo o número de épocas e a paciência.

Tabela 13 – Hiperparâmetros de treinamento

Parâmetro	Valor	Justificativa
Otimizador	AdamW	desacopla regularização do gradiente
Taxa de aprendizado	$1{,}0 \times 10^{-4}$	valores maiores causaram instabilidade
Regularização (λ)	$1{,}0 \times 10^{-2}$	limite superior usual
Descarte	0,6	compensa a razão parâmetros/eventos
Tamanho do lote	256[1]	
Épocas máximas	20 / 30	melhor época ocorreu cedo
Paciência	10 / 15	sobre média móvel de três
Agrupamento	média e máximo	estado típico e instante extremo
Precisão	mista (fp16)	reduz consumo de memória

Fonte: elaborado pelo autor (2026). Nota: em épocas e paciência, o primeiro valor refere-se às redes residuais, de atenção e com concatenação, e o segundo, às redes convolucionais.

Os valores de regularização e descarte situam-se no extremo superior das faixas habituais. A escolha decorre da razão entre o número de parâmetros e o de eventos disponíveis: mesmo a arquitetura mais enxuta avaliada dispõe de 14 425 parâmetros para 33 casos positivos no conjunto de treinamento de cada partição, e as redes residuais, de milhões. Nas primeiras execuções, valores menores de regularização produziram perdas de treinamento próximas de zero já na terceira época.

O limite de 20 ou 30 épocas acompanha a observação, recorrente em todas as arquiteturas, de que o melhor valor de AUC sobre o conjunto de validação ocorre nas primeiras épocas.

[1] Reduzido para 128 na ResNet-50 por limitação de memória da unidade de processamento gráfico.

O critério de parada emprega média móvel de três épocas em lugar do valor pontual: com apenas 11 eventos no conjunto de validação, a métrica de uma única época oscila substancialmente sem que o modelo tenha se alterado de forma apreciável, e a suavização evita que se selecione o pico do ruído.

4.4.3 Desbalanceamento entre classes

Com prevalência de 10,6 %, um classificador que atribua a classe majoritária a todos os pacientes alcança acurácia de 89,4 % com sensibilidade nula. Para evitar a convergência a esse ótimo local, a função de perda de entropia cruzada binária foi ponderada pelo fator

$$w_+ = \frac{N_0}{N_1} \approx 8{,}4, \tag{4.1}$$

em que N_0 e N_1 denotam, respectivamente, o número de controles e de casos no conjunto de treinamento de cada partição. O fator multiplica a contribuição dos casos positivos ao gradiente, sendo equivalente a replicar cada evento cerca de 8,4 vezes sem descartar controles.

Técnicas de subamostragem da classe majoritária foram descartadas: o equilíbrio entre classes seria obtido às custas de reduzir a coorte de 517 para 110 pacientes, sem alterar o número de eventos — que constitui o fator efetivamente limitante — e com ampliação dos intervalos de confiança.

4.4.4 Experimentos com a rede convolucional

A rede convolucional descrita na subseção 4.3.2 foi avaliada em um delineamento fatorial com dois fatores: a capacidade do modelo, nas variantes mínima, simples e média, e a duração da janela de entrada, de 2 minutos e de 10 segundos. As seis combinações resultantes, listadas na Tabela 14, foram treinadas sob configuração idêntica, de modo que as diferenças de desempenho possam ser atribuídas apenas a esses dois fatores.

Tabela 14 – Combinações avaliadas da rede convolucional

Variante	Parâmetros	Janela de 2 min	Janela de 10 s
Mínima	14 425	E1	E4
Simples	109 361	E2	E5
Média	418 145	E3	E6

Fonte: elaborado pelo autor (2026).

4.4.4.1 Amostragem das janelas

No treinamento, cada paciente contribui com o mesmo número de janelas por época nas duas durações. Desse modo, as seis configurações recebem o mesmo número de atualizações de gradiente, e o que varia entre as janelas de 2 minutos e de 10 segundos é apenas o conteúdo de cada exemplo. As janelas de um paciente são sorteadas a cada época entre blocos consecutivos e sem sobreposição do registro, descartados os 5 minutos iniciais e finais. A permutação dos blocos é determinada pelo paciente e pela época, o que garante que duas janelas do mesmo paciente nunca se sobreponham dentro de uma época e que épocas sucessivas percorram trechos diferentes do exame.

Na avaliação, as janelas são posicionadas em uma grade fixa e uniforme ao longo do registro, o que torna a predição reprodutível. São avaliadas 200 janelas por paciente nas duas durações, o que corresponde a cerca de 6,7 horas de registro com a janela de 2 minutos e a cerca de 33 minutos com a de 10 segundos.

4.4.4.2 Filtragem com margem

O filtro passa-faixa descrito na seção 4.2 requer alguns segundos de sinal para estabilizar e, quando aplicado a um trecho curto, distorce suas extremidades. Para evitar esse efeito, cada janela é lida com 5 segundos adicionais de cada lado, filtrada e, em seguida, recortada no comprimento nominal. A rede recebe, assim, exatamente 24 000 ou 2 000 amostras livres do transitório de borda, o que é particularmente relevante para a janela de 10 segundos, na qual as margens distorcidas representariam fração apreciável do sinal.

4.4.4.3 Configuração comum

As seis configurações compartilham a validação cruzada em cinco partições estratificadas por paciente, com 25 % do conjunto de treinamento de cada partição reservado para validação interna (309 ou 310 pacientes de treinamento por partição), a função de perda ponderada da Equação 3.11, o otimizador AdamW com taxa de aprendizado de 10^{-4} e decaimento de pesos de 10^{-2}, lotes de 256 janelas e no máximo 30 épocas, com interrupção antecipada após 15 épocas sem melhora. Em cada época, cada paciente contribui com 350 janelas de treinamento. A probabilidade de cada paciente é a média das probabilidades de suas janelas, e o limiar de decisão é escolhido pelo índice de Youden na validação interna, nunca no conjunto de teste.

4.4.5 Protocolo de treinamento e avaliação

Todas as redes foram treinadas e avaliadas pelo mesmo procedimento, resumido na Figura 5 e detalhado a seguir. Os hiperparâmetros constam da Tabela 13.

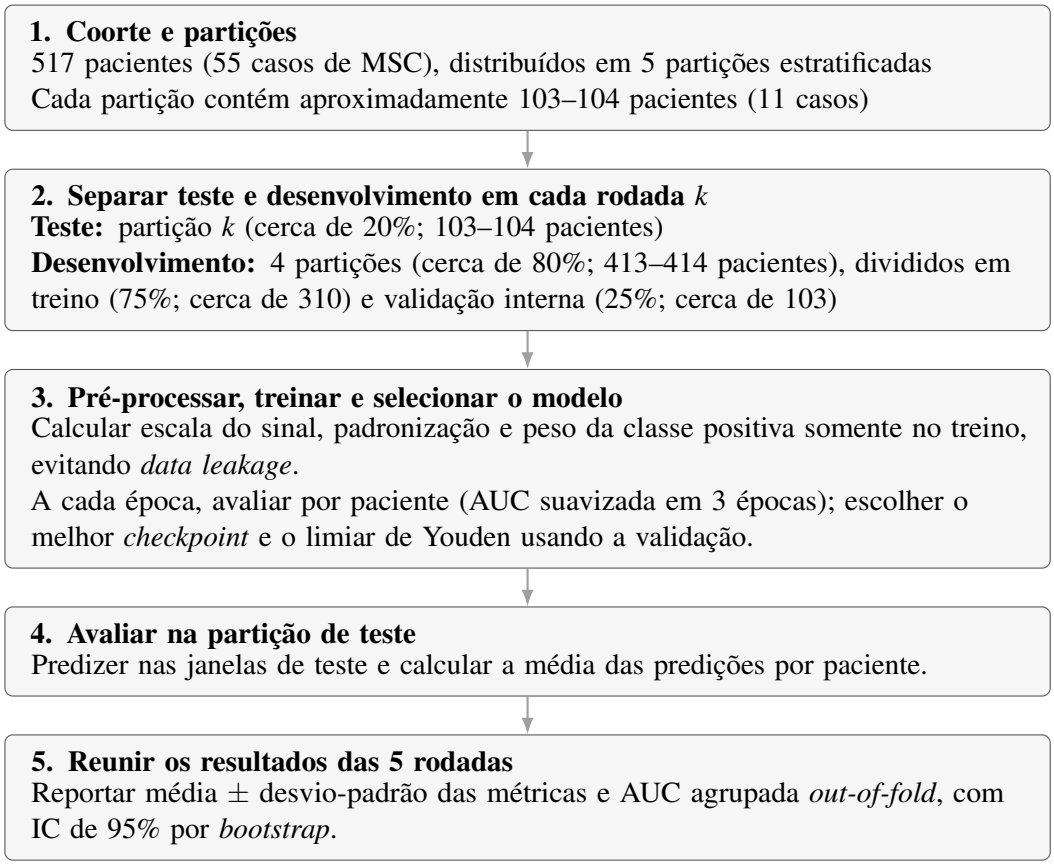


Figura 5 – Fluxo da validação cruzada estratificada em 5 partições. As etapas 2–4 são repetidas para cada partição, com avaliação no nível do paciente.

4.4.5.1 Divisão dos pacientes

Os 517 pacientes foram divididos em cinco partições estratificadas, com 103 ou 104 pacientes e 11 casos cada uma. Em cada rodada, uma partição forma o conjunto de teste e as outras quatro, o conjunto de desenvolvimento. Deste, 25 % dos pacientes, também por sorteio estratificado, formam a validação interna, e os 75 % restantes, o treinamento — 309 ou 310 pacientes, dos quais 33 casos. A validação interna é usada para escolher a época do modelo e o limiar de decisão; o conjunto de teste não participa de nenhuma escolha.

A cada rodada, as estatísticas que dependem dos dados — a escala do sinal por derivação, as médias e desvios das variáveis clínicas e o peso da classe positiva, $w_+ = N_0/N_1 \approx 8{,}4$ — são recalculadas com os pacientes de treinamento daquela rodada.

4.4.5.2 Seleção da época

Ao final de cada época, a rede prediz as janelas da validação interna, as probabilidades são agregadas por paciente, e calcula-se a AUC. Como a validação contém apenas 11 casos, a AUC de uma única época oscila consideravelmente sem que o modelo tenha mudado de forma relevante. Por isso, o critério de seleção é a média móvel da AUC nas três últimas épocas: os pesos são salvos sempre que essa média supera o melhor valor anterior, e o treinamento é interrompido quando ela deixa de melhorar por um número pré-definido de épocas.

A taxa de aprendizado decai ao longo das épocas segundo uma função cosseno (LOSHCHILOV; HUTTER, 2017). Ela parte do valor inicial $\eta_{\max} = 10^{-4}$ e diminui suavemente até próximo de zero na última época prevista:

$$\eta_t = \frac{\eta_{\max}}{2}\left(1 + \cos\frac{\pi t}{T}\right), \tag{4.2}$$

em que η_t é a taxa de aprendizado na época t e T é o número máximo de épocas. O decaimento permite passos maiores no início do treinamento, quando a rede ainda está longe de uma boa solução, e ajustes finos no fim. Com a parada antecipada, o treinamento costuma ser interrompido antes de a taxa chegar a zero.

4.4.5.3 Avaliação no teste

Concluído o treinamento, os pesos da melhor época são restaurados. O limiar de decisão é obtido pelo índice de Youden (Equação 3.23) sobre as predições da validação interna e aplicado, sem alteração, ao conjunto de teste. Para cada paciente de teste, a probabilidade é a média das probabilidades de suas janelas.

4.4.5.4 Consolidação das cinco rodadas

Os resultados de cada arquitetura são reportados de duas formas complementares. A primeira é a média e o desvio-padrão das métricas das cinco partições, que indicam a estabilidade do modelo: desvios elevados sinalizam que o resultado depende de quais pacientes caíram em cada partição. A segunda reúne as predições fora da partição dos 517 pacientes em uma única curva ROC, cuja AUC recebe um intervalo de confiança de 95 % por *bootstrap* com $B^* = 1\,000$ reamostragens de pacientes. Para as métricas dependentes de limiar dessa curva agrupada,

emprega-se a mediana dos cinco limiares obtidos nas validações internas.

Como análise secundária, registra-se também a AUC obtida quando a probabilidade do paciente é a máxima, e não a média, de suas janelas, o que privilegia a janela de maior risco ao longo do registro.

4.5 Cenário II: extração de características do ECG

No segundo cenário, o sinal do Holter passa por pré-processamento e extração de características, e as medidas obtidas — os marcadores eletrocardiográficos — são a entrada de modelos de aprendizado de máquina clássico. Os marcadores descritos na seção 3.2 foram extraídos dos registros de Holter dos 517 pacientes da coorte segundo dois protocolos, que diferem na duração e na densidade dos segmentos analisados. O protocolo A privilegia segmentos longos, que permitem a análise espectral; o protocolo B adota segmentos curtos e densos, que permitem acompanhar o ritmo ao longo do dia, seguindo o desenho de Swee *et al.* (2026). A Tabela 15 resume as diferenças. Ambos empregam o mesmo filtro passa-faixa das redes neurais (seção 4.2) e a biblioteca NeuroKit2 (MAKOWSKI *et al.*, 2021) para a detecção de picos e a delineação dos batimentos.

Tabela 15 – Protocolos de extração dos marcadores

	Protocolo A	Protocolo B
Segmento	5 minutos	30 segundos
Espaçamento	um segmento por hora	um segmento a cada 2 minutos
Margem descartada	1 hora em cada extremidade	1 hora em cada extremidade
Segmentos por paciente	cerca de 21	cerca de 636 (máximo de 660)
Tempo analisado	cerca de 1 h 45 min	cerca de 5 h 20 min
Derivação dos marcadores	a de maior desvio-padrão, em cada segmento	Y
Amplitude do sinal	X, Y e Z, separadamente	X, Y e Z, separadamente
Correção de artefatos	sim	não
Base da VFC	intervalos RR filtrados	intervalos NN
Domínio da frequência	sim	não
Indicadores de ectopia	proporção de RR irregulares	contagens completas

Fonte: elaborado pelo autor (2026). Segmentos e tempo analisado por paciente, sobre as cerca de 22 horas úteis de cada registro: no protocolo A, um segmento de 5 minutos no início de cada hora; no protocolo B, um segmento de 30 segundos a cada 2 minutos (total de 328 807 segmentos nos 517 pacientes).

4.5.1 Marcadores extraídos

A Tabela 16 reúne os marcadores extraídos neste trabalho, com sua definição, unidade e significado fisiológico. Cada um é calculado em cada segmento e depois resumido por paciente

de duas formas: a média entre os segmentos, que representa o nível típico do marcador, e o desvio-padrão entre os segmentos, que representa quanto ele varia ao longo do dia. Assim, o desvio-padrão da frequência cardíaca média, por exemplo, não mede a variação batimento a batimento, mas a diferença de frequência entre os períodos do registro, incluindo o ciclo dia–noite.

4.5.2 Protocolo A: segmentos de 5 minutos

Do registro de cada paciente foi extraído um segmento de 5 minutos a cada hora, a partir de 1 hora após o início e até 1 hora antes do fim. A primeira e a última hora foram descartadas por concentrarem os artefatos de colocação e de retirada dos eletrodos. Foram obtidos 11 071 segmentos dos 517 pacientes, com mediana de 22 por paciente (mínimo de 16).

Em cada segmento, os picos R foram detectados na derivação de maior desvio-padrão naquele segmento, que tende a apresentar a melhor relação sinal-ruído, e todos os marcadores de ritmo e de morfologia foram medidos nessa mesma derivação. Cada marcador tem, assim, um único valor por segmento, e não um valor por derivação; a exceção é a amplitude, registrada em cada uma das três derivações. Os picos foram detectados com a correção de artefatos do NeuroKit2 (LIPPONEN; TARVAINEN, 2019). Intervalos RR fora da faixa de 300 a 2 000 ms, ou afastados mais de 40 % da mediana do segmento, foram descartados, e segmentos com menos de 30 picos ou 20 intervalos válidos não produziram marcadores. Foram calculados 22 marcadores: a frequência cardíaca média, o intervalo RR médio, o SDNN, o RMSSD, o pNN50, o coeficiente de variação e o índice triangular dos intervalos; as potências VLF, LF e HF e a razão LF/HF; o SD1, o SD2, a razão SD1/SD2 e a entropia amostral; a duração do QRS, o QT e o QTc; a amplitude de cada derivação; e a proporção de intervalos afastados mais de 20 % da mediana, como indicador de irregularidade. Todos foram obtidos em pelo menos 99,6 % dos segmentos.

Os segmentos de cada paciente foram resumidos pela média de cada marcador, que descreve seu nível típico, e pelo desvio-padrão entre segmentos, que descreve sua variação ao longo do registro, totalizando 44 variáveis por paciente. A diferença entre o primeiro e o último terço do registro também foi calculada, mas não foi utilizada nos modelos.

Antes da modelagem, valores acima de limites fisiológicos — 200 ms para SDNN, RMSSD e SD1, e 400 ms para SD2 — foram tratados como ausentes, o que afetou 200 valores, e imputados pela mediana do conjunto de treinamento de cada partição. Esse tratamento tem uma consequência que se tornou evidente apenas depois: os valores extremos não se distribuíam

Tabela 16 – Marcadores eletrocardiográficos extraídos: definição e significado

Marcador	Definição	Unidade	Significado
Ritmo e variabilidade (sobre intervalos NN)			
Frequência cardíaca média	60 000 dividido pela média dos intervalos NN	bpm	Nível de ativação do ritmo
Intervalo RR médio	Média dos intervalos NN	ms	Inverso da frequência
SDNN	Desvio-padrão dos intervalos NN (Equação 3.2)	ms	Variabilidade total do segmento
RMSSD	Raiz da média dos quadrados das diferenças sucessivas (Equação 3.3)	ms	Variação batimento a batimento; tônus vagal
pNN50	Porcentagem de diferenças sucessivas maiores que 50 ms	%	Tônus vagal
SD1 e SD2	Dispersões do gráfico de Poincaré (Equação 3.4)	ms	Variabilidade de curto e de longo prazo
SD1/SD2	Razão entre as duas dispersões	—	Forma da nuvem de Poincaré
VLF, LF, HF, LF/HF	Potência espectral por faixa (só em 5 minutos)	u.a.[a]	Modulação autonômica por mecanismo
Entropia amostral	Regularidade da sequência de intervalos (só em 5 minutos)	—	Complexidade do ritmo
Ectopia e pausas (pelo ritmo, sem distinguir a origem)			
Batimentos precoces	Intervalos RR menores que 80 % da mediana local	contagem	Batimentos fora do ritmo sinusal
Extrassístoles	Precoce seguido de intervalo maior que 115 % da mediana local	contagem	Batimento ectópico com pausa compensatória
Dupletes	Dois intervalos precoces consecutivos	contagem	Ectopia repetitiva; instabilidade elétrica
Carga de ectopia	Porcentagem de intervalos precoces	%	Frequência global de ectopia
Intervalos irregulares	Porcentagem de intervalos plausíveis que não são NN	%	Irregularidade do ritmo
Maior pausa	Maior intervalo RR plausível do segmento	ms	Pausas e bradiarritmias
Pausas acima de 2 s	Intervalos RR maiores que 2 000 ms	contagem	Pausas prolongadas
Morfologia (mediana dos batimentos delineados)			
Duração do QRS	Do início ao fim do complexo QRS	ms	Condução ventricular; bloqueios de ramo
Intervalo QT	Do início do QRS ao fim da onda T	ms	Despolarização e repolarização ventriculares
QTc	QT corrigido pela frequência (Equação 3.5)	ms	Repolarização prolongada; risco arrítmico
Ondas P e T identificadas	Fração dos batimentos com cada onda delineada	—	Qualidade do sinal e da delineação
Amplitude	Percentil 99 do valor absoluto do sinal filtrado, por derivação	mV	Massa ventricular ativa e geometria

Fonte: elaborado pelo autor (2026), com base em Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology (1996). [a]Unidades arbitrárias: o NeuroKit2 normaliza o espectro de potência pelo seu valor máximo, de modo que as potências são relativas; a razão LF/HF é adimensional.

ao acaso. Dos 34 pacientes com SD1 médio superior a 200 ms, 7 eram casos, o que corresponde a 12,7 % dos casos contra 5,8 % dos controles. Os extremos refletiam, em boa parte, batimentos ectópicos e falhas de detecção, que a correção de artefatos e o filtro de 40 % não removeram por completo, e motivaram a revisão adotada no protocolo B.

4.5.3 Protocolo B: segmentos de 30 segundos

O protocolo B segue Swee *et al.* (2026), que extraem marcadores de segmentos de 30 segundos não sobrepostos. Para reduzir o custo computacional, extraiu-se um segmento de 30 segundos a cada 2 minutos de registro, mantidas as margens de 1 hora, o que resultou em 328 807 segmentos, com mediana de 652 por paciente. Os picos R foram detectados na derivação Y, como no trabalho de referência, e todos os marcadores de ritmo e de morfologia foram medidos nessa derivação, com um único valor por segmento; apenas a amplitude foi registrada também nas derivações X e Z. A detecção foi feita após a limpeza do sinal pelo método padrão do NeuroKit2 e *sem* correção de artefatos: a correção substitui os batimentos ectópicos por batimentos interpolados e apagaria justamente os eventos que os indicadores de ectopia procuram contar.

4.5.3.1 Classificação dos intervalos

Cada intervalo RR foi classificado em três categorias. Intervalos fora da faixa de 250 a 3 000 ms foram considerados *implausíveis*, por corresponderem a picos duplicados ou a perdas de sinal. Entre os plausíveis, foram considerados *normais* (NN) os que não se afastam mais de 20 % da mediana móvel dos cinco intervalos vizinhos. A mediana local, e não a do segmento inteiro, acompanha as variações lentas da frequência cardíaca, de modo que um trecho em que o paciente apenas acelerou não seja confundido com ectopia. Os intervalos plausíveis restantes foram considerados *irregulares*.

4.5.3.2 Marcadores calculados

Os marcadores de VFC — frequência média, SDNN, RMSSD, pNN50, SD1, SD2 e SD1/SD2 — foram calculados apenas sobre os intervalos NN, e somente em segmentos com pelo menos oito deles. As diferenças sucessivas consideraram apenas pares de intervalos NN adjacentes no registro. Marcadores espectrais e a entropia amostral não foram calculados, pelos motivos expostos na subseção 3.2.6.

Os indicadores de ectopia foram obtidos a partir da mediana local: foram considerados *precoces* os intervalos inferiores a 80 % dela; *extrassístoles*, os intervalos precoces seguidos de outro superior a 115 % dela; e *dupletes*, dois intervalos precoces consecutivos. Registraram-se ainda a maior pausa, o número de pausas superiores a 2 segundos e as frações de intervalos

irregulares e implausíveis.

Para a morfologia, os batimentos foram delineados pelo método de proeminência do NeuroKit2 (EMRICH *et al.*, 2024). A largura do QRS foi tomada entre o início e o fim do complexo, e o QT, do início do QRS ao fim da onda T, com a mediana sobre os batimentos do segmento. O QTc foi calculado pela Equação 3.5 com a média dos intervalos NN. Registraram-se ainda as frações de batimentos com onda P e com onda T identificadas e a amplitude de cada derivação. Em um teste preliminar, o método de ondaletas inicialmente considerado produziu durações de QRS sistematicamente superiores a 125 ms em todos os segmentos de um mesmo paciente, indício de superestimação, e foi substituído.

4.5.3.3 Controle de qualidade

Uma primeira versão da extração calculava a VFC sobre todos os intervalos plausíveis, sem separar os intervalos NN. Nela, 19,65 % dos segmentos apresentaram RMSSD superior a 200 ms, valor implausível em repouso, e 12,35 % apresentaram SDNN acima do mesmo limite. Esses valores não eram ruído aleatório: resultavam de batimentos ectópicos e de picos não detectados, que inflam as diferenças sucessivas. Tratá-los como ausentes teria removido seletivamente os segmentos com ectopia.

Com o cálculo restrito aos intervalos NN, as proporções caíram para 2,21 % e 2,94 %, e as medianas do RMSSD e do SDNN passaram de 41,7 para 23,9 ms e de 44,0 para 29,5 ms, respectivamente (Tabela 17). A queda das medianas mostra que a inflação não se restringia aos extremos, mas afetava a distribuição como um todo. Na versão final, a mediana da fração de intervalos NN por segmento foi de 1,00, e 11,1 % dos segmentos tiveram menos de 80 % de intervalos normais. Todos os marcadores foram calculados em pelo menos 96 % dos segmentos, e a largura do QRS em 98,7 %.

Tabela 17 – Efeito do cálculo sobre intervalos NN nos marcadores de variabilidade (328 807 segmentos)

	Acima de 200 ms		Mediana (ms)	
Marcador	Todos os RR	NN	Todos os RR	NN
RMSSD	19,65 %	2,21 %	41,7	23,9
SDNN	12,35 %	2,94 %	44,0	29,5

Fonte: elaborado pelo autor (2026).

4.5.3.4 Resumo por paciente

Os segmentos de cada paciente foram resumidos em uma única linha. Para os marcadores contínuos, calcularam-se a mediana, o intervalo interquartil e os percentis 10 e 90; para as contagens de ectopia, a média por segmento e a fração de segmentos com pelo menos um evento. Os limites fisiológicos não foram aplicados nesta etapa, pois os resumos por mediana e percentis são robustos aos valores extremos remanescentes.

A partir desses resumos, foram definidos três conjuntos de variáveis, de dimensão crescente: o conjunto A, apenas com a mediana de cada marcador contínuo e a média de cada contagem (32 variáveis); o conjunto B, que acrescenta o intervalo interquartil e a fração de segmentos com evento (64 variáveis); e o conjunto C, com todos os resumos (122 variáveis).

4.5.4 Número de variáveis e risco de sobreajuste

Os dois protocolos produzem de algumas dezenas a mais de uma centena de variáveis por paciente, um número elevado diante de 55 eventos. A regra usual de pelo menos dez eventos por variável em modelos de regressão logística (PEDUZZI *et al.*, 1996) limitaria o modelo a cerca de cinco variáveis. Por isso, os modelos apresentados na seção 4.6 empregam penalização, redução de dimensionalidade ou seleção de variáveis, sempre ajustadas dentro de cada partição da validação cruzada, conforme a subseção 3.7.6.

4.6 Cenário II: modelos de aprendizado de máquina sobre os marcadores

Os marcadores extraídos conforme a seção 4.5 foram analisados em duas etapas: uma revisão estatística, que verifica se cada marcador isoladamente difere entre casos e controles, e uma etapa de modelagem, que verifica se os marcadores, em conjunto, discriminam os grupos e se acrescentam informação às variáveis clínicas. Todos os modelos seguem o protocolo de validação cruzada descrito na subseção 3.7.6, com as mesmas cinco partições estratificadas das redes neurais, e são avaliados pela AUC das predições fora da partição, com intervalo de confiança por *bootstrap* com $B^{*} = 2\,000$ reamostragens.

4.6.1 Revisão estatística

Cada marcador, resumido por paciente, foi comparado entre casos e controles pelo teste de Mann-Whitney (MANN; WHITNEY, 1947), que não pressupõe distribuição normal. Como dezenas de marcadores são testados simultaneamente, os valores-p foram corrigidos pelo procedimento de Benjamini-Hochberg, que controla a proporção esperada de falsos positivos entre os resultados declarados significativos (BENJAMINI; HOCHBERG, 1995), e, de forma mais conservadora, pela correção de Bonferroni.

No protocolo B, a mesma comparação foi repetida também no nível do segmento, tratando cada um dos 328 807 segmentos como uma observação. Essa análise é incorreta por construção, pois os segmentos de um mesmo paciente não são independentes, e foi incluída deliberadamente para quantificar o efeito da pseudorreplicação sobre a significância estatística. Pares de marcadores com correlação de Spearman superior a 0,8 em módulo foram identificados como redundantes.

4.6.2 Modelos

Foram empregadas quatro famílias de modelos, todas precedidas da imputação dos valores ausentes pela mediana e da padronização das variáveis, ajustadas no conjunto de treinamento de cada partição:

- *regressão logística com penalização L2*, com coeficiente de regularização forte ($C = 0{,}05$), que reduz os coeficientes de variáveis pouco informativas sem eliminá-las;
- *regressão logística com penalização L1* ($C = 0{,}1$), que anula os coeficientes das variáveis menos úteis e realiza, assim, uma seleção de variáveis dentro de cada partição;
- *análise de componentes principais seguida de regressão logística*, que substitui os marcadores, fortemente correlacionados entre si, por poucas combinações lineares não correlacionadas, ajustadas sem uso do desfecho;
- *florestas aleatórias* (BREIMAN, 2001), com 500 árvores de profundidade limitada, capazes de representar relações não lineares e interações entre marcadores.

Todos os modelos ponderam as classes de forma inversamente proporcional à sua frequência, pelo mesmo motivo exposto na subseção 3.3.6. O modelo de referência é a regressão logística sobre as seis variáveis clínicas, sem penalização relevante ($C = 1$).

4.6.3 Comparações planejadas

Três perguntas orientaram as comparações. A primeira é se os marcadores, sozinhos, discriminam os grupos melhor que o acaso, o que se verifica pelo intervalo de confiança da AUC. A segunda é se os marcadores acrescentam informação às variáveis clínicas, o que se verifica pela diferença de AUC entre o modelo com marcadores e variáveis clínicas e o modelo apenas clínico, estimada por *bootstrap* pareado (Equação 3.25). A terceira, específica do protocolo A, é se um número reduzido de marcadores, compatível com a regra de dez eventos por variável, preserva o desempenho.

Para essa terceira pergunta, foram comparadas duas formas de escolher os marcadores. Na primeira, quatro marcadores foram escolhidos pela significância no teste de Mann-Whitney sobre a coorte inteira, pela interpretação fisiológica e pela baixa redundância entre si. Como essa escolha utilizou o desfecho de todos os pacientes, inclusive dos que mais tarde compõem cada conjunto de teste, ela é otimista por construção. Na segunda, a seleção dos quatro marcadores mais associados ao desfecho, pela estatística F da análise de variância, foi refeita dentro de cada partição, usando apenas os pacientes de treinamento; para a combinação com as variáveis clínicas, foram selecionadas da mesma forma seis variáveis entre as clínicas e os marcadores. Em ambas as formas, o modelo foi a regressão logística com penalização L2 ($C = 1$). A diferença entre as duas estima o otimismo introduzido pela seleção.

No protocolo B, além dos modelos sobre os resumos por paciente, foram treinados modelos diretamente sobre os segmentos, cada um rotulado com o desfecho de seu paciente, com as probabilidades dos segmentos agregadas por paciente pela Equação 3.24 antes da avaliação. Para os resumos por paciente, os três conjuntos de variáveis A, B e C da subseção 4.5.3 foram combinados com quatro modelos, o que resulta em doze configurações. Como a melhor delas é escolhida após a observação dos resultados, todas as doze são reportadas.

4.6.4 Marcadores pré-especificados nas três derivações

Os marcadores do protocolo B foram recalculados em cada uma das três derivações, de modo que cada marcador passou a ter três versões, uma por derivação. Em cada segmento, os marcadores de uma derivação foram descartados quando menos de 80 % de seus intervalos RR foram classificados como NN, e os marcadores de ritmo foram tomados também da derivação com a maior fração de intervalos NN. Para evitar a seleção de variáveis sobre os dados, definiu-

se, com base na literatura, um modelo com dois marcadores: o desvio-padrão da frequência cardíaca média entre os segmentos, que mede sua variação ao longo do dia, e a carga de ectopia. Definiu-se também um conjunto de quatro marcadores, que acrescenta aos dois anteriores o número médio de dupletes e a maior pausa média entre os segmentos, outros indicadores de instabilidade do ritmo, usado na replicação da Tabela 35. O modelo foi ajustado separadamente para cada versão dos marcadores — derivação X, Y, Z e derivação de melhor qualidade —, sempre com os dois marcadores de uma única derivação, por regressão logística com penalização L2, sem seleção, sozinho e com as variáveis clínicas.

4.7 Cenário III: variáveis clínicas e combinação com o ECG

O terceiro cenário avalia, para fins de comparação e análise, modelos baseados nas variáveis clínicas descritas na subseção 4.1.3 e a combinação dessas variáveis com os dados extraídos do ECG. Todos os modelos usam as mesmas cinco partições dos cenários anteriores.

4.7.1 Modelos baseados em variáveis clínicas

O modelo de referência é uma regressão logística sobre as seis variáveis clínicas. Para avaliar a contribuição dos exames, foram ajustadas regressões logísticas com penalização L2 ($C = 1$) e pesos de classe inversamente proporcionais à frequência, sobre cada grupo de exames isolado e sobre cada grupo somado às seis variáveis clínicas. Valores ausentes foram imputados pela mediana do conjunto de treinamento de cada partição, e todas as variáveis foram padronizadas com as estatísticas do mesmo conjunto.

4.7.2 Combinação com os marcadores do ECG

A combinação com os marcadores do Cenário II foi avaliada acrescentando às seis variáveis clínicas, na mesma regressão logística, os marcadores do protocolo A (com penalização L1 e L2) e os dois marcadores pré-especificados da subseção 4.6.4. O ganho de cada combinação sobre o modelo apenas clínico foi estimado pela diferença de AUC com *bootstrap* pareado (Equação 3.25).

4.7.3 Combinação com o sinal: rede profunda com variáveis clínicas concatenadas

A combinação das variáveis clínicas com o sinal bruto foi avaliada por uma rede neural profunda com variáveis clínicas concatenadas: a ResNet-18 do Cenário I com um segundo ramo, que recebe as seis variáveis clínicas. As representações dos dois ramos são concatenadas antes do classificador, e a rede é treinada para prever a MSC pelo mesmo protocolo das redes do Cenário I. Para medir a contribuição de cada modalidade, a mesma arquitetura foi treinada também apenas com o ramo clínico.

4.7.3.1 Estratégias de treinamento da rede com concatenação

Na rede com concatenação, o ramo do sinal tem cerca de 4 milhões de parâmetros, enquanto o ramo clínico recebe apenas seis variáveis. Treinados juntos com a mesma taxa de aprendizado, o ramo do sinal tende a dominar o ajuste e a memorizar os pacientes de treinamento antes que o ramo clínico contribua. Para controlar esse desequilíbrio, foram comparadas três estratégias:

- *treinamento conjunto*, com a mesma taxa de aprendizado (10^{-4}) para toda a rede;
- *taxa de aprendizado discriminativa*, em que o ramo do sinal recebe taxa de 10^{-6} e decaimento de pesos de 10^{-1}, e o restante da rede mantém 10^{-4} e 10^{-2};
- *ramo do sinal congelado*, em que apenas o ramo clínico e o classificador são ajustados.

4.8 Protocolo de avaliação

Os três cenários foram avaliados pelo mesmo protocolo, descrito a seguir, de modo que suas diferenças de desempenho possam ser atribuídas às abordagens, e não a escolhas de avaliação.

4.8.1 Particionamento

A coorte foi dividida em cinco partições estratificadas pelo desfecho, com divisão no nível do paciente: cada indivíduo pertence a uma única partição, e as janelas são extraídas apenas após a divisão. Cada partição contém 103 ou 104 pacientes, com 11 casos.

Em cada rodada da validação cruzada, uma partição constitui o conjunto de teste e as quatro restantes, com 413 ou 414 pacientes, são subdivididas: 75 % compõem o conjunto de

treinamento e 25 % a validação interna, também com estratificação pelo desfecho. A validação interna define a época de parada do treinamento e o limiar de decisão, que é então aplicado ao conjunto de teste sem ajuste adicional.

4.8.2 Validação e agregação por paciente

A avaliação emprega validação cruzada estratificada em cinco partições. A divisão ocorre no nível do paciente, e as janelas são extraídas somente após a separação: nenhum indivíduo contribui simultaneamente para treinamento e teste. O cuidado é necessário porque janelas de um mesmo registro compartilham a assinatura eletrocardiográfica individual — eixo elétrico, morfologia do complexo QRS e relação de amplitude entre derivações —, e sua presença em ambos os conjuntos permitiria ao modelo reconhecer o paciente em lugar de estimar o risco.

De cada conjunto de treinamento, uma fração é reservada para a definição do critério de parada antecipada e do limiar de decisão. O limiar é obtido pelo índice de Youden, que maximiza a soma de sensibilidade e especificidade, e apenas aplicado ao conjunto de teste — sua determinação a partir do próprio teste produziria estimativas otimistas.

As probabilidades preditas para as janelas de um mesmo paciente são agregadas por média antes do cálculo de qualquer métrica. Sem essa agregação, um indivíduo com 100 janelas seria contabilizado cem vezes, como se correspondesse a cem observações independentes — o que estreitaria artificialmente os intervalos de confiança.

Os intervalos de confiança de 95 % foram estimados por reamostragem *bootstrap*, sorteando pacientes com reposição: 1 000 repetições para as redes neurais e 2 000 para os modelos sobre os marcadores. Comparações entre modelos empregaram reamostragem pareada: a mesma amostra avalia ambos os modelos, de modo a isolar a incerteza da diferença.

4.8.3 Métricas

A métrica principal é a AUC, que mede a capacidade de ordenar corretamente os pacientes por risco e independe do limiar adotado. Reporta-se também a AUPRC, cuja linha de base sob classificação aleatória é a prevalência da classe positiva — 0,106 nesta coorte — em lugar de 0,5, o que a torna mais informativa quando os eventos são raros.

Sensibilidade, especificidade e VPP são reportadas no limiar definido na validação. A acurácia não é empregada como critério de comparação pela razão já exposta: o classificador trivial a maximiza sem apresentar utilidade.

Dois valores de AUC são apresentados em cada seção. A média entre partições, acompanhada do desvio-padrão, indica a estabilidade do resultado em relação à composição das partições. A estimativa agrupada, calculada sobre a totalidade dos 517 pacientes — cada um predito pelo modelo que não o observou durante o treinamento —, é considerada mais confiável por avaliar simultaneamente os 55 eventos, enquanto cada partição isolada dispõe de apenas onze. Eventuais discrepâncias entre as duas estimativas decorrem de os modelos ajustados em cada partição produzirem probabilidades em escalas distintas, que não coincidem exatamente ao serem reunidas em ordenamento único.

4.8.4 Ambiente computacional

Os experimentos foram executados em um servidor com sistema operacional Ubuntu, cujas características constam da Tabela 18. Cada treinamento utilizou uma das duas unidades de processamento gráfico, com precisão mista. A extração dos marcadores e os modelos sobre variáveis tabulares foram executados nos processadores, com paralelismo entre pacientes.

Tabela 18 – Ambiente computacional

Componente	Especificação
Unidades de processamento gráfico	2 × NVIDIA A100-SXM4, 40 GB de memória cada
Processadores	2 × AMD EPYC 7742 (128 núcleos, 256 *threads*)
Memória principal	2 TB
Sistema operacional	Ubuntu 22.04
Linguagem e bibliotecas	Python, PyTorch, scikit-learn, NeuroKit2, WFDB

Fonte: elaborado pelo autor (2026).

5 RESULTADOS

Os resultados são apresentados na mesma ordem da metodologia: o Cenário I, de aprendizado profundo sobre o sinal bruto; o Cenário II, de aprendizado de características extraídas do ECG; e o Cenário III, de modelos baseados em variáveis clínicas e em sua combinação com o ECG. Em todos, a métrica principal é a AUC da predição de MSC contra sobrevivência, calculada sobre as predições fora da partição dos 517 pacientes, com intervalo de confiança de 95 % por *bootstrap*. A coluna "Partições" das tabelas traz a média e o desvio-padrão da AUC nas cinco partições da validação cruzada: a média indica o desempenho típico em cada conjunto de teste, e o desvio-padrão, quanto o resultado depende de quais pacientes caíram em cada partição. A AUPRC resume a curva precisão-revocação; seu valor sob classificação ao acaso é igual à prevalência, 0,106.

5.1 Cenário I: aprendizado profundo sobre o sinal bruto

Esta seção apresenta o desempenho das redes neurais treinadas diretamente sobre o sinal das três derivações do Holter. Todas foram avaliadas pelo mesmo protocolo: cinco partições estratificadas sobre os 517 pacientes, com 309 ou 310 pacientes de treinamento, 104 de validação interna e 103 ou 104 de teste em cada partição. O valor principal é a AUC fora da partição, calculada sobre as predições dos 517 pacientes, cada um predito pelo modelo que não o viu no treinamento, com intervalo de confiança de 95 % obtido por *bootstrap*. A média e o desvio-padrão da AUC entre as cinco partições são informados ao lado, como medida da instabilidade do resultado.

5.1.1 Redes convolucionais: capacidade e duração da janela

A Tabela 19 apresenta as redes convolucionais do desenho da subseção 4.4.4, que varia a capacidade da rede e a duração da janela de entrada.

Nenhuma configuração se distinguiu do acaso: todos os intervalos de confiança incluem 0,5. A rede mínima obteve os maiores valores nas duas durações de janela. Nas duas durações, o desempenho caiu à medida que a capacidade aumentou: 0,523, 0,486 e 0,485 com a janela de 2 minutos e 0,554, 0,491 e 0,485 com a de 10 segundos. A diferença entre a rede mínima e a média, no entanto, é menor que a largura de qualquer um dos intervalos e não permite afirmar uma relação entre capacidade e desempenho. O mesmo vale para a duração da janela: a

Tabela 19 – Desempenho das redes convolucionais segundo a capacidade e a duração da janela

Rede	Janela	Parâmetros	AUC partições	AUC fora da partição [IC 95 %]
Mínima	2 min	14 425	0,543 ± 0,059	0,523 [0,440–0,612]
Simples	2 min	109 361	0,500 ± 0,067	0,486 [0,402–0,578]
Média	2 min	418 145	0,494 ± 0,119	0,485 [0,400–0,574]
Mínima	10 s	14 425	0,589 ± 0,090	0,554 [0,467–0,634]
Simples	10 s	109 361	0,509 ± 0,051	0,491 [0,411–0,578]
Média	10 s	418 145	0,495 ± 0,118	0,485 [0,406–0,569]

Fonte: elaborado pelo autor (2026).

rede mínima obteve 0,523 com 2 minutos e 0,554 com 10 segundos, valores compatíveis entre si.

5.1.2 Redes residuais: largura da ResNet-18

As redes residuais foram treinadas com uma configuração anterior à das redes convolucionais da seção precedente: 20 épocas no máximo, paciência de 10 épocas, 250 janelas de treinamento e 100 de avaliação por paciente. A Tabela 20 compara três larguras da ResNet-18, que mantêm os quatro estágios de dois blocos e variam o número de canais.

Tabela 20 – Desempenho da ResNet-18 em três larguras

Rede	Janela	Parâmetros	AUC partições	AUC fora da partição [IC 95 %]
ResNet-18 mínima	5,12 s	78 169	0,569 ± 0,067	0,562 [0,475–0,642]
ResNet-18 reduzida	2 min	1 029 985	0,516 ± 0,102	0,504 [0,420–0,588]
ResNet-18 completa	2 min	3 976 385	0,528 ± 0,088	0,508 [0,431–0,588]
ResNet-18 completa	5,12 s	3 976 385	0,500 ± 0,080	0,492 [0,411–0,577]

Fonte: elaborado pelo autor (2026).

A versão mínima, com 78 mil parâmetros (253 por paciente de treinamento), obteve o maior valor entre as redes residuais (0,562), e as versões reduzida e completa ficaram em torno de 0,50. Assim como nas redes convolucionais, a redução da largura retardou a memorização dos pacientes de treinamento, mas o intervalo de confiança da versão mínima ainda inclui 0,5. A ResNet-18 completa obteve resultados equivalentes com janelas de 2 minutos e de 5,12 segundos.

5.1.3 Redes residuais: profundidade (ResNet-18, ResNet-34 e ResNet-50)

A Tabela 21 compara redes residuais de 18, 34 e 50 camadas com a mesma largura e a mesma janela de 2 minutos. A ResNet-34 empilha mais blocos básicos em cada estágio, e a ResNet-50 substitui o bloco básico pelo bloco de gargalo (seção 3.4).

Quadruplicar o número de parâmetros, da ResNet-18 para a ResNet-50, não alterou

Tabela 21 – Desempenho das redes residuais segundo a profundidade

Rede	Parâmetros	Por paciente	AUC partições	AUC fora da partição [IC 95 %]
ResNet-18	3 976 385	12 869	0,528 ± 0,088	0,508 [0,431–0,588]
ResNet-34	7 350 721	23 789	0,540 ± 0,039	0,514 [0,429–0,601]
ResNet-50	16 479 937	53 333	0,569 ± 0,098	0,536 [0,448–0,618]

Fonte: elaborado pelo autor (2026). Parâmetros por paciente de treinamento (309 pacientes).

o desempenho: os três valores ficaram entre 0,51 e 0,54, com intervalos amplamente sobrepostos e todos incluindo 0,5. A ResNet-50, com mais de 53 mil parâmetros por paciente de treinamento, memorizou o conjunto de treinamento já nas primeiras épocas, como as demais, e não extraiu do sinal informação adicional.

5.1.4 ResNet-18 com mecanismo de atenção

Na rede com atenção, as características extraídas pela ResNet-18 ao longo da janela são relacionadas entre si por um codificador *Transformer* antes do agrupamento (seção 3.5), totalizando 1 491 553 parâmetros. A AUC fora da partição foi de 0,493 [0,419–0,577], com média entre partições de 0,512 ± 0,041. A modelagem explícita das relações temporais dentro da janela de 2 minutos, portanto, não acrescentou capacidade discriminativa à ResNet-18.

5.1.5 Busca de hiperparâmetros

Para verificar se o desempenho dependia de uma escolha inadequada de hiperparâmetros, uma rede convolucional e uma rede residual foram configuradas por busca bayesiana com o *Optuna* (Tabela 22). Foram feitas 25 tentativas para cada família, variando largura, profundidade, tipo de agrupamento, taxa de aprendizado, decaimento de pesos, descarte e duração da janela. A busca maximizou a AUC média da validação interna em três partições, sem acesso aos conjuntos de teste, e a configuração escolhida foi avaliada nas cinco partições do protocolo.

Tabela 22 – Desempenho das redes configuradas por busca de hiperparâmetros

Rede	Janela	Parâmetros	AUC partições	AUC fora da partição [IC 95 %]
Convolucional[a]	1 min	473 417	0,574 ± 0,112	0,556 [0,464–0,647]
Residual[b]	1 min	1 818 049	0,510 ± 0,079	0,496 [0,411–0,584]

Fonte: elaborado pelo autor (2026). [a]Quatro blocos com 24, 48, 96 e 96 canais, núcleo de 31 amostras e agrupamento por média. [b]ResNet com quatro estágios de um bloco, 64 canais iniciais e agrupamento por máximo.

A busca não superou as configurações escolhidas manualmente. A rede convolucional

encontrada obteve 0,556, o mesmo valor da rede convolucional mínima sem busca (0,554), e a rede residual obteve 0,496. Como os hiperparâmetros foram escolhidos pela validação interna, e não em uma validação cruzada aninhada, mesmo esses valores carregam algum otimismo residual.

5.1.6 Comportamento durante o treinamento

Os registros de treinamento mostram o mesmo padrão em todas as arquiteturas. A perda de treinamento cai rapidamente — na ResNet-18, de cerca de 0,65 para menos de 0,02 em dez épocas —, enquanto a perda de validação sobe desde a segunda ou terceira época, de cerca de 1,5 para valores entre 4 e 8. A rede memoriza os pacientes de treinamento em vez de aprender um padrão que se transfira para pacientes novos. As redes de menor capacidade retardam esse processo: na rede convolucional mínima, a perda de treinamento ainda estava em torno de 0,55 ao final das 30 épocas, e é nela que se observaram os maiores valores de AUC, ainda que não significativos.

A AUC de validação mostrou-se um indicador pouco confiável do desempenho no teste. Na quarta partição da rede convolucional média, por exemplo, a validação interna atingiu AUC de 0,64, e o teste, 0,30; na terceira partição da ResNet-50, a validação chegou a 0,75 e o teste ficou em 0,49. Com 11 casos na validação interna, a AUC de validação oscila o suficiente entre épocas para que a escolha do melhor modelo seja, em boa parte, determinada pelo acaso.

5.1.7 Variabilidade entre execuções

A ResNet-18 mínima, com janela de 5,12 segundos, foi treinada duas vezes sobre as mesmas partições, alterando-se apenas o tamanho do lote (2 000 e 1 000 janelas) e o número de janelas sorteadas por paciente (500 e 850). A AUC fora da partição passou de 0,562 [0,475–0,642] para 0,480 [0,403–0,557]. Essa diferença de 0,08 entre duas execuções da mesma arquitetura é maior que a diferença entre a rede de melhor e a de pior desempenho entre as redes convolucionais e residuais avaliadas. O desvio-padrão da AUC entre partições, entre 0,04 e 0,12, aponta na mesma direção. A ordenação das arquiteturas, portanto, não deve ser interpretada como evidência de superioridade de uma sobre as outras.

5.1.8 Análise de sensibilidade: ResNet-18 sem restrição ao ritmo sinusal

Para verificar se o pipeline é capaz de extrair do sinal alguma informação associada ao desfecho, a ResNet-18 foi treinada também sobre a coorte sem o critério de ritmo sinusal, com 703 pacientes e 85 casos. Nessa coorte, a AUC fora da partição foi de 0,575 [0,511–0,642], o único intervalo entre as redes que exclui 0,5 (média entre partições de 0,601 $\pm$ 0,049). Esse ganho não pode ser atribuído a um marcador de morte súbita: a coorte ampliada inclui pacientes em fibrilação atrial, um ritmo facilmente reconhecível no sinal e associado a pior prognóstico. A rede tem, portanto, um atalho para discriminar os grupos que não existe na coorte restrita ao ritmo sinusal. O resultado mostra que o pipeline aprende quando há um padrão reconhecível no sinal e justifica a restrição adotada na subseção 4.1.2, que remove essa fonte de confundimento.

5.1.9 Métricas dependentes de limiar

A Tabela 23 reúne, para todas as redes do protocolo principal, as métricas calculadas sobre as predições fora da partição após a aplicação do limiar de decisão escolhido na validação interna.

As métricas dependentes de limiar confirmam o quadro da AUC. O VPP ficou entre 0,09 e 0,14 em todas as redes, próximo da prevalência de 0,106, ou seja, entre os pacientes classificados como de alto risco a proporção de casos foi praticamente a mesma da coorte. O VPN, entre 0,88 e 0,93, também se manteve próximo do valor de 0,894 que se obteria classificando todos os pacientes como controles. A sensibilidade e a especificidade variaram em sentidos opostos entre as redes — de 0,29 a 0,73 e de 0,35 a 0,70, respectivamente —, o que reflete apenas a posição do limiar, e não uma capacidade de separação: as redes de maior sensibilidade são as de menor especificidade. A acurácia, entre 0,38 e 0,66, fica sempre abaixo dos 0,894 obtidos pela classificação trivial de todos os pacientes como controles, o que ilustra por que ela não é adequada com classes desbalanceadas. A rede com concatenação com extrator congelado obteve a maior sensibilidade (0,727) com VPN de 0,929, mas à custa de especificidade de 0,424.

A Tabela 24 apresenta as matrizes de confusão que originam essas métricas. Em todas as redes, o número de controles classificados como de alto risco (FP) supera em várias vezes o de casos corretamente identificados (VP): para cada morte súbita detectada, entre seis e dez sobreviventes foram classificados como de alto risco.

Tabela 23 – Métricas dependentes de limiar das redes neurais, calculadas sobre as predições fora da partição dos 517 pacientes

Rede	Entrada	Janela	AUC	AUPRC	Sens.	Espec.	VPP	VPN	F1	Acur.
CNN mínima	ECG	2 min	0,523	0,139	0,582	0,448	0,111	0,900	0,187	0,462
CNN simples	ECG	2 min	0,486	0,121	0,364	0,645	0,109	0,895	0,167	0,615
CNN média	ECG	2 min	0,485	0,126	0,309	0,688	0,106	0,893	0,157	0,648
CNN mínima	ECG	10 s	0,554	0,132	0,691	0,346	0,112	0,904	0,192	0,383
CNN simples	ECG	10 s	0,491	0,119	0,400	0,530	0,092	0,881	0,150	0,516
CNN média	ECG	10 s	0,485	0,110	0,455	0,485	0,095	0,882	0,157	0,482
ResNet-18 mínima	ECG	5,12 s	0,562	0,160	0,455	0,654	0,135	0,910	0,208	0,632
ResNet-18 reduzida	ECG	2 min	0,504	0,117	0,582	0,437	0,110	0,898	0,184	0,453
ResNet-18 completa	ECG	2 min	0,508	0,121	0,455	0,461	0,091	0,877	0,152	0,460
ResNet-18 completa	ECG	5,12 s	0,492	0,129	0,582	0,442	0,110	0,899	0,186	0,456
ResNet-34	ECG	2 min	0,514	0,122	0,509	0,517	0,112	0,898	0,183	0,516
ResNet-50	ECG	2 min	0,536	0,137	0,455	0,511	0,100	0,887	0,163	0,505
ResNet-18 + Transformer	ECG	2 min	0,493	0,134	0,291	0,703	0,105	0,893	0,154	0,660
CNN (Optuna)	ECG	1 min	0,556	0,189	0,509	0,552	0,119	0,904	0,193	0,547
ResNet (Optuna)	ECG	1 min	0,496	0,122	0,455	0,565	0,111	0,897	0,178	0,553
ResNet-18, conjunto	ECG + clínicos	2 min	0,516	0,141	0,418	0,548	0,099	0,888	0,160	0,534
ResNet-18, taxa reduzida	ECG + clínicos	2 min	0,579	0,180	0,455	0,673	0,142	0,912	0,216	0,650
ResNet-18, congelada	ECG + clínicos	2 min	0,577	0,146	0,727	0,424	0,131	0,929	0,222	0,456
ResNet-18, conjunto	ECG + clínicos	10 s	0,491	0,113	0,400	0,569	0,100	0,889	0,159	0,551

Fonte: elaborado pelo autor (2026). Limiar de decisão escolhido pelo índice de Youden na validação interna de cada partição. Referência sob classificação aleatória: AUPRC e VPP iguais à prevalência (0,106); VPN igual a 0,894. Entrada: ECG = só o sinal bruto; ECG + clínicos = sinal bruto com as seis variáveis clínicas concatenadas (subseção 4.7.3.1). Optuna: hiperparâmetros escolhidos por busca bayesiana (subseção 5.1.5). Acur.: acurácia. Conjunto: extrator e ramo clínico treinados juntos; taxa reduzida: extrator com taxa de aprendizado menor; congelada: extrator de sinal congelado.

5.1.10 Síntese

Em 15 configurações avaliadas no protocolo principal — as quatro redes com variáveis clínicas concatenadas são discutidas no Cenário III (seção 5.3) —, nenhuma rede treinada sobre o sinal do Holter discriminou casos e controles de forma distinguível do acaso. Os valores de AUC fora da partição ficaram entre 0,48 e 0,56, sem relação com a capacidade da rede, com a duração da janela ou com a presença de mecanismos de atenção, e a variação entre execuções da mesma rede foi da mesma ordem que a variação entre arquiteturas. A melhor rede, a ResNet-18 mínima com janelas de 5,12 segundos, obteve 0,562 [0,475–0,642]. Treinadas diretamente para o desfecho, as redes não extraíram do sinal bruto um padrão que distinguisse os pacientes que sofreram MSC; as medidas extraídas do ECG no Cenário II, apresentadas a seguir, tiveram desempenho superior.

Tabela 24 – Limiar de decisão e matriz de confusão agregada das redes neurais sobre os 517 pacientes

Rede	Entrada	Janela	Limiar	VP	FN	FP	VN
CNN mínima	ECG	2 min	0,460	32	23	255	207
CNN simples	ECG	2 min	0,409	20	35	164	298
CNN média	ECG	2 min	0,357	17	38	144	318
CNN mínima	ECG	10 s	0,348	38	17	302	160
CNN simples	ECG	10 s	0,246	22	33	217	245
CNN média	ECG	10 s	0,268	25	30	238	224
ResNet-18 mínima	ECG	5,12 s	0,489	25	30	160	302
ResNet-18 reduzida	ECG	2 min	0,092	32	23	260	202
ResNet-18 completa	ECG	2 min	0,058	25	30	249	213
ResNet-18 completa	ECG	5,12 s	0,186	32	23	258	204
ResNet-34	ECG	2 min	0,154	28	27	223	239
ResNet-50	ECG	2 min	0,032	25	30	226	236
ResNet-18 + Transformer	ECG	2 min	0,040	16	39	137	325
CNN (Optuna)	ECG	1 min	–	28	27	207	255
ResNet (Optuna)	ECG	1 min	–	25	30	201	261
ResNet-18, conjunto	ECG + clínicos	2 min	0,062	23	32	209	253
ResNet-18, taxa reduzida	ECG + clínicos	2 min	0,489	25	30	151	311
ResNet-18, congelada	ECG + clínicos	2 min	0,447	40	15	266	196
ResNet-18, conjunto	ECG + clínicos	10 s	0,026	22	33	199	263

Fonte: elaborado pelo autor (2026). VP: casos classificados como de alto risco; FN: casos classificados como de baixo risco; FP: controles classificados como de alto risco; VN: controles classificados como de baixo risco. Total de 55 casos e 462 controles. Limiar: mediana dos limiares de Youden das cinco partições; não registrado nas redes configuradas pelo Optuna. Entrada e nomes das redes como na Tabela 23.

5.2 Cenário II: aprendizado de características do ECG

No segundo cenário, o modelo não recebe o sinal do Holter, mas medidas calculadas a partir dele — os marcadores eletrocardiográficos da Tabela 16, como a frequência cardíaca, a variabilidade da frequência cardíaca, a contagem de batimentos ectópicos e as durações do QRS e do QT. Como o registro tem 24 horas, os marcadores não são calculados sobre o registro inteiro, mas sobre trechos curtos dele, os *segmentos*. A forma de escolher esses trechos foi chamada de *protocolo*, e foram usados dois (Tabela 15):

- *protocolo A*: um segmento de 5 minutos no início de cada hora, cerca de 21 por paciente. Segmentos longos permitem calcular as medidas espectrais (potências VLF, LF e HF) e a entropia amostral, que não são confiáveis em trechos curtos;
- *protocolo B*: um segmento de 30 segundos a cada 2 minutos, cerca de 636 por paciente, seguindo o desenho de Swee *et al.* (2026). Segmentos curtos e frequentes acompanham o ritmo ao longo do dia e contam os batimentos ectópicos com mais detalhe, mas não permitem as medidas espectrais.

Em ambos, cada marcador é calculado em cada segmento e, em seguida, os segmentos de um paciente são resumidos em uma única linha — por exemplo, a média e o desvio-padrão da frequência cardíaca entre os segmentos —, porque o desfecho pertence ao paciente, e não ao segmento (subseção 3.7.5). São esses resumos por paciente que entram nos testes estatísticos e nos modelos.

Embora o Holter registre três derivações (X, Y e Z), nos protocolos A e B cada marcador tem um *único valor* por segmento, medido em uma só derivação: no protocolo A, a de maior desvio-padrão naquele segmento, escolhida segmento a segmento; no protocolo B, sempre a derivação Y. A única exceção é a amplitude do sinal, registrada separadamente em cada uma das três derivações. Os marcadores não são, portanto, triplicados por derivação. Apenas na análise dos marcadores pré-especificados (subseção 5.2.3) os marcadores foram recalculados em cada derivação, e cada derivação deu origem a um modelo separado.

Os resultados de cada protocolo seguem a mesma ordem. Primeiro, cada marcador é comparado isoladamente entre casos e controles, para verificar se algum deles, sozinho, difere entre os grupos. Depois, os marcadores são combinados em modelos de aprendizado de máquina clássico (subseção 4.6.2), avaliados pela mesma validação cruzada por paciente do Cenário I. Por fim, a subseção 5.2.3 avalia poucos marcadores escolhidos de antemão pela literatura, e a subseção 5.2.4 reúne os resultados.

5.2.1 Protocolo A: segmentos de 5 minutos

5.2.1.1 Comparação univariada

Dos 44 resumos por paciente, oito apresentaram diferença entre casos e controles com $p < 0{,}05$ no teste de Mann-Whitney (Tabela 25). Com 44 testes, cerca de dois resultados dessa ordem seriam esperados apenas por acaso. Após a correção de Benjamini-Hochberg, três permaneceram significativos: o desvio-padrão e a média da potência HF e o desvio-padrão da frequência cardíaca entre os segmentos. Os dois desvios-padrão — da potência HF e da frequência cardíaca — sobrevivem também à correção de Bonferroni.

A direção das diferenças contraria a leitura clássica da VFC. Os casos apresentaram maior potência HF e maior razão SD1/SD2, isto é, mais variabilidade de curto prazo, e menor variação da frequência cardíaca ao longo do registro. Em pacientes com insuficiência cardíaca, variabilidade de curto prazo elevada pode refletir um ritmo errático, com batimentos ectópicos

Tabela 25 – Marcadores do protocolo A com $p < 0{,}05$ na comparação entre casos e controles

Marcador	Controles	Casos	p
Potência HF, desvio-padrão (u.a.)	0,01	0,02	0,001
Frequência cardíaca, desvio-padrão (bpm)	7,84	6,28	0,001
Potência HF, média (u.a.)	0,01	0,02	0,001
SD1/SD2, média (adimensional)	0,46	0,56	0,006
LF/HF, média (adimensional)	2,07	1,50	0,008
Entropia amostral, média (adimensional)	1,10	0,97	0,013
Amplitude da derivação Y, média (mV)	0,78	0,95	0,030
Entropia amostral, desvio-padrão (adim.)	0,45	0,39	0,034

Fonte: elaborado pelo autor (2026). Valores são medianas em cada grupo. u.a.: unidades arbitrárias; o NeuroKit2 normaliza o espectro de potência pelo seu valor máximo, de modo que as potências LF e HF são relativas. bpm: batimentos por minuto. Média e desvio-padrão referem-se aos segmentos de 5 minutos de cada paciente.

e irregularidades não removidos pela correção de artefatos, e não um tônus vagal preservado. Essa interpretação é coerente com a proporção de intervalos irregulares, maior nos casos (4,80 % contra 2,87 %; $p = 0{,}077$), e com a concentração de valores extremos de SD1 entre os casos, descrita na subseção 4.5.2.

5.2.1.2 Modelos

A Tabela 26 apresenta o desempenho dos modelos. Os marcadores, sozinhos, alcançaram AUC entre 0,585 e 0,624, com intervalos de confiança que excluem o acaso por pequena margem. Os melhores resultados vieram dos modelos que reduzem a dimensão do problema — a análise de componentes principais e a floresta aleatória —, e não das regressões penalizadas sobre as 44 variáveis. Nenhum modelo baseado apenas em marcadores alcançou o modelo clínico, de AUC 0,661.

Tabela 26 – Desempenho dos modelos sobre os marcadores do protocolo A

Modelo	Variáveis	AUC [IC 95 %]	Partições	AUPRC
Clínicas (referência)	6	0,661 [0,577–0,741]	0,673 ± 0,114	0,233
Marcadores, logística L2	44	0,589 [0,507–0,671]	0,595 ± 0,066	0,180
Marcadores, logística L1	44	0,585 [0,503–0,666]	0,588 ± 0,044	0,163
Marcadores, PCA (4) + logística	44	0,624 [0,535–0,708]	0,623 ± 0,052	0,232
Marcadores, floresta aleatória	44	0,621 [0,537–0,701]	0,627 ± 0,025	0,184
Clínicas + marcadores, L2	50	0,672 [0,597–0,745]	0,679 ± 0,099	0,201
Clínicas + marcadores, L1	50	0,681 [0,604–0,756]	0,690 ± 0,065	0,191

Fonte: elaborado pelo autor (2026). Partições: média ± desvio-padrão da AUC nas cinco partições. AUPRC de referência (acaso): 0,106.

Somar os marcadores às variáveis clínicas elevou a AUC de 0,661 para 0,672 e 0,681,

mas as diferenças não foram distinguíveis de zero: $+0{,}010$ [$-0{,}056$; $+0{,}086$] com penalização L2 e $+0{,}020$ [$-0{,}047$; $+0{,}095$] com L1.

5.2.1.3 Número reduzido de marcadores e otimismo da seleção

A Tabela 27 compara as duas formas de escolher poucos marcadores descritas na subseção 4.6.3. A partir da análise univariada da coorte inteira, foram escolhidos a média da potência HF, o desvio-padrão da frequência cardíaca, a média da entropia amostral e a média da razão SD1/SD2. Todos os modelos da tabela são regressões logísticas com penalização L2 ($C = 1$). Seguindo os critérios da subseção 4.6.3 — significância no teste de Mann-Whitney, interpretação fisiológica e baixa redundância —, foram deixados de fora, entre os oito marcadores da Tabela 25, o desvio-padrão da potência HF e a razão LF/HF, redundantes com a média da potência HF; o desvio-padrão da entropia amostral, redundante com a sua média; e a amplitude da derivação Y, que depende da posição dos eletrodos e do biotipo do paciente, e não da atividade elétrica associada ao risco. Esses quatro marcadores alcançaram AUC de 0,627, e os dois primeiros, isoladamente, 0,647. Somados às variáveis clínicas, produziram os maiores valores deste trabalho, 0,684 e 0,689.

Tabela 27 – Efeito da forma de seleção dos marcadores no protocolo A

Seleção	Variáveis	Modelo	AUC [IC 95 %]	Δ sobre clínicas [IC 95 %]
Coorte inteira	4 marcadores[a]	Logística L2	0,627 [0,541–0,710]	—
Coorte inteira	2 marcadores[b]	Logística L2	0,647 [0,559–0,727]	—
Coorte inteira	clínicas + 4 marcadores[a]	Logística L2	0,684 [0,601–0,762]	$+0{,}023$ [$-0{,}027$; $+0{,}078$]
Coorte inteira	clínicas + 2 marcadores[b]	Logística L2	0,689 [0,607–0,769]	$+0{,}027$ [$-0{,}022$; $+0{,}081$]
Dentro da partição	4 marcadores[c]	Logística L2	0,580 [0,497–0,660]	—
Dentro da partição	6 variáveis[d]	Logística L2	0,640 [0,553–0,726]	$-0{,}021$ [$-0{,}094$; $+0{,}060$]

Fonte: elaborado pelo autor (2026). Logística L2 com $C = 1$, classes ponderadas, imputação pela mediana e padronização ajustadas no treinamento de cada partição. [a]Média da potência HF, desvio-padrão da frequência cardíaca, média da entropia amostral e média da razão SD1/SD2. [b]Média da potência HF e desvio-padrão da frequência cardíaca. [c]Os quatro, entre os 44 marcadores, com maior estatística F no treinamento de cada partição. [d]As seis, entre as seis variáveis clínicas e os 44 marcadores, com maior estatística F no treinamento de cada partição.

Quando a seleção foi refeita dentro de cada partição, sem acesso ao desfecho dos pacientes de teste, a AUC dos quatro marcadores caiu para 0,580, com intervalo que inclui o acaso. Quando as seis variáveis foram escolhidas dentro da partição entre as clínicas e os marcadores, a AUC de 0,640 ficou abaixo do modelo clínico isolado. A diferença de cerca de 0,05 entre as duas formas de seleção estima o otimismo introduzido por escolher os marcadores olhando o desfecho de toda a coorte. Os valores obtidos com seleção dentro da partição são, por

isso, os que melhor representam o desempenho esperado em pacientes novos.

5.2.2 Protocolo B: segmentos de 30 segundos

5.2.2.1 Comparação dos marcadores: segmento ou paciente como unidade

Antes de qualquer modelo, verificou-se, marcador a marcador, se os valores dos casos diferem dos valores dos controles. Para isso, é preciso decidir o que conta como uma observação. No protocolo B, cada paciente tem cerca de 636 segmentos de 30 segundos, e há duas formas de fazer a comparação:

- *por segmento*: cada um dos 328 807 segmentos entra como uma observação, com o rótulo do seu paciente;
- *por paciente*: os segmentos de cada paciente são primeiro resumidos pela média, e a comparação é feita entre os 55 valores dos casos e os 462 valores dos controles.

A forma correta é a segunda. Os segmentos de um mesmo paciente não são observações independentes: repetem a mesma pessoa, o mesmo coração e o mesmo desfecho. Contá-los separadamente equivale a fingir que a amostra tem 328 807 pacientes, quando tem 517. Esse erro é chamado de *pseudorreplicação* (subseção 3.7.5).

O efeito do erro aparece no valor-p. O valor-p indica quão provável seria observar uma diferença do tamanho encontrada se casos e controles fossem, na verdade, iguais; abaixo de 0,05, a diferença é considerada significativa. Como o valor-p diminui à medida que o número de observações cresce, multiplicar artificialmente as observações torna significativas diferenças pequenas demais para ter valor prático. A Tabela 28 mostra o resultado, obtido na primeira versão da extração (anterior à correção pelos intervalos NN), com o teste de Mann-Whitney.

Tabela 28 – Número de marcadores, entre 24, com diferença significativa entre casos e controles segundo a unidade de análise

Análise	Marcadores com diferença significativa
Por segmento ($n = 328\,807$), $p < 0{,}05$	22
Por paciente ($n = 517$), $p < 0{,}05$	2
Por paciente, Benjamini-Hochberg	0
Por paciente, Bonferroni	0

Fonte: elaborado pelo autor (2026). Teste de Mann-Whitney. Por segmento: cada segmento de 30 s conta como uma observação (análise incorreta, incluída para comparação). Por paciente: cada paciente conta uma vez, com a média de seus segmentos. Benjamini-Hochberg e Bonferroni: correções para os 24 testes feitos ao mesmo tempo.

Contando os segmentos como observações, 22 dos 24 marcadores pareceriam dife-

rentes entre casos e controles. Contando cada paciente uma única vez, apenas dois — a razão SD1/SD2 e a amplitude da derivação Y — tiveram $p < 0{,}05$. Como 24 testes foram feitos ao mesmo tempo, espera-se que cerca de um deles fique abaixo de 0,05 apenas por acaso; as correções de Benjamini-Hochberg e de Bonferroni ajustam os valores-p para isso, e, após elas, nenhum marcador permaneceu significativo.

A conclusão é que, no nível correto de análise, nenhum marcador dos segmentos de 30 segundos separa, sozinho, os pacientes que sofreram morte súbita dos demais; a aparente significância da análise por segmento é consequência do número inflado de observações. A mesma análise identificou 26 pares de marcadores redundantes, isto é, que medem praticamente a mesma coisa, como o RMSSD e o SD1 (correlação de 0,97), o que é esperado pela relação algébrica entre ambos (Equação 3.4).

5.2.2.2 Modelos treinados sobre cada segmento

Há também duas formas de treinar um modelo com os segmentos. Na primeira, apresentada adiante, cada paciente é resumido em uma única linha de marcadores e o modelo aprende com 517 linhas. Na segunda, apresentada aqui, o modelo aprende diretamente com os segmentos: cada segmento de 30 segundos é uma linha de treinamento, com os seus 24 marcadores e o rótulo do paciente a que pertence (1 para morte súbita, 0 para os demais). Assim, os cerca de 636 segmentos de um paciente com morte súbita são todos rotulados como 1, e os de um sobrevivente, todos como 0.

Na avaliação, o modelo atribui uma probabilidade de morte súbita a cada segmento do paciente de teste, e a probabilidade do paciente é a média das probabilidades de seus segmentos (Equação 3.24). A AUC é então calculada sobre os 517 pacientes, e não sobre os segmentos, para não repetir o problema descrito na seção anterior. A divisão em partições também é feita por paciente, de modo que nenhum segmento de um paciente de teste é visto no treinamento.

Os resultados estão na Tabela 29. Os quatro modelos ficaram entre 0,53 e 0,56, e todos os intervalos de confiança incluem 0,5, o valor do acaso. Treinar com centenas de milhares de segmentos, portanto, não fez os marcadores de 30 segundos distinguirem os pacientes de alto risco: o número de exemplos aumenta, mas a informação sobre o desfecho continua sendo a dos 517 pacientes.

Tabela 29 – Modelos treinados sobre cada segmento de 30 segundos e avaliados por paciente

Modelo	AUC [IC 95 %]	Partições
Logística L2	0,563 [0,461–0,663]	0,569 ± 0,079
PCA (6) + logística	0,532 [0,442–0,616]	0,537 ± 0,031
Floresta aleatória	0,564 [0,472–0,650]	0,576 ± 0,094
Gradient boosting	0,549 [0,451–0,636]	0,559 ± 0,114

Fonte: elaborado pelo autor (2026). Cada segmento é uma linha de treinamento, com o rótulo do seu paciente; a probabilidade do paciente é a média das probabilidades de seus segmentos, e a AUC é calculada sobre os 517 pacientes. PCA (6): seis componentes principais.

5.2.2.3 Modelos sobre os resumos por paciente

A Tabela 30 apresenta as doze configurações avaliadas sobre os resumos por paciente da extração corrigida. Onze delas tiveram intervalo de confiança que inclui 0,5. A única exceção, a análise de componentes principais sobre o conjunto B, com AUC de 0,619 [0,537–0,700], é a melhor de doze tentativas e deve ser interpretada com a correspondente cautela. A versão da extração anterior à correção NN produziu o mesmo quadro, com o melhor resultado em 0,583 [0,483–0,674].

Tabela 30 – Modelos sobre os resumos por paciente dos segmentos de 30 segundos (extração corrigida)

Conjunto	Variáveis	Logística L2	Logística L1	PCA (4) + logística	Floresta aleatória
A (mediana)	32	0,552	0,550	0,563	0,532
B (A + dispersão e fração)	64	0,540	0,548	0,619	0,562
C (todos os resumos)	122	0,545	0,550	0,548	0,582

Fonte: elaborado pelo autor (2026). Valores de AUC das predições fora da partição.

Na comparação univariada dos 122 resumos, sete apresentaram $p < 0{,}05$, número próximo do esperado por acaso, e nenhum permaneceu significativo após a correção de Benjamini-Hochberg. Os menores valores-p concentraram-se, porém, em um padrão consistente: medidas de dispersão ao longo do registro foram menores nos casos, como o intervalo interquartil do QT (35 contra 45 ms; $p < 0{,}001$; $q = 0{,}083$) e o da frequência cardíaca (9,9 contra 11,5 bpm; $p = 0{,}004$). O mesmo padrão apareceu no protocolo A, no qual o desvio-padrão da frequência cardíaca entre os segmentos foi um dos três marcadores que resistiram à correção para comparações múltiplas.

5.2.3 Marcadores pré-especificados (segmentos de 30 segundos)

Nesta análise, os dois marcadores pré-especificados — variação da frequência cardíaca média ao longo do dia e carga de ectopia — foram calculados em cada derivação, e cada versão foi avaliada em um modelo próprio, com os dois marcadores daquela derivação: um modelo com os valores da derivação X, outro com os da Y, outro com os da Z e um quarto com os da derivação de melhor qualidade em cada segmento (a de maior fração de intervalos NN). As derivações não foram somadas em um mesmo modelo. Sozinhos, os dois marcadores alcançaram AUC entre 0,635 e 0,660 conforme a derivação — 0,647 [0,563–0,726] na derivação de melhor qualidade —, próximas das seis variáveis clínicas. Os casos apresentaram menor variação da frequência ao longo do dia (desvio-padrão de 7,0 contra 8,5 bpm) e maior carga de ectopia. Quando todos os marcadores foram usados com seleção L1, o desempenho caiu à medida que o número de colunas cresceu: de 0,68 com 8 a 10 colunas para 0,57 com 138, efeito do sobreajuste com 33 casos de treinamento.

5.2.4 Síntese

A Tabela 31 reúne os principais resultados. Os marcadores extraídos do ECG contêm informação sobre o desfecho, mas essa informação é fraca: nos melhores casos, a AUC situou-se entre 0,60 e 0,66, e cai para perto do acaso quando muitos marcadores são usados ou quando a escolha é feita sem acesso ao desfecho dos pacientes de teste. Os dois marcadores pré-especificados alcançaram 0,647, 0,085 acima da melhor rede do Cenário I (0,562), e ficaram próximos das seis variáveis clínicas (0,661). O sinal mais consistente entre os dois protocolos foi a menor variação da frequência cardíaca ao longo do registro entre os pacientes que sofreram MSC.

Tabela 31 – Síntese dos resultados com marcadores eletrocardiográficos

Modelo	AUC [IC 95 %]
Clínicas (referência)	0,661 [0,577–0,741]
Protocolo A, PCA (4) + logística	0,624 [0,535–0,708]
Protocolo A, 4 marcadores com seleção dentro da partição	0,580 [0,497–0,660]
Protocolo A, clínicas + marcadores (L1)	0,681 [0,604–0,756]
Protocolo B, por segmento (melhor de quatro)	0,564 [0,472–0,650]
Protocolo B, por paciente (melhor de doze)	0,619 [0,537–0,700]
Dois marcadores pré-especificados (30 s)	0,647 [0,563–0,726]

Fonte: elaborado pelo autor (2026).

Swee *et al.* (2026) relatam, na mesma base, AUC de 0,682 $\pm$ 0,030 com um modelo apenas de ECG sobre marcadores de segmentos de 30 segundos. A comparação direta é limitada: aquele trabalho utilizou 746 pacientes, sem restrição ao ritmo sinusal e com critérios de exclusão distintos, e reporta a média entre partições, enquanto a métrica principal deste trabalho é a AUC das predições agrupadas. Na mesma métrica, a média entre partições, os modelos por segmento deste trabalho alcançaram entre 0,537 e 0,576.

5.3 Cenário III: variáveis clínicas e combinação com o ECG

5.3.1 Variáveis clínicas e exames

As seis variáveis clínicas, em regressão logística, previram a MSC com AUC de 0,661 [0,577–0,741] (Tabela 26), valor superior ao de todas as redes do Cenário I e próximo ao dos dois marcadores pré-especificados do Cenário II. Entre os exames do estudo, o ecocardiograma foi o grupo mais informativo: sozinho, alcançou AUC de 0,714 e, somado às variáveis clínicas, 0,720 (diferença de +0,058, $p = 0{,}072$). O Pro-BNP acrescentou +0,047 ($p = 0{,}054$), enquanto o laudo do ECG de repouso (+0,022) e as medidas do Holter tabuladas pelo estudo (+0,012) pouco acrescentaram. As variáveis clínicas somadas a todos os exames alcançaram 0,733 [0,656–0,804], o maior valor deste trabalho, e os exames sem as variáveis clínicas, 0,738.

5.3.2 Combinação com os marcadores do ECG

Somar os marcadores do protocolo A às variáveis clínicas elevou a AUC de 0,661 para 0,672 com penalização L2 e 0,681 [0,604–0,756] com L1 (Tabela 26), diferenças de +0,010 e +0,020 não distinguíveis de zero. Com os dois marcadores pré-especificados, a AUC ficou entre 0,679 e 0,683 nas quatro versões (derivações X, Y e Z e a derivação de melhor qualidade), ganho de 0,014 a 0,017 sobre as variáveis clínicas, também não significativo. Os marcadores do ECG acrescentaram, portanto, um ganho pequeno e consistente às variáveis clínicas, que não atingiu significância estatística com os pacientes disponíveis.

5.3.3 Combinação com o sinal: rede profunda com variáveis clínicas concatenadas

A rede com concatenação combina o extrator da ResNet-18 com um ramo que recebe seis variáveis clínicas — idade, sexo, classe funcional da NYHA, ondas Q, taquicardia

ventricular não sustentada e taquiarritmia supraventricular paroxística —, totalizando 3 987 041 parâmetros, dos quais 10 656 pertencem ao ramo clínico. A Tabela 32 compara as três estratégias de treinamento descritas na subseção 4.7.3.1.

Tabela 32 – Desempenho da rede com concatenação segundo a estratégia de treinamento do extrator de sinal

Estratégia	Janela	AUC partições	AUC fora da partição [IC 95 %]
Treinamento conjunto	2 min	0,534 ± 0,090	0,516 [0,433–0,603]
Taxa reduzida no extrator	2 min	0,578 ± 0,046	0,579 [0,492–0,669]
Extrator congelado[a]	2 min	0,572 ± 0,043	0,577 [0,491–0,659]
Treinamento conjunto	10 s	0,492 ± 0,105	0,491 [0,409–0,576]

Fonte: elaborado pelo autor (2026). [a] 142 241 parâmetros treináveis; o extrator de sinal permanece com os pesos iniciais.

O resultado é informativo justamente pelo contraste entre as estratégias. Quando o extrator de sinal é congelado, a rede ajusta apenas o ramo clínico e o classificador, e a AUC chega a 0,577. Quando o extrator aprende com taxa reduzida, o resultado é praticamente o mesmo (0,579). Quando o extrator é treinado livremente, junto com o restante da rede, a AUC cai para 0,516. Ou seja, o desempenho da rede com concatenação vem das variáveis clínicas, e o sinal, quando treinado, introduz variabilidade que prejudica a discriminação em vez de acrescentar informação. Para referência, o modelo logístico sobre as variáveis clínicas, sem nenhuma informação do sinal, obteve 0,661 [0,577–0,741] (Tabela 26).

5.3.4 Síntese dos três cenários

A Tabela 33 reúne o melhor resultado de cada cenário. O processamento do ECG com extração de características superou o aprendizado profundo sobre o sinal bruto, e os melhores modelos combinaram as variáveis clínicas aos dados extraídos do ECG ou aos exames. Combinadas ao sinal bruto, nas redes com concatenação, as variáveis clínicas tiveram desempenho inferior ao que obtiveram sozinhas.

Tabela 33 – Melhor resultado de cada cenário na predição de MSC

Cenário	Modelo	AUC [IC 95 %]
I	ResNet-18 mínima, janelas de 5,12 s	0,562 [0,475–0,642]
II	Dois marcadores pré-especificados (30 s)	0,647 [0,563–0,726]
II	44 marcadores, PCA (4) + logística (5 min)	0,624 [0,535–0,708]
III	Seis variáveis clínicas	0,661 [0,577–0,741]
III	Clínicas + marcadores (L1)	0,681 [0,604–0,756]
III	ResNet-18 + clínicas concatenadas (taxa reduzida)	0,579 [0,492–0,669]
III	Clínicas + todos os exames	0,733 [0,656–0,804]

Fonte: elaborado pelo autor (2026).

6 CONCLUSÕES E TRABALHOS FUTUROS

Esta dissertação investigou cenários de predição da MSC em pacientes com insuficiência cardíaca crônica, com base no uso do sinal de ECG Holter de 24 horas puro, dos parâmetros extraídos do ECG e de variáveis clínicas. Sobre os 517 pacientes em ritmo sinusal da base MUSIC, com 55 casos de MSC em quatro anos de acompanhamento, foram comparados três cenários no mesmo protocolo de validação cruzada por paciente: (I) redes neurais profundas que recebem como entrada o sinal de ECG puro; (II) pré-processamento do sinal, extração de características e modelos de aprendizado de máquina clássico; e (III) modelos baseados em variáveis clínicas, isoladas e combinadas aos dados extraídos do ECG.

6.1 Conclusões

A Tabela 34 reúne os três melhores resultados de cada cenário, todos avaliados nos mesmos 517 pacientes, nas mesmas cinco partições e pela AUC das predições fora da partição.

Tabela 34 – Os três melhores resultados de cada cenário

Cenário		Modelo	Entrada	AUC [IC 95 %]
I	1.º	ResNet-18 mínima	ECG bruto, janelas de 5,12 s	0,562 [0,475–0,642]
	2.º	CNN configurada pelo Optuna	ECG bruto, janelas de 1 min	0,556 [0,464–0,647]
	3.º	CNN mínima	ECG bruto, janelas de 10 s	0,554 [0,467–0,634]
II	1.º	Logística L2	2 marcadores pré-especificados[a] (30 s)	0,647 [0,563–0,726]
	2.º	PCA (4) + logística	44 marcadores, protocolo A (5 min)	0,624 [0,535–0,708]
	3.º	PCA (4) + logística	64 resumos, protocolo B (30 s)	0,619 [0,537–0,700]
III	1.º	Logística L2	Exames do estudo[b]	0,738 [0,666–0,809]
	2.º	Logística L2	Clínicas + exames do estudo[b]	0,733 [0,656–0,804]
	3.º	Logística L2	Clínicas + ecocardiograma	0,720 [0,640–0,789]

Fonte: elaborado pelo autor (2026). [a]Desvio-padrão da frequência cardíaca entre os segmentos e carga de ectopia, na derivação de melhor qualidade; as versões calculadas nas derivações X, Y e Z ficaram entre 0,635 e 0,660 e foram contadas como um único modelo. Os resultados com marcadores escolhidos observando o desfecho de toda a coorte, otimistas por construção, não foram considerados. [b]Ecocardiograma, Pro-BNP, laudo do ECG de repouso e medidas do Holter tabuladas pelo estudo. Referências: seis variáveis clínicas, 0,661 [0,577–0,741]; acaso, 0,5.

No Cenário I, as redes convolucionais, residuais e com atenção, treinadas diretamente sobre o sinal bruto para prever a MSC, obtiveram AUC entre 0,48 e 0,56. Os três melhores resultados vieram de redes pequenas — a ResNet-18 mínima (0,562), a CNN configurada pela busca de hiperparâmetros (0,556) e a CNN mínima (0,554) —, separados por menos de 0,01 e com intervalos de confiança que incluem o acaso. Não houve relação com a capacidade da rede, com a duração da janela ou com a arquitetura: redes maiores, como a ResNet-50 e a ResNet-18

com *Transformer*, ficaram entre 0,49 e 0,54. Quando a restrição ao ritmo sinusal foi removida, a melhor rede passou a discriminar acima do acaso, o que mostra que o procedimento aprende quando há um padrão reconhecível no sinal — no caso, a fibrilação atrial — e justifica a restrição adotada.

No Cenário II, os modelos baseados em parâmetros extraídos do ECG obtiveram desempenho superior ao do Cenário I nos três primeiros lugares. O melhor resultado veio de apenas dois marcadores escolhidos de antemão com base na literatura — a variação da frequência cardíaca ao longo do dia e a carga de ectopia —, com AUC de 0,647 [0,563–0,726], 0,085 acima da melhor rede do Cenário I. Os dois seguintes reduziram os marcadores a quatro componentes principais: 0,624 com os 44 marcadores dos segmentos de 5 minutos e 0,619 com os resumos dos segmentos de 30 segundos. Os três superam a melhor rede, mas o ganho não atingiu significância estatística. Os resultados indicam que a informação está concentrada em poucos marcadores ligados à frequência cardíaca: quando muitos marcadores entram no modelo, ou quando são selecionados sem acesso ao desfecho dos pacientes de teste, a AUC cai para perto de 0,58. Escolher poucos marcadores observando o desfecho de toda a coorte eleva a AUC em cerca de 0,05, otimismo que desaparece quando a escolha é feita apenas no treinamento.

No Cenário III, os três melhores resultados de todo o trabalho vieram dos exames do estudo: sozinhos, alcançaram 0,738 [0,666–0,809]; somados às seis variáveis clínicas, 0,733 [0,656–0,804]; e, considerando apenas o ecocardiograma somado às variáveis clínicas, 0,720 [0,640–0,789]. As seis variáveis clínicas sozinhas obtiveram 0,661 [0,577–0,741], valor superior ao de todas as redes do Cenário I. Na comparação entre o modelo clínico e o modelo clínico somado ao ECG, os marcadores acrescentaram um ganho pequeno e consistente — 0,681 [0,604–0,756] com os marcadores do protocolo A e entre 0,679 e 0,683 com os dois marcadores pré-especificados —, que não atingiu significância estatística. Somadas ao sinal bruto, nas redes com concatenação, as variáveis clínicas tiveram desempenho inferior ao que obtiveram sozinhas (no máximo 0,579).

Em síntese, as técnicas de processamento do ECG com extração de características produziram preditores de MSC superiores aos do aprendizado profundo aplicado ao sinal bruto, e os melhores modelos combinaram as variáveis clínicas com os dados extraídos do ECG ou com os exames dos pacientes.

6.2 Comparação com os trabalhos relacionados

O Quadro 1 compara os resultados deste trabalho com os dos trabalhos relacionados. Swee *et al.* (2026) relatam, na mesma base, AUC de 0,682 ± 0,030 apenas com o ECG, valor acima dos obtidos com os marcadores neste trabalho. Como aquele estudo usa outra coorte, outra derivação e outra métrica, a comparação direta não é possível.

Para separar o efeito da coorte do efeito do método, a extração do Cenário II foi repetida nas condições de Swee *et al.* (2026): os mesmos critérios de seleção daquele trabalho — Holter disponível, desfecho de sobrevivência, morte súbita ou morte por falência de bomba, ausência de dispositivo implantável prévio e de transplante —, que resultam em 746 pacientes e 74 mortes súbitas, sem restrição de ritmo; apenas a derivação Y; segmentos de 30 segundos contíguos, cerca de 2 500 por paciente (1 884 569 no total); e filtro passa-faixa Butterworth de quarta ordem do NeuroKit2. Os marcadores foram calculados pelo mesmo extrator do protocolo B e resumidos por paciente pela média e pelo desvio-padrão, e os modelos foram os mesmos deste trabalho. A Tabela 35 apresenta os resultados na métrica de Swee *et al.* (2026), a média e o desvio-padrão da AUC entre as cinco partições.

Tabela 35 – Replicação nas condições de Swee *et al.* (2026): 746 pacientes, derivação Y, segmentos de 30 segundos contíguos

Variáveis	Modelo	AUC partições	AUC fora da partição [IC 95 %]
44 marcadores	Logística L1	0,605 ± 0,088	0,587 [0,516–0,657]
44 marcadores	Logística L2	0,611 ± 0,094	0,602 [0,534–0,665]
44 marcadores	PCA (4) + logística	0,580 ± 0,099	0,571 [0,498–0,644]
44 marcadores	Floresta aleatória	0,566 ± 0,113	0,559 [0,488–0,633]
4 marcadores pré-especificados[a]	Logística L2	0,659 ± 0,078	0,657 [0,595–0,719]
Seis variáveis clínicas	Logística L2	0,659 ± 0,082	0,657 [0,592–0,724]
Clínicas + 4 marcadores[a]	Logística L2	0,694 ± 0,102	0,683 [0,618–0,748]
Swee *et al.* (2026), apenas ECG		0,682 ± 0,030	—

Fonte: elaborado pelo autor (2026). [a]Desvio-padrão da frequência cardíaca entre os segmentos, carga de ectopia, número médio de dupletes e maior pausa média, definidos de antemão (subseção 4.6.4).

Os resultados reproduzem, na coorte de Swee *et al.* (2026), o quadro observado nos 517 pacientes em ritmo sinusal. Com os 44 marcadores, a AUC média entre partições ficou entre 0,566 e 0,611, e o melhor modelo apenas de ECG foi o de quatro marcadores pré-especificados, com 0,659 ± 0,078, cerca de 0,02 abaixo do valor de referência. Segmentos contíguos e o filtro de quarta ordem não alteraram o desempenho: a mesma análise com um segmento a cada 2 minutos e filtro de terceira ordem produziu 0,606 ± 0,112 com logística L1 e 0,656 ± 0,090

com os quatro marcadores. A diferença restante não parece, portanto, decorrer da extração dos marcadores, mas do modelo: Swee *et al.* (2026) não resumem os segmentos por paciente, e sim processam a sequência de segmentos das 24 horas com uma rede convolucional temporal em um arcabouço de aprendizado de múltiplas instâncias, que pode capturar a evolução dos marcadores ao longo do registro. Outra diferença está na dispersão entre partições, de $\pm$0,030 naquele trabalho contra $\pm$0,08 a $\pm$0,11 aqui, o que sugere um esquema de validação diferente, não descrito em detalhe no material disponível.

O desempenho das redes treinadas sobre o sinal é coerente com o obtido por Kim *et al.* (2025) no subgrupo de insuficiência cardíaca (0,60), mesmo com um codificador pré-treinado em grandes bases. O valor de 0,73 de Ramírez *et al.* (2017) foi obtido sem validação separada, condição que tende a superestimar a discriminação.

Quadro 1 – Comparação entre os trabalhos relacionados e esta dissertação

Trabalho	**Coorte**	**Entrada**	**Método e validação**	**Resultado principal**
Ramírez *et al.* (2017)	MUSIC, ritmo sinusal; 597 pacientes, 49 mortes súbitas	Marcadores do Holter (repolarização, turbulência) e clínicos	Cox com seleção regressiva; sem validação separada	Razão de risco 13,8 (alto contra baixo risco); AUC 0,73 na fração de ejeção reduzida
Swee *et al.* (2026)	MUSIC, sem restrição de ritmo; 746 pacientes, 74 mortes súbitas	Marcadores de segmentos de 30 s e clínicos	Rede convolucional temporal sobre a sequência de segmentos (múltiplas instâncias); validação cruzada	AUC 0,682 (apenas ECG, média entre partições)
Kim *et al.* (2025)	Coreia; infarto ou insuficiência cardíaca; 1 108 pacientes, 70 eventos	Holter de 24 h, derivação V1	Codificador pré-treinado e congelado; validação cruzada em 5 partições	AUC 0,74 na coorte completa; 0,60 no subgrupo de 223 pacientes com insuficiência cardíaca
Esta dissertação	MUSIC, ritmo sinusal; 517 pacientes, 55 mortes súbitas em 4 anos	Sinal bruto das três derivações; marcadores extraídos do ECG; variáveis clínicas e exames	Três cenários: redes profundas sobre o sinal; marcadores + aprendizado de máquina; clínicas e combinações; validação cruzada em 5 partições	Melhores AUC: 0,562 (I, redes); 0,647 (II, 2 marcadores); 0,738 (III, exames); 0,681 (clínicas + marcadores)

Fonte: elaborado pelo autor.

6.3 Limitações

A população tem 55 casos de MSC no total e 11 por conjunto de teste, o que torna os intervalos de confiança largos: diferenças de até 0,1 na AUC não podem ser detectadas com

segurança, como ocorreu com os ganhos observados nos Cenários II e III. A coorte é única, sem validação externa, e cada paciente tem um único registro de Holter. A busca de hiperparâmetros não usou validação cruzada aninhada, e as redes residuais foram treinadas com uma configuração anterior à das redes convolucionais. Por fim, o desfecho foi tratado como classificação binária em quatro anos, o que descarta a informação sobre o tempo até o evento e exclui os pacientes vivos com seguimento mais curto.

6.4 Trabalhos futuros

1. **Modelos sequenciais sobre os marcadores dos segmentos.** Em vez de resumir os segmentos de cada paciente pela média e pelo desvio-padrão, modelar a sequência de marcadores das 24 horas com redes temporais, como a rede convolucional temporal em aprendizado de múltiplas instâncias de Swee *et al.* (2026). A replicação nas condições daquele trabalho (Tabela 35) indicou que a diferença de desempenho está no modelo, e não na extração dos marcadores.
2. **Representações pré-treinadas e orientadas por atributos clínicos.** Treinar o extrator de características do sinal em bases grandes de ECG, ou orientá-lo a prever atributos clínicos disponíveis para todos os pacientes, e ajustar sobre a coorte apenas um classificador pequeno, como em Kim *et al.* (2025).
3. **Marcadores da repolarização.** Incluir os marcadores que Ramírez *et al.* (2017) identificaram como os mais informativos nesta coorte — alternância da onda T e restituição da morfologia da onda T —, que exigem delineação precisa e não foram calculados aqui.
4. **Análise de sobrevivência.** Modelar o tempo até o evento, com riscos competitivos entre morte súbita e morte por falência de bomba, o que aproveita todos os pacientes e todo o seguimento.
5. **Validação externa.** Avaliar os modelos em outra coorte de pacientes com insuficiência cardíaca e Holter de 24 horas, condição necessária para qualquer conclusão sobre generalização.

REFERÊNCIAS

BA, J. L.; KIROS, J. R.; HINTON, G. E. Layer normalization. **arXiv preprint arXiv:1607.06450**, 2016.

BARDY, G. H.; LEE, K. L.; MARK, D. B. *et al.* Amiodarone or an implantable cardioverter-defibrillator for congestive heart failure. **The New England Journal of Medicine**, v. 352, n. 3, p. 225–237, 2005.

BAZETT, H. C. An analysis of the time-relations of electrocardiograms. **Heart**, v. 7, p. 353–370, 1920.

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289–300, 1995.

BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

BRENNAN, M.; PALANISWAMI, M.; KAMEN, P. Do existing measures of Poincaré plot geometry reflect nonlinear features of heart rate variability? **IEEE Transactions on Biomedical Engineering**, v. 48, n. 11, p. 1342–1347, 2001.

BUTTERWORTH, S. On the theory of filter amplifiers. **Experimental Wireless and the Wireless Engineer**, v. 7, p. 536–541, 1930.

CLIFFORD, G. D.; AZUAJE, F.; MCSHARRY, P. E. (Ed.). **Advanced Methods and Tools for ECG Data Analysis**. Boston: Artech House, 2006.

DAVIS, J.; GOADRICH, M. The relationship between precision-recall and ROC curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.: s.n.], 2006. p. 233–240.

DOSOVITSKIY, A.; BEYER, L.; KOLESNIKOV, A.; WEISSENBORN, D.; ZHAI, X.; UNTERTHINER, T.; DEHGHANI, M.; MINDERER, M.; HEIGOLD, G.; GELLY, S.; USZKOREIT, J.; HOULSBY, N. An image is worth 16x16 words: transformers for image recognition at scale. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2021.

EFRON, B.; TIBSHIRANI, R. J. **An Introduction to the Bootstrap**. New York: Chapman & Hall, 1993.

EMRICH, J.; GARGANO, A.; KOKA, T.; MUMA, M. Physiology-informed ECG delineation based on peak prominence. In: **Proceedings of the 32nd European Signal Processing Conference (EUSIPCO)**. [S.l.: s.n.], 2024.

FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006.

GUSTAFSSON, F. Determining the initial states in forward-backward filtering. **IEEE Transactions on Signal Processing**, v. 44, n. 4, p. 988–992, 1996.

HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. **Radiology**, v. 143, n. 1, p. 29–36, 1982.

HANNUN, A. Y.; RAJPURKAR, P.; HAGHPANAHI, M.; TISON, G. H.; BOURN, C.; TURAKHIA, M. P.; NG, A. Y. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. **Nature Medicine**, v. 25, n. 1, p. 65–69, 2019.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification. In: **Proceedings of the IEEE International Conference on Computer Vision**. [S.l.: s.n.], 2015. p. 1026–1034.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. [S.l.: s.n.], 2016. p. 770–778.

HURLBERT, S. H. Pseudoreplication and the design of ecological field experiments. **Ecological Monographs**, v. 54, n. 2, p. 187–211, 1984.

IOFFE, S.; SZEGEDY, C. Batch normalization: accelerating deep network training by reducing internal covariate shift. In: **Proceedings of the 32nd International Conference on Machine Learning**. [S.l.: s.n.], 2015. (Proceedings of Machine Learning Research, v. 37), p. 448–456.

KAPOOR, S.; NARAYANAN, A. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, p. 100804, 2023.

KIM, J. Y.; KIM, K. G.; JOO, S.; CHANG, M.; KIM, J.; PARK, K.-M.; ON, Y. K.; KIM, J. S.; LEE, Y. S.; PARK, S.-J. Deep learning-based risk assessment and prediction of cardiac outcomes using single-lead 24-hour Holter-ECG in patients with heart failure or myocardial infarction. **Journal of Clinical Medicine**, v. 14, n. 20, p. 7209, 2025.

KIRANYAZ, S.; AVCI, O.; ABDELJABER, O.; INCE, T.; GABBOUJ, M.; INMAN, D. J. 1D convolutional neural networks and applications: a survey. **Mechanical Systems and Signal Processing**, v. 151, p. 107398, 2021.

KLEIGER, R. E.; MILLER, J. P.; BIGGER, J. T.; MOSS, A. J. Decreased heart rate variability and its association with increased mortality after acute myocardial infarction. **The American Journal of Cardiology**, v. 59, n. 4, p. 256–262, 1987.

KLIGFIELD, P.; GETTES, L. S.; BAILEY, J. J.; CHILDERS, R.; DEAL, B. J.; HANCOCK, E. W.; HERPEN, G. van; KORS, J. A.; MACFARLANE, P.; MIRVIS, D. M.; PAHLM, O.; RAUTAHARJU, P.; WAGNER, G. S. Recommendations for the standardization and interpretation of the electrocardiogram: part I: the electrocardiogram and its technology. **Circulation**, v. 115, n. 10, p. 1306–1324, 2007.

KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: **Proceedings of the 14th International Joint Conference on Artificial Intelligence**. [S.l.: s.n.], 1995. v. 2, p. 1137–1145.

LECUN, Y.; BOTTOU, L.; BENGIO, Y.; HAFFNER, P. Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, v. 86, n. 11, p. 2278–2324, 1998.

LIN, M.; CHEN, Q.; YAN, S. Network in network. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2014.

LIPPONEN, J. A.; TARVAINEN, M. P. A robust algorithm for heart rate variability time series artefact correction using novel beat classification. **Journal of Medical Engineering & Technology**, v. 43, n. 3, p. 173–181, 2019.

LOSHCHILOV, I.; HUTTER, F. SGDR: Stochastic gradient descent with warm restarts. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2019.

MAKOWSKI, D.; PHAM, T.; LAU, Z. J.; BRAMMER, J. C.; LESPINASSE, F.; PHAM, H.; SCHÖLZEL, C.; CHEN, S. H. A. NeuroKit2: A Python toolbox for neurophysiological signal processing. **Behavior Research Methods**, v. 53, n. 4, p. 1689–1696, 2021.

MANN, H. B.; WHITNEY, D. R. On a test of whether one of two random variables is stochastically larger than the other. **The Annals of Mathematical Statistics**, v. 18, n. 1, p. 50–60, 1947.

MARTÍN-YEBRA, A.; LUNA, A. Bayés de; VÁZQUEZ, R.; CAMINAL, P.; LAGUNA, P.; MARTÍNEZ, J. P. The MUSIC database: Sudden cardiac death in heart failure patients. In: **Computing in Cardiology**. [S.l.: s.n.], 2024. v. 51.

MARTIN-YEBRA, A.; MARTÍNEZ, J. P.; LAGUNA, P. **MUSIC (Sudden Cardiac Death in Chronic Heart Failure) (version 1.0.1)**. PhysioNet, 2025. RRID:SCR_007345. Disponível em: <https://physionet.org/content/music-sudden-cardiac-death/1.0.1/>.

NAIR, V.; HINTON, G. E. Rectified linear units improve restricted Boltzmann machines. In: **Proceedings of the 27th International Conference on Machine Learning**. [S.l.: s.n.], 2010. p. 807–814.

PEDUZZI, P.; CONCATO, J.; KEMPER, E.; HOLFORD, T. R.; FEINSTEIN, A. R. A simulation study of the number of events per variable in logistic regression analysis. **Journal of Clinical Epidemiology**, v. 49, n. 12, p. 1373–1379, 1996.

RAMÍREZ, J.; ORINI, M.; MINCHOLÉ, A.; MONASTERIO, V.; CYGANKIEWICZ, I.; LUNA, A. Bayés de; MARTÍNEZ, J. P.; LAGUNA, P.; PUEYO, E. Sudden cardiac death and pump failure death prediction in chronic heart failure by combining ECG and clinical markers in an integrated risk model. **PLoS ONE**, v. 12, n. 10, p. e0186152, 2017.

RIBEIRO, A. H.; RIBEIRO, M. H.; PAIXÃO, G. M. M.; OLIVEIRA, D. M.; GOMES, P. R.; CANAZART, J. A.; FERREIRA, M. P. S.; ANDERSSON, C. R.; MACFARLANE, P. W.; JR., W. M.; SCHÖN, T. B.; RIBEIRO, A. L. P. Automatic diagnosis of the 12-lead ECG using a deep neural network. **Nature Communications**, v. 11, p. 1760, 2020.

RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLoS ONE**, v. 10, n. 3, p. e0118432, 2015.

SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. Dropout: a simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

SWEE, S.; ADAM, I.; ZHENG, E. Y.; JI, E.; WANG, D.; SPEIER, W.; HSU, J.; CHANG, K.-W.; SHIVKUMAR, K.; PING, P. Multimodal integration of ambulatory ECG and clinical features for sudden cardiac death and pump failure death prediction. **medRxiv**, 2026. Disponível em: <https://doi.org/10.64898/2026.04.21.26351421>.

Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology. Heart rate variability: standards of measurement, physiological interpretation, and clinical use. **Circulation**, v. 93, n. 5, p. 1043–1065, 1996.

TOMASELLI, G. F.; ZIPES, D. P. What causes sudden death in heart failure? **Circulation Research**, v. 95, n. 8, p. 754–763, 2004.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2017. v. 30, p. 5998–6008.

YOUDEN, W. J. Index for rating diagnostic tests. **Cancer**, v. 3, n. 1, p. 32–35, 1950.

ZEPPENFELD, K.; TFELT-HANSEN, J.; RIVA, M. de *et al.* 2022 ESC guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. **European Heart Journal**, v. 43, n. 40, p. 3997–4126, 2022.