

UNIVERSIDADE FEDERAL DO CEARÁ

CENTRO DE CIÊNCIAS

DEPARTAMENTO DE COMPUTAÇÃO

PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIAS DA COMPUTAÇÃO

MESTRADO ACADÊMICO EM CIÊNCIAS DA COMPUTAÇÃO

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

FORTALEZA

2026

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciências da Computação do Programa de Pós-Graduação em Ciências da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Ciências da Computação. Área de Concentração: Ciências da Computação

Orientador: Prof. Dr. João Paulo do Vale Madeiro

Coorientador: José Maria da Silva Monteiro Filho

FORTALEZA

2026

DANIEL OLIVEIRA DOS SANTOS

TÍTULO DO TRABALHO

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciências da Computação do Programa de Pós-Graduação em Ciências da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Ciências da Computação. Área de Concentração: Ciências da Computação

Aprovada em:

BANCA EXAMINADORA

Prof. Dr. João Paulo do Vale Madeiro (Orientador)
Universidade Federal do Ceará (UFC)

José Maria da Silva Monteiro Filho (Coorientador)
Universidade Coorientador (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Dois (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Três (SIGLA)

Prof. Dr. Xxxxxxx Xxxxxx Xxxxxxx
Universidade do Membro da Banca Quatro (SIGLA)

À minha família, por sua capacidade de acreditar em mim e investir em mim. Mãe, seu cuidado e dedicação foi que deram, em alguns momentos, a esperança para seguir. Pai, sua presença significou segurança e certeza de que não estou sozinho nessa caminhada.

AGRADECIMENTOS

Ao Prof. Dr. Ricardo Silva Thé Pontes por me orientar em minha tese de doutorado.

Ao Prof. Dr. Tobias Rafael Fernandes Neto, coordenador do Laboratório de Sistemas Motrizes (LAMOTRIZ) onde este *template* foi desenvolvido.

Ao Doutorando em Engenharia Elétrica, Ednardo Moreira Rodrigues, e seu assistente, Alan Batista de Oliveira, aluno de graduação em Engenharia Elétrica, pela adequação do *template* utilizado neste trabalho para que o mesmo ficasse de acordo com as normas da biblioteca da Universidade Federal do Ceará (UFC).

Aos bibliotecários da Universidade Federal do Ceará: Francisco Edvander Pires Santos, Juliana Soares Lima, Izabel Lima dos Santos, Kalline Yasmin Soares Feitosa e Eliene Maria Vieira de Moura, pela revisão e discussão da formatação utilizada neste *template*.

Ao aluno Thiago Nascimento do curso de ciência da computação da Universidade Estadual do Ceará que elaborou o *template* do qual este trabalho foi adaptado para Universidade Federal do Ceará.

Ao Prof. Dr. Humberto de Andrade Carmona do Curso de Física da UFC pelo primeiro incentivo para o uso do LaTeX.

Ao aluno de graduação em engenharia elétrica e amigo, Lohan Costa por me apresentar a plataforma *ShareLatex* que depois migrou para a plataforma *OverLeaf*.

Aos amigos de laboratório, Felipe Bandeira, Renan Barroso e Roney Coelho, pelas discussões sobre os recursos do LaTeX.

Aos meus pais, irmãos e sobrinhos, que nos momentos de minha ausência dedicados ao estudo superior, sempre fizeram entender que o futuro é feito a partir da constante dedicação no presente!

Agradeço a todos os professores por me proporcionar o conhecimento não apenas racional, mas a manifestação do caráter e afetividade da educação no processo de formação profissional, por tanto que se dedicaram a mim, não somente por terem me ensinado, mas por terem me feito aprender.

E à Fundação Cearense de Apoio ao Desenvolvimento (Funcap), na pessoa do Presidente Tarcísio Haroldo Cavalcante Pequeno pelo financiamento da pesquisa de doutorado via bolsa de estudos.

"O sonho é que leva a gente para frente. Se a gente for seguir a razão, fica aquietado, acomodado."

(Ariano Suassuna)

RESUMO

Este trabalho investiga a predição de morte súbita cardíaca em pacientes com insuficiência cardíaca crônica a partir de eletrocardiograma (ECG) Holter de 24 horas. Os dados provêm da base MUSIC, disponível na plataforma PhysioNet, e compreendem sinais de três derivações ortogonais (X, Y e Z) amostrados a 200 Hz, além de variáveis clínicas e demográficas de 992 pacientes acompanhados em hospitais universitários espanhóis entre 2003 e 2008. Adotou-se um desenho caso-controle em que os casos correspondem a óbitos por morte súbita cardíaca documentada e os controles, a sobreviventes com seguimento completo de quatro anos, restrito a pacientes em ritmo sinusal, totalizando 517 indivíduos e 55 eventos. Três estratégias de modelagem foram comparadas sob o mesmo protocolo de avaliação. A primeira aplica aprendizado profundo diretamente ao sinal bruto, abrangendo onze configurações entre redes convolucionais, residuais, recorrentes e baseadas em atenção, com capacidade variando de 109 mil a 16 milhões de parâmetros, incluindo busca bayesiana de hiperparâmetros. A segunda extrai marcadores do sinal por processamento digital — variabilidade da frequência cardíaca, análise espectral e medidas morfológicas — com amostra em janelas de dois minutos a cada hora de registro, o que permite caracterizar também a variação desses marcadores ao longo do dia. A terceira utiliza apenas variáveis clínicas. Todos os modelos foram avaliados por validação cruzada estratificada em cinco partições, com divisão realizada no nível do paciente para evitar que segmentos de um mesmo indivíduo ocorram simultaneamente em treinamento e teste, limiar de decisão definido na partição de validação e intervalos de confiança estimados por reamostragem *bootstrap*. Os modelos aplicados ao sinal bruto apresentaram área sob a curva ROC entre 0,48 e 0,56, com intervalos de confiança compatíveis com o acaso em todas as configurações avaliadas. Os marcadores extraídos alcançaram 0,62 (IC 95%: 0,54–0,71) quando reduzidos por análise de componentes principais, procedimento que não utiliza informação do desfecho, e o melhor desempenho global foi obtido pela combinação de seis variáveis clínicas com dois marcadores de variabilidade da frequência cardíaca (0,69; IC 95%: 0,61–0,77). O ganho incremental do ECG sobre as variáveis clínicas isoladas não se mostrou estatisticamente demonstrável. Os resultados indicam que, em coortes com número reduzido de eventos, a extração de marcadores por processamento de sinal supera o aprendizado de representação a partir do sinal bruto, e que o poder estatístico disponível limita a detecção de efeitos de magnitude clinicamente realista.

Palavras-chave: Morte Súbita Cardíaca. ECG Holter. Aprendizado Profundo. Variabilidade da Frequência Cardíaca. Insuficiência Cardíaca. Estratificação de Risco.

ABSTRACT

This work investigates the prediction of sudden cardiac death in patients with chronic heart failure from 24-hour Holter electrocardiography (ECG). Data were obtained from the MUSIC database, available on the PhysioNet platform, comprising three orthogonal lead signals (X, Y and Z) sampled at 200 Hz, along with clinical and demographic variables from 992 patients followed at Spanish university hospitals between 2003 and 2008. A case-control design was adopted, in which cases correspond to documented sudden cardiac death and controls to survivors with complete four-year follow-up, restricted to patients in sinus rhythm, totalling 517 individuals and 55 events. Three modelling strategies were compared under the same evaluation protocol. The first applies deep learning directly to the raw signal, covering eleven configurations across convolutional, residual, recurrent and attention-based networks, with capacity ranging from 109 thousand to 16 million parameters, including Bayesian hyperparameter search. The second extracts signal-derived markers — heart rate variability, spectral analysis and morphological measures — sampled in five-minute windows at hourly intervals, which also allows characterising how these markers vary throughout the day. The third uses clinical variables only. All models were evaluated by five-fold stratified cross-validation with patient-level partitioning, decision thresholds defined on the validation split, and confidence intervals estimated by bootstrap resampling. Models applied to the raw signal achieved areas under the ROC curve between 0.48 and 0.56, with confidence intervals compatible with chance in every configuration. Extracted markers reached 0.62 (95% CI: 0.54–0.71) when reduced by principal component analysis, a procedure that does not use outcome information, and the best overall performance was obtained by combining six clinical variables with two heart rate variability markers (0.69; 95% CI: 0.61–0.77). The incremental gain of ECG over clinical variables alone was not statistically demonstrable. The results indicate that, in cohorts with a small number of events, signal-processing feature extraction outperforms representation learning from raw signals, and that the available statistical power limits the detection of clinically realistic effect sizes.

Keywords: Sudden Cardiac Death. Holter ECG. Deep Learning. Heart Rate Variability. Heart Failure. Risk Stratification.

LISTA DE FIGURAS

Figura 1 – Arquitetura da rede convolucional unidimensional 31
Figura 2 – Blocos residuais básico (tipo a) e de gargalo (tipo b) 35
Figura 3 – Fluxograma de seleção da coorte 49
Figura 4 – Fluxo da validação cruzada estratificada em 5 partições. As etapas 2–4 são repetidas para cada partição, com avaliação no nível do paciente. 60

LISTA DE TABELAS

Tabela 1 – Delimitação da coorte a partir da base MUSIC 22
Tabela 2 – Canais e comprimento das representações intermediárias das variantes da rede convolucional 31
Tabela 3 – Distribuição dos parâmetros das variantes da rede convolucional 33
Tabela 4 – Configurações das redes residuais avaliadas 36
Tabela 5 – Dimensões e campo receptivo das redes residuais para janela de 24 000 amostras 37
Tabela 6 – Marcadores calculáveis em segmentos de 5 minutos e de 30 segundos 43
Tabela 7 – Matriz de confusão de um classificador binário 44
Tabela 8 – Métricas derivadas da matriz de confusão 44
Tabela 9 – Fluxo de seleção da base MUSIC e disponibilidade dos registros de Holter. . 50
Tabela 10 – Parâmetros de representação do sinal 53
Tabela 11 – Hiperparâmetros de treinamento 54
Tabela 12 – Combinações avaliadas da rede convolucional 56
Tabela 13 – Arquiteturas de redes neurais avaliadas sobre o sinal de Holter 58
Tabela 14 – Protocolos de extração dos marcadores 61
Tabela 15 – Efeito do cálculo sobre intervalos NN nos marcadores de variabilidade (328 807 segmentos) 64
Tabela 16 – Parâmetros de representação do sinal 66
Tabela 17 – Hiperparâmetros de treinamento 67
Tabela 18 – Desempenho da rede convolucional por partição da validação cruzada . . . 71
Tabela 19 – Perdas de treinamento e validação no início e ao término do ajuste, por partição 71
Tabela 20 – Matriz de confusão agregada da rede convolucional 72
Tabela 21 – Desempenho da ResNet-18 reduzida em cada partição da validação cruzada 73
Tabela 22 – Evolução das perdas e da área sob a curva ROC (AUC) de validação na partição 0 74
Tabela 23 – Matriz de confusão agregada da ResNet-18 reduzida 75
Tabela 24 – Desempenho da ResNet-18 em configuração completa, por partição da validação cruzada 76
Tabela 25 – Comparação entre as configurações reduzida e completa da ResNet-18 . . . 77
Tabela 26 – Perdas de treinamento e validação no início e ao término do ajuste, por partição 78
Tabela 27 – Matriz de confusão agregada da ResNet-18 em configuração completa . . . 78

Tabela 28 – Desempenho da ResNet-18 com camada de atenção, por partição da validação cruzada 79
Tabela 29 – Perdas de treinamento e validação no início e ao término do ajuste, por partição 80
Tabela 30 – Matriz de confusão agregada da ResNet-18 com camada de atenção 81
Tabela 31 – Desempenho da ResNet-34 por partição da validação cruzada 82
Tabela 32 – Comparação entre as configurações da família ResNet com blocos básicos . 82
Tabela 33 – Matriz de confusão agregada da ResNet-34 83
Tabela 34 – Desempenho da ResNet-50 por partição da validação cruzada 85
Tabela 35 – Perdas de treinamento e validação no início e ao término do ajuste, por partição 86
Tabela 36 – Matriz de confusão agregada da ResNet-50 86
Tabela 37 – Desempenho da arquitetura CNN-LSTM sobre o exame de repouso, por partição 88
Tabela 38 – Comparação entre as modalidades de exame avaliadas 89
Tabela 39 – Matriz de confusão agregada da arquitetura CNN-LSTM sobre o exame de repouso 90
Tabela 40 – Marcadores do protocolo A com $p < 0{,}05$ na comparação entre casos e controles 91
Tabela 41 – Desempenho dos modelos sobre os marcadores do protocolo A 91
Tabela 42 – Efeito da forma de seleção dos marcadores no protocolo A 92
Tabela 43 – Marcadores significativos segundo a unidade de análise (24 marcadores) . . 93
Tabela 44 – Modelos treinados por segmento de 30 segundos e avaliados por paciente . . 93
Tabela 45 – Modelos sobre os resumos por paciente dos segmentos de 30 segundos (extração corrigida) 94
Tabela 46 – Síntese dos resultados com marcadores eletrocardiográficos 94
Tabela 47 – Desempenho das redes convolucionais segundo a capacidade e a duração da janela 95
Tabela 48 – Desempenho da ResNet-18 em três larguras 96
Tabela 49 – Desempenho das redes residuais segundo a profundidade 96
Tabela 50 – Desempenho das redes configuradas por busca de hiperparâmetros 97
Tabela 51 – Desempenho da rede de fusão segundo a estratégia de treinamento do extrator de sinal 99

LISTA DE ABREVIATURAS E SIGLAS

AP	precisão média
AUC	área sob a curva ROC
CNN	rede neural convolucional
ECG	eletrocardiograma
MSC	morte súbita cardíaca
MUSIC	*Muerte Súbita en Insuficiencia Cardiaca*
NYHA	*New York Heart Association*
RMSSD	raiz quadrada da média dos quadrados das diferenças entre intervalos NN adjacentes
SDNN	desvio-padrão dos intervalos NN
VFC	variabilidade da frequência cardíaca
VPP	valor preditivo positivo

LISTA DE SÍMBOLOS

$b_{c'}$	Termo de viés do filtro c'
B	Tamanho do lote de treinamento
B^*	Número de reamostragens *bootstrap*
C	Número de derivações do sinal (canais de entrada)
C'	Número de filtros de uma camada convolucional
d	Dimensão das representações no *Transformer*
d_k	Dimensão das consultas e das chaves
d_{ff}	Dimensão interna da rede alimentada adiante
E	Fator de expansão do bloco residual
f	Frequência
f_c	Frequência de corte
f_{inf}	Frequência de corte inferior
f_{sup}	Frequência de corte superior
$H(f)$	Resposta em frequência do filtro
i	Índice do paciente
J	Índice de Youden
K	Número de partições da validação cruzada
L	Comprimento do sinal, em amostras
L'	Comprimento da sequência após as camadas convolucionais
m	Índice da janela
M_i	Número de janelas do paciente i
n	Ordem do filtro de Butterworth
n_h	Número de cabeças de atenção
N	Número de pacientes da coorte
N_0	Número de controles
N_1	Número de casos

$\hat{p}_i$	Probabilidade estimada de óbito para o paciente i
$\hat{p}_{i,m}$	Probabilidade estimada para a m-ésima janela do paciente i
P	Número de canais do primeiro estágio da rede residual
r	Fator de agrupamento
t	Posição temporal no sinal
w_+	Peso da classe positiva na função de perda
y_i	Rótulo do paciente i
z_i	*Logit* do paciente i
$\mathbf{Q}, \mathbf{K}, \mathbf{V}$	Matrizes de consultas, chaves e valores
$\mathbf{S}$	Sinal de eletrocardiograma (ECG), matriz de C derivações por L amostras
$\mathbf{U}_Q, \mathbf{U}_K, \mathbf{U}_V, \mathbf{U}_O$	Matrizes de projeção da atenção
$\mathbf{x}$	Entrada de um bloco residual
$\mathbf{X}$	Sequência de entrada do *Transformer*
$\mathscr{B}$	Lote de exemplos de treinamento
$\mathscr{C}_0$	Conjunto dos controles
$\mathscr{C}_1$	Conjunto dos casos
$\mathscr{F}$	Transformação aprendida por um bloco residual
$\mathscr{H}$	Mapeamento desejado de um bloco residual
$\mathscr{L}$	Função de perda
β	Parâmetro de deslocamento da normalização em lote
γ	Parâmetro de escala da normalização em lote
δ	Limiar de decisão
δ^*	Limiar escolhido pelo índice de Youden
Δ	Diferença entre duas medidas
ε	Constante de estabilidade numérica
θ	Conjunto de parâmetros treináveis
Θ	Pesos de uma camada convolucional
Θ_s	Projeção do atalho residual

κ	Largura do núcleo convolucional
λ	Coeficiente de decaimento de pesos
$\mu_{\mathscr{B}}$	Média calculada sobre o lote
π	Prevalência do evento na coorte
$\sigma(\cdot)$	Função logística
$\sigma^2_{\mathscr{B}}$	Variância calculada sobre o lote
φ	Função de comparação entre um caso e um controle

SUMÁRIO

1 INTRODUÇÃO 20
1.0.1 Objetivo e visão geral 20
1.0.2 Escolha dos dados e delimitação da coorte 21
2 FUNDAMENTAÇÃO TEÓRICA 24
2.1 Pré-processamento de sinais eletrocardiográficos 24
2.1.1 Fontes de interferência 24
2.1.2 Filtragem digital 25
2.1.2.1 Filtro de Butterworth *25*
2.1.2.2 Filtragem de fase nula *25*
2.1.3 Normalização de amplitude 26
2.1.4 Amostragem em janelas e independência entre exemplos 26
2.2 Redes neurais convolucionais unidimensionais 27
2.2.1 Convolução unidimensional 27
2.2.2 Função de ativação 28
2.2.3 Normalização em lote 28
2.2.4 Agrupamento 29
2.2.5 Descarte 29
2.2.6 Função de perda e desbalanceamento 29
2.2.7 Arquitetura empregada 30
2.2.7.1 Variantes de capacidade *30*
2.2.7.2 Largura do núcleo *32*
2.2.7.3 Agrupamento combinado *32*
2.2.7.4 Ausência de conexões residuais *32*
2.2.7.5 Classificador e número de parâmetros *33*
2.3 Redes neurais residuais 33
2.3.1 Aprendizado residual 34
2.3.2 Blocos residuais 34
2.3.2.1 Bloco básico *35*
2.3.2.2 Bloco de gargalo *35*
2.3.3 Arquitetura 36

2.3.3.1 Configurações avaliadas . . . 36
2.3.3.2 Dimensões e campo receptivo . . . 37
2.3.3.3 Distribuição dos parâmetros . . . 38
2.3.4 Considerações sobre o regime de dados . . . 38
2.4 Marcadores eletrocardiográficos . . . 38
2.4.1 Intervalos RR e intervalos NN . . . 39
2.4.2 Variabilidade da frequência cardíaca . . . 40
2.4.2.1 Domínio do tempo . . . 40
2.4.2.2 Domínio da frequência . . . 40
2.4.2.3 Medidas não lineares . . . 41
2.4.3 Morfologia do batimento . . . 41
2.4.4 Ectopia . . . 42
2.4.5 Duração do segmento de análise . . . 43
2.5 Avaliação de classificadores binários . . . 43
2.5.1 Matriz de confusão e métricas dependentes de limiar . . . 44
2.5.2 Curva ROC e área sob a curva . . . 45
2.5.3 Curva precisão-revocação e precisão média . . . 46
2.5.4 Escolha do limiar de decisão . . . 46
2.5.5 Agregação por paciente . . . 47
2.5.6 Validação cruzada estratificada por paciente . . . 47
2.5.7 Intervalos de confiança e comparação entre modelos . . . 48
3 SITEMETODOLOGIA . . . 49
3.1 Seleção da coorte . . . 49
3.2 Pré-processamento do sinal . . . 50
3.2.1 Extração de janelas . . . 50
3.2.2 Filtragem . . . 51
3.2.3 Normalização . . . 51
3.2.4 Particionamento . . . 52
3.2.5 Variáveis clínicas . . . 52
3.3 Configuração experimental . . . 52
3.3.1 Representação do sinal . . . 53
3.3.2 Treinamento . . . 54

3.3.3 ***Desbalanceamento entre classes*** . . . 54
3.3.4 ***Protocolo de avaliação*** . . . 55
3.3.5 ***Métricas*** . . . 55
3.3.6 ***Experimentos com a rede convolucional*** . . . 56
3.3.6.1 *Amostragem das janelas* . . . *56*
3.3.6.2 *Filtragem com margem* . . . *57*
3.3.6.3 *Configuração comum* . . . *57*
3.4 **Redes neurais aplicadas ao sinal** . . . 57
3.4.1 ***Arquiteturas avaliadas*** . . . 58
3.4.2 ***Estratégias de treinamento da rede de fusão*** . . . 59
3.4.3 ***Protocolo de treinamento e avaliação*** . . . 59
3.4.3.1 *Divisão dos pacientes* . . . *59*
3.4.3.2 *Seleção da época* . . . *60*
3.4.3.3 *Avaliação no teste* . . . *60*
3.4.3.4 *Consolidação das cinco rodadas* . . . *61*
3.5 **Extração dos marcadores eletrocardiográficos** . . . 61
3.5.1 ***Protocolo A: segmentos de 5 minutos*** . . . 62
3.5.2 ***Protocolo B: segmentos de 30 segundos*** . . . 62
3.5.2.1 *Classificação dos intervalos* . . . *63*
3.5.2.2 *Marcadores calculados* . . . *63*
3.5.2.3 *Controle de qualidade* . . . *64*
3.5.2.4 *Resumo por paciente* . . . *64*
3.5.3 ***Número de variáveis e risco de sobreajuste*** . . . 65
4 **RESULTADOS** . . . 66
4.1 **Configuração experimental** . . . 66
4.1.1 ***Representação do sinal*** . . . 66
4.1.2 ***Treinamento*** . . . 67
4.1.3 ***Desbalanceamento entre classes*** . . . 68
4.1.4 ***Protocolo de avaliação*** . . . 68
4.1.5 ***Métricas*** . . . 69
4.2 **Rede convolucional aplicada ao sinal bruto** . . . 69
4.2.1 ***Protocolo*** . . . 70

4.2.2 ***Desempenho*** . . . 70
4.2.3 ***Comportamento durante o treinamento*** . . . 71
4.2.4 ***Matriz de confusão*** . . . 72
4.3 Rede residual aplicada ao sinal bruto . . . 72
4.3.1 ***Desempenho*** . . . 73
4.3.2 ***Comportamento durante o treinamento*** . . . 74
4.3.3 ***Matriz de confusão*** . . . 75
4.4 Efeito da capacidade do modelo . . . 76
4.4.1 ***Desempenho*** . . . 76
4.4.2 ***Comparação com a configuração reduzida*** . . . 77
4.4.3 ***Comportamento durante o treinamento*** . . . 77
4.4.4 ***Matriz de confusão*** . . . 78
4.5 Incorporação de mecanismo de atenção . . . 78
4.5.1 ***Desempenho*** . . . 79
4.5.2 ***Comportamento durante o treinamento*** . . . 80
4.5.3 ***Matriz de confusão*** . . . 80
4.6 Efeito da profundidade do modelo . . . 81
4.6.1 ***Desempenho*** . . . 81
4.6.2 ***Comparação entre largura e profundidade*** . . . 82
4.6.3 ***Comportamento durante o treinamento*** . . . 83
4.6.4 ***Matriz de confusão*** . . . 83
4.7 Rede residual de 50 camadas aplicada ao sinal bruto . . . 83
4.7.1 ***Protocolo*** . . . 84
4.7.2 ***Desempenho*** . . . 84
4.7.3 ***Comportamento durante o treinamento*** . . . 85
4.7.4 ***Matriz de confusão*** . . . 86
4.8 Eletrocardiograma de repouso de alta resolução . . . 87
4.8.1 ***Dados e arquitetura*** . . . 87
4.8.2 ***Desempenho*** . . . 88
4.8.3 ***Comparação entre modalidades*** . . . 89
4.8.4 ***Matriz de confusão*** . . . 89
4.8.5 ***Síntese*** . . . 90

4.9 Marcadores eletrocardiográficos 90
4.9.1 Protocolo A: segmentos de 5 minutos 90
4.9.1.1 Comparação univariada *90*
4.9.1.2 Modelos *91*
4.9.1.3 Número reduzido de marcadores e otimismo da seleção *92*
4.9.2 Protocolo B: segmentos de 30 segundos 92
4.9.2.1 Pseudorreplicação *92*
4.9.2.2 Modelos treinados por segmento *93*
4.9.2.3 Modelos sobre os resumos por paciente *93*
4.9.3 Síntese 94
4.10 Redes neurais sobre o sinal de Holter 95
4.10.1 Redes convolucionais: capacidade e duração da janela 95
4.10.2 Redes residuais: largura da ResNet-18 96
4.10.3 Redes residuais: profundidade (ResNet-18, ResNet-34 e ResNet-50) 96
4.10.4 ResNet-18 com mecanismo de atenção 97
4.10.5 Busca de hiperparâmetros 97
4.10.6 Comportamento durante o treinamento 97
4.10.7 Variabilidade entre execuções 98
4.10.8 Fusão da ResNet-18 com variáveis clínicas 98
4.10.9 Análise de sensibilidade: ResNet-18 sem restrição ao ritmo sinusal 99
4.10.10 Síntese 99
5 CONCLUSÕES E TRABALHOS FUTUROS 101
5.1 Conclusões 101
5.2 Limitações 102
5.3 Trabalhos futuros 102
REFERÊNCIAS 104

1 INTRODUÇÃO

1.0.1 Objetivo e visão geral

Este trabalho investiga se o ECG de Holter de 24 horas contém informação suficiente para identificar, entre pacientes com insuficiência cardíaca, aqueles que viriam a sofrer morte súbita cardíaca (MSC). A insuficiência cardíaca é a condição comum a todos os pacientes estudados, e não o desfecho: o que se procura distinguir é quem, dentro dessa população, morreu subitamente de quem sobreviveu. Para responder a essa pergunta, foram comparadas duas famílias de abordagens sobre a mesma coorte e sob o mesmo protocolo de avaliação: modelos de aprendizado profundo, que recebem o sinal bruto e aprendem dele as próprias representações, e modelos de aprendizado de máquina clássico, que recebem marcadores extraídos do ECG — medidas de variabilidade da frequência cardíaca, de ectopia e de morfologia — combinados ou não a variáveis clínicas.

A comparação foi conduzida em validação cruzada estratificada por paciente, com a AUC como métrica principal e intervalos de confiança estimados por *bootstrap*. Entre as redes avaliadas estão uma rede convolucional simples, redes residuais de profundidades crescentes, uma rede residual seguida de um codificador *Transformer*, uma rede convolucional com camada recorrente (*Long Short-Term Memory*) e um codificador pré-treinado em outra base de Holter.

O resultado central é que a complexidade do modelo não se converteu em desempenho. Nenhuma das redes alimentadas com o sinal bruto se distinguiu do acaso, com AUC entre 0,49 e 0,54. Os modelos mais simples alcançaram os melhores valores: as seis variáveis clínicas, em regressão logística, atingiram AUC de 0,661 [0,577–0,741], e os marcadores extraídos do ECG, isoladamente, valores entre 0,58 e 0,65. Acrescentar os marcadores às variáveis clínicas não produziu ganho estatisticamente distinguível de zero. Atribui-se esse comportamento principalmente ao tamanho da amostra e ao desbalanceamento entre as classes: com apenas 55 eventos, modelos com milhões de parâmetros não encontram exemplos suficientes para aprender padrões que generalizem, enquanto modelos com poucas variáveis bem definidas se ajustam com menor variância.

Mais do que propor um classificador, o trabalho contribui com uma avaliação controlada dos limites dessas abordagens em uma coorte real e pequena. O protocolo foi desenhado para evitar erros de avaliação que, quando presentes, fazem um modelo parecer melhor do que é e que são frequentes em estudos de aprendizado de máquina aplicado (KAPOOR; NARAYA-

NAN, 2023). Dois exemplos tratados neste trabalho são calcular as métricas sobre janelas do sinal, e não sobre pacientes, o que trata como independentes trechos de um mesmo exame, e escolher o melhor entre vários modelos olhando o próprio conjunto de teste, o que superestima o desempenho do modelo escolhido.

1.0.2 Escolha dos dados e delimitação da coorte

Os dados deste trabalho provêm da base *Muerte Súbita en Insuficiencia Cardiaca* (MUSIC), disponibilizada publicamente no PhysioNet (MARTIN-YEBRA *et al.*, 2025; MARTÍN-YEBRA *et al.*, 2024). A base reúne 992 pacientes com insuficiência cardíaca crônica sintomática (classes II e III da *New York Heart Association*), recrutados entre abril de 2003 e dezembro de 2004 em oito hospitais universitários da Espanha e acompanhados por uma mediana de 44 meses. Para 936 deles há um registro de Holter de 24 horas, e as causas de óbito foram adjudicadas segundo definições explícitas, que separam a MSC do óbito por falência de bomba.

Três características tornam a MUSIC adequada ao problema estudado. Primeiro, trata-se de uma população em que a MSC é um desfecho frequente e clinicamente relevante, e não de uma amostra da população geral, na qual o evento seria raro demais para o aprendizado. Segundo, o Holter de 24 horas oferece uma observação longa do ECG, que capta variações ao longo do dia inacessíveis a um traçado de repouso de poucos segundos. Terceiro, a adjudicação do mecanismo de óbito permite isolar a morte de origem elétrica, que é o objeto deste trabalho.

O problema foi formulado como uma classificação binária no nível do paciente: a partir do Holter, distinguir quem veio a óbito por MSC de quem sobreviveu ao período de observação. Essa formulação dispensa o tratamento de censura próprio da análise de sobrevivência, mas transfere a exigência para o rótulo, que precisa ser inequívoco para cada paciente. Os critérios de seleção decorrem dessa exigência e são três.

Critério 1: ritmo sinusal durante o Holter. Foram mantidos apenas os pacientes cujo registro foi anotado como ritmo sinusal. Em fibrilação ou *flutter* atrial não há onda P organizada e os intervalos entre batimentos são irregulares por definição, de modo que as medidas de variabilidade da frequência cardíaca e de morfologia perdem o significado fisiológico que têm em ritmo sinusal. Além disso, o próprio ritmo está associado ao risco: incluí-lo permitiria que um modelo aprendesse a reconhecer a arritmia atrial, e não marcadores de vulnerabilidade elétrica ventricular. Restringir a coorte ao ritmo sinusal remove esse fator de confusão e torna homogêneo o sinal de entrada.

Critério 2: somente óbito por MSC e sobreviventes. Os casos são os pacientes cuja causa de óbito foi adjudicada como MSC; os controles, os que permaneceram vivos. Foram excluídos os óbitos por falência de bomba, cujo mecanismo é mecânico e progressivo, e os óbitos de causa não cardíaca. Incluir a falência de bomba entre os casos ensinaria o modelo a reconhecer a gravidade da insuficiência cardíaca em geral, e não o risco específico de morte súbita; incluí-la entre os controles colocaria do lado "sem evento" pacientes que também morreram de causa cardíaca.

Critério 3: controles com quatro anos completos de seguimento. Um paciente vivo na última avaliação só é um controle confiável se tiver sido acompanhado por tempo suficiente. Um sobrevivente observado por poucos meses pode ter sofrido o evento logo depois de deixar o estudo; rotulá-lo como controle introduziria erro no rótulo. Por isso exigiu-se dos controles um seguimento de pelo menos 1.460 dias (quatro anos), horizonte compatível com a mediana de acompanhamento da base.

A aplicação sucessiva desses critérios está resumida na Tabela 1. Dos 710 pacientes em ritmo sinusal, 123 foram excluídos por desfecho ambíguo, restando 587 casos e controles. Desses, 47 não tinham registro de Holter disponível e 23 tinham um registro sem as três derivações exigidas pelos modelos. A coorte final reúne 517 pacientes: 55 casos de MSC e 462 controles, uma prevalência de 10,6%.

Tabela 1 – Delimitação da coorte a partir da base MUSIC

Etapa	Excluídos	Restantes
Pacientes na base MUSIC	—	992
Critério 1: ritmo não sinusal	282	710
Critério 2: óbito não cardíaco	35	
Critério 2: óbito por falência de bomba	67	
Critério 3: vivos com seguimento inferior a quatro anos	21	587
Sem registro de Holter	47	
Registro sem as três derivações	23	517
Coorte final: 55 casos de MSC e 462 controles (prevalência de 10,6%)		

Fonte: elaborado pelo autor (2026), a partir de Martin-Yebra *et al.* (2025).

Os critérios têm um custo que deve ser reconhecido desde já. A restrição ao ritmo sinusal e a exclusão dos desfechos ambíguos reduzem a coorte a pouco mais da metade da base e deixam apenas 55 eventos, o que limita o poder estatístico de qualquer comparação e torna amplos os intervalos de confiança. Além disso, os resultados se aplicam a pacientes com insuficiência cardíaca em ritmo sinusal e não podem ser estendidos, sem nova avaliação, a pacientes com fibrilação atrial. Optou-se por essa troca porque um rótulo confiável e um

sinal de entrada homogêneo são pré-requisitos para que um resultado, positivo ou negativo, possa ser interpretado. Os detalhes de cada etapa, incluindo as variáveis da base utilizadas, são apresentados na metodologia.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Pré-processamento de sinais eletrocardiográficos

O sinal registrado pelo eletrocardiógrafo contém, além da atividade elétrica cardíaca, componentes de origem diversa que se sobrepõem a ela. O pré-processamento tem por objetivo atenuar esses componentes preservando a morfologia das ondas de interesse, e a escolha de seus parâmetros resulta de um compromisso entre remover ruído e não distorcer o sinal (CLIFFORD *et al.*, 2006).

2.1.1 Fontes de interferência

Três fontes de interferência predominam no registro ambulatorial.

A *oscilação da linha de base* consiste em variações lentas do nível do sinal, provocadas pela respiração, pela movimentação do paciente e pela alteração da impedância na interface entre eletrodo e pele. Seu conteúdo espectral concentra-se abaixo de 0,5 Hz, e seu efeito é deslocar o traçado verticalmente ao longo do tempo, dificultando a comparação de amplitudes entre batimentos.

A *interferência da rede elétrica* manifesta-se como componente senoidal na frequência de alimentação — 50 Hz na Europa, onde foi adquirida a base empregada neste trabalho — e em seus harmônicos.

O *ruído muscular*, decorrente da atividade elétrica dos músculos esqueléticos, ocupa banda larga, predominantemente acima de 20 Hz. No Holter, ao qual o paciente permanece conectado durante suas atividades habituais, esse ruído é mais frequente que no exame de repouso, e se soma aos *artefatos de movimento* produzidos pelo deslocamento dos eletrodos.

A energia do próprio ECG, por sua vez, concentra-se em faixa relativamente estreita. As ondas P e T, de evolução lenta, ocupam predominantemente frequências abaixo de 10 Hz; o complexo QRS, de transição rápida, estende-se até algumas dezenas de hertz. Essa separação parcial entre o conteúdo do sinal e o das interferências é o que torna a filtragem por faixa de frequência eficaz.

2.1.2 Filtragem digital

Um filtro passa-faixa atenua as componentes situadas abaixo de uma frequência de corte inferior f_{inf} e acima de uma frequência de corte superior f_{sup}, preservando a faixa intermediária. A escolha de f_{inf} determina quanto da oscilação de linha de base é removida; a de f_{sup}, quanto do ruído muscular e da interferência da rede.

As recomendações da American Heart Association para o ECG diagnóstico estabelecem frequência de corte inferior de 0,05 Hz para filtros convencionais, admitindo até 0,67 Hz quando o filtro digital não introduz distorção de fase (KLIGFIELD *et al.*, 2007). A ressalva decorre de que filtros com resposta de fase não linear deslocam componentes de frequências distintas por intervalos de tempo diferentes, o que distorce segmentos de evolução lenta, como o segmento ST.

2.1.2.1 Filtro de Butterworth

O filtro de Butterworth (BUTTERWORTH, 1930) caracteriza-se por resposta em magnitude maximamente plana na banda passante. Para um filtro passa-baixas de ordem n e frequência de corte f_c, a magnitude da resposta em frequência é

$$|H(f)| = \frac{1}{\sqrt{1 + (f/f_c)^{2n}}}. \tag{2.1}$$

A ausência de ondulações na banda passante preserva a amplitude relativa das componentes do sinal, propriedade desejável quando a morfologia das ondas é a informação de interesse. A ordem n controla a inclinação da transição entre as bandas passante e de rejeição: ordens maiores produzem corte mais abrupto, ao custo de maior atraso e maior sensibilidade numérica. A implementação em seções de segunda ordem em cascata contorna essa sensibilidade, decompondo o filtro em blocos de baixa ordem numericamente estáveis.

2.1.2.2 Filtragem de fase nula

A filtragem direta e reversa aplica o mesmo filtro duas vezes: primeiro no sentido temporal e, em seguida, sobre o sinal invertido no tempo (GUSTAFSSON, 1996). O atraso de fase introduzido na primeira passagem é exatamente compensado pela segunda, de modo que o resultado não apresenta distorção de fase. A magnitude da resposta, por sua vez, é elevada ao

quadrado, o que equivale a dobrar a ordem efetiva do filtro.

A operação não é causal, pois a saída em cada instante depende de amostras futuras. Essa restrição impede seu uso em monitoramento em tempo real, mas não representa limitação na análise de registros já adquiridos, como é o caso do Holter.

2.1.3 Normalização de amplitude

Redes neurais são sensíveis à escala da entrada: valores de magnitudes muito distintas entre exemplos dificultam a otimização. Duas estratégias de normalização são usuais em sinais, e diferem quanto à informação que preservam.

A *padronização por segmento* subtrai a média e divide pelo desvio-padrão de cada trecho individualmente. Todos os segmentos passam a ter média nula e variância unitária, independentemente da amplitude original. A estratégia é robusta a diferenças de ganho entre equipamentos, mas elimina a informação de amplitude absoluta — um traçado de baixa voltagem e outro de alta voltagem tornam-se indistinguíveis quanto à escala.

A *normalização por escala global* divide todos os segmentos por uma mesma constante, estimada sobre o conjunto de treinamento. A amplitude relativa entre pacientes é preservada, o que é relevante no ECG: a baixa voltagem e a hipertrofia ventricular manifestam-se justamente como amplitudes anormalmente reduzidas ou elevadas. A estimativa da constante por percentil elevado do valor absoluto, em lugar do máximo, confere robustez a artefatos pontuais de grande amplitude.

2.1.4 Amostragem em janelas e independência entre exemplos

Registros de longa duração raramente são processados integralmente por redes neurais, em razão do volume de memória envolvido: 24 horas a 200 Hz em três derivações correspondem a aproximadamente 17 milhões de amostras. A prática usual consiste em extrair janelas de duração fixa, cada uma tratada como exemplo de treinamento.

Essa estratégia introduz uma dependência entre exemplos que tem consequências metodológicas. Janelas de um mesmo paciente compartilham características individuais estáveis — eixo elétrico, morfologia do complexo QRS, relação de amplitude entre derivações —, e não constituem observações independentes. Se janelas de um mesmo indivíduo forem distribuídas entre os conjuntos de treinamento e teste, o modelo pode reconhecer o paciente em lugar de estimar o desfecho, produzindo estimativas de desempenho otimistas. Esse tipo de vazamento de

informação está entre as causas mais frequentes de resultados não reprodutíveis em aprendizado de máquina aplicado (KAPOOR; NARAYANAN, 2023). A prevenção exige que a divisão entre conjuntos seja realizada no nível do paciente, e que as métricas sejam calculadas após a agregação das predições de suas janelas.

2.2 Redes neurais convolucionais unidimensionais

As redes neurais convolucionais foram concebidas para dados com estrutura espacial ou temporal, nos quais elementos próximos guardam relação entre si (LECUN *et al.*, 1998). Embora popularizadas no processamento de imagens, sua formulação unidimensional aplica-se diretamente a sinais fisiológicos, nos quais a vizinhança temporal carrega a informação relevante (KIRANYAZ *et al.*, 2021). No ECG, a morfologia de cada onda é definida pela sucessão de amostras ao longo de algumas dezenas de milissegundos, e é essa estrutura local que a convolução explora.

Esta seção apresenta inicialmente as operações que compõem as arquiteturas avaliadas neste trabalho e, em seguida, descreve a rede convolucional empregada como primeira abordagem.

2.2.1 Convolução unidimensional

Seja $\mathbf{S} \in \mathbb{R}^{C \times L}$ um sinal com C derivações e L amostras. Uma camada convolucional unidimensional aplica C' filtros, cada um definido por um núcleo $\Theta_{c'} \in \mathbb{R}^{C \times \kappa}$ de largura κ. A saída do filtro c' na posição t é dada por

$$h_{c'}(t) = b_{c'} + \sum_{c=1}^{C} \sum_{j=0}^{\kappa-1} \Theta_{c',c,j}\, S_c(t + j - \lfloor \kappa/2 \rfloor), \tag{2.2}$$

em que $b_{c'}$ é um termo de viés. O filtro percorre o sinal posição a posição, e em cada uma combina os κ valores vizinhos de todas as derivações em um único número. Valores elevados indicam que o trecho analisado se assemelha ao padrão codificado no filtro.

Duas propriedades tornam a operação adequada a sinais. A primeira é o *compartilhamento de pesos*: o mesmo núcleo é aplicado em todas as posições, de modo que um padrão aprendido em um instante é reconhecido em qualquer outro. A segunda é a *conectividade local*: cada saída depende apenas de κ amostras vizinhas, o que reduz drasticamente o número de

parâmetros em relação a uma camada totalmente conectada. Uma camada com C entradas, C' filtros e núcleo κ possui $C \cdot C' \cdot \kappa$ pesos, independentemente do comprimento L do sinal.

O preenchimento de $\lfloor \kappa/2 \rfloor$ amostras nas extremidades preserva o comprimento da saída. A largura do núcleo, por sua vez, determina a escala temporal dos padrões que cada filtro é capaz de representar isoladamente.

2.2.2 Função de ativação

A composição de operações lineares resulta em operação linear, de modo que empilhar camadas convolucionais sem não linearidades intermediárias não aumentaria a capacidade de representação do modelo. Emprega-se, por isso, a função de ativação retificada linear (NAIR; HINTON, 2010):

$$\mathrm{ReLU}(z) = \max(0, z). \tag{2.3}$$

A função anula valores negativos e preserva os positivos. Em termos interpretativos, cada filtro passa a indicar a presença do padrão correspondente, e não sua ausência. Do ponto de vista da otimização, sua derivada unitária na região positiva evita a atenuação do gradiente que afeta funções saturantes, como a tangente hiperbólica.

2.2.3 Normalização em lote

À medida que os parâmetros de uma camada se alteram durante o treinamento, a distribuição de suas saídas também se altera, o que obriga as camadas seguintes a se readaptarem continuamente. A normalização em lote (IOFFE; SZEGEDY, 2015) atenua esse efeito padronizando cada canal com a média $\mu_{\mathscr{B}}$ e a variância $\sigma^2_{\mathscr{B}}$ calculadas sobre o lote $\mathscr{B}$:

$$\hat{h} = \gamma \frac{h - \mu_{\mathscr{B}}}{\sqrt{\sigma^2_{\mathscr{B}} + \varepsilon}} + \beta, \tag{2.4}$$

em que γ e β são parâmetros aprendidos que permitem à rede recuperar a escala original, caso seja conveniente, e ε é uma constante de estabilidade numérica. Durante a avaliação, $\mu_{\mathscr{B}}$ e $\sigma^2_{\mathscr{B}}$ são substituídas por médias móveis acumuladas no treinamento, de modo que a predição de um paciente não dependa dos demais presentes no mesmo lote.

2.2.4 Agrupamento

O agrupamento máximo com fator r divide a sequência em trechos de r posições e retém apenas o maior valor de cada um, reduzindo o comprimento por esse fator. A operação tem dois efeitos. O primeiro é a redução do custo computacional das camadas seguintes. O segundo é a ampliação progressiva da escala temporal: após o agrupamento, cada posição resume r amostras da camada anterior, e a convolução seguinte, com o mesmo núcleo κ, passa a abranger trecho r vezes mais longo do sinal original.

Ao término da sequência de camadas convolucionais, o agrupamento global colapsa integralmente o eixo temporal (LIN *et al.*, 2014). O agrupamento global por média produz, para cada canal, o valor médio ao longo da janela; o agrupamento global máximo, o valor no instante de maior ativação:

$$z_c^{\text{méd}} = \frac{1}{L'} \sum_{t=1}^{L'} h_c(t), \qquad z_c^{\text{máx}} = \max_t h_c(t), \tag{2.5}$$

em que L' é o comprimento da sequência após as camadas convolucionais. A representação resultante tem dimensão fixa, independente do comprimento da entrada, o que permite à mesma rede processar janelas de durações distintas.

2.2.5 Descarte

O descarte (*dropout*) anula aleatoriamente uma fração p das unidades a cada passo de treinamento (SRIVASTAVA *et al.*, 2014). Como nenhuma unidade pode contar com a presença das demais, a rede é impelida a distribuir a informação entre múltiplos caminhos redundantes, o que reduz a tendência de memorizar exemplos específicos. Na avaliação, todas as unidades são mantidas e suas saídas, escaladas pelo fator correspondente.

2.2.6 Função de perda e desbalanceamento

A rede produz, para cada exemplo i, um valor real z_i denominado *logit*, convertido em probabilidade pela função logística:

$$\hat{p}_i = \sigma(z_i) = \frac{1}{1 + \mathrm{e}^{-z_i}}. \tag{2.6}$$

O ajuste dos parâmetros θ minimiza a entropia cruzada binária. Em problemas com classes desbalanceadas, a contribuição dos exemplos positivos é multiplicada por um peso w_+:

$$\mathscr{L}(\theta) = -\frac{1}{B}\sum_{i=1}^{B}\Big[w_+\, y_i \log \hat{p}_i + (1-y_i)\log(1-\hat{p}_i)\Big], \tag{2.7}$$

em que B é o tamanho do lote e $y_i \in \{0,1\}$ o rótulo. Sem a ponderação, a perda poderia ser minimizada atribuindo-se a classe majoritária a todos os exemplos — solução que, com prevalência de 10,6 %, alcança acurácia de 89,4 % com sensibilidade nula. A escolha $w_+ = N_0/N_1$, razão entre o número de exemplos negativos e positivos, torna a contribuição total das duas classes equivalente, o que corresponde a replicar cada exemplo positivo w_+ vezes sem descartar exemplos negativos.

A minimização emprega o otimizador AdamW (LOSHCHILOV; HUTTER, 2019), que adapta a taxa de aprendizado de cada parâmetro à magnitude histórica de seus gradientes e aplica a regularização por decaimento de pesos de forma desacoplada da atualização do gradiente.

2.2.7 Arquitetura empregada

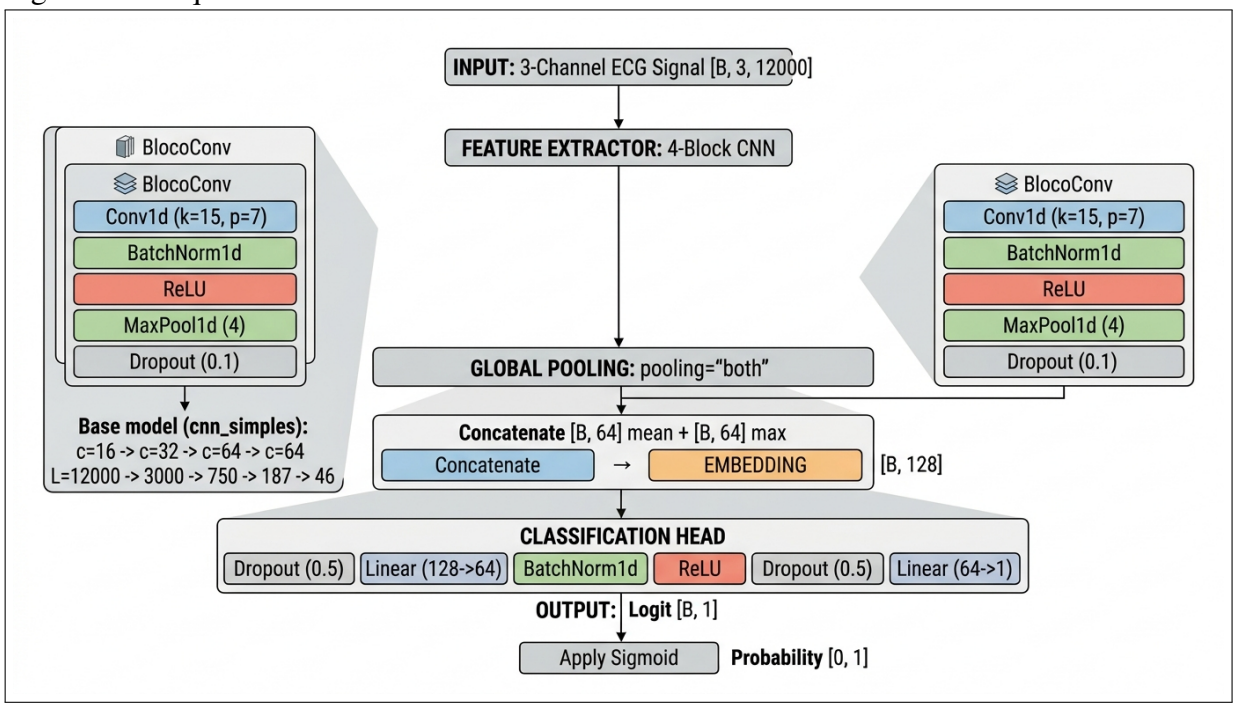
A rede convolucional adotada neste trabalho é composta por blocos sequenciais, seguidos de agrupamento global e de um classificador de duas camadas. Cada bloco aplica, nesta ordem, convolução, normalização em lote, ativação *ReLU*, agrupamento máximo com fator quatro e descarte com probabilidade 0,1. A Figura 1 ilustra o fluxo.

2.2.7.1 Variantes de capacidade

Para avaliar se o desempenho depende da capacidade do modelo, a mesma estrutura foi instanciada em três tamanhos, que diferem apenas no número de blocos e de filtros por bloco. A variante *mínima* tem três blocos, com 8, 16 e 32 filtros; a *simples*, quatro blocos, com 16, 32, 64 e 64 filtros; a *média*, quatro blocos, com 32, 64, 128 e 128 filtros. Todos os demais elementos — largura do núcleo, agrupamento, descarte, classificador e inicialização — são idênticos. Entre a menor e a maior variante, o número de parâmetros cresce cerca de 29 vezes. Se o desempenho não acompanhar esse crescimento, a limitação não está na capacidade da rede, mas na informação disponível nos dados.

A Tabela 2 detalha os canais de cada variante e o comprimento das representações intermediárias para as duas durações de janela avaliadas: 2 minutos (24 000 amostras) e

Figura 1 – Arquitetura da rede convolucional unidimensional



Fonte: elaborado pelo autor (2026).

10 segundos (2 000 amostras).

Tabela 2 – Canais e comprimento das representações intermediárias das variantes da rede convolucional

	Canais			Comprimento		
Etapa	Mínima	Simples	Média	2 min	10 s	Campo receptivo
Entrada	3	3	3	24 000	2 000	5 ms
Bloco 1	8	16	32	6 000	500	90 ms
Bloco 2	16	32	64	1 500	125	430 ms
Bloco 3	32	64	128	375	31	1,8 s
Bloco 4	—	64	128	93	7	7,2 s
Agrupamento global	64	128	256	—	—	janela inteira

Fonte: elaborado pelo autor (2026).

A coluna de campo receptivo indica a extensão do sinal original que influencia cada posição de saída e não depende da duração da janela. Ao final do primeiro bloco, cada posição reflete 90 ms de registro — aproximadamente a duração de um complexo QRS —; ao final do quarto, 7,2 s, o equivalente a oito a nove ciclos cardíacos a 70 bpm. A rede, portanto, combina progressivamente padrões morfológicos de batimentos isolados em padrões que abrangem sequências de batimentos.

A duração da janela altera o que esses padrões representam no conjunto. Na janela de 2 minutos, o quarto bloco ainda produz 93 posições, cada uma resumindo alguns segundos, e

o agrupamento global combina dezenas de trechos distintos. Na janela de 10 segundos, restam 7 posições cujo campo receptivo já cobre a maior parte da janela, de modo que a rede analisa essencialmente um único trecho de poucos batimentos. Na variante mínima, que não possui o quarto bloco, o campo receptivo final é de 1,8 s, cerca de dois ciclos cardíacos.

2.2.7.2 Largura do núcleo

O núcleo convolucional foi dimensionado em $\kappa = 15$ amostras, equivalentes a 75 ms na frequência de 200 Hz. A escolha difere da convenção predominante em arquiteturas originadas no processamento de imagens, em que núcleos de três elementos são usuais e corresponderiam, neste contexto, a apenas 15 ms. Com núcleo de 75 ms, um único filtro da primeira camada abrange parcela substancial de um complexo QRS, cuja duração normal situa-se entre 80 e 100 ms, podendo representar diretamente padrões de despolarização ventricular.

2.2.7.3 Agrupamento combinado

Ao término do último bloco, os canais são reduzidos a um vetor com o dobro da sua dimensão pela concatenação dos agrupamentos globais por média e máximo, conforme a Equação 2.5: 64, 128 e 256 dimensões nas variantes mínima, simples e média. As duas operações capturam aspectos complementares: a média reflete o comportamento típico da janela, enquanto o máximo registra o instante de maior ativação de cada filtro. A combinação permite que a rede seja sensível tanto a alterações persistentes quanto a eventos breves, como extrassístoles isoladas, que a média isoladamente diluiria.

2.2.7.4 Ausência de conexões residuais

A arquitetura não emprega as conexões residuais descritas na seção 2.3. Essas conexões foram concebidas para viabilizar o treinamento de redes com dezenas de camadas, nas quais o gradiente tenderia a se atenuar ao percorrer a sequência de transformações. Com três ou quatro blocos convolucionais, o gradiente alcança as camadas iniciais sem atenuação significativa, e os atalhos acrescentariam parâmetros sem benefício correspondente.

2.2.7.5 Classificador e número de parâmetros

O vetor resultante do agrupamento alimenta um classificador composto por duas camadas totalmente conectadas — a primeira com 64 unidades, normalização em lote e ativação *ReLU*, a segunda com uma unidade de saída —, ambas precedidas por descarte com probabilidade 0,6. Os pesos das camadas convolucionais são inicializados conforme He *et al.* (2015), esquema adequado a redes com ativação *ReLU*.

A Tabela 3 decompõe os parâmetros treináveis de cada variante. Como as camadas convolucionais não dependem do comprimento do sinal, os valores são os mesmos para as duas durações de janela.

Tabela 3 – Distribuição dos parâmetros das variantes da rede convolucional

Componente	Mínima	Simples	Média
Bloco 1	360	720	1 440
Bloco 2	1 920	7 680	30 720
Bloco 3	7 680	30 720	122 880
Bloco 4	—	61 440	245 760
Normalização dos blocos	112	352	704
Classificador	4 353	8 449	16 641
Total	14 425	109 361	418 145
Por paciente de treino	47	354	1 353

Fonte: elaborado pelo autor (2026).

Cada bloco convolucional tem $C \cdot C' \cdot \kappa$ pesos, sem termo de viés, pois a normalização em lote seguinte o tornaria redundante. A última linha divide o total pelos 309 pacientes do conjunto de treinamento de cada partição. Mesmo a variante média tem cerca de dez vezes menos parâmetros por paciente que a ResNet-18 descrita na seção 2.3, que tem 3 976 385 parâmetros, ou 12 869 por paciente de treinamento.

2.3 Redes neurais residuais

A profundidade é um dos fatores que determinam a capacidade de representação de uma rede neural: camadas sucessivas permitem compor padrões simples em padrões progressivamente mais abstratos. Empiricamente, contudo, o acréscimo de camadas a partir de certo ponto deixa de melhorar e passa a piorar o desempenho — não por sobreajuste, mas porque o próprio erro de treinamento aumenta. He *et al.* (2016) denominaram esse fenômeno *problema de degradação* e propuseram as redes residuais como solução.

2.3.1 Aprendizado residual

O argumento parte de uma construção. Uma rede mais profunda poderia, em princípio, reproduzir o desempenho de uma rede rasa se as camadas adicionais implementassem a função identidade. Que redes profundas não alcancem sequer esse desempenho indica que aproximar a identidade por meio de sucessivas transformações não lineares é difícil para os métodos de otimização usuais.

A proposta consiste em reformular o que cada bloco aprende. Em lugar de estimar diretamente o mapeamento desejado $\mathscr{H}(\mathbf{x})$, o bloco estima o resíduo $\mathscr{F}(\mathbf{x}) = \mathscr{H}(\mathbf{x}) - \mathbf{x}$, e a saída é obtida somando-se a entrada de volta:

$$\mathbf{y} = \mathscr{F}(\mathbf{x}; \Theta) + \mathbf{x}. \tag{2.8}$$

A soma com a entrada, denominada *conexão de atalho*, não introduz parâmetros. Se a transformação ideal for próxima da identidade, basta que os pesos de $\mathscr{F}$ tendam a zero — solução mais simples de alcançar que aproximar a identidade por meio de camadas não lineares. Do ponto de vista da otimização, o atalho oferece ao gradiente um caminho direto entre camadas distantes, que não depende das derivadas das transformações intermediárias, o que mitiga sua atenuação ao longo de redes profundas.

Quando o bloco altera o número de canais ou reduz o comprimento temporal, a soma da Equação 2.8 não é definida, pois as dimensões de $\mathscr{F}(\mathbf{x})$ e $\mathbf{x}$ diferem. Nesse caso, a entrada é projetada por uma convolução de núcleo unitário Θ_s, com o mesmo passo da transformação principal, seguida de normalização em lote:

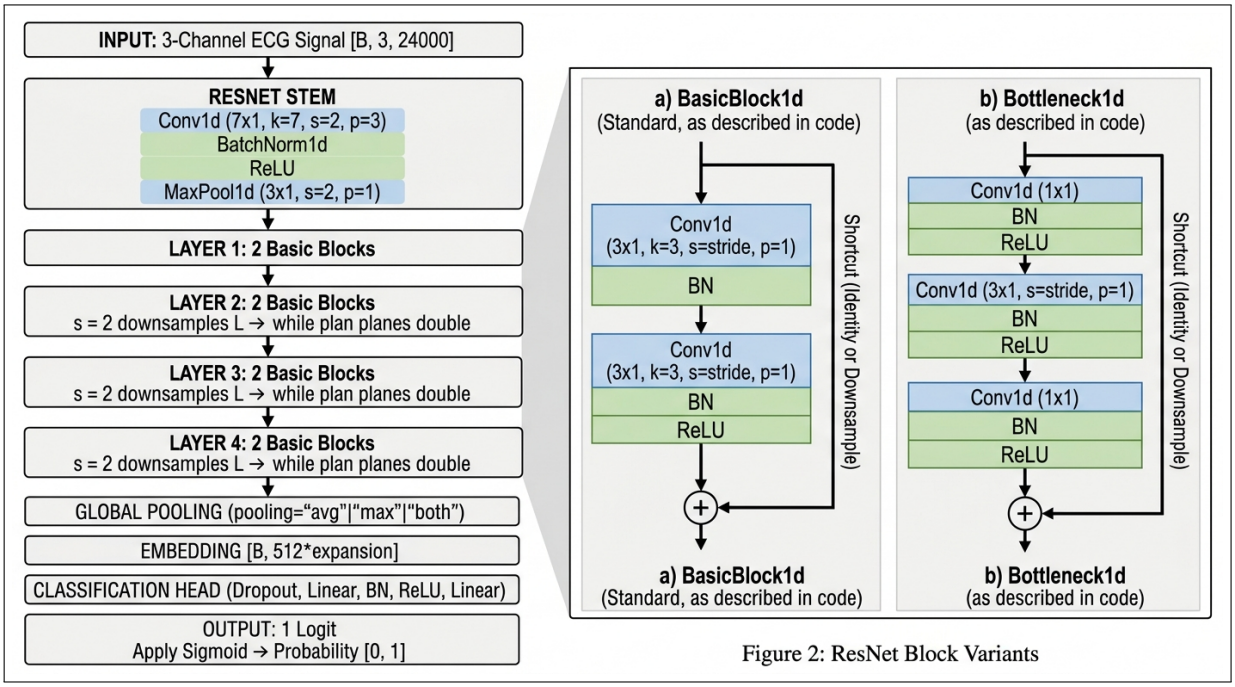
$$\mathbf{y} = \mathscr{F}(\mathbf{x}; \Theta) + \Theta_s \mathbf{x}. \tag{2.9}$$

Nos demais blocos de um mesmo estágio, em que as dimensões coincidem, o atalho é a identidade e não acrescenta custo.

2.3.2 Blocos residuais

Duas variantes de bloco foram empregadas neste trabalho, ilustradas na Figura 2.

Figura 2 – Blocos residuais básico (tipo a) e de gargalo (tipo b)



Fonte: adaptado de He *et al.* (2016).

2.3.2.1 Bloco básico

O bloco básico é composto por duas convoluções de núcleo $\kappa = 3$, cada uma seguida de normalização em lote, com ativação *ReLU* após a primeira e após a soma com o atalho:

$$\mathscr{F}(\mathbf{x}) = \mathrm{BN}\Big(\mathrm{Conv}_3\big(\mathrm{ReLU}(\mathrm{BN}(\mathrm{Conv}_3(\mathbf{x})))\big)\Big), \qquad \mathbf{y} = \mathrm{ReLU}\big(\mathscr{F}(\mathbf{x}) + \mathbf{x}\big). \tag{2.10}$$

O número de canais na saída é igual ao da camada interna, o que se expressa por um fator de expansão $E = 1$.

2.3.2.2 Bloco de gargalo

Em redes mais profundas, o custo de duas convoluções de núcleo três com muitos canais torna-se proibitivo. O bloco de gargalo substitui-as por três convoluções: a primeira, de núcleo unitário, reduz o número de canais; a segunda, de núcleo três, opera sobre a dimensão reduzida; a terceira, também de núcleo unitário, expande os canais em $E = 4$ vezes. A convolução de núcleo unitário não considera vizinhança temporal — combina apenas os canais em cada posição —, e é por isso computacionalmente barata.

Para um bloco com 256 canais na entrada e na saída, a versão básica exigiria $2 \times 256 \times 256 \times 3 \approx 393\,000$ pesos; a de gargalo, com dimensão interna de 64, exige $256 \times 64 +$

$64 \times 64 \times 3 + 64 \times 256 \approx 45\,000$ — cerca de nove vezes menos. É essa economia que viabiliza arquiteturas com dezenas de camadas.

2.3.3 Arquitetura

A arquitetura empregada adapta ao domínio unidimensional a estrutura proposta por He *et al.* (2016), seguindo a prática estabelecida em trabalhos de classificação de ECG com redes residuais (HANNUN *et al.*, 2019; RIBEIRO *et al.*, 2020). Uma etapa inicial precede quatro estágios de blocos residuais:

- **Etapa inicial:** convolução com núcleo 7 e passo 2, seguida de normalização em lote, *ReLU* e agrupamento máximo com núcleo 3 e passo 2. O comprimento é reduzido por quatro antes do primeiro bloco.
- **Estágios 1 a 4:** sequências de blocos residuais com P, $2P$, $4P$ e $8P$ canais internos, em que P denota a largura inicial. O primeiro bloco dos estágios 2 a 4 emprega passo 2, dividindo o comprimento pela metade e exigindo projeção no atalho.
- **Agrupamento global e classificador:** idênticos aos da subseção 2.2.7, com o vetor resultante de dimensão $2 \times 8 \cdot P \cdot E$ ao combinar média e máximo.

A cada estágio, portanto, o comprimento temporal é dividido por dois e a profundidade da representação, multiplicada por dois — progressão distinta da adotada na rede convolucional da seção 2.2, que divide o comprimento por quatro a cada bloco.

2.3.3.1 Configurações avaliadas

Três parâmetros definem cada configuração: o tipo de bloco, o número de blocos por estágio e a largura inicial P. A Tabela 4 reúne as quatro variantes avaliadas, que percorrem uma faixa de dezesseis vezes em número de parâmetros.

Tabela 4 – Configurações das redes residuais avaliadas

Configuração	Bloco	Blocos por estágio	P	Saída	Parâmetros
ResNet-18 reduzida	básico	2–2–2–2	32	256	1 029 985
ResNet-18 completa	básico	2–2–2–2	64	512	3 976 385
ResNet-34	básico	3–4–6–3	64	512	7 350 721
ResNet-50	gargalo	3–4–6–3	64	2 048	16 479 937

Fonte: elaborado pelo autor (2026).

As configurações permitem examinar separadamente duas dimensões da capacidade.

A comparação entre as duas variantes da ResNet-18 isola o efeito da *largura*: mesma profundidade, o dobro de canais. A comparação entre a ResNet-18 completa e a ResNet-34 isola o efeito da *profundidade*: mesma largura, o dobro de blocos. A ResNet-50 combina a profundidade da ResNet-34 com o bloco de gargalo e saída quatro vezes mais larga.

Os números de parâmetros são inferiores aos das versões bidimensionais homônimas, nas quais a ResNet-18 possui cerca de 11 milhões, porque o núcleo unidimensional de largura três contém três pesos por par de canais, contra nove do núcleo 3×3.

2.3.3.2 Dimensões e campo receptivo

A Tabela 5 apresenta as dimensões das representações intermediárias para a janela de 24 000 amostras e o campo receptivo ao término de cada etapa.

Tabela 5 – Dimensões e campo receptivo das redes residuais para janela de 24 000 amostras

		Canais		Campo receptivo	
Etapa	Comprimento	18 e 34	50	ResNet-18	ResNet-34
Entrada	24 000	3	3	5 ms	5 ms
Etapa inicial	6 000	64	64	55 ms	55 ms
Estágio 1	6 000	64	256	215 ms	295 ms
Estágio 2	3 000	128	512	495 ms	895 ms
Estágio 3	1 500	256	1 024	1,1 s	2,7 s
Estágio 4	750	512	2 048	2,2 s	4,5 s

Fonte: elaborado pelo autor (2026).

O campo receptivo ao final da ResNet-18 é de 2,2 s — inferior aos 7,2 s da rede convolucional rasa, apesar de esta possuir apenas quatro camadas convolucionais contra dezessete. A diferença decorre do núcleo: com três amostras (15 ms), cada convolução residual amplia pouco a extensão observada, e a cobertura temporal depende do empilhamento de muitas camadas. A ResNet-34, com o dobro de blocos, alcança 4,5 s. A ResNet-50 apresenta campo receptivo semelhante ao da ResNet-18, pois apenas uma das três convoluções de cada bloco de gargalo considera vizinhança temporal.

Ainda que inferior à duração da janela, esse campo receptivo não limita a informação disponível ao classificador: o agrupamento global da Equação 2.5 combina as 750 posições do último estágio, abrangendo os dois minutos integralmente.

2.3.3.3 Distribuição dos parâmetros

Os parâmetros concentram-se nos estágios finais, em que o número de canais é maior. Na ResNet-18 completa, o quarto estágio, com 512 canais, responde por aproximadamente três quartos do total. Na ResNet-50, o classificador recebe vetor de 4 096 dimensões — 2 048 de cada agrupamento —, e sua primeira camada sozinha possui cerca de 525 000 parâmetros.

Os pesos das camadas convolucionais são inicializados conforme He *et al.* (2015), e os parâmetros de escala e deslocamento da normalização em lote, com um e zero, respectivamente, de modo que cada bloco inicie próximo da identidade.

2.3.4 Considerações sobre o regime de dados

As redes residuais foram concebidas para conjuntos de treinamento de grande porte. A ResNet original foi avaliada sobre 1,28 milhão de imagens (HE *et al.*, 2016); no domínio do ECG, os trabalhos que estabeleceram seu desempenho empregaram dezenas de milhares a milhões de registros (HANNUN *et al.*, 2019; RIBEIRO *et al.*, 2020).

Neste trabalho, cada partição dispõe de 309 pacientes no treinamento, dos quais 33 casos. A razão entre parâmetros e pacientes varia de 3 333 na ResNet-18 reduzida a cerca de 53 000 na ResNet-50. Nesse regime, a capacidade da rede é amplamente suficiente para ajustar individualmente cada exemplo de treinamento, o que motiva a comparação sistemática entre configurações de capacidade crescente apresentada no **??**: se a capacidade fosse o fator limitante, o desempenho deveria variar com ela.

2.4 Marcadores eletrocardiográficos

As redes neurais descritas nas seções anteriores aprendem diretamente do sinal quais padrões são relevantes para a tarefa. A alternativa clássica inverte essa ordem: calculam-se do ECG medidas com significado fisiológico conhecido, e um modelo estatístico simples relaciona essas medidas ao desfecho. Essas medidas são chamadas, neste trabalho, de *marcadores eletrocardiográficos*; na literatura, recebem também os nomes de biomarcadores digitais ou de métricas derivadas do ECG.

A abordagem tem duas vantagens em uma coorte pequena. A primeira é a economia de parâmetros: cada marcador condensa milhares de amostras do sinal em um único número, e um modelo com poucas dezenas de coeficientes pode ser ajustado com 55 eventos sem

memorizar os pacientes de treinamento. A segunda é a interpretabilidade: cada coeficiente refere-se a um mecanismo fisiológico identificável — o controle autonômico do ritmo, a duração da repolarização ventricular, a frequência de batimentos ectópicos —, o que permite confrontar os resultados com o conhecimento clínico. Em contrapartida, o modelo só tem acesso à informação que os marcadores escolhidos capturam; padrões do sinal que não correspondam a nenhum deles são descartados.

Os marcadores empregados pertencem a três grupos: a variabilidade da frequência cardíaca, a morfologia do batimento e a ectopia. Todos partem da mesma etapa inicial, a localização dos picos R.

2.4.1 Intervalos RR e intervalos NN

O pico R é o ponto de maior amplitude do complexo QRS e marca a despolarização ventricular de cada batimento. Detectados os picos, o intervalo RR_ℓ é o tempo, em milissegundos, entre o ℓ-ésimo pico e o seguinte. A sequência de intervalos RR descreve a frequência cardíaca batimento a batimento e é a matéria-prima de todos os marcadores de ritmo.

Nem todo intervalo RR reflete, porém, a modulação normal do ritmo sinusal. Um batimento ectópico — originado fora do nó sinusal — produz um intervalo curto seguido de outro longo; um pico não detectado produz um intervalo com aproximadamente o dobro da duração esperada; um artefato detectado como pico produz dois intervalos curtos. A diretriz da *Task Force* (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996) estabelece, por isso, que os marcadores de variabilidade sejam calculados apenas sobre intervalos entre batimentos sinusais normais, chamados intervalos NN. Na prática, um intervalo é considerado normal quando não se afasta mais que uma fração pré-definida da mediana dos intervalos vizinhos. Um único batimento ectópico em um segmento curto pode multiplicar o valor de alguns marcadores, como se mostra na seção 3.5.

A distinção é especialmente importante neste trabalho, que procura nos batimentos ectópicos um sinal de risco. Os intervalos que não são NN não são descartados da análise: eles deixam de entrar nos marcadores de variabilidade, mas passam a compor os marcadores de ectopia descritos na subseção 2.4.4.

2.4.2 Variabilidade da frequência cardíaca

A frequência cardíaca de um indivíduo saudável em repouso não é constante. Ela oscila continuamente sob a ação do sistema nervoso autônomo: o ramo parassimpático, mediado pelo nervo vago, produz variações rápidas, acopladas à respiração; o ramo simpático, variações mais lentas. A variabilidade da frequência cardíaca (VFC) quantifica essas oscilações e funciona, assim, como uma medida indireta do equilíbrio autonômico. Na insuficiência cardíaca, a ativação simpática persistente e a retirada vagal reduzem a VFC. A redução da VFC está associada a maior mortalidade desde os primeiros estudos com Holter, realizados em pacientes após infarto do miocárdio (KLEIGER *et al.*, 1987).

2.4.2.1 Domínio do tempo

Os marcadores do domínio do tempo são estatísticas calculadas diretamente sobre a sequência de n_{NN} intervalos NN de um segmento. O desvio-padrão dos intervalos,

$$\mathrm{SDNN} = \sqrt{\frac{1}{n_{\mathrm{NN}}-1}\sum_{\ell=1}^{n_{\mathrm{NN}}}\left(\mathrm{NN}_\ell - \overline{\mathrm{NN}}\right)^2}, \tag{2.11}$$

em que $\overline{\mathrm{NN}}$ é a média dos intervalos, reflete a variabilidade total do segmento, somando as componentes rápidas e lentas. A raiz quadrática média das diferenças sucessivas,

$$\mathrm{RMSSD} = \sqrt{\frac{1}{n_{\mathrm{NN}}-1}\sum_{\ell=1}^{n_{\mathrm{NN}}-1}\left(\Delta\mathrm{NN}_\ell\right)^2}, \qquad \Delta\mathrm{NN}_\ell = \mathrm{NN}_{\ell+1} - \mathrm{NN}_\ell, \tag{2.12}$$

e o percentual de diferenças sucessivas superiores a 50 ms, o pNN50, isolam as variações de um batimento para o seguinte e são, por isso, associados predominantemente à modulação vagal. A diferença $\Delta\mathrm{NN}_\ell$ só tem significado quando os dois intervalos são adjacentes no registro: se um batimento ectópico foi removido entre eles, a diferença compararia intervalos que não se sucederam, e não entra no cálculo.

2.4.2.2 Domínio da frequência

A análise espectral decompõe a variância dos intervalos em faixas de frequência associadas a mecanismos distintos (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996). A faixa de alta frequência

(HF, de 0,15 a 0,4 Hz) corresponde à arritmia sinusal respiratória e à modulação vagal; a de baixa frequência (LF, de 0,04 a 0,15 Hz), a uma combinação de influências simpáticas e vagais ligadas ao barorreflexo; a de muito baixa frequência (VLF, abaixo de 0,04 Hz), a mecanismos mais lentos, como a termorregulação. A razão LF/HF é frequentemente interpretada como índice do balanço simpatovagal, embora essa leitura seja controversa.

A estimativa espectral impõe uma duração mínima ao segmento. Um ciclo de 0,04 Hz, limite inferior da faixa LF, dura 25 s, e uma estimativa estável da potência nessa faixa exige que vários ciclos estejam contidos no segmento. A *Task Force* recomenda segmentos de pelo menos 2 minutos para a faixa LF e de 5 minutos como padrão para a análise espectral de curta duração (Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, 1996).

2.4.2.3 Medidas não lineares

O gráfico de Poincaré representa cada intervalo NN contra o seguinte. A dispersão dos pontos perpendicularmente à diagonal, SD1, mede a variabilidade de curto prazo; a dispersão ao longo da diagonal, SD2, a de longo prazo (BRENNAN *et al.*, 2001). Ambas podem ser obtidas das variâncias já definidas:

$$\mathrm{SD1} = \sqrt{\tfrac{1}{2}\,\mathrm{Var}(\Delta\mathrm{NN})}, \qquad \mathrm{SD2} = \sqrt{2\,\mathrm{Var}(\mathrm{NN}) - \tfrac{1}{2}\,\mathrm{Var}(\Delta\mathrm{NN})}. \tag{2.13}$$

A primeira expressão mostra que SD1 é proporcional ao raiz quadrada da média dos quadrados das diferenças entre intervalos NN adjacentes (RMSSD) e carrega, portanto, a mesma informação. A razão SD1/SD2 descreve a forma da nuvem de pontos e é menos redundante em relação aos demais marcadores.

A entropia amostral mede a regularidade da sequência de intervalos: valores baixos indicam uma série previsível, e valores altos, uma série complexa (RICHMAN; MOORMAN, 2000). Por depender da contagem de padrões repetidos, ela exige sequências de centenas de batimentos para ser estimada com estabilidade.

2.4.3 Morfologia do batimento

Os marcadores de morfologia descrevem a forma do batimento, e não o intervalo entre batimentos. Sua obtenção exige delinear cada batimento, isto é, localizar o início, o pico e

o fim das ondas P, QRS e T.

A *duração do QRS* mede o tempo de despolarização dos ventrículos. Seu prolongamento indica condução intraventricular lenta, como nos bloqueios de ramo, e está associado a pior prognóstico na insuficiência cardíaca. O *intervalo QT*, do início do QRS ao fim da onda T, abrange a despolarização e a repolarização ventriculares. Como o QT encurta naturalmente quando a frequência cardíaca aumenta, ele é comparado entre pacientes após correção pela frequência. A correção de Bazett (BAZETT, 1920) divide o QT pela raiz quadrada do intervalo RR expresso em segundos:

$$\mathrm{QTc} = \frac{\mathrm{QT}}{\sqrt{\mathrm{RR}}}. \tag{2.14}$$

O prolongamento do QTc reflete repolarização ventricular lenta ou heterogênea, substrato conhecido para arritmias ventriculares.

A delineação automática é a etapa menos robusta da extração. As fronteiras das ondas não têm definição única, os algoritmos divergem entre si, e o ruído do Holter — registrado durante as atividades diárias do paciente — desloca as marcações. Por isso, as durações obtidas automaticamente devem ser entendidas como estimativas consistentes dentro de um mesmo método, e não como medidas comparáveis aos valores de referência clínicos.

2.4.4 Ectopia

Um batimento ectópico ocorre antes do esperado e, quando de origem ventricular, costuma ser seguido de uma pausa compensatória. As extrassístoles ventriculares frequentes e, sobretudo, as sequências de dois ou mais batimentos ectópicos consecutivos são reconhecidas como marcadores de instabilidade elétrica na insuficiência cardíaca.

A identificação definitiva da origem de um batimento exige a análise de sua morfologia. Na ausência dessa análise, a ectopia pode ser aproximada pelo ritmo: um intervalo RR muito mais curto que os vizinhos indica um batimento precoce; um intervalo curto seguido de um longo, uma extrassístole com pausa compensatória; dois intervalos curtos consecutivos, um duplete. Essa aproximação não distingue a origem ventricular da supraventricular e deve ser descrita como um indicador de ectopia, e não como uma contagem de extrassístoles ventriculares.

2.4.5 Duração do segmento de análise

Os marcadores não são calculados sobre o Holter inteiro, mas sobre segmentos, e a duração do segmento determina quais deles podem ser estimados. A Tabela 6 resume essa relação. Segmentos curtos permitem acompanhar a evolução dos marcadores ao longo do dia, mas restringem o conjunto calculável e aumentam a variância de cada estimativa: com cerca de 35 batimentos em 30 segundos, um único intervalo anômalo pesa sobre o desvio-padrão dos intervalos NN (SDNN) e o RMSSD muito mais que em 5 minutos.

Tabela 6 – Marcadores calculáveis em segmentos de 5 minutos e de 30 segundos

Marcador	5 minutos	30 segundos
SDNN, RMSSD, pNN50, SD1, SD2	sim	sim, com maior variância
Potência LF, HF e razão LF/HF	sim	não
Potência VLF	não (exige registros longos)	não
Entropia amostral	sim	não
QRS, QT, QTc	sim	sim
Indicadores de ectopia	sim	sim

Fonte: elaborado pelo autor (2026), com base em Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology (1996).

Como cada paciente contribui com dezenas ou centenas de segmentos, os valores precisam ser resumidos em uma única linha por paciente antes da modelagem, pelas razões discutidas na subseção 2.5.5. O resumo pode descrever o nível típico de cada marcador, por exemplo pela mediana, e também sua variação ao longo do registro, que reflete a modulação circadiana e a instabilidade do controle autonômico.

2.5 Avaliação de classificadores binários

Um classificador binário, como as redes e os modelos logísticos deste trabalho, produz para cada paciente i uma probabilidade estimada $\hat{p}_i \in [0, 1]$ de pertencer à classe positiva — neste trabalho, o óbito por MSC. Avaliar o classificador significa medir o quanto essas probabilidades separam os pacientes que sofreram o evento dos que não o sofreram. Esta seção apresenta as métricas empregadas, distinguindo as que dependem de um limiar de decisão das que avaliam a ordenação das probabilidades, e descreve os procedimentos usados para estimar a incerteza dessas métricas em uma amostra pequena e desbalanceada.

2.5.1 Matriz de confusão e métricas dependentes de limiar

Para converter a probabilidade em uma decisão, fixa-se um limiar δ: o paciente é classificado como positivo se $\hat{p}_i \geq \delta$ e como negativo caso contrário. O cruzamento entre a classe predita e a classe real gera os quatro desfechos da matriz de confusão, apresentada na Tabela 7.

Tabela 7 – Matriz de confusão de um classificador binário

	Predito positivo	Predito negativo
Real positivo ($y = 1$)	Verdadeiro positivo (VP)	Falso negativo (FN)
Real negativo ($y = 0$)	Falso positivo (FP)	Verdadeiro negativo (VN)

Fonte: elaborado pelo autor (2026).

A partir dessas contagens definem-se as métricas da Tabela 8. A sensibilidade e a especificidade descrevem o desempenho dentro de cada classe real e não dependem da proporção entre as classes. O valor preditivo positivo (VPP) e o valor preditivo negativo (VPN), ao contrário, respondem à pergunta clínica — dado o resultado do classificador, qual a probabilidade de o paciente estar na classe indicada — e por isso dependem da prevalência π do evento na população avaliada.

Tabela 8 – Métricas derivadas da matriz de confusão

Métrica	Definição	Interpretação
Sensibilidade (revocação)	$\frac{\mathrm{VP}}{\mathrm{VP}+\mathrm{FN}}$	fração dos óbitos identificada
Especificidade	$\frac{\mathrm{VN}}{\mathrm{VN}+\mathrm{FP}}$	fração dos sobreviventes corretamente descartada
VPP (precisão)	$\frac{\mathrm{VP}}{\mathrm{VP}+\mathrm{FP}}$	probabilidade de óbito entre os sinalizados
VPN	$\frac{\mathrm{VN}}{\mathrm{VN}+\mathrm{FN}}$	probabilidade de sobrevida entre os não sinalizados
Acurácia	$\frac{\mathrm{VP}+\mathrm{VN}}{N}$	fração total de acertos
F1	$\frac{2 \cdot \mathrm{VPP} \cdot \mathrm{Sens.}}{\mathrm{VPP}+\mathrm{Sens.}}$	média harmônica entre VPP e sensibilidade

Fonte: elaborado pelo autor (2026).

A acurácia merece cautela em problemas desbalanceados. Com prevalência de 10,6 %, um classificador que declare todos os pacientes sobreviventes alcança acurácia de 89,4 % sem identificar nenhum óbito. Pelo mesmo motivo, o VPP deve ser lido em relação à prevalência: um VPP próximo de π indica que ser sinalizado pelo classificador pouco altera a probabilidade de óbito em relação à da coorte como um todo.

Todas essas métricas dependem do limiar escolhido. Reduzir δ aumenta a sensibilidade à custa da especificidade, e vice-versa, de modo que um único par de valores descreve apenas um ponto de operação do classificador. Por esse motivo, a métrica principal deste trabalho é independente de limiar.

2.5.2 Curva ROC e área sob a curva

A curva ROC (*Receiver Operating Characteristic*) representa o classificador em todos os limiares possíveis simultaneamente: para cada δ, marca-se a taxa de verdadeiros positivos (sensibilidade) contra a taxa de falsos positivos ($1-$ especificidade) (FAWCETT, 2006). Um classificador sem capacidade discriminativa produz a diagonal que liga $(0,0)$ a $(1,1)$; um classificador perfeito passa pelo ponto $(0,1)$.

A AUC resume a curva em um único número e admite uma interpretação probabilística direta (HANLEY; MCNEIL, 1982): é a probabilidade de que um paciente sorteado entre os que sofreram o evento receba probabilidade estimada maior que um paciente sorteado entre os que não o sofreram. Com N_1 positivos e N_0 negativos, ela é estimada por

$$\mathrm{AUC} = \frac{1}{N_1 N_0} \sum_{i \in \mathscr{C}_1} \sum_{j \in \mathscr{C}_0} \varphi\left(\hat{p}_i, \hat{p}_j\right), \qquad \varphi(a,b) = \begin{cases} 1, & a > b, \\ \frac{1}{2}, & a = b, \\ 0, & a < b, \end{cases} \tag{2.15}$$

em que $\mathscr{C}_1$ e $\mathscr{C}_0$ são os conjuntos de casos e de controles, com N_1 e N_0 elementos. A função φ compara um caso i com um controle j e vale 1 quando o caso recebeu a maior probabilidade. A AUC é, portanto, a fração dos $N_1 N_0$ pares em que o caso foi ordenado acima do controle: 0,5 corresponde à ordenação aleatória e 1,0 à separação perfeita.

Duas propriedades tornam a AUC adequada como métrica principal deste trabalho. Ela não depende de limiar, o que permite comparar modelos independentemente do ponto de operação escolhido. E ela não depende da prevalência, já que cada par contém exatamente um caso e um controle, o que a torna comparável entre coortes com proporções diferentes de eventos. Em contrapartida, a AUC mede apenas a ordenação: um modelo pode ter AUC elevada e, ainda assim, produzir probabilidades mal calibradas ou um VPP baixo quando o evento é raro.

2.5.3 Curva precisão-revocação e precisão média

Quando a classe positiva é rara, a curva ROC pode transmitir uma impressão otimista: como a taxa de falsos positivos é calculada sobre os numerosos negativos, um número absoluto elevado de falsos positivos pode corresponder a uma taxa pequena. A curva precisão-revocação contorna esse efeito ao relacionar o VPP à sensibilidade, concentrando-se no desempenho sobre a classe positiva (SAITO; REHMSMEIER, 2015; DAVIS; GOADRICH, 2006).

A precisão média (AP) resume essa curva como a média ponderada do VPP obtido em cada limiar, com pesos iguais ao incremento de sensibilidade:

$$\mathrm{AP} = \sum_{q} \left(\mathrm{Sens}_q - \mathrm{Sens}_{q-1}\right) \mathrm{VPP}_q, \tag{2.16}$$

em que VPP_q e Sens_q são o VPP e a sensibilidade no q-ésimo limiar, percorridos em ordem decrescente. Diferentemente da AUC, a AP depende da prevalência: o valor de referência de um classificador aleatório não é 0,5, mas a própria prevalência π, igual a 0,106 nesta coorte. Uma AP só indica capacidade discriminativa quando supera esse valor.

2.5.4 Escolha do limiar de decisão

As métricas da Tabela 8 exigem que um limiar seja fixado. Neste trabalho, o limiar é o que maximiza o índice de Youden (YOUDEN, 1950):

$$J(\delta) = \mathrm{Sensibilidade}(\delta) + \mathrm{Especificidade}(\delta) - 1, \qquad \delta^{*} = \arg\max_{\delta} J(\delta). \tag{2.17}$$

Geometricamente, δ^{*} corresponde ao ponto da curva ROC mais distante da diagonal. O critério atribui o mesmo peso a sensibilidade e especificidade, o que é apropriado quando não se fixou previamente o custo relativo de um falso negativo e de um falso positivo.

O limiar é um parâmetro ajustado aos dados e, como tal, deve ser escolhido sem acesso ao conjunto de teste. Escolhê-lo sobre os mesmos pacientes em que as métricas são reportadas produziria estimativas otimistas de sensibilidade e especificidade. Por isso, δ^{*} é determinado no conjunto de validação interna de cada partição e aplicado, sem alteração, ao conjunto de teste correspondente.

2.5.5 Agregação por paciente

As redes neurais deste trabalho não recebem o Holter inteiro, mas janelas extraídas dele, e produzem uma probabilidade para cada janela. O rótulo, por outro lado, pertence ao paciente. Calcular as métricas sobre janelas trataria como observações independentes centenas de trechos do mesmo exame, que compartilham o mesmo rótulo e são fortemente correlacionados entre si. O tamanho amostral efetivo seria superestimado, e os intervalos de confiança resultantes, estreitos demais — um caso de pseudorreplicação.

Por esse motivo, toda métrica é calculada no nível do paciente. A probabilidade do paciente i é a média das probabilidades de suas M_i janelas:

$$\hat{p}_i = \frac{1}{M_i} \sum_{m=1}^{M_i} \hat{p}_{i,m}, \tag{2.18}$$

em que $\hat{p}_{i,m}$ é a probabilidade estimada para a m-ésima janela. A média reflete o risco típico ao longo do registro e é menos sensível a janelas isoladas com artefato do que alternativas como o máximo.

2.5.6 Validação cruzada estratificada por paciente

Com 517 pacientes e 55 eventos, separar um único conjunto de teste deixaria cerca de uma dezena de casos para a avaliação, e o resultado dependeria fortemente de quais pacientes fossem sorteados. A validação cruzada em K partições reduz essa dependência: os pacientes são divididos em K grupos disjuntos, e cada grupo é usado uma vez como teste enquanto os demais formam o treinamento (KOHAVI, 1995). Ao final, cada paciente recebe exatamente uma predição feita por um modelo que não o viu durante o treinamento — a predição *fora da partição*.

Dois cuidados são essenciais nesse procedimento. O primeiro é a *estratificação*: as partições são formadas de modo que a proporção de eventos seja aproximadamente a mesma em todas, o que evita partições com pouquíssimos casos. O segundo é a *separação por paciente*: todas as janelas de um mesmo exame pertencem à mesma partição. Se janelas de um paciente estivessem simultaneamente no treinamento e no teste, o modelo poderia reconhecer o indivíduo, e não o padrão associado ao desfecho, inflando as métricas. Esse tipo de vazamento de informação está entre os erros mais frequentes em estudos de aprendizado de máquina aplicado (KAPOOR; NARAYANAN, 2023).

Pelo mesmo princípio, todo procedimento que aprende a partir dos dados — imputação de valores ausentes, padronização, cálculo da escala do sinal, redução de dimensionalidade e escolha do limiar — é ajustado apenas com os pacientes de treinamento de cada partição e então aplicado ao teste.

2.5.7 Intervalos de confiança e comparação entre modelos

Uma AUC estimada em 517 pacientes, dos quais 55 positivos, está sujeita a variabilidade amostral considerável, e reportá-la sem intervalo de confiança impediria distinguir um resultado de outro ou do acaso. Os intervalos foram obtidos por *bootstrap* (EFRON; TIBSHIRANI, 1993). O procedimento sorteia, com reposição, N pacientes entre os N da coorte, recalcula a métrica sobre essa reamostra a partir das predições fora da partição e repete o processo B^* vezes. O intervalo de confiança de 95 % é formado pelos percentis 2,5 e 97,5 da distribuição das B^* estimativas. O valor de B^* adotado em cada experimento é informado na metodologia.

O intervalo oferece um critério direto de comparação com o acaso: se ele contém 0,5, o desempenho do classificador não é distinguível de uma ordenação aleatória dos pacientes.

Comparar dois modelos exige um cuidado adicional. Como ambos são avaliados sobre os mesmos pacientes, suas AUC são correlacionadas, e comparar intervalos calculados separadamente seria conservador. Emprega-se, por isso, o *bootstrap* pareado: em cada reamostra, calcula-se a diferença

$$\Delta_b = \mathrm{AUC}_b^{(1)} - \mathrm{AUC}_b^{(2)}, \qquad b = 1, \ldots, B^*, \tag{2.19}$$

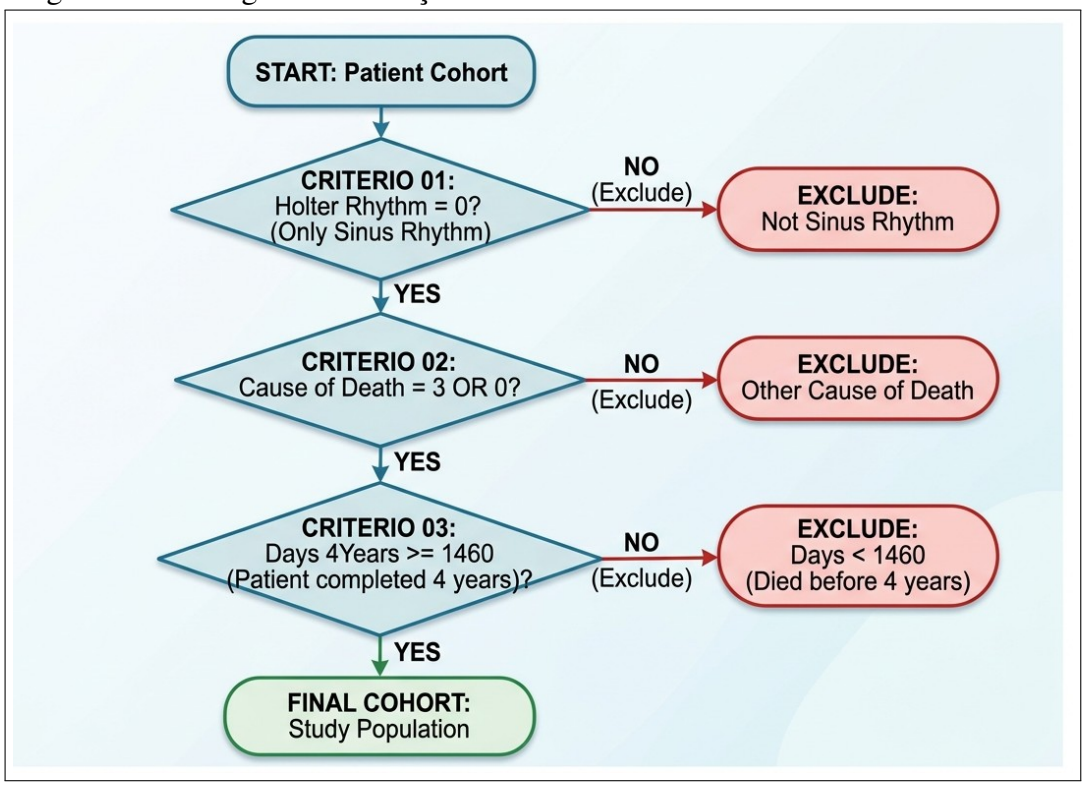
sobre o mesmo conjunto de pacientes sorteados, e o intervalo de confiança da diferença é obtido pelos percentis da distribuição de Δ_b. O modelo 1 é considerado superior ao modelo 2 apenas se esse intervalo não contiver zero.

3 SITEMETODOLOGIA

3.1 Seleção da coorte

A partir dos 992 pacientes da base MUSIC, a coorte foi definida em três etapas, resumidas na Figura 3.

Figura 3 – Fluxograma de seleção da coorte



Fonte: elaborado pelo autor (2026).

A primeira etapa restringiu a análise a pacientes em ritmo sinusal, excluindo 282 indivíduos com fibrilação atrial permanente, *flutter* atrial ou ritmo de marcapasso. A exclusão justifica-se porque a ausência de onda P e a irregularidade dos intervalos RR na fibrilação atrial alteram qualitativamente o traçado, e porque o ritmo imposto pelo marcapasso não reflete a atividade elétrica espontânea do coração.

A segunda etapa definiu os grupos. Foram considerados casos os pacientes com óbito por morte súbita cardíaca, e controles os sobreviventes com seguimento completo de quatro anos. Excluíram-se, por desfecho ambíguo, 35 óbitos de causa não cardíaca, 67 óbitos por falência de bomba e 21 sobreviventes com seguimento inferior a quatro anos. A exclusão destes últimos é necessária na formulação binária: diferentemente da análise de sobrevivência, que incorpora a informação parcial dos indivíduos censurados, a classificação exige rótulo definido para cada

Tabela 9 – Fluxo de seleção da base MUSIC e disponibilidade dos registros de Holter.

Etapa	**N**
Registros de Holter na base (total)	936
Pacientes na base MUSIC	992
Excluídos: ritmo não sinusal	282
Em ritmo sinusal	710
Excluídos por desfecho ambíguo	123
Morte não cardíaca (código 1)	35
Falência de bomba (códigos 6 e 7)	67
Vivos com seguimento inferior a 4 anos	21
Casos + controles	587
Sem registro de Holter	47
Registro sem derivação Z	23
Analisados	517
Casos (MSC; prevalência de 10,6%)	55
Controles	462

paciente, e um sobrevivente acompanhado por menos de quatro anos poderia ter vindo a óbito após o término do seguimento.

A terceira etapa exigiu a presença das três derivações no registro Holter. Foram excluídos 47 pacientes sem registro disponível e 23 cujo registro não continha a derivação Z. A coorte final compreendeu 517 pacientes, dos quais 55 casos e 462 controles, com prevalência de 10,6 %.

3.2 Pré-processamento do sinal

3.2.1 Extração de janelas

Cada registro foi representado por janelas de 24 000 amostras, equivalentes a dois minutos a 200 Hz. Os cinco minutos iniciais e finais de cada registro foram descartados, por concentrarem artefatos de calibração do equipamento, de acomodação do paciente e de retirada dos eletrodos.

As posições das janelas foram definidas de modo distinto no treinamento e na avaliação. No treinamento, cada uma das 250 janelas por paciente teve sua posição sorteada a cada época, de forma independente, ao longo do trecho útil do registro. O procedimento expõe o modelo a recortes diferentes a cada passagem pelos dados e admite sobreposição entre janelas. Na avaliação, as 100 janelas por paciente foram posicionadas em grade regular, igualmente espaçadas ao longo do registro, o que torna as métricas reprodutíveis.

3.2.2 Filtragem

Cada janela foi submetida a filtro passa-faixa de Butterworth de terceira ordem, com frequências de corte de 0,5 e 40 Hz, implementado em seções de segunda ordem e aplicado nos sentidos direto e reverso. A filtragem de fase nula resultante dobra a ordem efetiva do filtro e preserva a morfologia das ondas, conforme discutido na subseção 2.1.2.2.

A frequência de corte inferior remove a oscilação de linha de base e o deslocamento contínuo do sinal, que varia entre pacientes conforme o posicionamento dos eletrodos. A superior atenua o ruído muscular e elimina a interferência da rede elétrica de 50 Hz, situada acima da banda passante. O valor de 0,5 Hz encontra-se dentro do limite admitido pela American Heart Association para filtros digitais de fase nula (KLIGFIELD *et al.*, 2007).

A filtragem foi aplicada a cada janela individualmente, e não ao registro completo. A escolha torna o deslocamento de linha de base removido específico de cada trecho, sem pressupor estabilidade ao longo das 24 horas.

3.2.3 Normalização

Após a filtragem, cada derivação foi dividida por uma constante de escala global, comum a todos os pacientes. A constante corresponde ao percentil 99 do valor absoluto do sinal filtrado, estimado sobre 100 pacientes sorteados do conjunto de treinamento de cada partição, com cinco janelas de 60 s por paciente. As janelas usadas na estimativa passam pelo mesmo filtro aplicado no treinamento, de modo que a escala corresponde à distribuição efetivamente apresentada ao modelo.

A estimativa é refeita a cada partição da validação cruzada, utilizando exclusivamente pacientes do respectivo conjunto de treinamento. Calculá-la uma única vez sobre a coorte completa introduziria informação dos pacientes de teste no pré-processamento.

Os valores normalizados foram limitados ao intervalo $[-5, 5]$. Amostras fora desse intervalo correspondem a amplitudes superiores a cinco vezes a referência de escala, ocorrência compatível com artefato de movimento e não com atividade cardíaca.

A separação entre filtragem e normalização é deliberada. A filtragem por janela remove o deslocamento individual de cada trecho; a escala global preserva as diferenças de amplitude entre pacientes. A padronização por janela, alternativa descartada, realizaria as duas operações simultaneamente e eliminaria a informação de amplitude absoluta.

3.2.4 Particionamento

A coorte foi dividida em cinco partições estratificadas pelo desfecho, com divisão no nível do paciente: cada indivíduo pertence a uma única partição, e as janelas são extraídas apenas após a divisão. Cada partição contém 103 ou 104 pacientes, com 11 casos.

Em cada rodada da validação cruzada, uma partição constitui o conjunto de teste e as quatro restantes, com 413 ou 414 pacientes, são subdivididas: 75 % compõem o conjunto de treinamento e 25 % a validação interna, também com estratificação pelo desfecho. A validação interna define a época de parada do treinamento e o limiar de decisão, que é então aplicado ao conjunto de teste sem ajuste adicional.

3.2.5 Variáveis clínicas

Nos experimentos que combinam o sinal a variáveis clínicas, foram empregadas seis: idade, gênero, classe funcional *New York Heart Association* (NYHA), presença de ondas Q de necrose, taquicardia ventricular não sustentada e taquiarritmia supraventricular paroxística. As variáveis contínuas — idade — e as ordinais foram padronizadas pela média e pelo desvio-padrão do conjunto de treinamento de cada partição.

Duas particularidades da coorte merecem registro. A classe funcional NYHA assume apenas os valores II e III, comportando-se, na prática, como variável binária. A variável de taquiarritmia supraventricular paroxística é originalmente categórica nominal, com códigos para taquicardia supraventricular, fibrilação atrial paroxística, *flutter* e outras; o código de ausência por fibrilação atrial crônica deixa de ocorrer após a restrição ao ritmo sinusal, e a variável foi tratada como indicadora da presença de qualquer episódio.

3.3 Configuração experimental

As arquiteturas avaliadas nas seções seguintes compartilham o mesmo protocolo de preparação dos dados, treinamento e avaliação. Essa uniformidade é condição para que a comparação entre elas isole o efeito da arquitetura, e não o de escolhas acessórias de configuração. Os valores adotados resultaram de ensaios preliminares e são apresentados a seguir, acompanhados da justificativa correspondente.

3.3.1 Representação do sinal

Cada paciente é representado por janelas extraídas de seu registro de 24 horas, e não pelo registro integral. A opção decorre de uma limitação prática: a 200 Hz, três derivações durante 24 horas correspondem a aproximadamente 17 milhões de amostras por paciente, volume incompatível com o processamento em lote na memória disponível.

A Tabela 16 reúne os parâmetros de representação.

Tabela 10 – Parâmetros de representação do sinal

Parâmetro	Valor	Justificativa
Comprimento da janela	24 000 amostras	2 min, cerca de 140 ciclos cardíacos
Janelas por paciente (treino)	250	posições sorteadas a cada época
Janelas por paciente (avaliação)	100	posições em grade fixa
Margem descartada	5 min	calibração do equipamento
Filtro passa-banda	0,5–40 Hz	remove deriva e ruído muscular
Normalização	percentil 99 por derivação	preserva amplitude relativa
Limitação de amplitude	$[-5, 5]$	atenua artefatos de movimento

Fonte: elaborado pelo autor (2026).

A janela de dois minutos abrange aproximadamente 140 ciclos cardíacos a uma frequência de 70 bpm, quantidade suficiente para que a morfologia se repita e para que a variabilidade entre batimentos seja observável. Janelas mais curtas podem recair sobre trechos sem conteúdo relevante; janelas mais longas elevam o consumo de memória e reduzem o número de amostras disponíveis por paciente.

No treinamento, as posições das janelas são sorteadas a cada época, funcionando como forma de aumento de dados: o modelo nunca observa exatamente o mesmo recorte duas vezes. Na avaliação, as posições seguem grade regular determinística, assegurando reprodutibilidade das métricas.

A separação entre filtragem e normalização é deliberada. O filtro passa-banda remove o deslocamento de linha de base de cada janela individualmente — deslocamento que varia entre pacientes conforme o posicionamento dos eletrodos. A escala, por sua vez, é estimada uma única vez sobre o conjunto de treinamento de cada partição, de modo idêntico para todos os pacientes, o que preserva as diferenças de amplitude entre indivíduos — informação associada a condições como baixa voltagem e hipertrofia ventricular. A padronização por janela, alternativa descartada, executaria as duas operações simultaneamente e eliminaria essa informação.

3.3.2 Treinamento

A Tabela 17 apresenta os hiperparâmetros de otimização, mantidos constantes em todas as arquiteturas.

Tabela 11 – Hiperparâmetros de treinamento

Parâmetro	Valor	Justificativa
Otimizador	AdamW	desacopla regularização do gradiente
Taxa de aprendizado	$1{,}0 \times 10^{-4}$	valores maiores causaram instabilidade
Regularização (λ)	$1{,}0 \times 10^{-2}$	limite superior usual
Descarte	0,6	compensa a razão parâmetros/eventos
Tamanho do lote	256[1]	
Épocas máximas	20	melhor época ocorreu antes da quinta
Paciência	10 épocas	sobre média móvel de três
Agrupamento	média e máximo	estado típico e instante extremo
Precisão	mista (fp16)	reduz consumo de memória

Fonte: elaborado pelo autor (2026).

Os valores de regularização e descarte situam-se no extremo superior das faixas habituais. A escolha decorre da razão entre o número de parâmetros e o de eventos disponíveis: mesmo a arquitetura mais enxuta avaliada dispõe de 109 361 parâmetros para 37 casos positivos no conjunto de treinamento. Em ensaios preliminares, valores menores de regularização produziram perdas de treinamento próximas de zero já na terceira época.

O limite de 20 épocas acompanha a observação, recorrente em todas as arquiteturas, de que o melhor valor de AUC sobre o conjunto de validação ocorre nas primeiras épocas. O critério de parada emprega média móvel de três épocas em lugar do valor pontual: com sete a onze eventos no conjunto de validação, a métrica de uma única época oscila substancialmente sem que o modelo tenha se alterado de forma apreciável, e a suavização evita que se selecione o pico do ruído.

3.3.3 Desbalanceamento entre classes

Com prevalência de 10,6 %, um classificador que atribua a classe majoritária a todos os pacientes alcança acurácia de 89,4 % com sensibilidade nula. Para evitar a convergência a esse ótimo local, a função de perda de entropia cruzada binária foi ponderada pelo fator

$$w_+ = \frac{N_0}{N_1} \approx 8{,}5, \tag{3.1}$$

[1] Reduzido para 128 na ResNet-50 por limitação de memória da unidade de processamento gráfico.

em que N_0 e N_1 denotam, respectivamente, o número de controles e de casos no conjunto de treinamento de cada partição. O fator multiplica a contribuição dos casos positivos ao gradiente, sendo equivalente a replicar cada evento 8,5 vezes sem descartar controles.

Técnicas de subamostragem da classe majoritária foram descartadas: o equilíbrio entre classes seria obtido às custas de reduzir a coorte de 517 para 110 pacientes, sem alterar o número de eventos — que constitui o fator efetivamente limitante — e com ampliação dos intervalos de confiança.

3.3.4 Protocolo de avaliação

A avaliação emprega validação cruzada estratificada em cinco partições. A divisão ocorre no nível do paciente, e as janelas são extraídas somente após a separação: nenhum indivíduo contribui simultaneamente para treinamento e teste. O cuidado é necessário porque janelas de um mesmo registro compartilham a assinatura eletrocardiográfica individual — eixo elétrico, morfologia do complexo QRS e relação de amplitude entre derivações —, e sua presença em ambos os conjuntos permitiria ao modelo reconhecer o paciente em lugar de estimar o risco.

De cada conjunto de treinamento, uma fração é reservada para a definição do critério de parada antecipada e do limiar de decisão. O limiar é obtido pelo índice de Youden, que maximiza a soma de sensibilidade e especificidade, e apenas aplicado ao conjunto de teste — sua determinação a partir do próprio teste produziria estimativas otimistas.

As probabilidades preditas para as janelas de um mesmo paciente são agregadas por média antes do cálculo de qualquer métrica. Sem essa agregação, um indivíduo com 100 janelas seria contabilizado cem vezes, como se correspondesse a cem observações independentes — o que estreitaria artificialmente os intervalos de confiança.

Os intervalos de confiança de 95 % foram estimados por reamostragem *bootstrap* com 2 000 repetições, sorteando pacientes com reposição. Comparações entre modelos empregaram reamostragem pareada: a mesma amostra avalia ambos os modelos, de modo a isolar a incerteza da diferença.

3.3.5 Métricas

A métrica principal é a AUC, que mede a capacidade de ordenar corretamente os pacientes por risco e independe do limiar adotado. Reporta-se também a AP, cuja linha de base sob classificação aleatória é a prevalência da classe positiva — 0,106 nesta coorte — em lugar

de 0,5, o que a torna mais informativa quando os eventos são raros.

Sensibilidade, especificidade e VPP são reportadas no limiar definido na validação. A acurácia não é empregada como critério de comparação pela razão já exposta: o classificador trivial a maximiza sem apresentar utilidade.

Dois valores de AUC são apresentados em cada seção. A média entre partições, acompanhada do desvio-padrão, indica a estabilidade do resultado em relação à composição das partições. A estimativa agrupada, calculada sobre a totalidade dos 517 pacientes — cada um predito pelo modelo que não o observou durante o treinamento —, é considerada mais confiável por avaliar simultaneamente os 55 eventos, enquanto cada partição isolada dispõe de apenas onze. Eventuais discrepâncias entre as duas estimativas decorrem de os modelos ajustados em cada partição produzirem probabilidades em escalas distintas, que não coincidem exatamente ao serem reunidas em ordenamento único.

3.3.6 Experimentos com a rede convolucional

A rede convolucional descrita na subseção 2.2.7 foi avaliada em um delineamento fatorial com dois fatores: a capacidade do modelo, nas variantes mínima, simples e média, e a duração da janela de entrada, de 2 minutos e de 10 segundos. As seis combinações resultantes, listadas na Tabela 12, foram treinadas sob configuração idêntica, de modo que as diferenças de desempenho possam ser atribuídas apenas a esses dois fatores.

Tabela 12 – Combinações avaliadas da rede convolucional

Variante	Parâmetros	Janela de 2 min	Janela de 10 s
Mínima	14 425	E1	E4
Simples	109 361	E2	E5
Média	418 145	E3	E6

Fonte: elaborado pelo autor (2026).

3.3.6.1 Amostragem das janelas

No treinamento, cada paciente contribui com o mesmo número de janelas por época nas duas durações. Desse modo, as seis configurações recebem o mesmo número de atualizações de gradiente, e o que varia entre as janelas de 2 minutos e de 10 segundos é apenas o conteúdo de cada exemplo. As janelas de um paciente são sorteadas a cada época entre blocos consecutivos e sem sobreposição do registro, descartados os 5 minutos iniciais e finais. A permutação dos

blocos é determinada pelo paciente e pela época, o que garante que duas janelas do mesmo paciente nunca se sobreponham dentro de uma época e que épocas sucessivas percorram trechos diferentes do exame.

Na avaliação, as janelas são posicionadas em uma grade fixa e uniforme ao longo do registro, o que torna a predição reprodutível. São avaliadas 200 janelas por paciente nas duas durações, o que corresponde a cerca de 6,7 horas de registro com a janela de 2 minutos e a cerca de 33 minutos com a de 10 segundos.

3.3.6.2 Filtragem com margem

O filtro passa-faixa descrito na seção 3.2 requer alguns segundos de sinal para estabilizar e, quando aplicado a um trecho curto, distorce suas extremidades. Para evitar esse efeito, cada janela é lida com 5 segundos adicionais de cada lado, filtrada e, em seguida, recortada no comprimento nominal. A rede recebe, assim, exatamente 24 000 ou 2 000 amostras livres do transitório de borda, o que é particularmente relevante para a janela de 10 segundos, na qual as margens distorcidas representariam fração apreciável do sinal.

3.3.6.3 Configuração comum

As seis configurações compartilham a validação cruzada em cinco partições estratificadas por paciente, com 25 % do conjunto de treinamento de cada partição reservado para validação interna (309 ou 310 pacientes de treinamento por partição), a função de perda ponderada da Equação 2.7, o otimizador AdamW com taxa de aprendizado de 10^{-4} e decaimento de pesos de 10^{-2}, lotes de 256 janelas e no máximo 30 épocas, com interrupção antecipada após 15 épocas sem melhora. Em cada época, cada paciente contribui com 350 janelas de treinamento. A probabilidade de cada paciente é a média das probabilidades de suas janelas, e o limiar de decisão é escolhido pelo índice de Youden na validação interna, nunca no conjunto de teste.

3.4 Redes neurais aplicadas ao sinal

Esta seção descreve as arquiteturas de redes neurais avaliadas sobre o sinal de Holter e o protocolo comum de treinamento e avaliação. Todas as redes recebem janelas do sinal pré-processado conforme a seção 3.2, produzem uma probabilidade por janela e são avaliadas no nível do paciente, após a agregação descrita na subseção 2.5.5. Os fundamentos de cada

componente foram apresentados no **??**; esta seção registra as escolhas efetivamente adotadas.

3.4.1 Arquiteturas avaliadas

As arquiteturas foram organizadas em quatro famílias, avaliadas em ordem crescente de complexidade. A Tabela 13 resume cada uma delas.

1. **Redes convolucionais sem atalhos.** A rede convolucional descrita na seção 2.2, em três variantes de capacidade — mínima, simples e média — que diferem apenas no número de blocos e de filtros. É a família de menor capacidade e serve de referência para as demais.
2. **Redes residuais.** Adaptações unidimensionais da ResNet (HE *et al.*, 2016), na linha das redes empregadas para a classificação de ECG por Hannun *et al.* (2019) e Ribeiro *et al.* (2020). Foram avaliadas profundidades de 18, 34 e 50 camadas e, para a profundidade de 18 camadas, três larguras, de modo a separar o efeito da profundidade do efeito do número de canais.
3. **Rede residual com atenção.** A ResNet-18 seguida de um codificador *Transformer* (VASWANI *et al.*, 2017), que recebe a sequência de vetores produzida pelo último estágio residual e permite que cada trecho da janela seja relacionado aos demais antes do agrupamento.
4. **Fusão com variáveis clínicas.** A ResNet-18 com um segundo ramo, que recebe as seis variáveis clínicas da **??**. As representações dos dois ramos são concatenadas antes do classificador. Para medir a contribuição de cada modalidade, a mesma arquitetura foi treinada também com cada ramo isolado.

Tabela 13 – Arquiteturas de redes neurais avaliadas sobre o sinal de Holter

Família	Variante	Parâmetros	Entrada
Convolucional	mínima (3 blocos)	14 425	2 min e 10 s
	simples (4 blocos)	109 361	2 min e 10 s
	média (4 blocos)	418 145	2 min e 10 s
Residual	ResNet-18 mínima	78 169	5,12 s
	ResNet-18 reduzida	1 029 985	2 min
	ResNet-18	3 976 385	2 min e 5,12 s
	ResNet-34	7 350 721	2 min
	ResNet-50	16 479 937	2 min
Atenção	ResNet-18 + *Transformer*	1 491 553	2 min
Fusão	ResNet-18 + ramo clínico	3 987 041	2 min + 6 variáveis

Fonte: elaborado pelo autor (2026).

Todas as variantes compartilham o mesmo classificador final — agrupamento global

por média e máximo, seguido de duas camadas totalmente conectadas com descarte — e a mesma saída: um único *logit* por janela, convertido em probabilidade pela Equação 2.6. A diferença entre elas está apenas no extrator de características, o que permite atribuir as diferenças de desempenho à arquitetura.

3.4.2 Estratégias de treinamento da rede de fusão

Na rede de fusão, o ramo do sinal tem cerca de 4 milhões de parâmetros, enquanto o ramo clínico recebe apenas seis variáveis. Treinados juntos com a mesma taxa de aprendizado, o ramo do sinal tende a dominar o ajuste e a memorizar os pacientes de treinamento antes que o ramo clínico contribua. Para controlar esse desequilíbrio, foram comparadas três estratégias:

- *treinamento conjunto*, com a mesma taxa de aprendizado (10^{-4}) para toda a rede;
- *taxa de aprendizado discriminativa*, em que o ramo do sinal recebe taxa de 10^{-6} e decaimento de pesos de 10^{-1}, e o restante da rede mantém 10^{-4} e 10^{-2};
- *ramo do sinal congelado*, em que apenas o ramo clínico e o classificador são ajustados.

3.4.3 Protocolo de treinamento e avaliação

Todas as redes foram treinadas e avaliadas pelo mesmo procedimento, resumido na Figura 4 e detalhado a seguir. Os hiperparâmetros constam da Tabela 17.

3.4.3.1 Divisão dos pacientes

Os 517 pacientes foram divididos em cinco partições estratificadas, com 103 ou 104 pacientes e 11 casos cada uma. Em cada rodada, uma partição forma o conjunto de teste e as outras quatro, o conjunto de desenvolvimento. Deste, 25 % dos pacientes, também por sorteio estratificado, formam a validação interna, e os 75 % restantes, o treinamento — 309 ou 310 pacientes, dos quais 33 casos. A validação interna é usada para escolher a época do modelo e o limiar de decisão; o conjunto de teste não participa de nenhuma escolha.

A cada rodada, as estatísticas que dependem dos dados — a escala do sinal por derivação, as médias e desvios das variáveis clínicas e o peso da classe positiva, $w_+ = N_0/N_1 \approx 8{,}4$ — são recalculadas com os pacientes de treinamento daquela rodada.

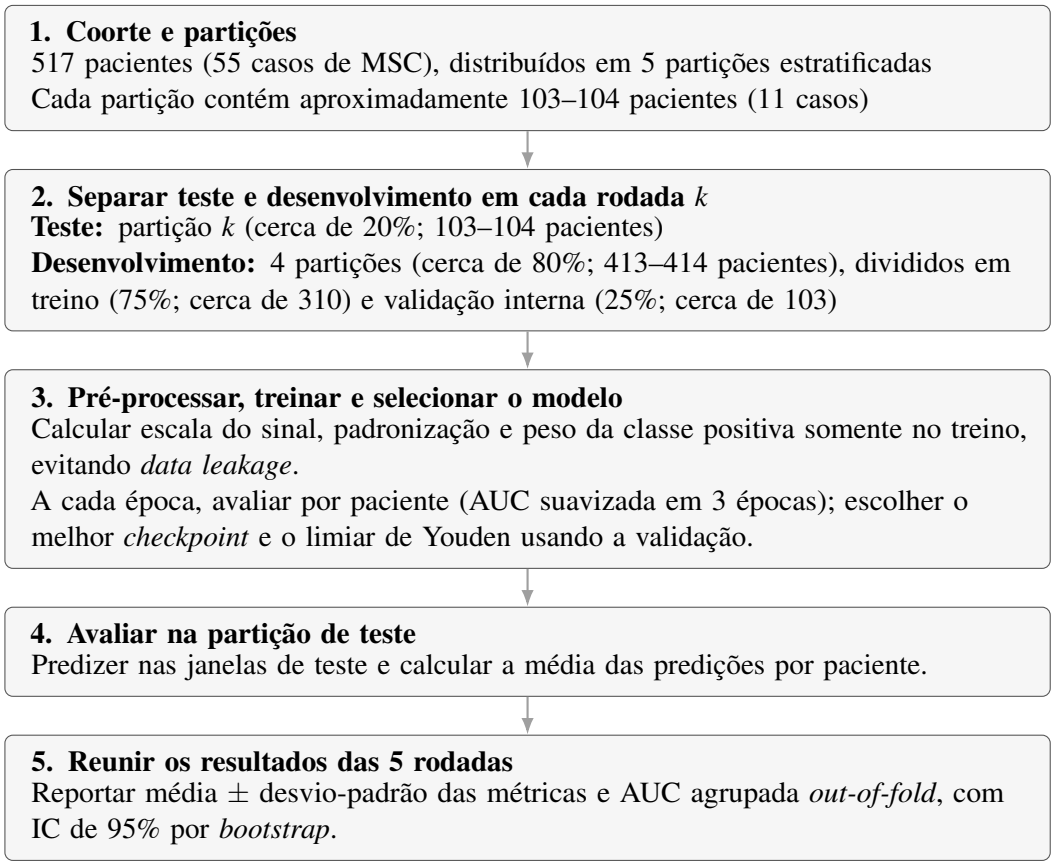


Figura 4 – Fluxo da validação cruzada estratificada em 5 partições. As etapas 2–4 são repetidas para cada partição, com avaliação no nível do paciente.

3.4.3.2 Seleção da época

Ao final de cada época, a rede prediz as janelas da validação interna, as probabilidades são agregadas por paciente, e calcula-se a AUC. Como a validação contém apenas 11 casos, a AUC de uma única época oscila consideravelmente sem que o modelo tenha mudado de forma relevante. Por isso, o critério de seleção é a média móvel da AUC nas três últimas épocas: os pesos são salvos sempre que essa média supera o melhor valor anterior, e o treinamento é interrompido quando ela deixa de melhorar por um número pré-definido de épocas. A taxa de aprendizado decai ao longo das épocas segundo uma função cosseno.

3.4.3.3 Avaliação no teste

Concluído o treinamento, os pesos da melhor época são restaurados. O limiar de decisão é obtido pelo índice de Youden (Equação 2.17) sobre as predições da validação interna e aplicado, sem alteração, ao conjunto de teste. Para cada paciente de teste, a probabilidade é a média das probabilidades de suas janelas.

3.4.3.4 Consolidação das cinco rodadas

Os resultados de cada arquitetura são reportados de duas formas complementares. A primeira é a média e o desvio-padrão das métricas das cinco partições, que indicam a estabilidade do modelo: desvios elevados sinalizam que o resultado depende de quais pacientes caíram em cada partição. A segunda reúne as predições fora da partição dos 517 pacientes em uma única curva ROC, cuja AUC recebe um intervalo de confiança de 95 % por *bootstrap* com $B^{*} = 1\,000$ reamostragens de pacientes. Para as métricas dependentes de limiar dessa curva agrupada, emprega-se a mediana dos cinco limiares obtidos nas validações internas.

Como análise secundária, registra-se também a AUC obtida quando a probabilidade do paciente é a máxima, e não a média, de suas janelas, o que privilegia a janela de maior risco ao longo do registro.

3.5 Extração dos marcadores eletrocardiográficos

Os marcadores descritos na seção 2.4 foram extraídos dos registros de Holter dos 517 pacientes da coorte segundo dois protocolos, que diferem na duração e na densidade dos segmentos analisados. O protocolo A privilegia segmentos longos, que permitem a análise espectral; o protocolo B adota segmentos curtos e densos, que permitem acompanhar o ritmo ao longo do dia, seguindo o desenho de Swee *et al.* (2026). A Tabela 14 resume as diferenças. Ambos empregam o mesmo filtro passa-faixa das redes neurais (seção 3.2) e a biblioteca NeuroKit2 (MAKOWSKI *et al.*, 2021) para a detecção de picos e a delineação dos batimentos.

Tabela 14 – Protocolos de extração dos marcadores

	Protocolo A	Protocolo B
Segmento	5 minutos	30 segundos
Espaçamento	um segmento por hora	um segmento a cada 2 minutos
Margem descartada	1 hora em cada extremidade	1 hora em cada extremidade
Segmentos por paciente	cerca de 21	cerca de 650
Derivação	a de maior amplitude	Y
Correção de artefatos	sim	não
Base da VFC	intervalos RR filtrados	intervalos NN
Domínio da frequência	sim	não
Indicadores de ectopia	proporção de RR irregulares	contagens completas

Fonte: elaborado pelo autor (2026).

3.5.1 Protocolo A: segmentos de 5 minutos

Do registro de cada paciente foi extraído um segmento de 5 minutos a cada hora, a partir de 1 hora após o início e até 1 hora antes do fim. A primeira e a última hora foram descartadas por concentrarem os artefatos de colocação e de retirada dos eletrodos. Foram obtidos 11 071 segmentos dos 517 pacientes, com mediana de 22 por paciente (mínimo de 16).

Em cada segmento, os picos R foram detectados na derivação de maior desvio-padrão, que tende a apresentar a melhor relação sinal-ruído, com a correção de artefatos do NeuroKit2 (LIPPONEN; TARVAINEN, 2019). Intervalos RR fora da faixa de 300 a 2 000 ms, ou afastados mais de 40 % da mediana do segmento, foram descartados, e segmentos com menos de 30 picos ou 20 intervalos válidos não produziram marcadores. Foram calculados 22 marcadores: a frequência cardíaca média, o intervalo RR médio, o SDNN, o RMSSD, o pNN50, o coeficiente de variação e o índice triangular dos intervalos; as potências VLF, LF e HF e a razão LF/HF; o SD1, o SD2, a razão SD1/SD2 e a entropia amostral; a duração do QRS, o QT e o QTc; a amplitude de cada derivação; e a proporção de intervalos afastados mais de 20 % da mediana, como indicador de irregularidade. Todos foram obtidos em pelo menos 99,6 % dos segmentos.

Os segmentos de cada paciente foram resumidos pela média de cada marcador, que descreve seu nível típico, e pelo desvio-padrão entre segmentos, que descreve sua variação ao longo do registro, totalizando 44 variáveis por paciente. A diferença entre o primeiro e o último terço do registro também foi calculada, mas não foi utilizada nos modelos.

Antes da modelagem, valores acima de limites fisiológicos — 200 ms para SDNN, RMSSD e SD1, e 400 ms para SD2 — foram tratados como ausentes, o que afetou 200 valores, e imputados pela mediana do conjunto de treinamento de cada partição. Esse tratamento tem uma consequência que se tornou evidente apenas depois: os valores extremos não se distribuíam ao acaso. Dos 34 pacientes com SD1 médio superior a 200 ms, 7 eram casos, o que corresponde a 12,7 % dos casos contra 5,8 % dos controles. Os extremos refletiam, em boa parte, batimentos ectópicos e falhas de detecção, que a correção de artefatos e o filtro de 40 % não removeram por completo, e motivaram a revisão adotada no protocolo B.

3.5.2 Protocolo B: segmentos de 30 segundos

O protocolo B segue Swee *et al.* (2026), que extraem marcadores de segmentos de 30 segundos não sobrepostos. Para reduzir o custo computacional, extraiu-se um segmento

de 30 segundos a cada 2 minutos de registro, mantidas as margens de 1 hora, o que resultou em 328 807 segmentos, com mediana de 652 por paciente. Os picos R foram detectados na derivação Y, como no trabalho de referência, após a limpeza do sinal pelo método padrão do NeuroKit2 e *sem* correção de artefatos: a correção substitui os batimentos ectópicos por batimentos interpolados e apagaria justamente os eventos que os indicadores de ectopia procuram contar.

3.5.2.1 Classificação dos intervalos

Cada intervalo RR foi classificado em três categorias. Intervalos fora da faixa de 250 a 3 000 ms foram considerados *implausíveis*, por corresponderem a picos duplicados ou a perdas de sinal. Entre os plausíveis, foram considerados *normais* (NN) os que não se afastam mais de 20 % da mediana móvel dos cinco intervalos vizinhos. A mediana local, e não a do segmento inteiro, acompanha as variações lentas da frequência cardíaca, de modo que um trecho em que o paciente apenas acelerou não seja confundido com ectopia. Os intervalos plausíveis restantes foram considerados *irregulares*.

3.5.2.2 Marcadores calculados

Os marcadores de VFC — frequência média, SDNN, RMSSD, pNN50, SD1, SD2 e SD1/SD2 — foram calculados apenas sobre os intervalos NN, e somente em segmentos com pelo menos oito deles. As diferenças sucessivas consideraram apenas pares de intervalos NN adjacentes no registro. Marcadores espectrais e a entropia amostral não foram calculados, pelos motivos expostos na subseção 2.4.5.

Os indicadores de ectopia foram obtidos a partir da mediana local: foram considerados *precoces* os intervalos inferiores a 80 % dela; *extrassístoles*, os intervalos precoces seguidos de outro superior a 115 % dela; e *dupletes*, dois intervalos precoces consecutivos. Registraram-se ainda a maior pausa, o número de pausas superiores a 2 segundos e as frações de intervalos irregulares e implausíveis.

Para a morfologia, os batimentos foram delineados pelo método de proeminência do NeuroKit2 (**??**). A largura do QRS foi tomada entre o início e o fim do complexo, e o QT, do início do QRS ao fim da onda T, com a mediana sobre os batimentos do segmento. O QTc foi calculado pela Equação 2.14 com a média dos intervalos NN. Registraram-se ainda as frações de batimentos com onda P e com onda T identificadas e a amplitude de cada derivação. Em um

teste preliminar, o método de ondaletas inicialmente considerado produziu durações de QRS sistematicamente superiores a 125 ms em todos os segmentos de um mesmo paciente, indício de superestimação, e foi substituído.

3.5.2.3 Controle de qualidade

Uma primeira versão da extração calculava a VFC sobre todos os intervalos plausíveis, sem separar os intervalos NN. Nela, 19,65 % dos segmentos apresentaram RMSSD superior a 200 ms, valor implausível em repouso, e 12,35 % apresentaram SDNN acima do mesmo limite. Esses valores não eram ruído aleatório: resultavam de batimentos ectópicos e de picos não detectados, que inflam as diferenças sucessivas. Tratá-los como ausentes teria removido seletivamente os segmentos com ectopia.

Com o cálculo restrito aos intervalos NN, as proporções caíram para 2,21 % e 2,94 %, e as medianas do RMSSD e do SDNN passaram de 41,7 para 23,9 ms e de 44,0 para 29,5 ms, respectivamente (Tabela 15). A queda das medianas mostra que a inflação não se restringia aos extremos, mas afetava a distribuição como um todo. Na versão final, a mediana da fração de intervalos NN por segmento foi de 1,00, e 11,1 % dos segmentos tiveram menos de 80 % de intervalos normais. Todos os marcadores foram calculados em pelo menos 96 % dos segmentos, e a largura do QRS em 98,7 %.

Tabela 15 – Efeito do cálculo sobre intervalos NN nos marcadores de variabilidade (328 807 segmentos)

	Acima de 200 ms		Mediana (ms)	
Marcador	Todos os RR	NN	Todos os RR	NN
RMSSD	19,65 %	2,21 %	41,7	23,9
SDNN	12,35 %	2,94 %	44,0	29,5

Fonte: elaborado pelo autor (2026).

3.5.2.4 Resumo por paciente

Os segmentos de cada paciente foram resumidos em uma única linha. Para os marcadores contínuos, calcularam-se a mediana, o intervalo interquartil e os percentis 10 e 90; para as contagens de ectopia, a média por segmento e a fração de segmentos com pelo menos um evento. Os limites fisiológicos não foram aplicados nesta etapa, pois os resumos por mediana e percentis são robustos aos valores extremos remanescentes.

A partir desses resumos, foram definidos três conjuntos de variáveis, de dimensão crescente: o conjunto A, apenas com a mediana de cada marcador contínuo e a média de cada contagem (32 variáveis); o conjunto B, que acrescenta o intervalo interquartil e a fração de segmentos com evento (64 variáveis); e o conjunto C, com todos os resumos (122 variáveis).

3.5.3 Número de variáveis e risco de sobreajuste

Os dois protocolos produzem de algumas dezenas a mais de uma centena de variáveis por paciente, um número elevado diante de 55 eventos. A regra usual de pelo menos dez eventos por variável em modelos de regressão logística (PEDUZZI *et al.*, 1996) limitaria o modelo a cerca de cinco variáveis. Por isso, os modelos apresentados na **??** empregam penalização, redução de dimensionalidade ou seleção de variáveis, sempre ajustadas dentro de cada partição da validação cruzada, conforme a subseção 2.5.6.

4 RESULTADOS

4.1 Configuração experimental

As arquiteturas avaliadas nas seções seguintes compartilham o mesmo protocolo de preparação dos dados, treinamento e avaliação. Essa uniformidade é condição para que a comparação entre elas isole o efeito da arquitetura, e não o de escolhas acessórias de configuração. Os valores adotados resultaram de ensaios preliminares e são apresentados a seguir, acompanhados da justificativa correspondente.

4.1.1 Representação do sinal

Cada paciente é representado por janelas extraídas de seu registro de 24 horas, e não pelo registro integral. A opção decorre de uma limitação prática: a 200 Hz, três derivações durante 24 horas correspondem a aproximadamente 17 milhões de amostras por paciente, volume incompatível com o processamento em lote na memória disponível.

A Tabela 16 reúne os parâmetros de representação.

Tabela 16 – Parâmetros de representação do sinal

Parâmetro	Valor	Justificativa
Comprimento da janela	24 000 amostras	2 min, cerca de 140 ciclos cardíacos
Janelas por paciente (treino)	250	posições sorteadas a cada época
Janelas por paciente (avaliação)	100	posições em grade fixa
Margem descartada	5 min	calibração do equipamento
Filtro passa-banda	0,5–40 Hz	remove deriva e ruído muscular
Normalização	escala global por derivação	preserva amplitude relativa

Fonte: elaborado pelo autor (2026).

A janela de dois minutos abrange aproximadamente 140 ciclos cardíacos a uma frequência de 70 bpm, quantidade suficiente para que a morfologia se repita e para que a variabilidade entre batimentos seja observável. Janelas mais curtas podem recair sobre trechos sem conteúdo relevante; janelas mais longas elevam o consumo de memória e reduzem o número de amostras disponíveis por paciente.

No treinamento, as posições das janelas são sorteadas a cada época, funcionando como forma de aumento de dados: o modelo nunca observa exatamente o mesmo recorte duas vezes. Na avaliação, as posições seguem grade regular determinística, assegurando reprodutibilidade das métricas.

A separação entre filtragem e normalização é deliberada. O filtro passa-banda remove o deslocamento de linha de base de cada janela individualmente — deslocamento que varia entre pacientes conforme o posicionamento dos eletrodos, tendo-se observado medianas de $-0{,}29$, $-0{,}96$ e $+0{,}42$ mV nas três derivações de um mesmo registro. A escala, por sua vez, é estimada uma única vez sobre o conjunto de treinamento de cada partição, de modo idêntico para todos os pacientes, o que preserva as diferenças de amplitude entre indivíduos — informação associada a condições como baixa voltagem e hipertrofia ventricular. A padronização por janela, alternativa descartada, executaria as duas operações simultaneamente e eliminaria essa informação.

4.1.2 Treinamento

A Tabela 17 apresenta os hiperparâmetros de otimização, mantidos constantes em todas as arquiteturas.

Tabela 17 – Hiperparâmetros de treinamento

Parâmetro	Valor	Justificativa
Otimizador	AdamW	desacopla regularização do gradiente
Taxa de aprendizado	$1{,}0 \times 10^{-4}$	valores maiores causaram instabilidade
Regularização (λ)	$1{,}0 \times 10^{-2}$	limite superior usual
Descarte	0,6	compensa a razão parâmetros/eventos
Tamanho do lote	256[1]	
Épocas máximas	20	melhor época ocorreu antes da quinta
Paciência	10 épocas	sobre média móvel de três
Agrupamento	média e máximo	estado típico e instante extremo
Precisão	mista (fp16)	reduz consumo de memória

Fonte: elaborado pelo autor (2026).

Os valores de regularização e descarte situam-se no extremo superior das faixas habituais. A escolha decorre da razão entre o número de parâmetros e o de eventos disponíveis: mesmo a arquitetura mais enxuta avaliada dispõe de 109 361 parâmetros para 37 casos positivos no conjunto de treinamento. Em ensaios preliminares, valores menores de regularização produziram perdas de treinamento próximas de zero já na terceira época.

O limite de 20 épocas acompanha a observação, recorrente em todas as arquiteturas, de que o melhor valor de AUC sobre o conjunto de validação ocorre nas primeiras épocas. O critério de parada emprega média móvel de três épocas em lugar do valor pontual: com sete a onze eventos no conjunto de validação, a métrica de uma única época oscila substancialmente sem que o modelo tenha se alterado de forma apreciável, e a suavização evita que se selecione o

[1] Reduzido para 128 na ResNet-50 por limitação de memória da unidade de processamento gráfico.

pico do ruído.

4.1.3 Desbalanceamento entre classes

Com prevalência de 10,6 %, um classificador que atribua a classe majoritária a todos os pacientes alcança acurácia de 89,4 % com sensibilidade nula. Para evitar a convergência a esse ótimo local, a função de perda de entropia cruzada binária foi ponderada pelo fator

$$w_+ = \frac{N_0}{N_1} \approx 8{,}5, \tag{4.1}$$

em que N_0 e N_1 denotam, respectivamente, o número de controles e de casos no conjunto de treinamento de cada partição. O fator multiplica a contribuição dos casos positivos ao gradiente, sendo equivalente a replicar cada evento 8,5 vezes sem descartar controles.

Técnicas de subamostragem da classe majoritária foram descartadas: o equilíbrio entre classes seria obtido às custas de reduzir a coorte de 517 para 110 pacientes, sem alterar o número de eventos — que constitui o fator efetivamente limitante — e com ampliação dos intervalos de confiança.

4.1.4 Protocolo de avaliação

A avaliação emprega validação cruzada estratificada em cinco partições. A divisão ocorre no nível do paciente, e as janelas são extraídas somente após a separação: nenhum indivíduo contribui simultaneamente para treinamento e teste. O cuidado é necessário porque janelas de um mesmo registro compartilham a assinatura eletrocardiográfica individual — eixo elétrico, morfologia do complexo QRS e relação de amplitude entre derivações —, e sua presença em ambos os conjuntos permitiria ao modelo reconhecer o paciente em lugar de estimar o risco.

De cada conjunto de treinamento, uma fração é reservada para a definição do critério de parada antecipada e do limiar de decisão. O limiar é obtido pelo índice de Youden, que maximiza a soma de sensibilidade e especificidade, e apenas aplicado ao conjunto de teste — sua determinação a partir do próprio teste produziria estimativas otimistas.

As probabilidades preditas para as janelas de um mesmo paciente são agregadas por média antes do cálculo de qualquer métrica. Sem essa agregação, um indivíduo com 100 janelas seria contabilizado cem vezes, como se correspondesse a cem observações independentes — o que estreitaria artificialmente os intervalos de confiança.

Os intervalos de confiança de 95 % foram estimados por reamostragem *bootstrap* com 2 000 repetições, sorteando pacientes com reposição. Comparações entre modelos empregaram reamostragem pareada: a mesma amostra avalia ambos os modelos, de modo a isolar a incerteza da diferença.

4.1.5 Métricas

A métrica principal é a AUC, que mede a capacidade de ordenar corretamente os pacientes por risco e independe do limiar adotado. Reporta-se também a AP, cuja linha de base sob classificação aleatória é a prevalência da classe positiva — 0,106 nesta coorte — em lugar de 0,5, o que a torna mais informativa quando os eventos são raros.

Sensibilidade, especificidade e VPP são reportadas no limiar definido na validação. A acurácia não é empregada como critério de comparação pela razão já exposta: o classificador trivial a maximiza sem apresentar utilidade.

Dois valores de AUC são apresentados em cada seção. A média entre partições, acompanhada do desvio-padrão, indica a estabilidade do resultado em relação à composição das partições. A estimativa agrupada, calculada sobre a totalidade dos 517 pacientes — cada um predito pelo modelo que não o observou durante o treinamento —, é considerada mais confiável por avaliar simultaneamente os 55 eventos, enquanto cada partição isolada dispõe de apenas onze. Eventuais discrepâncias entre as duas estimativas decorrem de os modelos ajustados em cada partição produzirem probabilidades em escalas distintas, que não coincidem exatamente ao serem reunidas em ordenamento único.

4.2 Rede convolucional aplicada ao sinal bruto

A primeira arquitetura avaliada foi uma rede neural convolucional (CNN) unidimensional sem conexões residuais, composta por quatro blocos sequenciais. Cada bloco executa convolução, normalização em lote, ativação *ReLU*, agrupamento máximo com fator quatro e descarte. O número de filtros duplica a cada bloco — 16, 32, 64 e 64 — enquanto o comprimento temporal é dividido por quatro, reduzindo-se de 24 000 para 93 posições.

O núcleo convolucional foi dimensionado em 15 amostras, equivalentes a 75 ms na frequência de amostragem de 200 Hz — aproximadamente a duração de um complexo QRS. Essa escolha difere da convenção herdada de arquiteturas para imagens, em que núcleos de três

elementos são predominantes e corresponderiam, neste contexto, a 15 ms. O agrupamento global combina média e máximo ao longo do tempo, permitindo que a representação final capture tanto o estado típico da janela quanto o instante de maior ativação.

A configuração resultante possui 109 361 parâmetros treináveis, o menor valor entre as arquiteturas aplicadas ao sinal bruto, correspondendo a 311 parâmetros por paciente do conjunto de treinamento.

4.2.1 Protocolo

Cada paciente foi representado por janelas de 24 000 amostras, equivalentes a dois minutos de registro, das quais 250 foram amostradas por indivíduo no treinamento e 100 na avaliação. Na avaliação, as posições das janelas são determinísticas, distribuídas em grade regular ao longo do registro, de modo a garantir reprodutibilidade.

O sinal passou por filtro passa-banda de 0,5 a 40 Hz, aplicado a cada janela individualmente, seguido de divisão por escala global estimada por derivação no conjunto de treinamento de cada partição. A separação entre as duas operações é deliberada: o filtro remove o deslocamento de linha de base, que é particular de cada paciente, enquanto a escala global preserva as diferenças de amplitude entre indivíduos.

O desbalanceamento entre as classes foi tratado por ponderação da função de perda, com peso de 8,5 atribuído à classe positiva. A validação cruzada empregou cinco partições estratificadas, com divisão no nível do paciente: 351 indivíduos no treinamento, 62 na validação interna e 104 no conjunto de teste de cada partição. As probabilidades preditas para as janelas de um mesmo paciente foram agregadas por média antes do cálculo de qualquer métrica, uma vez que janelas de um mesmo registro não constituem observações independentes.

4.2.2 Desempenho

A AUC sobre as predições fora da amostra foi de 0,498, com intervalo de confiança de 95 % entre 0,411 e 0,586. O intervalo contém o valor 0,5, de modo que não é possível afirmar que o modelo discrimine os desfechos acima do acaso. Os resultados por partição constam da Tabela 18.

A AUC manteve-se próxima de 0,5 em quatro das cinco partições, variando de 0,441 a 0,574, com desvio-padrão de 0,048. A estimativa agrupada coincide com a média entre partições, ambas em 0,498.

Tabela 18 – Desempenho da rede convolucional por partição da validação cruzada

Partição	AUC	AP	Sensibilidade	Especificidade	VPP
0	0,487	0,200	0,182	0,785	0,091
1	0,498	0,147	0,091	0,925	0,125
2	0,489	0,147	0,545	0,391	0,097
3	0,441	0,113	0,000	0,957	0,000
4	0,574	0,173	0,545	0,435	0,103
Média	0,498	0,156	0,273	0,698	0,083
Desvio-padrão	0,048	0,033	0,264	0,264	0,048
Out-of-fold	0,498	0,142	0,309	0,704	0,110

Fonte: elaborado pelo autor (2026).

As métricas dependentes de limiar, por outro lado, apresentaram dispersão elevada — desvio-padrão de 0,264 tanto na sensibilidade quanto na especificidade, valor próximo ou superior às respectivas médias. A partição 3 é o caso extremo: sensibilidade nula e especificidade de 0,957, situação em que o modelo classificou praticamente todos os pacientes como sobreviventes e nenhum dos onze eventos foi identificado. Esse comportamento aproxima-se do classificador trivial que atribui a classe majoritária a todos os indivíduos, o qual obteria acurácia de 89,4 % nesta coorte sem qualquer utilidade clínica.

A AP agrupada, de 0,142, situa-se acima da prevalência de 0,106, que constitui a linha de base dessa métrica sob classificação aleatória.

4.2.3 Comportamento durante o treinamento

A Tabela 19 apresenta a evolução das perdas nas cinco partições.

Tabela 19 – Perdas de treinamento e validação no início e ao término do ajuste, por partição

Partição	Época 1		Última época		Razão	Épocas
	Treino	Validação	Treino	Validação		
0	1,282	1,248	0,155	3,624	23	15
1	1,268	1,223	0,237	4,827	20	11
2	1,280	1,319	0,121	3,425	28	14
3	1,291	1,279	0,175	2,696	15	17
4	1,283	1,310	0,142	2,827	20	15

Fonte: elaborado pelo autor (2026).

As razões finais entre as perdas de validação e treinamento situaram-se entre 15 e 28 — valores que, embora indiquem ajuste excessivo, são substancialmente menores que os observados nas arquiteturas residuais avaliadas adiante, que alcançaram razões de três a quatro

ordens de grandeza superiores. A perda de treinamento permaneceu entre 0,121 e 0,237 ao término do ajuste, sem aproximar-se de zero.

Esse comportamento é consistente com o reduzido número de parâmetros: com 109 361 pesos e 37 casos positivos no conjunto de treinamento, a rede não dispõe de capacidade para ajustar individualmente cada exemplo. A perda de validação, contudo, cresce desde a primeira época em todas as partições, o que indica que o pouco aprendido não se transfere a pacientes não observados.

O melhor valor de AUC sobre o conjunto de validação ocorreu entre a primeira e a quinta época em todas as partições, alcançando 0,764 na partição 0 e 0,763 na partição 4. Esses valores elevados sobre sete eventos de validação não se sustentaram no conjunto de teste, em que as mesmas partições produziram 0,487 e 0,574 — discrepância que ilustra a instabilidade das estimativas obtidas sobre poucos eventos.

4.2.4 Matriz de confusão

A Tabela 20 apresenta a matriz de confusão agregada, construída a partir das predições fora da amostra e do limiar mediano entre as partições.

Tabela 20 – Matriz de confusão agregada da rede convolucional

	Predito: sobrevivente	Predito: óbito
Sobrevivente ($n = 462$)	325	137
Óbito por MSC ($n = 55$)	38	17

Fonte: elaborado pelo autor (2026).

Dos 55 pacientes que vieram a óbito por morte súbita cardíaca, 17 foram identificados — sensibilidade de 0,309 — com 137 falsos positivos entre os 462 sobreviventes. O VPP resultante, de 0,110, é praticamente igual à prevalência de 0,106: a classificação como alto risco não altera de forma apreciável a probabilidade estimada de óbito em relação à probabilidade basal da coorte.

4.3 Rede residual aplicada ao sinal bruto

A primeira estratégia avaliada consistiu em aplicar uma rede neural convolucional residual diretamente ao sinal de ECG, sem extração prévia de características. Adotou-se uma variante reduzida da arquitetura ResNet-18 unidimensional, com 32 filtros na camada inicial em

lugar dos 64 da configuração original, totalizando 1 029 985 parâmetros treináveis. A redução de capacidade foi motivada pelo tamanho da amostra: com 33 casos no conjunto de treinamento de cada partição, a configuração completa implicaria razão superior a 120 000 parâmetros por evento.

Cada paciente foi representado por janelas de 24 000 amostras, equivalentes a dois minutos de registro a 200 Hz, das quais 250 foram amostradas por indivíduo no treinamento. O sinal passou por filtro passa-banda de 0,5 a 40 Hz e normalização por escala global estimada em cada partição. O desbalanceamento entre as classes foi tratado por ponderação da função de perda, com peso de aproximadamente 8,4 atribuído à classe positiva.

A avaliação empregou validação cruzada estratificada em cinco partições, com divisão realizada no nível do paciente. Em cada partição, 104 pacientes compuseram o conjunto de teste e outros 104 foram reservados, a partir do conjunto de treinamento, para definição do critério de parada antecipada e do limiar de decisão pelo índice de Youden. As probabilidades preditas para as janelas de um mesmo indivíduo foram agregadas por média antes do cálculo de qualquer métrica.

4.3.1 Desempenho

O desempenho obtido encontra-se na Tabela 21. A AUC calculada sobre as predições fora da amostra foi de 0,504, com intervalo de confiança de 95 % entre 0,420 e 0,588. O intervalo contém o valor 0,5, de modo que não é possível afirmar que o modelo discrimine os desfechos acima do acaso.

Tabela 21 – Desempenho da ResNet-18 reduzida em cada partição da validação cruzada

Partição	AUC	AP	Sensibilidade	Especificidade	Épocas
0	0,589	0,201	0,364	0,742	11
1	0,537	0,168	0,636	0,462	14
2	0,360	0,090	0,455	0,337	18
3	0,616	0,193	0,909	0,250	—
4	0,478	0,119	0,727	0,185	—
Média	0,516	0,154	0,618	0,395	—
Desvio-padrão	0,102	0,048	0,222	0,222	—
Out-of-fold	0,504	0,117	0,582	0,437	—

Fonte: elaborado pelo autor (2026).

A AUC variou de 0,360 a 0,616 entre as partições, com desvio-padrão de 0,102.

Essa dispersão indica que o resultado depende substancialmente de quais pacientes compõem cada conjunto de teste. Duas partições apresentaram valores abaixo de 0,5, ou seja, ordenamento pior que o aleatório — o que não constitui evidência de relação inversa, mas de instabilidade da estimativa quando calculada sobre 11 eventos.

A média entre partições, de $0{,}516 \pm 0{,}102$, aproxima-se da estimativa agrupada. A pequena discrepância entre as duas decorre de os modelos ajustados em cada partição produzirem probabilidades em escalas distintas: ao serem reunidas em um único ordenamento, essas escalas não coincidem exatamente. A estimativa agrupada é considerada mais confiável por avaliar simultaneamente os 55 casos da coorte, enquanto cada partição isolada dispõe de apenas 11 eventos.

A dispersão nas métricas dependentes de limiar é ainda mais acentuada. A sensibilidade variou de 0,364 a 0,909 e a especificidade, de 0,185 a 0,742, ambas com desvio-padrão de 0,222 — valor próximo à própria média. Tal comportamento é compatível com o número reduzido de eventos em cada conjunto de teste, em que a reclassificação de dois pacientes altera a sensibilidade em quase vinte pontos percentuais.

A AP agrupada, de 0,117, situa-se marginalmente acima da prevalência de 0,106, que constitui a linha de base dessa métrica sob classificação aleatória.

4.3.2 Comportamento durante o treinamento

O acompanhamento das curvas de perda revela padrão consistente nas cinco partições e esclarece a origem do desempenho observado. A Tabela 22 apresenta a evolução na partição 0, representativa das demais.

Tabela 22 – Evolução das perdas e da AUC de validação na partição 0

Época	Perda (treinamento)	Perda (validação)	AUC (validação)
1	1,200	1,224	0,658
2	0,696	1,589	0,615
3	0,214	1,927	0,522
5	0,080	2,631	0,501
8	0,037	3,252	0,554
11	0,024	3,678	0,537

Fonte: elaborado pelo autor (2026).

A perda de treinamento reduziu-se de 1,2 para 0,024 ao longo de onze épocas, uma diminuição de aproximadamente cinquenta vezes, enquanto a perda de validação triplicou, de 1,224 para 3,678. A razão final entre as duas perdas atinge 153. Comportamento equivalente

ocorre nas demais partições, com razões finais entre 181 e 234.

Trata-se de memorização do conjunto de treinamento. Com 33 casos positivos disponíveis e mais de um milhão de parâmetros, a rede dispõe de capacidade suficiente para ajustar individualmente cada exemplo, sem que isso implique aprendizado de padrões transferíveis a pacientes não observados.

Dois aspectos adicionais merecem registro. O primeiro é que, em todas as partições, o melhor valor de AUC sobre o conjunto de validação ocorreu na primeira ou na segunda época — 0,658 na época 1 da partição 0 e 0,695 na época 2 da partição 1. A informação eventualmente extraível do sinal é, portanto, capturada em poucas passagens sobre os dados, e as épocas subsequentes apenas deterioram a capacidade de generalização.

O segundo é a alternância entre regimes degenerados. Na partição 2, entre as épocas 9 e 16, o classificador atribuiu a classe positiva à totalidade dos pacientes em sete das oito épocas, obtendo sensibilidade unitária com especificidade entre 0,183 e 0,333; na época 13 e na época 17, inverteu para sensibilidade de 0,364 com especificidade próxima de 0,79. Não se observa convergência para uma solução intermediária estável, o que indica que o modelo não identificou fronteira de decisão informativa.

4.3.3 Matriz de confusão

A Tabela 23 apresenta a matriz de confusão agregada, construída a partir das predições fora da amostra e do limiar mediano entre as partições.

Tabela 23 – Matriz de confusão agregada da ResNet-18 reduzida

	Predito: sobrevivente	Predito: óbito
Sobrevivente ($n = 462$)	202	260
Óbito por MSC ($n = 55$)	23	32

Fonte: elaborado pelo autor (2026).

Dos 55 pacientes que vieram a óbito por morte súbita cardíaca, 32 foram identificados pelo modelo, correspondendo a sensibilidade de 0,582. O custo associado foram 260 falsos positivos entre os 462 sobreviventes, resultando em especificidade de 0,437 e VPP de 0,110. Este último valor situa-se praticamente no mesmo patamar da prevalência de 0,106, o que significa que a classificação como alto risco não eleva de forma apreciável a probabilidade estimada de óbito em relação à probabilidade basal da coorte — resultado coerente com o intervalo de confiança da AUC incluir o valor correspondente ao acaso.

4.4 Efeito da capacidade do modelo

Para verificar se a limitação de desempenho observada na seção 4.3 decorria da capacidade reduzida do modelo, avaliou-se a mesma arquitetura em sua configuração completa, com 64 filtros na camada inicial em lugar de 32. O número de parâmetros treináveis passou de 1 029 985 para 3 976 385, um aumento de aproximadamente quatro vezes, elevando a razão para 12 869 parâmetros por paciente do conjunto de treinamento.

Todos os demais elementos do protocolo foram mantidos: janelas de 24 000 amostras, 250 por paciente, filtro passa-banda de 0,5 a 40 Hz, normalização por escala global, ponderação da classe positiva na função de perda e agregação das predições por paciente antes do cálculo das métricas. A validação cruzada empregou cinco partições, com 309 pacientes no conjunto de treinamento, 104 na validação interna e 104 no conjunto de teste de cada uma, contendo 11 eventos.

4.4.1 Desempenho

A AUC sobre as predições fora da amostra foi de 0,508, com intervalo de confiança de 95 % entre 0,431 e 0,588. O intervalo contém o valor 0,5, de modo que também nesta configuração não é possível afirmar que o modelo discrimine os desfechos acima do acaso. Os resultados por partição constam da Tabela 24.

Tabela 24 – Desempenho da ResNet-18 em configuração completa, por partição da validação cruzada

Partição	AUC	AP	Sensibilidade	Especificidade	VPP
0	0,547	0,185	0,455	0,667	0,139
1	0,578	0,138	0,727	0,419	0,129
2	0,547	0,127	0,545	0,457	0,107
3	0,375	0,115	0,182	0,478	0,040
4	0,592	0,161	0,818	0,337	0,129
Média	0,528	0,145	0,545	0,472	0,109
Desvio-padrão	0,088	0,028	0,255	0,122	0,041
Out-of-fold	0,508	0,121	0,455	0,461	0,091

Fonte: elaborado pelo autor (2026).

A AUC variou de 0,375 a 0,592 entre as partições, com desvio-padrão de 0,088. Quatro das cinco partições situaram-se acima de 0,5, enquanto a partição 3 apresentou valor substancialmente inferior, acompanhado de sensibilidade de 0,182 — identificação de dois dos onze eventos. Essa dispersão evidencia a dependência do resultado em relação à composição de

cada conjunto de teste, no qual a reclassificação de poucos pacientes altera de forma expressiva as métricas calculadas.

A média entre partições, de $0{,}528 \pm 0{,}088$, supera a estimativa agrupada de 0,508. A discrepância decorre de os modelos ajustados em cada partição produzirem probabilidades em escalas distintas: ao serem reunidas em um ordenamento único, essas escalas não coincidem exatamente. A estimativa agrupada é considerada mais confiável por avaliar simultaneamente os 55 casos da coorte, enquanto cada partição isolada dispõe de apenas 11 eventos.

A AP agrupada, de 0,121, situa-se pouco acima da prevalência de 0,106, que constitui a linha de base dessa métrica sob classificação aleatória.

4.4.2 Comparação com a configuração reduzida

A Tabela 25 confronta as duas configurações, ambas avaliadas em cinco partições sob protocolo idêntico.

Tabela 25 – Comparação entre as configurações reduzida e completa da ResNet-18

Configuração	Parâmetros	Por paciente	AUC	IC 95%
Reduzida (32 filtros)	1 029 985	3 333	0,504	0,420–0,588
Completa (64 filtros)	3 976 385	12 869	0,508	0,431–0,588

Fonte: elaborado pelo autor (2026).

Quadruplicar o número de parâmetros alterou a AUC em 0,004 — variação inferior a um centésimo e muito abaixo da amplitude dos intervalos de confiança, que se sobrepõem quase integralmente. A capacidade do modelo, portanto, não constitui o fator limitante do desempenho neste conjunto de dados.

4.4.3 Comportamento durante o treinamento

O ajuste ao conjunto de treinamento foi mais rápido que na configuração reduzida, como seria esperado de um modelo com quatro vezes mais parâmetros. A Tabela 26 sintetiza a evolução das perdas.

A perda de treinamento reduziu-se a valores entre 0,005 e 0,012, enquanto a de validação triplicou em todas as partições, atingindo patamares em torno de 4,6 a 4,9. As razões finais entre as duas perdas situaram-se entre 411 e 923, contra valores entre 153 e 234 na configuração reduzida — confirmando que o acréscimo de capacidade acelerou a memorização do conjunto de treinamento sem produzir ganho na capacidade de generalização.

Tabela 26 – Perdas de treinamento e validação no início e ao término do ajuste, por partição

Partição	Época 1		Última época		Razão	Épocas
	Treino	Validação	Treino	Validação		
0	0,655	1,583	0,012	4,727	411	11
1	0,651	1,528	0,005	4,892	923	20
2	0,636	1,605	0,007	4,656	638	18
3	0,648	1,539	0,009	4,642	505	13
4	0,703	1,525	0,010	4,545	450	11

Fonte: elaborado pelo autor (2026).

Observa-se ainda que o melhor valor de AUC sobre o conjunto de validação ocorreu precocemente: na primeira época nas partições 0 e 4, na terceira na partição 3, na sétima na partição 2 e na nona na partição 1. Em todos os casos, o modelo selecionado pela parada antecipada corresponde a um estágio inicial do ajuste.

4.4.4 Matriz de confusão

A Tabela 27 apresenta a matriz de confusão agregada.

Tabela 27 – Matriz de confusão agregada da ResNet-18 em configuração completa

	Predito: sobrevivente	Predito: óbito
Sobrevivente ($n = 462$)	213	249
Óbito por MSC ($n = 55$)	30	25

Fonte: elaborado pelo autor (2026).

Dos 55 óbitos por morte súbita cardíaca, 25 foram identificados — sensibilidade de 0,455 — com 249 falsos positivos entre os 462 sobreviventes. O VPP resultante, de 0,091, permanece abaixo da prevalência de 0,106, indicando que a classificação como alto risco não eleva a probabilidade estimada de óbito em relação à probabilidade basal da coorte.

4.5 Incorporação de mecanismo de atenção

As arquiteturas convolucionais avaliadas nas seções anteriores processam o sinal por meio de filtros que percorrem vizinhanças locais. Relações entre instantes temporalmente distantes só são alcançadas indiretamente, pelo empilhamento sucessivo de camadas. Para verificar se a modelagem explícita dessas relações alteraria o desempenho, acrescentou-se uma camada de codificação por atenção entre o corpo convolucional e o agrupamento global.

A arquitetura resultante mantém o corpo da ResNet-18 reduzida — quatro estágios residuais com 32 filtros iniciais, produzindo uma sequência de 750 instantes com 256 dimensões cada — e insere um codificador *Transformer* de uma camada, com quatro cabeças de atenção e dimensão interna de 512. O número de parâmetros treináveis passou de 1 029 985 para 1 491 553, e a razão em relação ao conjunto de treinamento situou-se em 4 827 parâmetros por paciente.

Os demais elementos do protocolo foram preservados: janelas de 24 000 amostras, 250 por paciente, filtro passa-banda de 0,5 a 40 Hz, agrupamento global combinando média e máximo, taxa de aprendizado de 10^{-4}, regularização de 10^{-2} e descarte de 0,6. A validação cruzada empregou cinco partições, com 309 pacientes no treinamento, 104 na validação interna e 104 no conjunto de teste de cada uma, contendo 11 eventos.

4.5.1 Desempenho

A AUC sobre as predições fora da amostra foi de 0,493, com intervalo de confiança de 95 % entre 0,419 e 0,577. O intervalo contém o valor 0,5, e o resultado não difere do obtido pela arquitetura puramente convolucional. Os valores por partição constam da Tabela 28.

Tabela 28 – Desempenho da ResNet-18 com camada de atenção, por partição da validação cruzada

Partição	AUC	AP	Sensibilidade	Especificidade	VPP
0	0,480	0,266	0,182	0,699	0,067
1	0,550	0,162	0,545	0,570	0,130
2	0,562	0,122	0,727	0,413	0,129
3	0,472	0,118	0,273	0,826	0,158
4	0,496	0,127	0,364	0,620	0,103
Média	0,512	0,159	0,418	0,626	0,117
Desvio-padrão	0,041	0,062	0,219	0,153	0,035
Out-of-fold	0,493	0,134	0,291	0,704	0,105

Fonte: elaborado pelo autor (2026).

A dispersão entre partições foi de 0,041, a menor observada entre as arquiteturas aplicadas ao sinal bruto. Esse valor reduzido não indica, contudo, maior confiabilidade do resultado: as cinco partições concentram-se em torno de 0,5, e a baixa variabilidade reflete a consistência com que o modelo deixa de discriminar, não a estabilidade de um desempenho útil.

A AP agrupada, de 0,134, situa-se acima da prevalência de 0,106, embora a margem seja estreita. A sensibilidade agrupada, de 0,291, corresponde à identificação de 16 dos 55 pacientes que vieram a óbito.

4.5.2 Comportamento durante o treinamento

O ajuste ao conjunto de treinamento foi o mais acentuado entre todas as configurações avaliadas. A Tabela 29 sintetiza a evolução das perdas nas cinco partições.

Tabela 29 – Perdas de treinamento e validação no início e ao término do ajuste, por partição

Partição	Época 1		Última época		Razão final
	Treino	Validação	Treino	Validação	
0	0,984	2,368	0,007	8,592	1 322
1	0,949	2,731	0,004	8,014	2 226
2	0,889	4,065	0,006	7,788	1 366
3	0,814	4,549	0,005	7,818	1 700
4	0,910	3,818	0,010	7,967	781

Fonte: elaborado pelo autor (2026).

A perda de treinamento reduziu-se a valores entre 0,004 e 0,010, enquanto a de validação atingiu patamares entre 7,8 e 8,6 — razões finais de 781 a 2 226 entre as duas. Para efeito de comparação, a ResNet-18 reduzida sem atenção apresentou razões entre 153 e 234, e a configuração completa, entre 346 e 400.

O acréscimo da camada de atenção, portanto, acelerou substancialmente a memorização do conjunto de treinamento. Com 33 casos positivos disponíveis, perdas de treinamento da ordem de 10^{-3} indicam que o modelo ajustou individualmente cada exemplo. O mecanismo de atenção, que em conjuntos extensos permite relacionar segmentos distantes do sinal, aqui dispõe de exemplos insuficientes para que tais relações sejam estimadas de forma generalizável.

Observa-se ainda que a AUC máxima sobre o conjunto de validação ocorreu precocemente em todas as partições — na época 8 da partição 0, na 6 da partição 1, na 4 da partição 2 e na 2 da partição 3. A parada antecipada interrompeu o ajuste entre a décima terceira e a vigésima época, e o modelo selecionado corresponde sempre a um estágio inicial do treinamento.

4.5.3 Matriz de confusão

A Tabela 30 apresenta a matriz de confusão agregada, construída a partir das predições fora da amostra e do limiar mediano entre as partições.

O limiar resultante produziu comportamento mais conservador que o das configurações anteriores: apenas 153 pacientes foram classificados como alto risco, contra 292 na ResNet-18 reduzida. Dos 55 óbitos, 16 foram identificados — sensibilidade de 0,291 — com 137

Tabela 30 – Matriz de confusão agregada da ResNet-18 com camada de atenção

	Predito: sobrevivente	Predito: óbito
Sobrevivente ($n = 462$)	325	137
Óbito por MSC ($n = 55$)	39	16

Fonte: elaborado pelo autor (2026).

falsos positivos entre os 462 sobreviventes. O VPP de 0,105 permanece equivalente à prevalência de 0,106, o que significa que a classificação como alto risco não altera a probabilidade estimada de óbito em relação à probabilidade basal da coorte.

4.6 Efeito da profundidade do modelo

A seção 4.4 demonstrou que ampliar a largura da rede — de 32 para 64 filtros — não alterou o desempenho. Resta verificar se o mesmo se aplica à profundidade.

A ResNet-34 preserva integralmente a largura da ResNet-18 completa: as mesmas 64 unidades na camada inicial e a mesma progressão até 512 na última. O que difere é o número de blocos residuais empilhados em cada estágio, que passa de dois em todos eles para três, quatro, seis e três — dobrando o total de 8 para 16 blocos, ou de 17 para 33 camadas convolucionais. O número de parâmetros treináveis sobe para 7 350 721, correspondendo a 23 789 por paciente do conjunto de treinamento.

Como a largura é idêntica, os tensores intermediários mantêm exatamente as mesmas dimensões da configuração anterior. Os blocos adicionais não alteram a forma da representação; apenas a refinam por meio de transformações sucessivas.

Todos os demais elementos seguem o protocolo da seção 4.1, com validação cruzada em cinco partições de 309 pacientes no treinamento, 104 na validação interna e 104 no conjunto de teste.

4.6.1 Desempenho

A AUC sobre as predições fora da amostra foi de 0,514, com intervalo de confiança de 95 % entre 0,429 e 0,601. Os resultados por partição constam da Tabela 31.

O desvio-padrão entre partições, de 0,039, é o menor observado entre as arquiteturas residuais, e todas as cinco partições situaram-se entre 0,493 e 0,601. Essa concentração não indica desempenho útil, mas consistência com que o modelo deixa de discriminar: as cinco

Tabela 31 – Desempenho da ResNet-34 por partição da validação cruzada

Partição	AUC	AP	Sensibilidade	Especificidade	VPP
0	0,534	0,186	0,545	0,484	0,111
1	0,493	0,130	0,727	0,312	0,111
2	0,546	0,132	0,273	0,707	0,100
3	0,526	0,153	0,455	0,522	0,102
4	0,601	0,155	0,727	0,370	0,121
Média	0,540	0,151	0,545	0,479	0,109
Desvio-padrão	0,039	0,022	0,201	0,159	0,008
Out-of-fold	0,514	0,122	0,509	0,517	0,112

Fonte: elaborado pelo autor (2026).

estimativas agrupam-se em torno de 0,5, e o intervalo de confiança da estimativa agrupada contém esse valor.

A AP agrupada, de 0,122, supera marginalmente a prevalência de 0,106.

4.6.2 Comparação entre largura e profundidade

A Tabela 32 reúne as três configurações da família residual com blocos básicos, avaliadas sob protocolo idêntico.

Tabela 32 – Comparação entre as configurações da família ResNet com blocos básicos

Configuração	Blocos	Parâmetros	Por paciente	AUC	IC 95%
ResNet-18 reduzida	8	1 029 985	3 333	0,504	0,420–0,588
ResNet-18 completa	8	3 976 385	12 869	0,508	0,431–0,588
ResNet-34	16	7 350 721	23 789	0,514	0,429–0,601

Fonte: elaborado pelo autor (2026).

As três configurações percorrem uma faixa de capacidade de sete vezes, de 1,03 a 7,35 milhões de parâmetros, combinando aumento de largura e de profundidade. A AUC varia de 0,504 a 0,514 — amplitude de 0,010, inferior a um décimo da largura dos intervalos de confiança, que se sobrepõem quase integralmente.

Nem a largura nem a profundidade, portanto, constituem o fator limitante. Esse resultado restringe o espaço de explicações possíveis para o desempenho observado: se o modelo dispusesse de capacidade insuficiente para representar os padrões relevantes, o acréscimo de parâmetros teria produzido ganho mensurável em alguma das direções testadas.

4.6.3 Comportamento durante o treinamento

As razões finais entre as perdas de validação e de treinamento situaram-se entre 283 e 476, valores intermediários entre os da ResNet-18 completa (411 a 923) e os da configuração reduzida (153 a 234). A perda de treinamento atingiu valores entre 0,0099 e 0,0166 ao término do ajuste, enquanto a de validação permaneceu em torno de 4,5 a 4,7 em todas as partições.

A parada antecipada interrompeu o treinamento entre a décima segunda e a vigésima época. O melhor valor de AUC sobre o conjunto de validação foi atingido precocemente — na segunda época nas partições 0 e 4, na quarta nas partições 2 e 3 e na nona na partição 1.

Registre-se a magnitude desses valores de validação: 0,721 na partição 2 e 0,676 na partição 1, ante 0,546 e 0,493 obtidos nos respectivos conjuntos de teste. A discrepância, de até 0,18, ilustra a limitação de selecionar modelos com base em onze eventos: o pico observado reflete, em boa medida, a composição particular do conjunto de validação, e não se reproduz em dados não observados.

4.6.4 Matriz de confusão

Tabela 33 – Matriz de confusão agregada da ResNet-34

	Predito: sobrevivente	Predito: óbito
Sobrevivente ($n = 462$)	239	223
Óbito por MSC ($n = 55$)	27	28

Fonte: elaborado pelo autor (2026).

Dos 55 óbitos por morte súbita cardíaca, 28 foram identificados — sensibilidade de 0,509 — com 223 falsos positivos entre os 462 sobreviventes. O VPP resultante, de 0,112, é praticamente igual à prevalência de 0,106: a classificação como alto risco eleva a probabilidade estimada de óbito em menos de um ponto percentual em relação à probabilidade basal da coorte.

4.7 Rede residual de 50 camadas aplicada ao sinal bruto

A segunda arquitetura avaliada foi uma versão unidimensional da ResNet-50, cujas conexões residuais permitem o treinamento de redes substancialmente mais profundas que a da seção anterior. **[PREENCHER: tamanho do núcleo convolucional, número de filtros por estágio e distribuição dos blocos.]** Como na rede convolucional simples, o agrupamento global combina média e máximo ao longo do tempo, e o descarte foi fixado em 0,6.

A configuração resultante possui 16 479 937 parâmetros treináveis, cerca de 151 vezes o da rede convolucional simples (109 361), correspondendo a 53 333 parâmetros por paciente do conjunto de treinamento. Como o conjunto de treinamento de cada partição contém 33 casos positivos, o número de parâmetros supera em ordens de grandeza o de eventos a ser aprendido.

4.7.1 Protocolo

O pré-processamento e a representação do sinal seguem o da seção anterior: janelas de 24 000 amostras, das quais 250 foram amostradas por paciente no treinamento e 100 na avaliação, filtro passa-banda de 0,5 a 40 Hz aplicado a cada janela e divisão por escala global estimada por derivação no conjunto de treinamento de cada partição. O desbalanceamento foi tratado por ponderação da função de perda, com peso de 8,4 atribuído à classe positiva (8,36 nas partições 0 e 1 e 8,39 nas demais). O tamanho do lote foi de 128, reduzido de 256 por limitação de memória (Tabela 17).

A validação cruzada empregou cinco partições estratificadas, com divisão no nível do paciente: 309 ou 310 indivíduos no treinamento (33 casos), 104 na validação interna (11 casos) e 103 ou 104 no conjunto de teste (11 casos). As probabilidades preditas para as janelas de um mesmo paciente foram agregadas por média antes do cálculo de qualquer métrica. O critério de parada antecipada foi acionado nas partições 2, 3 e 4, nas épocas 16, 11 e 11; nas partições 0 e 1, o ajuste atingiu o limite de 20 épocas.

4.7.2 Desempenho

A AUC sobre as predições fora da amostra foi de 0,536, com intervalo de confiança de 95 % entre 0,448 e 0,618. O intervalo contém o valor 0,5, de modo que não é possível afirmar que o modelo discrimine os desfechos acima do acaso. Os resultados por partição constam da Tabela 34.

A média entre partições, de 0,569, supera a estimativa agrupada em 0,033. A diferença decorre sobretudo da partição 1, a única em que a AUC se afasta de forma apreciável de 0,5 (0,728): nas outras quatro, os valores variam de 0,487 a 0,575, com média de 0,529. O desvio-padrão de 0,098 é aproximadamente o dobro do observado na rede convolucional simples (0,048), o que indica que o resultado depende da composição das partições. Com onze eventos por partição, um valor elevado isolado, sem replicação nas demais, não constitui evidência de

Tabela 34 – Desempenho da ResNet-50 por partição da validação cruzada

Partição	AUC	AP	Sensibilidade	Especificidade	VPP
0	0,487	0,188	0,818	0,258	0,115
1	0,728	0,290	0,636	0,796	0,269
2	0,492	0,108	0,000	0,848	0,000
3	0,575	0,171	0,636	0,576	0,152
4	0,562	0,179	0,727	0,391	0,125
Média	0,569	0,187	0,564	0,574	0,132
Desvio-padrão	0,098	0,065	0,324	0,254	0,096
Out-of-fold	0,536	0,137	0,455	0,511	0,100

Fonte: elaborado pelo autor (2026).

capacidade discriminativa.

As métricas dependentes de limiar apresentaram dispersão ainda maior — desvio-padrão de 0,324 na sensibilidade e de 0,254 na especificidade. As partições 0 e 2 representam extremos opostos. Na partição 0, a sensibilidade foi de 0,818 com especificidade de 0,258: o modelo atribuiu alto risco a cerca de três quartos dos controles. Na partição 2, a sensibilidade foi nula e a especificidade de 0,848, de modo que nenhum dos onze eventos foi identificado. Essa instabilidade já é visível durante o ajuste: na partição 0, entre as épocas 4 e 5, a sensibilidade na validação passou de 0,273 para 1,000 e a especificidade de 0,828 para 0,129, sem alteração apreciável da AUC (0,426 para 0,401). Como o limiar é definido sobre onze eventos de validação, sua escolha herda essa variabilidade.

A AP agrupada, de 0,137, situa-se acima da prevalência de 0,106, que constitui a linha de base dessa métrica sob classificação aleatória; a média entre partições foi de 0,187, com desvio-padrão de 0,065. A agregação das probabilidades por máximo, em lugar da média, produziu AUC de 0,537 e AP de 0,136, praticamente idênticas às obtidas pela média.

Em relação à rede convolucional simples, cuja AUC agrupada foi de 0,498 (intervalo de 0,411 a 0,586), o aumento de aproximadamente 151 vezes no número de parâmetros não foi acompanhado de ganho discernível. Os intervalos de confiança das duas arquiteturas se sobrepõem amplamente e ambos contêm 0,5.

4.7.3 Comportamento durante o treinamento

A Tabela 35 apresenta a evolução das perdas nas cinco partições.

A perda de treinamento reduziu-se de valores entre 0,860 e 1,061 na primeira época para valores entre 0,005 e 0,013 ao término do ajuste. Já na terceira época situava-se entre 0,082 e 0,096, apesar de a regularização e o descarte terem sido fixados nos valores máximos. As

Tabela 35 – Perdas de treinamento e validação no início e ao término do ajuste, por partição

Partição	Época 1		Última época		Razão	Épocas
	Treino	Validação	Treino	Validação		
0	0,881	1,744	0,008	6,370	777	20
1	1,019	1,648	0,005	6,416	1309	20
2	0,929	1,847	0,009	5,927	674	16
3	0,860	1,721	0,013	5,415	430	11
4	1,061	1,515	0,012	5,778	481	11

Fonte: elaborado pelo autor (2026).

razões finais entre as perdas de validação e treinamento situaram-se entre 430 e 1 309, de uma a duas ordens de grandeza acima das observadas na rede convolucional simples (15 a 28).

A perda de validação foi mínima na primeira época em todas as partições e cresceu desde então, com oscilações pontuais, até valores entre 5,4 e 6,4. Esse comportamento é consistente com o número de parâmetros: com mais de 16 milhões de pesos e 33 casos positivos, a rede dispõe de capacidade para ajustar individualmente os exemplos de treinamento, e o que foi aprendido não se transfere a pacientes não observados.

O melhor valor pontual de AUC sobre o conjunto de validação ocorreu nas épocas 11, 5, 4, 5 e 1 das partições 0 a 4, alcançando 0,753 na partição 2 e 0,675 na partição 3. Na partição 2, a AUC de validação manteve-se entre 0,56 e 0,69 da segunda à décima quinta época, e o conjunto de teste produziu 0,492 com sensibilidade nula. Em sentido oposto, a partição 1 teve pico de validação de 0,614 e AUC de teste de 0,728. Essas discrepâncias, em ambas as direções, ilustram a instabilidade das estimativas obtidas sobre onze eventos.

4.7.4 Matriz de confusão

A Tabela 36 apresenta a matriz de confusão agregada, construída a partir das predições fora da amostra e do limiar de 0,0318.

Tabela 36 – Matriz de confusão agregada da ResNet-50

	Predito: sobrevivente	Predito: óbito
Sobrevivente ($n = 462$)	236	226
Óbito por MSC ($n = 55$)	30	25

Fonte: elaborado pelo autor (2026).

Dos 55 pacientes que vieram a óbito por morte súbita cardíaca, 25 foram identificados — sensibilidade de 0,455 — com 226 falsos positivos entre os 462 sobreviventes, isto é, 48,9 %

destes foram classificados como de alto risco. O VPP resultante, de 0,100, é ligeiramente inferior à prevalência de 0,106, e o valor preditivo negativo, de 0,887, também não supera a probabilidade basal de sobrevivência, de 0,894. A classificação, em qualquer dos dois sentidos, não altera de forma apreciável a probabilidade estimada de óbito em relação à da coorte, e a acurácia de 50,5 % situa-se bem abaixo da do classificador trivial (89,4 %).

4.8 Eletrocardiograma de repouso de alta resolução

As seções anteriores avaliaram arquiteturas distintas sobre a mesma modalidade de exame. Esta seção altera a modalidade: em lugar do registro ambulatorial de 24 horas, emprega-se o eletrocardiograma de repouso de alta resolução, disponível para parte da coorte e adquirido sob condições controladas.

A mudança responde a uma hipótese específica. O registro de 24 horas contempla o paciente em sono, repouso, esforço e estresse, além de artefatos de movimento e de deslocamento de eletrodos. Essa variabilidade é alheia ao desfecho e pode dificultar a identificação de padrões morfológicos. O exame de repouso, por sua vez, é adquirido com o paciente deitado e imóvel, em ambiente controlado, e a 1 000 Hz — cinco vezes a frequência de amostragem do Holter.

4.8.1 Dados e arquitetura

O exame de repouso tem duração aproximada de 20 minutos e está disponível para 380 dos 517 pacientes da coorte. A arquitetura adotada processa o exame integral, e não janelas amostradas: cada paciente corresponde a um único tensor de 1 136 000 amostras por derivação, descartados 30 segundos em cada extremidade. Treze registros mais curtos que esse comprimento foram excluídos, restando 367 pacientes e 41 eventos — prevalência de 11,2 %.

A arquitetura foi adaptada de Freire (2025), que a propôs para estratificação de risco de morte súbita cardíaca por análise de sobrevivência. Três blocos convolucionais com passo e dilatação reduzem o sinal em aproximadamente 50 000 vezes, convertendo 1 136 000 amostras em 21 posições temporais; sobre essa sequência opera uma rede recorrente de memória longa e curta com duas camadas e 128 unidades ocultas, cujo último estado alimenta o classificador. A compressão agressiva é o que viabiliza o processamento do exame integral: arquiteturas convencionais, com redução de fator quatro por bloco, não comportariam entrada desse comprimento.

O modelo possui 321 825 parâmetros treináveis, dos quais cerca de 72 % pertencem à camada recorrente. Em relação à implementação original, três adaptações foram necessárias: a saída passou a fornecer um valor escalar por paciente, compatível com a função de perda de entropia cruzada binária; a camada densa destinada a variáveis tabulares, presente na versão original ainda quando não utilizada, foi suprimida; e acrescentou-se verificação do comprimento mínimo da entrada, uma vez que a compressão de aproximadamente 50 000 vezes inviabiliza sinais mais curtos que o previsto. A validação cruzada empregou cinco partições, com 219 ou 220 pacientes no treinamento, 74 na validação interna e 73 ou 74 no conjunto de teste.

4.8.2 Desempenho

A AUC sobre as predições fora da amostra foi de 0,514, com intervalo de confiança de 95 % entre 0,425 e 0,610. O intervalo contém o valor 0,5. Os resultados por partição constam da Tabela 37.

Tabela 37 – Desempenho da arquitetura CNN-LSTM sobre o exame de repouso, por partição

Partição	AUC	AP	Sensibilidade	Especificidade	VPP
0	0,549	0,164	0,444	0,723	0,160
1	0,648	0,185	0,625	0,606	0,156
2	0,616	0,160	0,375	0,708	0,125
3	0,564	0,158	0,125	0,923	0,167
4	0,555	0,145	0,750	0,246	0,107
Média	0,586	0,162	0,464	0,641	0,151
Desvio-padrão	0,044	0,015	0,240	0,249	0,029
Out-of-fold	0,514	0,124	0,537	0,451	0,110

Fonte: elaborado pelo autor (2026).

Chama atenção a discrepância entre as duas estimativas de AUC: a média entre partições, de $0{,}586 \pm 0{,}044$, supera em 0,072 a estimativa agrupada de 0,514. Trata-se da maior diferença observada entre todos os experimentos realizados.

A explicação reside na calibração. Cada partição ajusta um modelo independente, e as probabilidades produzidas situam-se em escalas distintas. Dentro de uma partição, o ordenamento relativo dos pacientes é razoável — donde os valores entre 0,549 e 0,648. Ao reunir as predições das cinco partições em um ordenamento único, as escalas não coincidem, e um paciente de baixo risco segundo um modelo pode receber probabilidade superior à de um paciente de alto risco segundo outro. A estimativa agrupada, embora inferior, é a que reflete o

desempenho esperado em aplicação, na qual um único modelo ordenaria todos os pacientes.

A AP agrupada, de 0,124, supera marginalmente a prevalência de 0,112.

4.8.3 Comparação entre modalidades

A Tabela 38 confronta os resultados obtidos nas duas modalidades de exame.

Tabela 38 – Comparação entre as modalidades de exame avaliadas

Modalidade	Arquitetura	*n* / eventos	AUC	IC 95%
Holter 24 h	CNN	517 / 55	0,498	0,411–0,586
Holter 24 h	ResNet-18 reduzida	517 / 55	0,504	0,420–0,588
Holter 24 h	ResNet-18 completa	517 / 55	0,508	0,431–0,588
Holter 24 h	ResNet-18 com atenção	517 / 55	0,493	0,419–0,577
Repouso 20 min	CNN-LSTM	367 / 41	0,514	0,425–0,610

Fonte: elaborado pelo autor (2026).

O valor obtido sobre o exame de repouso é o mais elevado da tabela, embora a diferença em relação às demais modalidades seja de 0,006 a 0,021 — inferior a um décimo da amplitude dos intervalos de confiança, que se sobrepõem integralmente. Não há, portanto, evidência de superioridade de uma modalidade sobre a outra.

Duas ressalvas restringem ainda mais a comparação. A primeira é que as coortes diferem: 367 pacientes com 41 eventos no exame de repouso, contra 517 com 55 no Holter. Parte de qualquer diferença observada pode decorrer da composição da amostra, e não da modalidade. A comparação rigorosa exigiria avaliar ambas as modalidades sobre o mesmo subconjunto de pacientes.

A segunda é que a arquitetura também difere. O exame de repouso foi avaliado com a CNN-LSTM, enquanto o Holter o foi com arquiteturas convolucionais e residuais. O experimento altera simultaneamente duas variáveis, o que impede atribuir eventual diferença a qualquer uma delas isoladamente.

4.8.4 Matriz de confusão

Dos 41 óbitos por morte súbita cardíaca, 22 foram identificados — sensibilidade de 0,537 — com 179 falsos positivos entre os 326 sobreviventes. O VPP de 0,110 permanece praticamente igual à prevalência de 0,112.

Tabela 39 – Matriz de confusão agregada da arquitetura CNN-LSTM sobre o exame de repouso

	Predito: sobrevivente	Predito: óbito
Sobrevivente ($n = 326$)	147	179
Óbito por MSC ($n = 41$)	19	22

Fonte: elaborado pelo autor (2026).

4.8.5 Síntese

A hipótese que motivou o experimento — de que a menor presença de artefatos no exame de repouso favoreceria a identificação de padrões morfológicos — não se confirmou. O desempenho permaneceu na mesma faixa observada com o Holter, com intervalo de confiança compatível com o acaso.

O resultado acrescenta elemento relevante ao conjunto de evidências: a limitação observada não decorre da qualidade do sinal nem da presença de artefatos de movimento, uma vez que persiste em registros adquiridos sob condições controladas e com frequência de amostragem cinco vezes superior.

4.9 Marcadores eletrocardiográficos

4.9.1 Protocolo A: segmentos de 5 minutos

4.9.1.1 Comparação univariada

Dos 44 resumos por paciente, oito apresentaram diferença entre casos e controles com $p < 0{,}05$ no teste de Mann-Whitney (Tabela 40). Com 44 testes, cerca de dois resultados dessa ordem seriam esperados apenas por acaso. Após a correção de Benjamini-Hochberg, três permaneceram significativos: o desvio-padrão e a média da potência HF e o desvio-padrão da frequência cardíaca entre os segmentos. Os dois desvios-padrão — da potência HF e da frequência cardíaca — sobrevivem também à correção de Bonferroni.

A direção das diferenças contraria a leitura clássica da VFC. Os casos apresentaram maior potência HF e maior razão SD1/SD2, isto é, mais variabilidade de curto prazo, e menor variação da frequência cardíaca ao longo do registro. Em pacientes com insuficiência cardíaca, variabilidade de curto prazo elevada pode refletir um ritmo errático, com batimentos ectópicos e irregularidades não removidos pela correção de artefatos, e não um tônus vagal preservado. Essa interpretação é coerente com a proporção de intervalos irregulares, maior nos casos (4,80 %

Tabela 40 – Marcadores do protocolo A com $p < 0{,}05$ na comparação entre casos e controles

Marcador	Controles	Casos	p
Potência HF, desvio-padrão	0,01	0,02	0,001
Frequência cardíaca, desvio-padrão (bpm)	7,84	6,28	0,001
Potência HF, média	0,01	0,02	0,001
SD1/SD2, média	0,46	0,56	0,006
LF/HF, média	2,07	1,50	0,008
Entropia amostral, média	1,10	0,97	0,013
Amplitude da derivação Y, média (mV)	0,78	0,95	0,030
Entropia amostral, desvio-padrão	0,45	0,39	0,034

Fonte: elaborado pelo autor (2026). Valores são medianas em cada grupo.

contra 2,87 %; $p = 0{,}077$), e com a concentração de valores extremos de SD1 entre os casos, descrita na subseção 3.5.1.

4.9.1.2 Modelos

A Tabela 41 apresenta o desempenho dos modelos. Os marcadores, sozinhos, alcançaram AUC entre 0,585 e 0,624, com intervalos de confiança que excluem o acaso por pequena margem. Os melhores resultados vieram dos modelos que reduzem a dimensão do problema — a análise de componentes principais e a floresta aleatória —, e não das regressões penalizadas sobre as 44 variáveis. Nenhum modelo baseado apenas em marcadores alcançou o modelo clínico, de AUC 0,661.

Tabela 41 – Desempenho dos modelos sobre os marcadores do protocolo A

Modelo	Variáveis	AUC [IC 95 %]	Partições	AP
Clínicas (referência)	6	0,661 [0,577–0,741]	0,673 ± 0,114	0,233
Marcadores, logística L2	44	0,589 [0,507–0,671]	0,595 ± 0,066	0,180
Marcadores, logística L1	44	0,585 [0,503–0,666]	0,588 ± 0,044	0,163
Marcadores, PCA (4) + logística	44	0,624 [0,535–0,708]	0,623 ± 0,052	0,232
Marcadores, floresta aleatória	44	0,621 [0,537–0,701]	0,627 ± 0,025	0,184
Clínicas + marcadores, L2	50	0,672 [0,597–0,745]	0,679 ± 0,099	0,201
Clínicas + marcadores, L1	50	0,681 [0,604–0,756]	0,690 ± 0,065	0,191

Fonte: elaborado pelo autor (2026). Partições: média ± desvio-padrão da AUC nas cinco partições. AP de referência (acaso): 0,106.

Somar os marcadores às variáveis clínicas elevou a AUC de 0,661 para 0,672 e 0,681, mas as diferenças não foram distinguíveis de zero: $+0{,}010$ $[-0{,}056; +0{,}086]$ com penalização L2 e $+0{,}020$ $[-0{,}047; +0{,}095]$ com L1.

4.9.1.3 Número reduzido de marcadores e otimismo da seleção

A Tabela 42 compara as duas formas de escolher poucos marcadores descritas na **??**. A partir da análise univariada da coorte inteira, foram escolhidos a média da potência HF, o desvio-padrão da frequência cardíaca, a média da entropia amostral e a média da razão SD1/SD2. Esses quatro marcadores alcançaram AUC de 0,627, e os dois primeiros, isoladamente, 0,647. Somados às variáveis clínicas, produziram os maiores valores deste trabalho, 0,684 e 0,689.

Tabela 42 – Efeito da forma de seleção dos marcadores no protocolo A

Seleção	Modelo	AUC [IC 95 %]	Δ sobre clínicas [IC 95 %]
Coorte inteira	4 marcadores	0,627 [0,541–0,710]	—
Coorte inteira	2 marcadores	0,647 [0,559–0,727]	—
Coorte inteira	clínicas + 4 marcadores	0,684 [0,601–0,762]	+0,023 [−0,027; +0,078]
Coorte inteira	clínicas + 2 marcadores	0,689 [0,607–0,769]	+0,027 [−0,022; +0,081]
Dentro da partição	4 marcadores	0,580 [0,497–0,660]	—
Dentro da partição	clínicas + 4 marcadores	0,640 [0,553–0,726]	−0,021 [−0,094; +0,060]

Fonte: elaborado pelo autor (2026).

Quando a seleção foi refeita dentro de cada partição, sem acesso ao desfecho dos pacientes de teste, a AUC dos quatro marcadores caiu para 0,580, com intervalo que inclui o acaso, e a combinação com as variáveis clínicas ficou abaixo do modelo clínico isolado. A diferença de cerca de 0,05 entre as duas formas de seleção estima o otimismo introduzido por escolher os marcadores olhando o desfecho de toda a coorte. Os valores obtidos com seleção dentro da partição são, por isso, os que melhor representam o desempenho esperado em pacientes novos.

4.9.2 Protocolo B: segmentos de 30 segundos

4.9.2.1 Pseudorreplicação

A revisão estatística no nível do segmento foi realizada sobre a primeira versão da extração, anterior à correção pelos intervalos NN. A Tabela 43 mostra como a unidade de análise altera as conclusões. Tratando os 328 807 segmentos como observações independentes, 22 dos 24 marcadores diferiram entre casos e controles com $p < 0{,}05$. No nível do paciente, apenas dois — a razão SD1/SD2 e a amplitude da derivação Y — atingiram esse limiar, e nenhum permaneceu significativo após as correções para comparações múltiplas.

O contraste ilustra o problema discutido na subseção 2.5.5. Com centenas de segmen-

Tabela 43 – Marcadores significativos segundo a unidade de análise (24 marcadores)

Análise	Marcadores com diferença significativa
Por segmento ($n = 328\,807$), $p < 0{,}05$	22
Por paciente ($n = 517$), $p < 0{,}05$	2
Por paciente, Benjamini-Hochberg	0
Por paciente, Bonferroni	0

Fonte: elaborado pelo autor (2026).

tos por paciente, diferenças mínimas entre os grupos tornam-se estatisticamente significativas, embora o número real de unidades independentes seja 517. Foram identificados ainda 26 pares de marcadores redundantes, entre os quais o RMSSD e o SD1 ($\rho = 0{,}97$), coerentemente com a relação algébrica entre ambos (Equação 2.13).

4.9.2.2 Modelos treinados por segmento

Os modelos treinados diretamente sobre os segmentos, com as probabilidades agregadas por paciente, permaneceram próximos do acaso (Tabela 44). Nenhum intervalo de confiança excluiu 0,5.

Tabela 44 – Modelos treinados por segmento de 30 segundos e avaliados por paciente

Modelo	AUC [IC 95 %]	Partições
Logística L2	0,563 [0,461–0,663]	$0{,}569 \pm 0{,}079$
PCA (6) + logística	0,532 [0,442–0,616]	$0{,}537 \pm 0{,}031$
Floresta aleatória	0,564 [0,472–0,650]	$0{,}576 \pm 0{,}094$
Gradient boosting	0,549 [0,451–0,636]	$0{,}559 \pm 0{,}114$

Fonte: elaborado pelo autor (2026).

4.9.2.3 Modelos sobre os resumos por paciente

A Tabela 45 apresenta as doze configurações avaliadas sobre os resumos por paciente da extração corrigida. Onze delas tiveram intervalo de confiança que inclui 0,5. A única exceção, a análise de componentes principais sobre o conjunto B, com AUC de 0,619 [0,537–0,700], é a melhor de doze tentativas e deve ser interpretada com a correspondente cautela. A versão da extração anterior à correção NN produziu o mesmo quadro, com o melhor resultado em 0,583 [0,483–0,674].

Na comparação univariada dos 122 resumos, sete apresentaram $p < 0{,}05$, número próximo do esperado por acaso, e nenhum permaneceu significativo após a correção de Benjamini-

Tabela 45 – Modelos sobre os resumos por paciente dos segmentos de 30 segundos (extração corrigida)

Conjunto	Variáveis	Logística L2	Logística L1	PCA (4) + logística	Floresta aleatória
A (mediana)	32	0,552	0,550	0,563	0,532
B (A + dispersão e fração)	64	0,540	0,548	0,619	0,562
C (todos os resumos)	122	0,545	0,550	0,548	0,582

Fonte: elaborado pelo autor (2026). Valores de AUC das predições fora da partição.

Hochberg. Os menores valores-p concentraram-se, porém, em um padrão consistente: medidas de dispersão ao longo do registro foram menores nos casos, como o intervalo interquartil do QT (35 contra 45 ms; $p < 0{,}001$; $q = 0{,}083$) e o da frequência cardíaca (9,9 contra 11,5 bpm; $p = 0{,}004$). O mesmo padrão apareceu no protocolo A, no qual o desvio-padrão da frequência cardíaca entre os segmentos foi um dos três marcadores que resistiram à correção para comparações múltiplas.

4.9.3 Síntese

A Tabela 46 reúne os principais resultados. Os marcadores extraídos do ECG contêm informação sobre o desfecho, mas essa informação é fraca: nos melhores casos, a AUC situou-se entre 0,60 e 0,65, e cai para perto do acaso quando a escolha dos marcadores é feita sem acesso ao desfecho dos pacientes de teste. Em nenhuma configuração os marcadores superaram as seis variáveis clínicas, nem acrescentaram a elas um ganho distinguível de zero. O sinal mais consistente entre os dois protocolos foi a menor variação da frequência cardíaca ao longo do registro entre os pacientes que sofreram MSC.

Tabela 46 – Síntese dos resultados com marcadores eletrocardiográficos

Modelo	AUC [IC 95 %]
Clínicas (referência)	0,661 [0,577–0,741]
Protocolo A, PCA (4) + logística	0,624 [0,535–0,708]
Protocolo A, 4 marcadores com seleção dentro da partição	0,580 [0,497–0,660]
Protocolo A, clínicas + marcadores (L1)	0,681 [0,604–0,756]
Protocolo B, por segmento (melhor de quatro)	0,564 [0,472–0,650]
Protocolo B, por paciente (melhor de doze)	0,619 [0,537–0,700]

Fonte: elaborado pelo autor (2026).

Swee *et al.* (2026) relatam, na mesma base, AUC de $0{,}682 \pm 0{,}030$ com um modelo apenas de ECG sobre marcadores de segmentos de 30 segundos. A comparação direta é limitada: aquele trabalho utilizou 746 pacientes, sem restrição ao ritmo sinusal e com critérios de exclusão distintos, e reporta a média entre partições, enquanto a métrica principal deste trabalho é a AUC das predições agrupadas. Na mesma métrica, a média entre partições, os modelos por segmento

deste trabalho alcançaram entre 0,537 e 0,576.

4.10 Redes neurais sobre o sinal de Holter

Esta seção apresenta o desempenho das redes neurais treinadas diretamente sobre o sinal das três derivações do Holter. Todas foram avaliadas pelo mesmo protocolo: cinco partições estratificadas sobre os 517 pacientes, com 309 ou 310 pacientes de treinamento, 104 de validação interna e 103 ou 104 de teste em cada partição. O valor principal é a AUC fora da partição, calculada sobre as predições dos 517 pacientes, cada um predito pelo modelo que não o viu no treinamento, com intervalo de confiança de 95 % obtido por *bootstrap*. A média e o desvio-padrão da AUC entre as cinco partições são informados ao lado, como medida da instabilidade do resultado.

4.10.1 Redes convolucionais: capacidade e duração da janela

A Tabela 47 apresenta as redes convolucionais do desenho da subseção 3.3.6, que varia a capacidade da rede e a duração da janela de entrada.

Tabela 47 – Desempenho das redes convolucionais segundo a capacidade e a duração da janela

Rede	Janela	Parâmetros	AUC partições	AUC fora da partição [IC 95 %]
Mínima	2 min	14 425	0,543 ± 0,059	0,523 [0,440–0,612]
Simples	2 min	109 361	[pendente]	[pendente]
Média	2 min	418 145	[pendente]	[pendente]
Mínima	10 s	14 425	0,589 ± 0,090	0,554 [0,467–0,634]
Simples	10 s	109 361	0,509 ± 0,051	0,491 [0,411–0,578]
Média	10 s	418 145	0,495 ± 0,118	0,485 [0,406–0,569]

Fonte: elaborado pelo autor (2026).

Nenhuma configuração se distinguiu do acaso: todos os intervalos de confiança incluem 0,5. A rede mínima obteve os maiores valores nas duas durações de janela, e, na janela de 10 segundos, o desempenho caiu à medida que a capacidade aumentou (0,554, 0,491 e 0,485). A diferença entre a rede mínima e a média, no entanto, é menor que a largura de qualquer um dos intervalos e não permite afirmar uma relação entre capacidade e desempenho. O mesmo vale para a duração da janela: a rede mínima obteve 0,523 com 2 minutos e 0,554 com 10 segundos, valores compatíveis entre si.

4.10.2 Redes residuais: largura da ResNet-18

As redes residuais foram treinadas com uma configuração anterior à das redes convolucionais da seção precedente: 20 épocas no máximo, paciência de 10 épocas, 250 janelas de treinamento e 100 de avaliação por paciente. A Tabela 48 compara três larguras da ResNet-18, que mantêm os quatro estágios de dois blocos e variam o número de canais.

Tabela 48 – Desempenho da ResNet-18 em três larguras

Rede	Janela	Parâmetros	AUC partições	AUC fora da partição [IC 95 %]
ResNet-18 mínima	5,12 s	78 169	0,569 ± 0,067	0,562 [0,475–0,642]
ResNet-18 reduzida	2 min	1 029 985	0,516 ± 0,102	0,504 [0,420–0,588]
ResNet-18 completa	2 min	3 976 385	0,528 ± 0,088	0,508 [0,431–0,588]
ResNet-18 completa	5,12 s	3 976 385	0,500 ± 0,080	0,492 [0,411–0,577]

Fonte: elaborado pelo autor (2026).

A versão mínima, com 78 mil parâmetros (253 por paciente de treinamento), obteve o maior valor entre as redes residuais (0,562), e as versões reduzida e completa ficaram em torno de 0,50. Assim como nas redes convolucionais, a redução da largura retardou a memorização dos pacientes de treinamento, mas o intervalo de confiança da versão mínima ainda inclui 0,5. A ResNet-18 completa obteve resultados equivalentes com janelas de 2 minutos e de 5,12 segundos.

4.10.3 Redes residuais: profundidade (ResNet-18, ResNet-34 e ResNet-50)

A Tabela 49 compara redes residuais de 18, 34 e 50 camadas com a mesma largura e a mesma janela de 2 minutos. A ResNet-34 empilha mais blocos básicos em cada estágio, e a ResNet-50 substitui o bloco básico pelo bloco de gargalo (seção 2.3).

Tabela 49 – Desempenho das redes residuais segundo a profundidade

Rede	Parâmetros	Por paciente	AUC partições	AUC fora da partição [IC 95 %]
ResNet-18	3 976 385	12 869	0,528 ± 0,088	0,508 [0,431–0,588]
ResNet-34	7 350 721	23 789	0,540 ± 0,039	0,514 [0,429–0,601]
ResNet-50	16 479 937	53 333	0,569 ± 0,098	0,536 [0,448–0,618]

Fonte: elaborado pelo autor (2026). Parâmetros por paciente de treinamento (309 pacientes).

Quadruplicar o número de parâmetros, da ResNet-18 para a ResNet-50, não alterou o desempenho: os três valores ficaram entre 0,51 e 0,54, com intervalos amplamente sobrepostos e todos incluindo 0,5. A ResNet-50, com mais de 53 mil parâmetros por paciente de treinamento, memorizou o conjunto de treinamento já nas primeiras épocas, como as demais, e não extraiu do

sinal informação adicional.

4.10.4 ResNet-18 com mecanismo de atenção

Na rede com atenção, as características extraídas pela ResNet-18 ao longo da janela são relacionadas entre si por um codificador *Transformer* antes do agrupamento (**??**), totalizando 1 491 553 parâmetros. A AUC fora da partição foi de 0,493 [0,419–0,577], com média entre partições de 0,512 $\pm$ 0,041. A modelagem explícita das relações temporais dentro da janela de 2 minutos, portanto, não acrescentou capacidade discriminativa à ResNet-18.

4.10.5 Busca de hiperparâmetros

Para verificar se o desempenho dependia de uma escolha inadequada de hiperparâmetros, uma rede convolucional e uma rede residual foram configuradas por busca bayesiana com o *Optuna* (Tabela 50). Foram feitas 25 tentativas para cada família, variando largura, profundidade, tipo de agrupamento, taxa de aprendizado, decaimento de pesos, descarte e duração da janela. A busca maximizou a AUC média da validação interna em três partições, sem acesso aos conjuntos de teste, e a configuração escolhida foi avaliada nas cinco partições do protocolo.

Tabela 50 – Desempenho das redes configuradas por busca de hiperparâmetros

Rede	Janela	Parâmetros	AUC partições	AUC fora da partição [IC 95 %]
Convolucional[a]	1 min	473 417	0,574 $\pm$ 0,112	0,556 [0,464–0,647]
Residual[b]	1 min	1 818 049	0,510 $\pm$ 0,079	0,496 [0,411–0,584]

Fonte: elaborado pelo autor (2026). [a]Quatro blocos com 24, 48, 96 e 96 canais, núcleo de 31 amostras e agrupamento por média. [b]ResNet com quatro estágios de um bloco, 64 canais iniciais e agrupamento por máximo.

A busca não superou as configurações escolhidas manualmente. A rede convolucional encontrada obteve 0,556, o mesmo valor da rede convolucional mínima sem busca (0,554), e a rede residual obteve 0,496. Como os hiperparâmetros foram escolhidos pela validação interna, e não em uma validação cruzada aninhada, mesmo esses valores carregam algum otimismo residual.

4.10.6 Comportamento durante o treinamento

Os registros de treinamento mostram o mesmo padrão em todas as arquiteturas. A perda de treinamento cai rapidamente — na ResNet-18, de cerca de 0,65 para menos de 0,02 em

dez épocas —, enquanto a perda de validação sobe desde a segunda ou terceira época, de cerca de 1,5 para valores entre 4 e 8. A rede memoriza os pacientes de treinamento em vez de aprender um padrão que se transfira para pacientes novos. As redes de menor capacidade retardam esse processo: na rede convolucional mínima, a perda de treinamento ainda estava em torno de 0,55 ao final das 30 épocas, e é nela que se observaram os maiores valores de AUC, ainda que não significativos.

A AUC de validação mostrou-se um indicador pouco confiável do desempenho no teste. Na quarta partição da rede convolucional média, por exemplo, a validação interna atingiu AUC de 0,64, e o teste, 0,30; na terceira partição da ResNet-50, a validação chegou a 0,75 e o teste ficou em 0,49. Com 11 casos na validação interna, a AUC de validação oscila o suficiente entre épocas para que a escolha do melhor modelo seja, em boa parte, determinada pelo acaso.

4.10.7 Variabilidade entre execuções

A ResNet-18 mínima, com janela de 5,12 segundos, foi treinada duas vezes sobre as mesmas partições, alterando-se apenas o tamanho do lote (2 000 e 1 000 janelas) e o número de janelas sorteadas por paciente (500 e 850). A AUC fora da partição passou de 0,562 [0,475–0,642] para 0,480 [0,403–0,557]. Essa diferença de 0,08 entre duas execuções da mesma arquitetura é maior que a diferença entre a rede de melhor e a de pior desempenho entre as redes convolucionais e residuais avaliadas. O desvio-padrão da AUC entre partições, entre 0,04 e 0,12, aponta na mesma direção. A ordenação das arquiteturas, portanto, não deve ser interpretada como evidência de superioridade de uma sobre as outras.

4.10.8 Fusão da ResNet-18 com variáveis clínicas

A rede de fusão combina o extrator da ResNet-18 com um ramo que recebe seis variáveis clínicas — idade, sexo, classe funcional da NYHA, ondas Q, taquicardia ventricular não sustentada e fibrilação atrial paroxística —, totalizando 3 987 041 parâmetros, dos quais 10 656 pertencem ao ramo clínico. A Tabela 51 compara as três estratégias de treinamento descritas na subseção 3.4.2.

O resultado é informativo justamente pelo contraste entre as estratégias. Quando o extrator de sinal é congelado, a rede ajusta apenas o ramo clínico e o classificador, e a AUC chega a 0,577. Quando o extrator aprende com taxa reduzida, o resultado é praticamente o mesmo (0,579). Quando o extrator é treinado livremente, junto com o restante da rede, a AUC cai para

Tabela 51 – Desempenho da rede de fusão segundo a estratégia de treinamento do extrator de sinal

Estratégia	Janela	AUC partições	AUC fora da partição [IC 95 %]
Treinamento conjunto	2 min	0,534 ± 0,090	0,516 [0,433–0,603]
Taxa reduzida no extrator	2 min	0,578 ± 0,046	0,579 [0,492–0,669]
Extrator congelado[a]	2 min	0,572 ± 0,043	0,577 [0,491–0,659]
Treinamento conjunto	10 s	0,492 ± 0,105	0,491 [0,409–0,576]

Fonte: elaborado pelo autor (2026). [a] 142 241 parâmetros treináveis; o extrator de sinal permanece com os pesos iniciais.

0,516. Ou seja, o desempenho da rede de fusão vem das variáveis clínicas, e o sinal, quando treinado, introduz variabilidade que prejudica a discriminação em vez de acrescentar informação. Para referência, o modelo logístico sobre as variáveis clínicas, sem nenhuma informação do sinal, obteve 0,661 [0,577–0,741].

4.10.9 Análise de sensibilidade: ResNet-18 sem restrição ao ritmo sinusal

Para verificar se o pipeline é capaz de extrair do sinal alguma informação associada ao desfecho, a ResNet-18 foi treinada também sobre a coorte sem o critério de ritmo sinusal, com 703 pacientes e 85 casos. Nessa coorte, a AUC fora da partição foi de 0,575 [0,511–0,642], o único intervalo entre as redes que exclui 0,5 (média entre partições de 0,601 ± 0,049). Esse ganho não pode ser atribuído a um marcador de morte súbita: a coorte ampliada inclui pacientes em fibrilação atrial, um ritmo facilmente reconhecível no sinal e associado a pior prognóstico. A rede tem, portanto, um atalho para discriminar os grupos que não existe na coorte restrita ao ritmo sinusal. O resultado mostra que o pipeline aprende quando há um padrão reconhecível no sinal e justifica a restrição adotada na subseção 1.0.2, que remove essa fonte de confundimento.

4.10.10 Síntese

Em 17 configurações avaliadas no protocolo principal, nenhuma rede treinada sobre o sinal do Holter discriminou casos e controles de forma distinguível do acaso. Os valores de AUC fora da partição ficaram entre 0,48 e 0,56, sem relação com a capacidade da rede, com a duração da janela ou com a presença de mecanismos de atenção, e a variação entre execuções da mesma rede foi da mesma ordem que a variação entre arquiteturas. Na rede de fusão, o sinal não acrescentou informação às variáveis clínicas. Esses resultados são coerentes com o tamanho da amostra: com 33 casos de treinamento por partição, mesmo a menor das redes tem centenas de parâmetros por caso, e a evidência disponível não sustenta a existência de um padrão no sinal de

Holter, em ritmo sinusal, que antecipe a morte súbita nesta coorte.

5 CONCLUSÕES E TRABALHOS FUTUROS

Esta dissertação investigou se o registro de Holter de 24 horas contém informação capaz de identificar, entre pacientes com insuficiência cardíaca em ritmo sinusal, aqueles que sofrerão morte súbita cardíaca em quatro anos. Sobre os 517 pacientes da coorte MUSIC, com 55 casos, foram comparadas três abordagens no mesmo protocolo de validação cruzada por paciente: redes neurais treinadas diretamente sobre o sinal das três derivações, modelos sobre marcadores eletrocardiográficos extraídos do Holter e modelos sobre variáveis clínicas.

5.1 Conclusões

A resposta obtida, dentro das condições deste estudo, é negativa para o sinal bruto. Nenhuma das redes neurais avaliadas — redes convolucionais de três capacidades, redes residuais de 18, 34 e 50 camadas, uma rede com mecanismo de atenção e redes configuradas por busca de hiperparâmetros — discriminou casos e controles de forma distinguível do acaso. As AUC fora da partição ficaram entre 0,48 e 0,56, sem relação com a capacidade da rede, com a duração da janela de entrada ou com a arquitetura, e a variação entre duas execuções da mesma rede foi da mesma ordem que a variação entre arquiteturas. Os registros de treinamento mostraram, em todos os casos, a memorização dos pacientes de treinamento nas primeiras épocas.

Os marcadores eletrocardiográficos tiveram desempenho modesto. Com seleção de variáveis feita dentro de cada partição, o melhor modelo sobre os marcadores de segmentos de 5 minutos obteve AUC de 0,580; valores maiores só foram alcançados quando a seleção usou a coorte inteira, o que torna a estimativa otimista. Os marcadores de segmentos de 30 segundos mostraram, em grande parte, diferenças significativas apenas quando cada segmento foi tratado como observação independente, efeito da pseudorreplicação, e desapareceram quando a análise foi feita por paciente.

As variáveis clínicas foram a fonte de informação mais consistente, com AUC de 0,661 [0,577–0,741], e a adição dos marcadores ou do sinal não trouxe ganho significativo. A rede de fusão confirmou esse resultado de forma direta: com o extrator de sinal congelado, ela obteve o mesmo desempenho que com o extrator treinado com taxa reduzida, e o desempenho caiu quando o extrator foi treinado livremente.

Dois resultados complementares ajudam a interpretar o quadro. Quando a restrição ao ritmo sinusal foi removida, a mesma rede residual passou a discriminar acima do acaso, o

que mostra que o pipeline aprende quando há um padrão reconhecível no sinal — no caso, a fibrilação atrial — e justifica a restrição adotada. E, na literatura, o desempenho de um modelo de aprendizado profundo pré-treinado em grandes bases caiu para 0,60 no subgrupo de insuficiência cardíaca (KIM *et al.*, 2025), valor próximo dos obtidos aqui.

A conclusão central é, portanto, que, com 33 casos de treinamento por partição, não foi possível aprender do sinal do Holter um padrão preditivo de morte súbita nesta população, e que as estimativas otimistas descritas na literatura e observadas em etapas iniciais deste trabalho decorrem, em boa parte, de escolhas de avaliação: seleção de variáveis sobre a coorte inteira, divisões únicas com poucos casos no teste, tratamento de segmentos como observações independentes e inclusão de ritmos não sinusais. A principal contribuição da dissertação está em quantificar esses efeitos sobre os mesmos pacientes e em documentar, com intervalos de confiança, os resultados de todas as configurações avaliadas, e não apenas os da melhor.

5.2 Limitações

O número de eventos é a principal limitação: 55 casos no total e 11 por conjunto de teste tornam os intervalos de confiança largos, de modo que diferenças de até 0,1 na AUC não podem ser detectadas com segurança. A coorte é única, sem validação externa, e cada paciente tem um único registro de Holter. A busca de hiperparâmetros não usou validação cruzada aninhada, e as redes residuais foram treinadas com uma configuração anterior à das redes convolucionais. Por fim, o desfecho foi tratado como classificação binária em quatro anos, o que descarta a informação sobre o tempo até o evento e exclui os pacientes vivos com seguimento mais curto.

5.3 Trabalhos futuros

Os resultados apontam para direções em que o problema do número reduzido de eventos é contornado, e não apenas enfrentado com arquiteturas maiores:

1. **Representações pré-treinadas.** Treinar o extrator de características em bases grandes de ECG, por aprendizado auto-supervisionado ou com rótulos substitutos abundantes, e ajustar sobre a coorte MUSIC apenas um classificador pequeno, como em Kim *et al.* (2025).
2. **Rótulo substituto na própria coorte.** Usar a fração de ejeção, disponível para todos os

pacientes, como alvo de um primeiro estágio de regressão, e empregar a representação aprendida na predição de morte súbita.

3. **Marcadores da repolarização.** Incluir os marcadores que Ramírez *et al.* (2017) identificaram como os mais informativos nesta coorte — alternância da onda T e restituição da morfologia da onda T —, que exigem delineação precisa e não foram calculados aqui.
4. **Análise de sobrevivência.** Modelar o tempo até o evento, com riscos competitivos entre morte súbita e morte por falência de bomba, o que aproveita todos os pacientes e todo o seguimento.
5. **Controle positivo.** Treinar as mesmas redes em uma tarefa sabidamente aprendível a partir do sinal, como a predição do sexo, para confirmar que o pipeline extrai informação quando ela existe.
6. **Validação externa.** Avaliar os modelos em outra coorte de pacientes com insuficiência cardíaca e Holter de 24 horas, condição necessária para qualquer conclusão sobre generalização.

REFERÊNCIAS

BAZETT, H. C. An analysis of the time-relations of electrocardiograms. **Heart**, v. 7, p. 353–370, 1920.

BRENNAN, M.; PALANISWAMI, M.; KAMEN, P. Do existing measures of Poincaré plot geometry reflect nonlinear features of heart rate variability? **IEEE Transactions on Biomedical Engineering**, v. 48, n. 11, p. 1342–1347, 2001.

BUTTERWORTH, S. On the theory of filter amplifiers. **Experimental Wireless and the Wireless Engineer**, v. 7, p. 536–541, 1930.

CLIFFORD, G. D.; AZUAJE, F.; MCSHARRY, P. E. (Ed.). **Advanced Methods and Tools for ECG Data Analysis**. Boston: Artech House, 2006.

DAVIS, J.; GOADRICH, M. The relationship between precision-recall and ROC curves. In: **Proceedings of the 23rd International Conference on Machine Learning**. [S.l.: s.n.], 2006. p. 233–240.

EFRON, B.; TIBSHIRANI, R. J. **An Introduction to the Bootstrap**. New York: Chapman & Hall, 1993.

FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006.

FREIRE, L. **Sudden cardiac death risk stratification with deep survival**. [S.l.]: GitHub, 2025. <https://github.com/luizfreire96/scd_risk_stratification_deep_survival>. Acesso em: 30 set. 2026.

GUSTAFSSON, F. Determining the initial states in forward-backward filtering. **IEEE Transactions on Signal Processing**, v. 44, n. 4, p. 988–992, 1996.

HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. **Radiology**, v. 143, n. 1, p. 29–36, 1982.

HANNUN, A. Y.; RAJPURKAR, P.; HAGHPANAHI, M.; TISON, G. H.; BOURN, C.; TURAKHIA, M. P.; NG, A. Y. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. **Nature Medicine**, v. 25, n. 1, p. 65–69, 2019.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification. In: **Proceedings of the IEEE International Conference on Computer Vision**. [S.l.: s.n.], 2015. p. 1026–1034.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. [S.l.: s.n.], 2016. p. 770–778.

IOFFE, S.; SZEGEDY, C. Batch normalization: accelerating deep network training by reducing internal covariate shift. In: **Proceedings of the 32nd International Conference on Machine Learning**. [S.l.: s.n.], 2015. (Proceedings of Machine Learning Research, v. 37), p. 448–456.

KAPOOR, S.; NARAYANAN, A. Leakage and the reproducibility crisis in machine-learning-based science. **Patterns**, v. 4, n. 9, p. 100804, 2023.

KIM, J. Y.; KIM, K. G.; JOO, S.; CHANG, M.; KIM, J.; PARK, K.-M.; ON, Y. K.; KIM, J. S.; LEE, Y. S.; PARK, S.-J. Deep learning-based risk assessment and prediction of cardiac outcomes using single-lead 24-hour Holter-ECG in patients with heart failure or myocardial infarction. **Journal of Clinical Medicine**, v. 14, n. 20, p. 7209, 2025.

KIRANYAZ, S.; AVCI, O.; ABDELJABER, O.; INCE, T.; GABBOUJ, M.; INMAN, D. J. 1D convolutional neural networks and applications: a survey. **Mechanical Systems and Signal Processing**, v. 151, p. 107398, 2021.

KLEIGER, R. E.; MILLER, J. P.; BIGGER, J. T.; MOSS, A. J. Decreased heart rate variability and its association with increased mortality after acute myocardial infarction. **The American Journal of Cardiology**, v. 59, n. 4, p. 256–262, 1987.

KLIGFIELD, P.; GETTES, L. S.; BAILEY, J. J.; CHILDERS, R.; DEAL, B. J.; HANCOCK, E. W.; HERPEN, G. van; KORS, J. A.; MACFARLANE, P.; MIRVIS, D. M.; PAHLM, O.; RAUTAHARJU, P.; WAGNER, G. S. Recommendations for the standardization and interpretation of the electrocardiogram: part I: the electrocardiogram and its technology. **Circulation**, v. 115, n. 10, p. 1306–1324, 2007.

KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: **Proceedings of the 14th International Joint Conference on Artificial Intelligence**. [S.l.: s.n.], 1995. v. 2, p. 1137–1145.

LECUN, Y.; BOTTOU, L.; BENGIO, Y.; HAFFNER, P. Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, v. 86, n. 11, p. 2278–2324, 1998.

LIN, M.; CHEN, Q.; YAN, S. Network in network. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2014.

LIPPONEN, J. A.; TARVAINEN, M. P. A robust algorithm for heart rate variability time series artefact correction using novel beat classification. **Journal of Medical Engineering & Technology**, v. 43, n. 3, p. 173–181, 2019.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: **International Conference on Learning Representations**. [S.l.: s.n.], 2019.

MAKOWSKI, D.; PHAM, T.; LAU, Z. J.; BRAMMER, J. C.; LESPINASSE, F.; PHAM, H.; SCHÖLZEL, C.; CHEN, S. H. A. NeuroKit2: A Python toolbox for neurophysiological signal processing. **Behavior Research Methods**, v. 53, n. 4, p. 1689–1696, 2021.

MARTÍN-YEBRA, A.; LUNA, A. Bayés de; VÁZQUEZ, R.; CAMINAL, P.; LAGUNA, P.; MARTÍNEZ, J. P. The MUSIC database: Sudden cardiac death in heart failure patients. In: **Computing in Cardiology**. [S.l.: s.n.], 2024. v. 51.

MARTIN-YEBRA, A.; MARTÍNEZ, J. P.; LAGUNA, P. **MUSIC (Sudden Cardiac Death in Chronic Heart Failure) (version 1.0.1)**. PhysioNet, 2025. RRID:SCR_007345. Disponível em: <https://physionet.org/content/music-sudden-cardiac-death/1.0.1/>.

NAIR, V.; HINTON, G. E. Rectified linear units improve restricted Boltzmann machines. In: **Proceedings of the 27th International Conference on Machine Learning**. [S.l.: s.n.], 2010. p. 807–814.

PEDUZZI, P.; CONCATO, J.; KEMPER, E.; HOLFORD, T. R.; FEINSTEIN, A. R. A simulation study of the number of events per variable in logistic regression analysis. **Journal of Clinical Epidemiology**, v. 49, n. 12, p. 1373–1379, 1996.

RAMÍREZ, J.; ORINI, M.; MINCHOLÉ, A.; MONASTERIO, V.; CYGANKIEWICZ, I.; LUNA, A. Bayés de; MARTÍNEZ, J. P.; LAGUNA, P.; PUEYO, E. Sudden cardiac death and pump failure death prediction in chronic heart failure by combining ECG and clinical markers in an integrated risk model. **PLoS ONE**, v. 12, n. 10, p. e0186152, 2017.

RIBEIRO, A. H.; RIBEIRO, M. H.; PAIXÃO, G. M. M.; OLIVEIRA, D. M.; GOMES, P. R.; CANAZART, J. A.; FERREIRA, M. P. S.; ANDERSSON, C. R.; MACFARLANE, P. W.; JR., W. M.; SCHÖN, T. B.; RIBEIRO, A. L. P. Automatic diagnosis of the 12-lead ECG using a deep neural network. **Nature Communications**, v. 11, p. 1760, 2020.

RICHMAN, J. S.; MOORMAN, J. R. Physiological time-series analysis using approximate entropy and sample entropy. **American Journal of Physiology – Heart and Circulatory Physiology**, v. 278, n. 6, p. H2039–H2049, 2000.

SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLoS ONE**, v. 10, n. 3, p. e0118432, 2015.

SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. Dropout: a simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.

SWEE, S.; ADAM, I.; ZHENG, E. Y.; JI, E.; WANG, D.; SPEIER, W.; HSU, J.; CHANG, K.-W.; SHIVKUMAR, K.; PING, P. Multimodal integration of ambulatory ECG and clinical features for sudden cardiac death and pump failure death prediction. **medRxiv**, 2026. Disponível em: <https://doi.org/10.64898/2026.04.21.26351421>.

Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology. Heart rate variability: standards of measurement, physiological interpretation, and clinical use. **Circulation**, v. 93, n. 5, p. 1043–1065, 1996.

VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. In: **Advances in Neural Information Processing Systems**. [S.l.: s.n.], 2017. v. 30, p. 5998–6008.

YOUDEN, W. J. Index for rating diagnostic tests. **Cancer**, v. 3, n. 1, p. 32–35, 1950.